



UNIVERSIDAD DEL ROSARIO

Escuela de Ingeniería, Ciencia y Tecnología

Maestría en Matemáticas Aplicadas y Ciencias de la Computación

Taller 1 — Exploración de datos meteorológicos (ORI)

Análisis Estadístico de Datos

Integrantes

Anyelo Leonardy Alvarez Baquero

Daniel Arias Mutis

Tania Fernanda Mora Cubillos

Over Haider Castrillón Valencia

Profesor

Andrés Nicolás López López

Bogotá D.C., septiembre de 2026

Resumen

Se explora de forma descriptiva la base meteorológica ORI del IDEAM (región Orinoquía), la cual cuenta con 4543 registros y 18 variables, de los que se toman los 118 medidos a medio día para desarrollar el resto del taller. Primeramente se identifican las unidades estadísticas, las frecuencias del pronóstico y la escala y clase de las variables, progresivamente se resumen la temperatura y la velocidad del viento de forma gráfica y numérica, se detectan atípicos por el criterio de Tukey en la presión y el punto de rocío y se estudia la asociación entre temperatura y viento mediante covarianza y correlación de Pearson, para finalmente estimar densidades por histograma y por kernel y compararlas con el modelo normal, encontrando que un pequeño grupo de municipios de piedemonte explica buena parte de las colas observadas.

Palabras clave: estadística descriptiva; diagrama de caja; atípicos de Tukey; covarianza; correlación de Pearson; densidad kernel; IDEAM

Índice general

Resumen	1
1. Los datos	3
2. Parte 1. Fundamentos estadísticos	4
2.1. Pregunta 1: unidades estadísticas y variables	4
2.2. Pregunta 2: pronóstico más y menos frecuente	5
2.3. Pregunta 3: escala y clase de las variables	6
2.4. Pregunta 4: diagramas de caja de temperatura y viento	7
2.5. Pregunta 5: resumen numérico	9
2.6. Pregunta 6: atípicos de Tukey en presión y punto de rocío	11
2.7. Pregunta 7: dispersión entre temperatura y viento	12
2.8. Pregunta 8: covarianza y correlación de Pearson	13
2.9. Pregunta 9: dimensión de los datos	15
3. Parte 2. Estimación de la densidad	16
3.1. Pregunta 10: densidad de la temperatura	17
3.2. Pregunta 11: densidad de la presión	18
3.3. Pregunta 12: densidad del viento frente a la normal	20
Bibliografía	23

Capítulo 1

Los datos

La base `ORI.csv` contiene mediciones meteorológicas de municipios de la región Orinoquía (IDEAM), donde cada observación corresponde a la medición de un municipio a una hora concreta de un día dado, y las unidades se toman del enunciado del taller (temperatura y punto de rocío en °C, velocidad del viento en mph, es decir, millas por hora, y presión en hPa). La base se descarga de Kaggle y, en caso de no haber conexión, se busca una copia local, detectando la codificación del archivo en vez de suponerla (suponerla es lo que rompe las tildes de los municipios).

```
url_ori <- paste0("https://www.kaggle.com/api/v1/datasets/download/",
                  "overhcv/ori-dataset")
zip_ori <- file.path(tempdir(), "ori-dataset.zip")
ruta <- tryCatch({
  download.file(url_ori, zip_ori, mode = "wb", quiet = TRUE)
  unzip(zip_ori, files = "ORI.csv", exdir = tempdir())
}, error = function(e) {
  Filter(file.exists,
         c("ORI.csv", "data/ORI.csv", "../.../data/ORI.csv"))[1]
})
codificacion <- if (all(validUTF8(readLines(ruta, warn = FALSE,
                                           encoding = "bytes"))))
  "UTF-8" else "latin1"
base <- read.csv(ruta, sep = ";", dec = ".",
                fileEncoding = codificacion,
                stringsAsFactors = FALSE)
names(base) <- trimws(names(base)) # el encabezado trae "Pronostico "
datos <- base[base$Hora == "12:00", ] # registros de medio día
```

Capítulo 2

Parte 1. Fundamentos estadísticos

2.1. Pregunta 1: unidades estadísticas y variables

```
dim(base)
```

```
[1] 4543  18
```

```
nrow(datos)
```

```
[1] 118
```

```
table(datos$Fecha)
```

```
26/08/2022 27/08/2022  
          59          59
```

La tabla cuenta con **4543 filas y 18 columnas**, de forma que existen 4543 unidades estadísticas (UE), entendidas como la entidad sobre la que se registra una medición completa, que en este caso es una medición meteorológica efectuada en un municipio a una hora y fecha específicas, así como 18 variables asociadas a cada una de ellas. De estos registros, **118 fueron recolectados a medio día** (Hora = "12:00"), lo que corresponde a los 59 municipios de la base medidos en cada una de las 2 fechas (26 y 27 de agosto de 2022), y es sobre este subconjunto que se desarrolla el resto del taller.

Cabe mencionar que no se imprime la tabla original porque sus 18 columnas no caben en el ancho de la página, y que no todas las columnas varían de igual forma, pues Region toma un único valor (ORI) en toda la base y Hora, aunque en la base completa tiene 24 valores, queda constante una vez se filtra el medio día. Técnicamente una columna constante no aporta variación, pero se cuentan igualmente como variables porque forman parte del diseño de la medición (en otra región u hora sí cambiarían el resultado).

2.2. Pregunta 2: pronóstico más y menos frecuente

```
tabla <- sort(table(datos$Pronostico), decreasing = TRUE)
knitr::kable(data.frame(Pronostico = names(tabla),
                        n = as.vector(tabla),
                        porcentaje = round(100 * as.vector(tabla) /
                                           sum(tabla), 2)),
              caption = "Frecuencias del pronóstico a medio día.")
```

Cuadro 2.1: Frecuencias del pronóstico a medio día.

Pronostico	n	porcentaje
Parcialmente Nublado	63	53.39
Nublado	31	26.27
Parcialmente Nublado - Lluvia Fuerte	6	5.08
Parcialmente Nublado - Llovizna	5	4.24
Nublado - Llovizna	4	3.39
Nublado - Lluvia	4	3.39
Despejado	3	2.54
Parcialmente Nublado - Tormenta Ligera	2	1.69

```
par(mar = c(4, 17, 1, 1))
barplot(rev(tabla), horiz = TRUE, las = 1, cex.names = 0.75,
        col = "steelblue", xlab = "Frecuencia")
```




Figura 2.1: Frecuencias del pronóstico climático a medio día (n = 118).

De las 8 categorías de pronóstico presentes a medio día (de las 11 que tiene la base completa), el más frecuente es Parcialmente Nublado, con 63 registros (53,39 % de los casos), mientras que el menos frecuente es Parcialmente Nublado - Tormenta Ligera, con apenas 2 registros (1,69 %). La masa se concentra entonces en estados de cielo parcial o totalmente nublado (el 80 % entre ambos), con los eventos de lluvia y tormenta como casos poco frecuentes.

2.3. Pregunta 3: escala y clase de las variables

La escala de medición indica qué operaciones tienen sentido sobre una variable (igualdad, orden, diferencias o cocientes), mientras que la clase describe su recorrido (categorías, valores contables o cualquier valor de un intervalo real), y ambos son ejes independientes, de forma que cada variable recibe una escala y una clase. Ninguno de los dos se puede deducir del tipo de dato en R, pues un código postal es numérico y sin embargo nominal, y los grados centígrados son numéricos pero de intervalo, no de razón.

```
knitr::kable(data.frame(
  Variable = c("Pronóstico", "Municipio", "Temperatura (°C)",
               "Velocidad del viento (mph)"),
  `Tipo en R` = sapply(datos[c("Pronostico", "Municipio",
                               "Temperatura",
                               "Velocidad_del_Viento")], class),
  Escala = c("Nominal", "Nominal", "Intervalo", "Razón"),
  Clase = c("Cualitativa politómica", "Cualitativa politómica",
            "Cuantitativa continua", "Cuantitativa continua"),
  check.names = FALSE, row.names = NULL),
  caption = "Escala y clase de las cuatro variables del enunciado.")
```


Cuadro 2.2: Escala y clase de las cuatro variables del enunciado.

Variable	Tipo en R	Escala	Clase
Pronóstico	character	Nominal	Cualitativa politómica
Municipio	character	Nominal	Cualitativa politómica
Temperatura (°C)	numeric	Intervalo	Cuantitativa continua
Velocidad del viento (mph)	numeric	Razón	Cuantitativa continua


- **Pronóstico:** Es nominal y cualitativa politómica (más de dos categorías), con el pequeño detalle que pudo haber sido ordinal, pues la nubosidad sí tiene orden (Despejado, Parcialmente Nublado, Nublado) y la precipitación también (Llovizna, Lluvia, Lluvia Fuerte), pero al combinarse ambas dimensiones en una misma etiqueta no existe un orden total, ya que no hay forma de decidir si “Nublado - Llovizna” está por encima o por debajo de “Parcialmente Nublado - Lluvia Fuerte”.
- **Municipio:** Es nominal y cualitativa politómica, puesto que es una etiqueta geográfica sobre la que solo tiene sentido preguntar si dos registros son del mismo municipio o no.

- **Temperatura:** Es de intervalo y cuantitativa continua, dado que las diferencias son equidistantes pero su cero es relativo (0 °C no es ausencia de temperatura), por lo que 30 °C no es el doble de calor que 15 °C, y cabe aclarar que R la carga como numeric sin distinguir esto, así que la escala la declara quien analiza y no la detección automática.
- **Velocidad del viento:** Es de razón y cuantitativa continua, ya que su cero es absoluto (0 mph sí es ausencia de viento), de forma que los cocientes tienen sentido y 2 mph es efectivamente el doble que 1 mph.

Las figuras siguientes resumen ambos ejes por separado, leyéndose cada una de arriba hacia abajo hasta llegar a los ejemplos de la base.



Eje 1, escala de medición: cada nivel hereda las operaciones del anterior.



Eje 2, clase según el recorrido: es independiente de la escala.

2.4. Pregunta 4: diagramas de caja de temperatura y viento

El diagrama de caja resume una variable en cinco posiciones, donde la caja va del primer cuartil (Q_1) al tercero (Q_3) y encierra el 50 % central de los datos, la línea interior es la mediana y los bigotes llegan hasta la observación más lejana que todavía cae dentro de las cercas de Tukey,

$$\text{cerca inferior} = Q_1 - 1,5 \cdot \text{RIC} \quad \text{cerca superior} = Q_3 + 1,5 \cdot \text{RIC}, \quad \text{RIC} = Q_3 - Q_1,$$

dibujándose punto por punto lo que queda por fuera. Para no leer las posiciones a ojo, se anotan sobre cada caja los valores de Q_1 , mediana y Q_3 .

```
caja <- function(variable, etiqueta) {
  x <- datos[[variable]]
  q <- quantile(x, c(0.25, 0.5, 0.75))
  ggplot(data.frame(x), aes(x = x, y = "")) +
    geom_boxplot(fill = "steelblue", alpha = 0.5,
                 outlier.colour = "firebrick") +
    annotate("text", x = q, y = 1.5, label = format(round(q, 2)),
            size = 3, check_overlap = TRUE) +
    labs(x = etiqueta, y = NULL) + theme_minimal()
}
```

```
caja("Temperatura", "Temperatura (°C)")
```




Figura 2.2: Diagrama de caja de la temperatura a medio día, con Q_1 , mediana y Q_3 anotados.

```
caja("Velocidad_del_Viento", "Velocidad del viento (mph)")
```




Figura 2.3: Diagrama de caja de la velocidad del viento a medio día, con Q1, mediana y Q3 anotados.

Temperatura. El centro se ubica alrededor de los 30,4 °C y la caja es estrecha (aproximadamente entre 28,8 y 31,3 °C), de forma que la mitad de los municipios registra a medio día temperaturas muy parecidas, con el pequeño detalle que la mediana está corrida hacia el borde derecho de la caja y el bigote superior es corto (llega a 32,7 °C), mientras que el inferior se extiende hasta los 26,5 °C y por debajo aparecen 8 puntos atípicos entre 22 y 25 °C. Todo esto indica que la localización es alta y concentrada, y que la dispersión no es simétrica, pues unos pocos registros frescos estiran la distribución hacia la izquierda (asimetría negativa).

Velocidad del viento. El centro está cerca de 1,7 mph y la caja va aproximadamente de 1,0 a 2,2 mph, así que en términos relativos la dispersión es mucho mayor que la de la temperatura, pues la caja ocupa buena parte del recorrido total (de 0,4 a 3,7 mph). Los bigotes son relativamente balanceados, aunque el superior es algo más largo, lo que sugiere una leve asimetría hacia valores altos, coherente con una variable que tiene piso físico en cero y solo puede estirarse hacia arriba, y no se observan atípicos.

2.5. Pregunta 5: resumen numérico

Además de los cuartiles, se calculan la desviación estándar (s , dispersión promedio alrededor de la media, sensible a extremos), el rango intercuartílico (RIC, dispersión del 50 % central, robusta a extremos) y el coeficiente de asimetría g_1 , cuyo signo indica hacia dónde va la cola,

$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{3/2}},$$

que vale cero para una distribución simétrica, es negativo con cola a la izquierda y positivo con cola a la derecha.

```
summary(datos$Temperatura)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
22.40	28.82	30.40	29.75	31.30	32.70

```
summary(datos$Velocidad_del_Viento)
```

```

      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.400    1.000    1.700    1.719    2.175    3.700

```

```

g1 <- function(x) {
  d <- x - mean(x)
  mean(d^3) / mean(d^2)^(3/2)
}
variables <- datos[c("Temperatura", "Velocidad_del_Viento")]
resumen <- sapply(variables, function(x)
  c(media = mean(x), mediana = median(x), s = sd(x), RIC = IQR(x),
    g1 = g1(x), faltantes = sum(is.na(x))))
knitr::kable(round(resumen, 3),
  col.names = c("Temperatura", "Viento"),
  caption = "Estadísticos complementarios a summary().")

```

Cuadro 2.3: Estadísticos complementarios a summary().

	Temperatura	Viento
media	29.754	1.719
mediana	30.400	1.700
s	2.276	0.789
RIC	2.475	1.175
g1	-1.391	0.485
faltantes	0.000	0.000

La descripción numérica **concuere** con los **diagramas de caja**, pues los cinco números de `summary()` son exactamente los que dibuja cada caja (mínimo, Q_1 , mediana, Q_3 y máximo), y agregan lo que el gráfico solo sugería:

- **Temperatura:** La media (29,75 °C) queda por debajo de la mediana (30,40 °C), que es la firma numérica de la asimetría negativa que se veía en el bigote inferior largo, y el coeficiente $g_1 = -1,39$ lo confirma, al tiempo que la desviación estándar (2,28 °C) es casi igual al RIC (2,48 °C) a pesar de que el RIC deja por fuera los extremos, lo que muestra que los 8 registros frescos están inflando s.
- **Velocidad del viento:** La media (1,719 mph) y la mediana (1,700 mph) casi coinciden, con la media apenas por encima, y $g_1 = 0,49$ confirma una asimetría positiva leve, coherente con el bigote superior más largo, así como un coeficiente de variación ($s/\bar{x}$) de 46 % que expresa la mayor dispersión relativa (este cociente solo tiene sentido para el viento, por ser de razón, y no para la temperatura, que es de intervalo).

Finalmente, no hay datos faltantes, pues las 118 filas están completas en ambas variables.

2.6. Pregunta 6: atípicos de Tukey en presión y punto de rocío

Siguiendo la ayuda del enunciado, se usa `boxplot(x, plot = FALSE)$out`, que calcula las cercas a partir de las bisagras de Tukey (muy cercanas a los cuartiles, pero no idénticas a las de `summary()`), lo que explica diferencias de centésimas en los límites).

```
boxplot(datos$Presion, plot = FALSE)$out
```

```
[1] 1015.7
```

```
boxplot(datos$Punto_de_Rocio, plot = FALSE)$out
```

```
numeric(0)
```

```
tukey <- sapply(c("Presion", "Punto_de_Rocio"), function(v) {  
  x <- datos[[v]]  
  b <- boxplot(x, plot = FALSE)  
  ric <- b$stats[4] - b$stats[2]  
  c(`cerca inferior` = b$stats[2] - 1.5 * ric,  
    `cerca superior` = b$stats[4] + 1.5 * ric,  
    `mínimo` = min(x), `máximo` = max(x),  
    `atípicos` = length(b$out))  
})  
knitr::kable(format(tukey, nsmall = 2, drop0trailing = TRUE),  
              align = "r",  
              col.names = c("Presión (hPa)",  
                             "Punto de rocío (°C)"),  
              caption = "Cercas de Tukey y conteo de atípicos.")
```

Cuadro 2.4: Cercas de Tukey y conteo de atípicos.

	Presión (hPa)	Punto de rocío (°C)
cerca inferior	1009.65	13.35
cerca superior	1015.65	30.55
mínimo	1010.9	16.5
máximo	1015.7	29.9
atípicos	1	0

```
par(mfrow = c(1, 2), mar = c(4, 2, 2, 1))  
boxplot(datos$Presion, horizontal = TRUE, col = "orange",  
        main = "Presión (hPa)")  
boxplot(datos$Punto_de_Rocio, horizontal = TRUE, col = "lightblue",  
        main = "Punto de rocío (°C)")
```




Figura 2.4: Diagramas de caja de Tukey para la presión y el punto de rocío a medio día.

La **presión presenta el mayor número de atipicidades**, aunque se trata de una sola y por un margen mínimo, pues el valor 1015,7 hPa (Chámeza, 26 de agosto) supera la cerca superior de 1015,65 hPa por apenas 0,05 hPa, mientras que el **punto de rocío no presenta ninguna** (`numeric(0)`) a pesar de moverse en un rango mucho más ancho (de 16,5 a 29,9 °C). Esto se debe a que el criterio de Tukey es relativo a la dispersión de cada variable y no a una escala absoluta, de forma que el RIC del punto de rocío (4,3 °C) genera cercas amplias ([13,35 ; 30,55]) mientras que el de la presión (1,5 hPa) las deja estrechas ([1009,65 ; 1015,65]). Cabe mencionar que atípico no es sinónimo de error, pues el criterio es geométrico y no sabe nada del fenómeno, y de hecho, como se verá en la Pregunta 11, este registro pertenece a un grupo de municipios con comportamiento propio.

2.7. Pregunta 7: dispersión entre temperatura y viento

```
temp <- datos$Temperatura
viento <- datos$Velocidad_del_Viento
recta <- lm(viento ~ temp)
subtitulo <- sprintf(
  "r = %.4f · cov = %.5f · n = %d\ny = %.2f + %.5fx · R² = %.3f",
  cor(temp, viento), cov(temp, viento), length(temp),
  coef(recta)[1], coef(recta)[2], summary(recta)$r.squared)
grafico <- ggplot(datos,
  aes(x = Temperatura, y = Velocidad_del_Viento)) +
  geom_point(alpha = 0.6, colour = "#3572a8") +
  geom_smooth(method = "lm", formula = y ~ x, colour = "#d2601a",
    fill = "grey70", linewidth = 0.9) +
  labs(x = "Temperatura (°C)", y = "Velocidad del viento (mph)",
    subtitle = subtitulo) +
  theme_minimal()
ggMarginal(grafico, type = "histogram", fill = "#3572a8",
  colour = "white")
```

$$r = 0.0263 \cdot \text{cov} = 0.04719 \cdot n = 118$$

$$y = 1.45 + 0.00911x \cdot R^2 = 0.001$$




Figura 2.5: Diagrama de dispersión de temperatura y velocidad del viento a medio día, con recta de mínimos cuadrados, banda de confianza del 95 % e histogramas marginales.

La nube de puntos no presenta estructura, pues para cualquier temperatura aparecen vientos de todo el recorrido, tanto en los registros cálidos (entre 29 y 32 °C, donde se concentra la mayoría) como en los pocos registros frescos de la izquierda, y la banda de puntos no sube ni baja al avanzar en el eje horizontal, así que **las dos variables no parecen correlacionarse**. La recta de mínimos cuadrados lo confirma, pues es prácticamente plana (el viento sube apenas 0,009 mph por cada grado de temperatura, con $R^2 = 0,001$, es decir, la temperatura explica el 0,1 % de la variación del viento), y su banda de confianza se abre hacia la izquierda porque en esa zona solo están los 8 registros frescos, de forma que ahí la recta está mucho peor determinada. Los histogramas marginales describen cada variable por separado (la temperatura apilada a la derecha con cola a la izquierda, y el viento con su masa entre 1 y 2 mph con cola a la derecha), y la razón de verlos junto a la nube es que dos variables pueden ser asimétricas cada una y aun así no tener ninguna relación entre sí.

2.8. Pregunta 8: covarianza y correlación de Pearson

La covarianza muestral mide si dos variables se desvían de sus medias en la misma dirección, y el coeficiente de correlación de Pearson es esa misma covarianza estandarizada por ambas desviaciones,

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad r = \frac{s_{xy}}{s_x s_y} \in [-1, 1],$$

de forma que r mide la fuerza de la relación **lineal**, siendo ± 1 una recta perfecta y 0 la ausencia de relación lineal.

```
cov(datos$Temperatura, datos$Velocidad_del_Viento)
```

```
[1] 0.04718528
```

```
cor(datos$Temperatura, datos$Velocidad_del_Viento)
```

```
[1] 0.02627245
```

```
cor.test(datos$Temperatura, datos$Velocidad_del_Viento)
```

Pearson's product-moment correlation

```
data:  datos$Temperatura and datos$Velocidad_del_Viento
t = 0.28306, df = 116, p-value = 0.7776
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.1552241  0.2060533
sample estimates:
      cor
0.02627245
```

La covarianza es $s_{xy} = 0,0472$ y la correlación es $r = 0,026$, lo que indica que **las variables no parecen correlacionarse**, pues r es prácticamente cero y la prueba asociada no lo distingue del azar con 118 datos ($p = 0,78$, con intervalo de confianza del 95 % entre $-0,16$ y $0,21$, que contiene al cero), confirmando lo que se veía en la nube de la Pregunta 7. Como verificación adicional se calculó la correlación de Spearman (que en vez de los valores usa sus rangos, es decir, sus posiciones de menor a mayor, y detecta relaciones monótonas, aquellas en las que al crecer una variable la otra tiende a crecer o a decrecer aunque no sea en línea recta), obteniendo $-0,011$, así que tampoco hay una relación curva escondida.

En cuanto a las unidades:

- **Covarianza:** Se expresa en el producto de las unidades de las dos variables, en este caso °C·mph, por lo que su valor por sí solo no dice si la relación es fuerte o débil, y además cambiaría si se midiera el viento en km/h (pasaría a 0,0759 °C·km/h sin que la relación haya cambiado).
- **Correlación de Pearson:** Es adimensional, pues al dividir por s_x (°C) y s_y (mph) las unidades se cancelan, y por esto siempre queda en $[-1, 1]$ y es comparable entre cualquier par de variables.

2.9. Pregunta 9: dimensión de los datos

Los datos son **multivariados**, ya que sobre cada unidad estadística (una medición en un municipio a las 12:00) se registran simultáneamente 18 variables, y las 118 observaciones comparten esa estructura. Que en las preguntas 4 a 6 se haya mirado una variable a la vez (análisis univariado) y en las preguntas 7 y 8 dos variables (análisis bivariado) no cambia la naturaleza de los datos, sino que describe el corte que se hace sobre ellos, de forma que los datos son multivariados y es el análisis el que va cambiando de dimensión.

Esta distinción no es solo de nombre, pues como se mencionó en clase, si un conjunto de variables sigue una distribución normal multivariada entonces cada variable por separado es normal, pero que cada variable sea normal univariadamente no garantiza que el conjunto sea normal multivariado, así que las conclusiones obtenidas mirando variable por variable no se pueden extender sin más al comportamiento conjunto.

Capítulo 3

Parte 2. Estimación de la densidad

Para las tres preguntas siguientes se usan dos estimadores de la densidad. El **histograma de densidad** divide el recorrido en clases y divide cada conteo por n y por el ancho de la clase, de forma que el área total vale 1, y el número de clases se toma con la regla de Sturges, $k = \lceil \log_2 n \rceil + 1 = 8$ para $n = 118$ (la regla por defecto de `hist()` en R, pensada para muestras moderadas y que evita tanto una campana artificial por pocas clases como un dentado ruidoso por demasiadas). La **estimación kernel** (KDE), por su parte, pone una pequeña campana (el núcleo K , gaussiano) sobre cada observación y las suma,

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad h = 0,9 \cdot \min\left(s, \frac{\text{RIC}}{1,34}\right) \cdot n^{-1/5},$$

donde el ancho de banda h se toma con la regla de Silverman (el valor por defecto de `density()` y `geom_density()`), que es óptima si los datos fueran normales y usa el mínimo entre s y $\text{RIC}/1,34$ para no suavizar de más cuando hay extremos. Un h pequeño inventa modas y uno grande las borra, así que como verificación se recalcula la KDE con $2h$ y se reportan solo las modas que sobreviven.

```
modas <- function(x, ajuste = 1) {  
  k <- density(x, adjust = ajuste)  
  round(k$x[which(diff(sign(diff(k$y))) == -2) + 1], 2)  
}  
densidad <- function(variable, etiqueta, color) {  
  x <- datos[[variable]]  
  ggplot(datos, aes(x = .data[[variable]])) +  
    geom_histogram(aes(y = after_stat(density)),  
                  bins = nclass.Sturges(x), fill = color,  
                  colour = "black", alpha = 0.5) +  
    geom_density(colour = "black", linewidth = 1) +  
    labs(x = etiqueta, y = "Densidad",  
         subtitle = sprintf("h (Silverman) = %.3f", bw.nrd0(x))) +  
    theme_minimal()  
}
```

3.1. Pregunta 10: densidad de la temperatura

```
densidad("Temperatura", "Temperatura (°C)", "lightblue")
```




Figura 3.1: Estimación histograma y kernel de la densidad de la temperatura a medio día.

```
x <- datos$Temperatura  
c(h = bw.nrd0(x), g1 = g1(x))
```

```
      h      g1  
0.6402307 -1.3912340
```

```
list(modas_h = modas(x), modas_2h = modas(x, 2))
```

```
$modas_h  
[1] 23.50 31.08
```

```
$modas_2h  
[1] 23.77 30.84
```

```
shapiro.test(x)
```

Shapiro-Wilk normality test

```
data:  x  
W = 0.85961, p-value = 3.403e-09
```

```
datos[x < 26, c("Municipio", "Departamento", "Temperatura")]
```

	Municipio	Departamento	Temperatura
637	CHÁMEZA	CASANARE	23.0
661	CHÁMEZA	CASANARE	23.7
2254	PAJARITO	BOYACÁ	22.4
2278	PAJARITO	BOYACÁ	23.4
2408	PAYA	BOYACÁ	23.5
2432	PAYA	BOYACÁ	23.7
3178	RECETOR	CASANARE	23.7
3202	RECETOR	CASANARE	24.8

No se podría afirmar que los datos provienen de una distribución normal, pues ambas estimaciones ($h = 0,640$ °C) muestran una forma que una campana no puede producir. Primeramente, la masa se apila entre 29 y 32 °C con una moda cerca de 31,1 °C y una cola larga hacia la izquierda ($g_1 = -1,39$), cuando una normal es simétrica. Progresivamente, en esa cola aparece una segunda moda pequeña cerca de 23,5 °C, que sobrevive al duplicar el ancho de banda y por tanto no es ruido del suavizado, formada por los 8 registros frescos que ya se habían marcado como atípicos en la Pregunta 4, y que corresponden a solo cuatro municipios medidos en ambas fechas (Chámeza y Recetor en Casanare, Pajarito y Paya en Boyacá), es decir, a una subpoblación de municipios más frescos y no a mediciones aisladas. Finalmente, la prueba de Shapiro-Wilk (cuya hipótesis nula es que los datos son normales) la rechaza con contundencia ($W = 0,860$, $p < 0,001$), aunque la decisión se sostiene principalmente en la forma del gráfico.

Nota. Se atribuye el grupo fresco a que son municipios de piedemonte o de la cordillera, pero la base no tiene una columna de altitud, así que esta explicación geográfica no se verificó con los datos.

3.2. Pregunta 11: densidad de la presión

```
densidad("Presion", "Presión (hPa)", "orange")
```




Figura 3.2: Estimación histograma y kernel de la densidad de la presión a medio día.

```
x <- datos$Presion
c(h = bw.nrd0(x), g1 = g1(x), media = mean(x), mediana = median(x))
```

h	g1	media	mediana
0.3844894	0.8384434	1012.7762712	1012.5000000

```
list(modas_h = modas(x), modas_2h = modas(x, 2))
```

```
$modas_h
[1] 1012.00 1015.46
```

```
$modas_2h
[1] 1012.28
```

La distribución estimada no es simétrica, sino que presenta asimetría positiva (cola a la derecha), lo cual se sostiene por varias vías que coinciden:

- **Coefficiente de asimetría:** Vale $g_1 = +0,84$, de signo opuesto al de la temperatura.
- **Media contra mediana:** La media (1012,78 hPa) queda por encima de la mediana (1012,50 hPa), y los cuartiles lo confirman, pues de Q_1 a la mediana hay 0,6 hPa mientras que de la mediana a Q_3 hay 0,9 hPa.

- **Forma de la KDE:** Con $h = 0,384$ hPa la curva sube rápido desde 1010,9 hPa, hace su moda cerca de 1012 hPa y baja despacio con una pequeña joroba alrededor de 1015,5 hPa, hasta el valor 1015,7 hPa que la Pregunta 6 marcó como atípico.

Cabe mencionar que esa joroba la forman los mismos cuatro municipios de la cola fresca de la temperatura (Chámeza, Recetor, Pajarito y Paya), de forma que un único grupo de municipios estira a la vez la cola izquierda de una variable y la derecha de la otra. A diferencia de la moda secundaria de la temperatura, esta joroba desaparece al duplicar el ancho de banda, así que no se afirma una bimodalidad, pero la asimetría positiva sí se mantiene con cualquier h razonable.

Nota. Que municipios presumiblemente más altos registren más presión resulta extraño si fuera presión de estación, lo que sugiere que el IDEAM reporta presión reducida al nivel del mar, sin embargo esto no se confirmó en la documentación de la fuente.

3.3. Pregunta 12: densidad del viento frente a la normal

La densidad normal teórica se construye con la media y la desviación estándar observadas, $\bar{x} = 1,719$ mph y $s = 0,789$ mph,

$$f(x) = \frac{1}{s\sqrt{2\pi}} \exp\left(-\frac{(x - \bar{x})^2}{2s^2}\right),$$

y se superpone sobre la KDE de la velocidad del viento.

```
media_v <- mean(datos$Velocidad_del_Viento)
sd_v <- sd(datos$Velocidad_del_Viento)
ggplot(datos, aes(x = Velocidad_del_Viento)) +
  geom_density(colour = "blue", fill = "blue", alpha = 0.2,
               linewidth = 1) +
  stat_function(fun = dnorm, args = list(mean = media_v, sd = sd_v),
               colour = "firebrick", linetype = "dashed",
               linewidth = 1) +
  xlim(-0.5, 4.5) +
  labs(x = "Velocidad del viento (mph)", y = "Densidad") +
  theme_minimal()
```




Figura 3.3: Estimación kernel de la densidad de la velocidad del viento (azul) frente a la normal con media y desviación observadas (rojo punteado).

```
x <- datos$Velocidad_del_Viento
list(modas_h = modas(x), modas_2h = modas(x, 2))
```

```
$modas_h
[1] 1.01 1.93 3.28
```

```
$modas_2h
[1] 1.63
```

```
c(`P(X < 0) normal` = pnorm(0, media_v, sd_v))
```

```
P(X < 0) normal
0.01471799
```

```
shapiro.test(x)
```

Shapiro-Wilk normality test

```
data: x
W = 0.96155, p-value = 0.001885
```

El modelo normal $N(1,719; 0,789)$ se aproxima solo de lejos a la densidad estimada, pues acierta el centro y el ancho general de la distribución, pero falla en la forma por tres motivos:

- **Asimetría y jorobas:** La KDE ($h = 0,274$ mph) tiene su masa entre 1 y 2 mph con jorobas locales cerca de 1,0, 1,9 y 3,3 mph y una cola derecha más pesada ($g_1 = +0,49$), mientras que la normal es una sola campana simétrica, con el pequeño detalle que esas jorobas se funden en una sola moda al duplicar h , así que lo robusto es la asimetría y no la multimodalidad.
- **Masa imposible:** Con esa media y desviación, la normal le asigna un 1,5 % de probabilidad a velocidades negativas, lo cual es imposible para una variable de razón acotada por cero, siendo este el defecto conceptual del ajuste y no un detalle de la muestra (la KDE también derrama algo de masa bajo cero, pero por la cola infinita de su núcleo gaussiano).
- **Prueba de normalidad:** Shapiro-Wilk rechaza la normalidad ($W = 0,962$, $p = 0,002$), aunque de forma mucho menos rotunda que en la temperatura, coherente con que aquí las dos curvas al menos se parecen.

En resumen, la normal sirve como aproximación gruesa del centro y la dispersión del viento a medio día, pero no como modelo de su forma, y en particular no describe bien la cola derecha ni el piso físico en cero.

Bibliografía

- Attali, D. y C. Baker (2023). *ggExtra: Add Marginal Histograms to 'ggplot2', and More 'ggplot2' Enhancements*. R package version 0.10.4. URL: <https://CRAN.R-project.org/package=ggExtra>.
- Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (2022). *Datos meteorológicos de la red de estaciones — región Orinoquía*. Descarga libre del portal IDEAM. URL: <http://www.ideam.gov.co>.
- R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. URL: <https://www.R-project.org>.
- Wickham, H. (2016). “ggplot2: Elegant Graphics for Data Analysis”. En: *Journal of Statistical Software* 35.1, págs. 1-33. DOI: [10.18637/jss.v035.i01](https://doi.org/10.18637/jss.v035.i01).