



UNIVERSIDAD DEL ROSARIO

Escuela de Ingeniería, Ciencia y Tecnología

Maestría en Matemáticas Aplicadas y Ciencias de la Computación

Taller 1 — Exploración de datos meteorológicos (ORI)

Análisis Estadístico de Datos

Integrantes

Anyelo Leonardy Alvarez Baquero

Daniel Arias Mutis

Tania Fernanda Mora Cubillos

Over Haider Castrillón Valencia

Profesor

Andrés Nicolás López López

Bogotá D.C., septiembre de 2026

Resumen

Exploración descriptiva de la base meteorológica ORI (IDEAM, región Orinoquía): 4543 registros de 18 variables, de los cuales 118 corresponden a mediciones al mediodía. Se clasifican las variables por escala y clase, se resumen univariadamente temperatura y velocidad del viento (posición, dispersión y forma), se detectan atípicos por el criterio de Tukey en presión y punto de rocío, y se estudia la asociación bivariada entre temperatura y viento mediante covarianza y correlación de Pearson. Se cierra con la estimación no paramétrica de densidades (histograma y kernel) y su comparación con el modelo normal. **Palabras clave:** estadística descriptiva; boxplot; atípicos de Tukey; covarianza; correlación; densidad kernel; IDEAM

Índice general

Resumen	1
1. Los datos	3
2. Registros del mediodía	4
3. Frecuencias del pronóstico	5
4. Clasificación de las variables	7
5. Diagramas de caja: temperatura y viento	10
6. Resumen numérico	12
7. Valores atípicos: presión y punto de rocío	14
8. Asociación temperatura–viento	16
9. Covarianza y correlación	17
10. Dimensionalidad de los datos	18
11. Estimación de densidades	19
11.1. Temperatura: histograma y kernel	19
11.2. Presión: simetría	20
11.3. Velocidad del viento: KDE vs. normal teórica	20
Bibliografía	22

Capítulo 1

Los datos

La base `ORI.csv` (IDEAM) contiene mediciones meteorológicas de municipios de la región Orinoquía. Cada observación es la medición de un municipio a una hora de un día dado; las unidades provienen del enunciado del taller y de la fuente IDEAM: temperatura en °C, velocidad del viento en mph, presión en hPa, precipitación en mm/h.

```
# ORI.csv se autolocaliza: se prueban los lugares habituales en orden.
# La copia del curso viene en ISO-8859-1 y la de data/ en UTF-8: se detecta
# en vez de suponer (suponer rompe las tildes de los municipios).
ruta <- Filter(file.exists, c("ORI.csv", "data/ORI.csv",
                             "../.../data/ORI.csv"))[1]
codificacion <- if (all(validUTF8(readLines(ruta, warn = FALSE,
                                             encoding = "bytes"))))
  "UTF-8" else "latin1"
datos <- read.csv(ruta, sep = ";", dec = ".", fileEncoding = codificacion,
                  stringsAsFactors = FALSE)
names(datos) <- trimws(names(datos)) # el encabezado trae "Pronostico "
cat("Al cargar:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Al cargar: 4543 filas x 18 columnas

Cada fila es una **unidad estadística**: la entidad sobre la que se hace una medición completa (un municipio en un momento dado). Las columnas son las variables medidas.

Capítulo 2

Registros del mediodía

```
datos <- datos[datos$Hora %in% c("12:00"), ]  
cat("Registros a medio día (12:00):", nrow(datos), "\n")
```

Registros a medio día (12:00): 118

De las 4543 unidades estadísticas, 118 fueron medidas al mediodía; sobre ese subconjunto se desarrolla el resto del taller.

Capítulo 3

Frecuencias del pronóstico


```
tabla <- sort(table(datos$Pronostico), decreasing = TRUE)
knitr::kable(cbind(n = tabla, prop = round(prop.table(tabla), 3)),
             col.names = c("Frecuencia", "Proporción"),
             caption = "Frecuencias del pronóstico al mediodía (n = 118)")
```

Cuadro 3.1: Frecuencias del pronóstico al mediodía (n = 118)

	Frecuencia	Proporción
Parcialmente Nublado	63	0.534
Nublado	31	0.263
Parcialmente Nublado - Lluvia Fuerte	6	0.051
Parcialmente Nublado - Llovizna	5	0.042
Nublado - Llovizna	4	0.034
Nublado - Lluvia	4	0.034
Despejado	3	0.025
Parcialmente Nublado - Tormenta Ligera	2	0.017

```
barplot(tabla, horiz = TRUE, las = 1, cex.names = 0.65,
        main = "Frecuencias del pronóstico al mediodía")
```

Frecuencias del pronóstico al mediodía



El pronóstico más frecuente es Parcialmente Nublado (63 de 118, 53.4%); el menos frecuente es Parcialmente Nublado - Tormenta Ligera (2). La distribución concentra la masa en los estados de cielo parcialmente nublado y nublado, con eventos de lluvia y tormenta poco frecuentes.

Capítulo 4

Clasificación de las variables

La escala de medición no se deduce del tipo de dato en R: un código postal es numérico y nominal; los grados centígrados son de intervalo, no de razón. Escala y clase son dos ejes independientes: cada variable recibe una de cada eje.

```
diccionario <- data.frame(
  columna = c("Cod_Div", "Latitud", "Longitud", "Region", "Departamento",
    "Municipio", "Fecha", "Hora", "Temperatura",
    "Velocidad_del_Viento", "Direccion_del_Viento", "Presion",
    "Punto_de_Rocio", "Cobertura_total_nubosa",
    "Precipitacion_mm_h", "Probabilidad_de_Tormenta", "Humedad",
    "Pronostico"),
  escala = c("razón", "razón", "razón", "nominal", "nominal", "nominal",
    "nominal", "nominal", "intervalo", "razón", "razón", "razón",
    "razón", "razón", "razón", "razón", "razón", "nominal"),
  clase = c("continua", "continua", "continua", "cualitativa", "cualitativa",
    "cualitativa", "cualitativa", "cualitativa", "continua",
    "continua", "continua", "continua", "continua", "continua",
    "continua", "discreta", "continua", "cualitativa")
)
knitr::kable(diccionario,
  caption = "Diccionario de columnas: escala y clase declaradas")
```


Cuadro 4.1: Diccionario de columnas: escala y clase declaradas

columna	escala	clase
Cod_Div	razón	continua
Latitud	razón	continua
Longitud	razón	continua
Region	nominal	cualitativa
Departamento	nominal	cualitativa
Municipio	nominal	cualitativa


columna	escala	clase
Fecha	nominal	cualitativa
Hora	nominal	cualitativa
Temperatura	intervalo	continua
Velocidad_del_Viento	razón	continua
Direccion_del_Viento	razón	continua
Presion	razón	continua
Punto_de_Rocio	razón	continua
Cobertura_total_nubosa	razón	continua
Precipitacion_mm_h	razón	continua
Probabilidad_de_Tormenta	razón	discreta
Humedad	razón	continua
Pronostico	nominal	cualitativa

Para las cuatro variables del enunciado:

- **Pronóstico:** nominal (las 11 categorías combinan dos dimensiones ordenadas —nubosidad y precipitación—, por lo que no existe un orden total único) y cualitativa politómica.
- **Municipio:** nominal y cualitativa politómica.
- **Temperatura (°C):** intervalo (intervalos equidistantes pero cero relativo: 0 °C no es ausencia de temperatura) y continua.
- **Velocidad del viento (mph):** razón (cero absoluto: 0 mph es ausencia de viento) y continua.



Eje 1 — escala de medición: niveles acumulativos; cada uno hereda las propiedades del anterior.



Eje 2 — clase según el recorrido; es independiente del eje 1: cada variable recibe una escala y una clase.

Capítulo 5

Diagramas de caja: temperatura y viento

```
boxplot(datos$Temperatura, horizontal = TRUE, main = "Temperatura (°C)",  
        col = "skyblue")
```




Figura 5.1: Distribución de la temperatura al mediodía (°C)

```
boxplot(datos$Velocidad_del_Viento, horizontal = TRUE,  
        main = "Velocidad del viento (mph)", col = "lightgreen")
```

Velocidad del viento (mph)




Figura 5.2: Distribución de la velocidad del viento al mediodía (mph)

Temperatura. Centro: mediana ≈ 30.4 °C. Localización: el 50 % central de los días (Q1 a Q3) vive en una banda estrecha alrededor de 29–31.5 °C. Dispersión: RIC de ≈ 2.5 °C; bigote derecho corto (el máximo está a ≈ 1.4 °C de Q3) y bigote izquierdo largo, señal de asimetría negativa: unos pocos días frescos estiran la distribución hacia abajo.

Velocidad del viento. Centro: mediana ≈ 1.7 mph. Dispersión relativa mucho mayor (RIC ≈ 1.2 sobre un nivel de 1.7). El bigote derecho es más largo que el izquierdo: asimetría positiva, coherente con una variable con piso físico en cero que solo puede estirarse hacia arriba.

Capítulo 6

Resumen numérico

```
x <- datos$Temperatura
v <- x[!is.na(x)]
centrado <- v - mean(v)
raiz <- sqrt(mean(centrado^2))
asimetria <- mean(centrado^3) / raiz^3 # g1: hacia dónde va la cola
curtosis <- mean(centrado^4) / raiz^4 - 3 # g2: exceso sobre la normal
knitr::kable(data.frame(
  estadístico = c("n", "mínimo", "Q1", "mediana", "media", "Q3", "máximo",
    "desviación", "RIC"),
  valor = round(c(length(v), min(v), quantile(v, .25), median(v), mean(v),
    quantile(v, .75), max(v), sd(v), IQR(v)), 2)
), caption = "Resumen de la temperatura al mediodía (°C)")
```

Cuadro 6.1: Resumen de la temperatura al mediodía (°C)

estadístico	valor
n	118.00
mínimo	22.40
Q1	28.83
mediana	30.40
media	29.75
Q3	31.30
máximo	32.70
desviación	2.28
RIC	2.47

```
cat("Moda:", names(which.max(table(v))), ". g1:", round(asimetria, 3),
  ". g2:", round(curtosis, 3), "\n")
```

Moda: 31 · g1: -1.391 · g2: 1.576

```
x <- datos$Velocidad_del_Viento
v <- x[!is.na(x)]
centrado <- v - mean(v)
raiz <- sqrt(mean(centrado^2))
asimetria <- mean(centrado^3) / raiz^3
curtosis <- mean(centrado^4) / raiz^4 - 3
knitr::kable(data.frame(
  estadístico = c("n", "mínimo", "Q1", "mediana", "media", "Q3", "máximo",
    "desviación", "RIC"),
  valor = round(c(length(v), min(v), quantile(v, .25), median(v), mean(v),
    quantile(v, .75), max(v), sd(v), IQR(v)), 2)
), caption = "Resumen de la velocidad del viento al mediodía (mph)")
```

Cuadro 6.2: Resumen de la velocidad del viento al mediodía (mph)

estadístico	valor
n	118.00
mínimo	0.40
Q1	1.00
mediana	1.70
media	1.72
Q3	2.18
máximo	3.70
desviación	0.79
RIC	1.18

```
cat("Moda:", names(which.max(table(v))), ". g1:", round(asimetria, 3),
  ". g2:", round(curtosis, 3), ". CV:", round(sd(v) / mean(v), 3), "\n")
```

Moda: 0.9 · g1: 0.485 · g2: -0.323 · CV: 0.459

Concuerda con los boxplots. En temperatura, media (29.75) < mediana (30.4) < moda (31): la cascada clásica de la asimetría negativa; el coeficiente de asimetría $g1 \approx -1.4$ la confirma. En el viento, media y mediana casi coinciden con $g1 \approx 0.49$: asimetría positiva leve. El CV solo se reporta para el viento (escala razón): 46 % frente a la estabilidad térmica relativa del mediodía.

Capítulo 7

Valores atípicos: presión y punto de rocío

```
x <- datos$Presion
caja <- boxplot(x, plot = FALSE)
atipicos <- caja$out
ric <- diff(caja$stats[c(2, 4)])
cercas <- c(caja$stats[2] - 1.5 * ric, caja$stats[4] + 1.5 * ric)
cat("Presión – atípicos de Tukey:", length(atipicos), "de", length(x), "\n")
```

Presión – atípicos de Tukey: 1 de 118

```
cat("Cercas:", round(cercas, 2), "\n")
```


Cercas: 1009.65 1015.65

```
print(round(atipicos, 2))
```

[1] 1015.7

```
boxplot(x, horizontal = TRUE, main = "Presión (hPa)", col = "orange")
```

Presión (hPa)



```
x <- datos$Punto_de_Rocio
caja <- boxplot(x, plot = FALSE)
atipicos <- caja$out
ric <- diff(caja$stats[c(2, 4)])
cerkas <- c(caja$stats[2] - 1.5 * ric, caja$stats[4] + 1.5 * ric)
cat("Punto de rocío – atípicos de Tukey:", length(atipicos), "de",
    length(x), "\n")
```

Punto de rocío – atípicos de Tukey: 0 de 118


```
cat("Cercas:", round(cerkas, 2), "\n")
```

Cercas: 13.35 30.55

```
print(round(atipicos, 2))
```

```
numeric(0)
```

```
boxplot(x, horizontal = TRUE, main = "Punto de rocío (°C)", col = "lightblue")
```



El criterio de Tukey (1.5·RIC desde las bisagras) es una convención geométrica: señala observaciones lejanas del 50 % central, no errores de medición. La variable con mayor número de atípicos es la que reporta la salida; conviene verificar si los extremos de cada variable caen de un solo lado (firmarían asimetría, no error).

Capítulo 8

Asociación temperatura–viento

```
grafico <- ggplot(datos, aes(x = Temperatura, y = Velocidad_del_Viento)) +  
  geom_point(alpha = 0.6) +  
  geom_smooth(method = "lm", se = FALSE, color = "firebrick", linetype = 2) +  
  labs(x = "Temperatura (°C)", y = "Velocidad del viento (mph)")  
ggExtra::ggMarginal(grafico, type = "histogram", fill = "grey70",  
  color = "white")
```




Figura 8.1: Dispersión de temperatura vs. velocidad del viento con histogramas marginales

La nube no muestra una dirección clara: a temperaturas altas el viento toma casi todo su recorrido y a temperaturas bajas también. La recta ajustada (aproximación lineal) es casi plana, anticipando una asociación débil.

Capítulo 9

Covarianza y correlación

```
cov_tv <- cov(datos$Temperatura, datos$Velocidad_del_Viento,  
              use = "complete.obs")  
cor_tv <- cor(datos$Temperatura, datos$Velocidad_del_Viento,  
              use = "complete.obs")  
cat("Covarianza:", round(cov_tv, 4), "\n")
```

Covarianza: 0.0472

```
cat("Pearson:    ", round(cor_tv, 4), "\n")
```

Pearson: 0.0263

La covarianza vive en unidades de producto ($^{\circ}\text{C}\cdot\text{mph}$) y su magnitud no es interpretable por sí sola; el coeficiente de Pearson es adimensional y queda en 0.026. Con $|r|$ tan cercano a cero, la asociación lineal es prácticamente nula: conocer la temperatura del mediodía no ayuda a predecir el viento (linealmente).

Capítulo 10

Dimensionalidad de los datos

Los análisis de las secciones anteriores son **univariados** (una variable: boxplots, resúmenes, atípicos) y **bivariados** (temperatura vs. viento: dispersión, covarianza, correlación). El conjunto de datos en sí, con 18 variables medidas por unidad estadística, es **multivariado**; los métodos para explotar esa estructura (por ejemplo, componentes principales) vienen más adelante en el curso.

Capítulo 11

Estimación de densidades

11.1. Temperatura: histograma y kernel

```
ggplot(datos, aes(x = Temperatura)) +  
  geom_histogram(aes(y = after_stat(density)), bins = 15,  
                 fill = "lightblue", color = "black", alpha = 0.6) +  
  geom_density(color = "darkblue", linewidth = 1) +  
  labs(x = "Temperatura (°C)", y = "Densidad")
```




Figura 11.1: Temperatura al mediodía: estimación histograma y kernel de la densidad

La densidad estimada no es compatible con una normal: la masa se apila contra el techo térmico (montaña a la derecha) y una cola izquierda larga ($g_1 \approx -1.4$, $g_2 > 0$). Los días anómalamente

frescos —coherentes con pronósticos de lluvia— son más frecuentes de lo que una campana con esa misma desviación prometería.

11.2. Presión: simetría

```
ggplot(datos, aes(x = Presion)) +  
  geom_histogram(aes(y = after_stat(density)), bins = 15,  
                 fill = "orange", color = "black", alpha = 0.5) +  
  geom_density(color = "brown", linewidth = 1) +  
  labs(x = "Presión (hPa)", y = "Densidad")
```




Figura 11.2: Presión al mediodía: estimación histograma y kernel de la densidad

11.3. Velocidad del viento: KDE vs. normal teórica

```
media_v <- mean(datos$Velocidad_del_Viento, na.rm = TRUE)  
sd_v <- sd(datos$Velocidad_del_Viento, na.rm = TRUE)  
ggplot(datos, aes(x = Velocidad_del_Viento)) +  
  geom_density(color = "blue", linewidth = 1.2, fill = "blue", alpha = 0.2) +  
  stat_function(fun = dnorm, args = list(mean = media_v, sd = sd_v),  
               color = "red", linetype = "dashed", linewidth = 1) +  
  labs(x = "Velocidad del viento (mph)", y = "Densidad",  
       caption = "Azul: KDE empírica | Rojo punteado: normal teórica")
```




Figura 11.3: Velocidad del viento: densidad kernel vs. normal teórica con media y desviación observadas

El modelo normal ajusta razonablemente el centro de la distribución, pero subestima la cola derecha (la empírica cae más lento) y sobreestima la masa cerca de cero. La asimetría positiva leve ($g_1 \approx 0.5$) y el piso en cero explican la discrepancia: la normal es una aproximación aceptable para cálculos gruesos, no un modelo exacto del viento.

Bibliografía

- Attali, D. y C. Baker (2023). *ggExtra: Add Marginal Histograms to 'ggplot2', and More 'ggplot2' Enhancements*. R package version 0.10.4. URL: <https://CRAN.R-project.org/package=ggExtra>.
- Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (2022). *Datos meteorológicos de la red de estaciones — región Orinoquía*. Descarga libre del portal IDEAM. URL: <http://www.ideam.gov.co>.
- R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. URL: <https://www.R-project.org>.
- Wickham, H. (2016). “ggplot2: Elegant Graphics for Data Analysis”. En: *Journal of Statistical Software* 35.1, págs. 1-33. DOI: [10.18637/jss.v035.i01](https://doi.org/10.18637/jss.v035.i01).