



UNIVERSIDAD DEL ROSARIO

Escuela de Ingeniería, Ciencia y Tecnología

Maestría en Matemáticas Aplicadas y Ciencias de la Computación

Taller 1 — Exploración de datos meteorológicos (ORI)

Análisis Estadístico de Datos

Integrantes

Anyelo Leonardy Alvarez Baquero

Daniel Arias Mutis

Tania Fernanda Mora Cubillos

Over Haider Castrillón Valencia

Profesor

Andrés Nicolás López López

Bogotá D.C., 15 de septiembre de 2026

Resumen

Se explora de forma descriptiva la base meteorológica ORI del IDEAM (región Orinoquía), la cual cuenta con 4.543 registros y 18 variables de los que se toman los 118 medidos a medio día para desarrollar el resto del taller. Primero se identifican las unidades estadísticas, las frecuencias del pronóstico y la escala y clase de las variables, para luego resumir la temperatura y la velocidad del viento de forma gráfica y numérica, detectar atípicos por el criterio de Tukey en la presión y el punto de rocío y estudiar la asociación entre temperatura y viento mediante covarianza y correlación de Pearson. Finalmente se estiman densidades por histograma y por kernel que se comparan con el modelo normal, encontrando que un pequeño grupo de cuatro municipios explica buena parte de las colas observadas.

Palabras clave: Estadística descriptiva; Diagrama de caja; Atípicos de Tukey; Covarianza; Correlación de Pearson; Densidad kernel; IDEAM

Índice general

Resumen	1
1. Los datos	3
2. Parte 1. Fundamentos estadísticos	4
2.1. Pregunta 1 — Unidades estadísticas y variables	4
2.2. Pregunta 2 — Pronóstico más y menos frecuente	4
2.3. Pregunta 3 — Escala y clase de las variables	6
2.4. Pregunta 4 — Diagramas de caja de temperatura y viento	7
2.5. Pregunta 5 — Resumen numérico	9
2.6. Pregunta 6 — Atípicos de Tukey en presión y punto de rocío	10
2.7. Pregunta 7 — Dispersión entre temperatura y viento	12
2.8. Pregunta 8 — Covarianza y correlación de Pearson	13
2.9. Pregunta 9 — Dimensión de los datos	14
3. Parte 2. Estimación de la densidad	15
3.1. Pregunta 10 — Densidad de la temperatura	15
3.2. Pregunta 11 — Densidad de la presión	17
3.3. Pregunta 12 — Densidad del viento frente a la normal	19
Bibliografía	22
A. Documentación de R	23

Capítulo 1

Los datos

La base `ORI.csv` contiene mediciones meteorológicas de municipios de la región Orinoquía (IDEAM 2022) donde cada observación corresponde a la medición de un municipio a una hora concreta de un día dado. Las unidades se toman del enunciado del taller, es decir, temperatura y punto de rocío en °C, velocidad del viento en m/h y presión en hPa. Todo el análisis se realiza en R (R Core Team 2026) con gráficos elaborados en `ggplot2` (Wickham 2016) e histogramas marginales en `ggExtra` (Attali y Baker 2025), mientras que la documentación de cada función utilizada se reúne en el Apéndice A.

La base se descarga de Kaggle o, en caso de no haber conexión, se busca una copia local detectando la codificación del archivo en vez de suponerla, pues suponerla es justamente lo que rompe las tildes de los municipios.

```
url_ori <- paste0("https://www.kaggle.com/api/v1/datasets/download/",
                 "overhcv/ori-dataset")
zip_ori <- file.path(tempdir(), "ori-dataset.zip")
ruta <- tryCatch({
  download.file(url_ori, zip_ori, mode = "wb", quiet = TRUE)
  unzip(zip_ori, files = "ORI.csv", exdir = tempdir())
}, error = function(e) {
  Filter(file.exists,
         c("ORI.csv", "data/ORI.csv", "../.../data/ORI.csv"))[1]
})
codificacion <- if (all(validUTF8(readLines(ruta, warn = FALSE,
                                           encoding = "bytes"))))
  "UTF-8" else "latin1"
base <- read.csv(ruta, sep = ";", dec = ".",
               fileEncoding = codificacion,
               stringsAsFactors = FALSE)
names(base) <- trimws(names(base)) # el encabezado trae "Pronostico "
datos <- base[base$Hora == "12:00", ] # registros de medio día
```

Capítulo 2

Parte 1. Fundamentos estadísticos

2.1. Pregunta 1 — Unidades estadísticas y variables

```
dim(base)      [1] 4543    18
nrow(datos)    [1] 118
table(datos$Fecha) 26/08/2022 27/08/2022
                    59          59
```

¿Cuántas UE, variables, filas y columnas tiene la base? La tabla cuenta con 4.543 filas y 18 columnas, lo que significa que existen 4.543 unidades estadísticas (UE) y 18 variables asociadas a cada una de ellas. Una unidad estadística es la entidad sobre la que se registra una medición completa, que en este caso corresponde a una medición meteorológica efectuada en un municipio a una hora y fecha específicas.

¿Cuántos registros se recolectaron a medio día? Se recolectaron 118 registros con Hora = "12:00", que corresponden exactamente a los 59 municipios de la base medidos en cada una de las 2 fechas (26 y 27 de agosto de 2022). Es sobre este subconjunto que se desarrolla el resto del taller.

Vale la pena anotar que no se imprime la tabla original porque sus 18 columnas no caben en el ancho de la página. Además no todas las columnas varían de igual forma, ya que Region toma un único valor (ORI) en toda la base y Hora queda constante una vez se filtra el medio día aunque en la base completa tiene 24 valores. Técnicamente una columna constante no aporta variación, pero se cuentan igualmente como variables porque forman parte del diseño de la medición y en otra región u hora sí cambiarían el resultado.

2.2. Pregunta 2 — Pronóstico más y menos frecuente

```
tabla <- sort(table(datos$Pronostico), decreasing = TRUE)
knitr::kable(data.frame(Pronostico = names(tabla),
                        n = as.vector(tabla),
                        porcentaje = round(100 * as.vector(tabla) /
```

```
sum(tabla), 2)),  
caption = "Frecuencias del pronóstico a medio día.")
```

Cuadro 2.1: Frecuencias del pronóstico a medio día.

Pronostico	n	porcentaje
Parcialmente Nublado	63	53.39
Nublado	31	26.27
Parcialmente Nublado - Lluvia Fuerte	6	5.08
Parcialmente Nublado - Llovizna	5	4.24
Nublado - Llovizna	4	3.39
Nublado - Lluvia	4	3.39
Despejado	3	2.54
Parcialmente Nublado - Tormenta Ligera	2	1.69

```
par(mar = c(4, 17, 1, 1))  
barplot(rev(tabla), horiz = TRUE, las = 1, cex.names = 0.75,  
col = "#a6192e", xlab = "Frecuencia")
```




Figura 2.1: Frecuencias del pronóstico climático a medio día (n = 118).

Más frecuente. Parcialmente Nublado, con 63 de los 118 registros (53.39 %).

Menos frecuente. Parcialmente Nublado - Tormenta Ligera, con apenas 2 registros (1.69 %).

De las 11 categorías que tiene la base completa solo 8 aparecen a medio día. La masa se concentra en estados de cielo parcial o totalmente nublado (cerca del 80 % entre ambos), por lo que los eventos de lluvia y tormenta quedan como casos poco frecuentes.

2.3. Pregunta 3 — Escala y clase de las variables

La escala de medición indica qué operaciones tienen sentido sobre una variable (igualdad, orden, diferencias o cocientes), mientras que la clase describe su recorrido según sean categorías, valores contables o cualquier valor de un intervalo real. Ambos son ejes independientes de modo que cada variable recibe una escala y una clase. Ninguno de los dos se puede deducir del tipo de dato en R, pues un código postal es numérico y sin embargo nominal así como los grados centígrados son numéricos pero de intervalo y no de razón.


```
knitr::kable(data.frame(
  Variable = c("Pronóstico", "Municipio", "Temperatura (°C)",
               "Velocidad del viento (m/h)"),
  `Tipo en R` = sapply(datos[c("Pronostico", "Municipio",
                              "Temperatura",
                              "Velocidad_del_Viento")], class),
  Escala = c("Nominal", "Nominal", "Intervalo", "Razón"),
  Clase = c("Cualitativa politómica", "Cualitativa politómica",
            "Cuantitativa continua", "Cuantitativa continua"),
  check.names = FALSE, row.names = NULL),
  caption = "Escala y clase de las cuatro variables del enunciado.")
```

Cuadro 2.2: Escala y clase de las cuatro variables del enunciado.


Variable	Tipo en R	Escala	Clase
Pronóstico	character	Nominal	Cualitativa politómica
Municipio	character	Nominal	Cualitativa politómica
Temperatura (°C)	numeric	Intervalo	Cuantitativa continua
Velocidad del viento (m/h)	numeric	Razón	Cuantitativa continua

- Pronóstico.** Es nominal y cualitativa politómica (más de dos categorías), con el pequeño detalle que pudo haber sido ordinal porque la nubosidad sí tiene orden (Despejado, Parcialmente Nublado, Nublado) al igual que la precipitación (Llovizna, Lluvia, Lluvia Fuerte). Sin embargo, al combinarse ambas dimensiones en una misma etiqueta deja de existir un orden total, ya que no hay forma de decidir si “Nublado - Llovizna” está por encima o por debajo de “Parcialmente Nublado - Lluvia Fuerte”.
- Municipio.** Es nominal y cualitativa politómica, puesto que se trata de una etiqueta geográfica sobre la que solo tiene sentido preguntar si dos registros son del mismo municipio o no.
- Temperatura.** Es de intervalo y cuantitativa continua dado que sus diferencias son equidistantes pero su cero es relativo (0 °C no es ausencia de temperatura), por lo que 30 °C no es el doble de calor que 15 °C. Cabe aclarar que R la carga como `numeric` sin distinguir nada de esto, así que la escala la declara quien analiza y no la detección automática.
- Velocidad del viento.** Es de razón y cuantitativa continua ya que su cero es absoluto (0 m/h sí es ausencia de viento), lo cual hace que los cocientes tengan sentido y que 2 m/h sea efectivamente el doble que 1 m/h.

Las figuras siguientes resumen ambos ejes por separado y se leen de arriba hacia abajo hasta llegar a los ejemplos de la base.



Eje 1, escala de medición: Cada nivel hereda las operaciones del anterior.



Eje 2, clase según el recorrido: Es independiente de la escala.

2.4. Pregunta 4 — Diagramas de caja de temperatura y viento

El diagrama de caja (Tukey 1977) resume una variable en cinco posiciones. La caja va del primer cuartil (Q_1) al tercero (Q_3) de modo que encierra el 50 % central de los datos, la línea interior marca la mediana y los bigotes llegan hasta la observación más lejana que todavía cae dentro de las cercas de Tukey

$$\text{cerca inferior} = Q_1 - 1.5 \cdot \text{RIC} \quad \text{cerca superior} = Q_3 + 1.5 \cdot \text{RIC}, \quad \text{RIC} = Q_3 - Q_1,$$

mientras que lo que queda por fuera se dibuja punto por punto. Para no leer las posiciones a ojo se anotan sobre cada caja los valores de Q_1 , mediana y Q_3 .

```
caja("Temperatura", "Temperatura (°C)")
```




Figura 2.2: Diagrama de caja de la temperatura a medio día: Se anotan Q1, mediana y Q3.

```
caja("Velocidad_del_Viento", "Velocidad del viento (m/h)")
```




Figura 2.3: Diagrama de caja de la velocidad del viento a medio día: Se anotan Q1, mediana y Q3.

Temperatura. El centro se ubica alrededor de los 30.4 °C y la caja es estrecha (aproximadamente entre 28.8 y 31.3 °C), lo que indica que la mitad de los municipios registra a medio día temperaturas muy parecidas. La mediana está corrida hacia el borde derecho de la caja y el bigote superior es corto porque solo llega a 32.7 °C, mientras que el inferior se extiende hasta los 26.5 °C y por debajo de él aparecen 8 puntos atípicos entre 22 y 25 °C. En conjunto la localización es alta y concentrada pero la dispersión no es simétrica, puesto que unos pocos registros frescos estiran la distribución hacia la izquierda (asimetría negativa).

Velocidad del viento. El centro está cerca de 1.7 m/h y la caja va aproximadamente de 1.0 a 2.2 m/h, así que en términos relativos su dispersión es mucho mayor que la de la temperatura dado que la caja ocupa buena parte del recorrido total (de 0.4 a 3.7 m/h). Los bigotes son relativamente balanceados aunque el superior es algo más largo, lo cual sugiere una leve asimetría hacia valores altos que resulta coherente con una variable cuyo piso físico es cero y que solo puede estirarse hacia arriba. En esta variable no se observan atípicos.

2.5. Pregunta 5 – Resumen numérico

Además de los cuartiles se calculan la desviación estándar (s), que mide la dispersión promedio alrededor de la media y es sensible a los extremos, el rango intercuartílico (RIC), que mide la dispersión del 50 % central y es robusto a ellos, así como el coeficiente de asimetría

$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^{3/2}},$$

cuyo signo indica hacia dónde va la cola, pues vale cero para una distribución simétrica, es negativo con cola a la izquierda y positivo con cola a la derecha.

```
summary(datos$Temperatura)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
22.40	28.82	30.40	29.75	31.30	32.70

```
summary(datos$Velocidad_del_Viento)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.400	1.000	1.700	1.719	2.175	3.700

```
variables <- datos[c("Temperatura", "Velocidad_del_Viento")]
resumen <- sapply(variables, function(x)
  c(media = mean(x), mediana = median(x), s = sd(x), RIC = IQR(x),
    g1 = g1(x), faltantes = sum(is.na(x))))
knitr::kable(round(resumen, 3),
  col.names = c("Temperatura", "Viento"),
  caption = "Estadísticos complementarios a summary().")
```

Cuadro 2.3: Estadísticos complementarios a summary().

	Temperatura	Viento
media	29.754	1.719
mediana	30.400	1.700
s	2.276	0.789
RIC	2.475	1.175
g1	-1.391	0.485
faltantes	0.000	0.000

¿Concuerda la descripción numérica con los diagramas de caja? Sí, pues los cinco números de summary() son exactamente los que dibuja cada caja (mínimo, Q_1 , mediana, Q_3 y máximo) y además agregan lo que el gráfico solo sugería:

- a. **Temperatura.** La media (29.75 °C) queda por debajo de la mediana (30.40 °C), que es la firma numérica de la asimetría negativa vista en el bigote inferior largo y que el coeficiente $g_1 = -1.39$ confirma. Por otro lado la desviación estándar (2.28 °C) resulta casi igual al RIC (2.48 °C) a pesar de que el RIC deja por fuera los extremos, lo que muestra que los 8 registros frescos están inflando s.
- b. **Velocidad del viento.** La media (1.719 m/h) y la mediana (1.700 m/h) casi coinciden con la media apenas por encima, mientras que $g_1 = 0.49$ confirma una asimetría positiva leve coherente con el bigote superior más largo. Su coeficiente de variación ($s/\bar{x}$) de 46 % expresa la mayor dispersión relativa, cociente que solo tiene sentido para el viento por ser de razón y no para la temperatura por ser de intervalo.

Finalmente no hay datos faltantes, pues las 118 filas están completas en ambas variables.

2.6. Pregunta 6 — Atípicos de Tukey en presión y punto de rocío

Siguiendo la ayuda del enunciado se usa `boxplot(x, plot = FALSE)$out`, que calcula las cercas a partir de las bisagras de Tukey. Estas son muy cercanas a los cuartiles de `summary()` pero no idénticas, lo que explica diferencias de centésimas en los límites.

```
boxplot(datos$Presion,
        plot = FALSE)$out
```

[1] 1015.7

```
boxplot(datos$Punto_de_Rocio,
        plot = FALSE)$out
```

numeric(0)

```
tukey <- sapply(c("Presion", "Punto_de_Rocio"), function(v) {
  x <- datos[[v]]
  b <- boxplot(x, plot = FALSE)
  ric <- b$stats[4] - b$stats[2]
  c(`cerca inferior` = b$stats[2] - 1.5 * ric,
    `cerca superior` = b$stats[4] + 1.5 * ric,
    `mínimo` = min(x), `máximo` = max(x),
    `atípicos` = length(b$out))
})
knitr::kable(format(tukey, nsmall = 2, drop0trailing = TRUE),
              align = "r",
              col.names = c("Presión (hPa)",
                            "Punto de rocío (°C)"),
              caption = "Cercas de Tukey y conteo de atípicos.")
```

Cuadro 2.4: Cercas de Tukey y conteo de atípicos.

	Presión (hPa)	Punto de rocío (°C)
cerca inferior	1009.65	13.35
cerca superior	1015.65	30.55
mínimo	1010.9	16.5
máximo	1015.7	29.9
atípicos	1	0

```
par(mfrow = c(1, 2), mar = c(4, 2, 2, 1))
boxplot(datos$Presion, horizontal = TRUE, col = "#f08a3c",
        main = "Presión (hPa)")
boxplot(datos$Punto_de_Rocio, horizontal = TRUE, col = "#fdecc0",
        main = "Punto de rocío (°C)")
```




Figura 2.4: Diagramas de caja de Tukey para la presión y el punto de rocío a medio día.

¿Existen observaciones atípicas? Sí en la presión, que presenta una única observación atípica (1015.7 hPa en Chámeza el 26 de agosto), pero no en el punto de rocío cuya salida es numérica (0).

¿Cuál variable presenta mayor número de atipicidades? La presión, aunque vale la pena matizarlo porque se trata de un solo valor que supera la cerca superior de 1015.65 hPa por apenas 0.05 hPa. El punto de rocío en cambio no tiene ninguno a pesar de moverse en un rango mucho más ancho (de 16.5 a 29.9 °C), lo cual se debe a que el criterio de Tukey es relativo a la dispersión de cada variable y no a una escala absoluta. Así el RIC del punto de rocío (4.3 °C) genera cercas amplias ([13.35, 30.55]) mientras que el de la presión (1.5 hPa) las deja estrechas ([1009.65, 1015.65]). Cabe mencionar además que atípico no es sinónimo de error, puesto que el criterio es geométrico y no sabe nada del fenómeno. De hecho, como se verá en la Pregunta 11, este registro pertenece a un grupo de municipios con comportamiento propio.

2.7. Pregunta 7 – Dispersión entre temperatura y viento

```
temp <- datos$Temperatura
viento <- datos$Velocidad_del_Viento
recta <- lm(viento ~ temp)
subtitulo <- sprintf(
  "r = %.4f · cov = %.5f · n = %d\nty = %.2f + %.5fx · R² = %.3f",
  cor(temp, viento), cov(temp, viento), length(temp),
  coef(recta)[1], coef(recta)[2], summary(recta)$r.squared)
grafico <- ggplot(datos,
  aes(x = Temperatura, y = Velocidad_del_Viento)) +
  geom_point(alpha = 0.6, colour = "#3572a8") +
  geom_smooth(method = "lm", formula = y ~ x, colour = "#d2601a",
    fill = "grey70", linewidth = 0.9) +
  labs(x = "Temperatura (°C)", y = "Velocidad del viento (m/h)",
    subtitle = subtitulo) +
  theme_minimal()
ggMarginal(grafico, type = "histogram", fill = "#3572a8",
  colour = "white")
```

$r = 0.0263 \cdot \text{cov} = 0.04719 \cdot n = 118$
 $y = 1.45 + 0.00911x \cdot R^2 = 0.001$




Figura 2.5: Dispersión de temperatura y velocidad del viento a medio día: Se incluyen la recta de mínimos cuadrados, su banda de confianza del 95 % y los histogramas marginales.

¿Parecen correlacionarse las dos variables? No, pues la nube de puntos no presenta estructura alguna. Para cualquier temperatura aparecen vientos de todo el recorrido, tanto en los registros cálidos entre 29 y 32 °C donde se concentra la mayoría como en los pocos registros frescos de la izquierda, sin que la banda de puntos suba o baje al avanzar en el eje horizontal. La recta de mínimos cuadrados lo confirma al ser prácticamente plana, ya que el viento sube apenas 0.009 m/h por cada grado de temperatura con $R^2 = 0.001$, es decir que la temperatura explica el 0.1 % de la variación del viento. Su banda de confianza se abre hacia la izquierda porque en esa zona solo están los 8 registros frescos, de modo que ahí la recta está mucho peor determinada.

Los histogramas marginales por su parte describen cada variable por separado, con la temperatura apilada a la derecha y cola a la izquierda frente al viento con su masa entre 1 y 2 m/h y cola a la derecha. La razón de verlos junto a la nube es que dos variables pueden ser asimétricas cada una y aun así no tener ninguna relación entre sí.

2.8. Pregunta 8 — Covarianza y correlación de Pearson

La covarianza muestral mide si dos variables se desvían de sus medias en la misma dirección, mientras que el coeficiente de correlación de Pearson (Pearson 1895) es esa misma covarianza estandarizada por ambas desviaciones

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad r = \frac{s_{xy}}{s_x s_y} \in [-1, 1],$$

por lo que r mide la fuerza de la relación **lineal** siendo ± 1 una recta perfecta y 0 la ausencia de relación lineal.

```
cov(datos$Temperatura,
     datos$Velocidad_del_Viento) [1] 0.04718528
```

```
cor(datos$Temperatura,
     datos$Velocidad_del_Viento) [1] 0.02627245
```

```
cor.test(datos$Temperatura, datos$Velocidad_del_Viento)
```

Pearson's product-moment correlation

```
data: datos$Temperatura and datos$Velocidad_del_Viento
t = 0.28306, df = 116, p-value = 0.7776
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
-0.1552241 0.2060533
sample estimates:
cor
0.02627245
```

¿Parecen correlacionarse las dos variables? No, pues la covarianza es $s_{xy} = 0.0472$ y la correlación $r = 0.026$ es prácticamente cero. La prueba asociada tampoco la distingue del azar con 118 datos ($p = 0.78$), dado que su intervalo de confianza del 95 % va de -0.16 a 0.21 y contiene al cero, lo cual confirma lo que ya se veía en la nube de la Pregunta 7. Como verificación adicional se calculó la correlación de Spearman (Spearman 1904), que en vez de los valores usa sus rangos (sus posiciones de menor a mayor) y por ello detecta relaciones monótonas, es decir, aquellas en las que al crecer una variable la otra tiende a crecer o a decrecer aunque no sea en línea recta. Esta dio -0.011 , así que tampoco hay una relación curva escondida.

¿En qué unidades se encuentra cada medida?

- Covarianza.** Se expresa en el producto de las unidades de las dos variables, en este caso $^{\circ}\text{C}\cdot\text{m/h}$, por lo que su valor por sí solo no dice si la relación es fuerte o débil. Además cambiaría si se midiera el viento en km/h y pasaría a $0.0000472\text{ }^{\circ}\text{C}\cdot\text{km/h}$ sin que la relación haya cambiado en lo más mínimo.
- Correlación de Pearson.** Es adimensional, pues al dividir por s_x ($^{\circ}\text{C}$) y s_y (m/h) las unidades se cancelan. Por esto siempre queda en $[-1, 1]$ y es comparable entre cualquier par de variables.

2.9. Pregunta 9 – Dimensión de los datos

¿Son estos datos univariados, bivariados o multivariados? Multivariados, ya que sobre cada unidad estadística (una medición en un municipio a las 12:00) se registran simultáneamente 18 variables que comparten las 118 observaciones. Que en las preguntas 4 a 6 se haya mirado una variable a la vez (análisis univariado) y en las preguntas 7 y 8 dos variables (análisis bivariado) no cambia la naturaleza de los datos, sino que describe el corte que se hace sobre ellos. Los datos son entonces multivariados y es el análisis el que va cambiando de dimensión.

Esta distinción no es solo de nombre, pues como se mencionó en clase, si un conjunto de variables sigue una distribución normal multivariada entonces cada variable por separado es normal, pero que cada variable sea normal univariadamente no garantiza que el conjunto sea normal multivariado. Por ello las conclusiones obtenidas mirando variable por variable no se pueden extender sin más al comportamiento conjunto.

Capítulo 3

Parte 2. Estimación de la densidad

Para las tres preguntas siguientes se usan dos estimadores de la densidad. El **histograma de densidad** divide el recorrido en clases y cada conteo entre n y el ancho de la clase para que el área total valga 1, tomando el número de clases con la regla de Sturges (Sturges 1926), que para $n = 118$ da $k = \lceil \log_2 n \rceil + 1 = 8$. Esta es la regla por defecto de `hist()` en R y está pensada para muestras moderadas, evitando tanto una campana artificial por pocas clases como un dentado ruidoso por demasiadas. La **estimación kernel** (KDE) en cambio pone una pequeña campana sobre cada observación (el núcleo K , en este caso gaussiano) y las suma

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad h = 0.9 \cdot \min\left(s, \frac{\text{RIC}}{1.34}\right) \cdot n^{-1/5},$$

donde el ancho de banda h se toma con la regla de Silverman (Silverman 1986), que es el valor por defecto de `density()` y de `geom_density()`. Esta regla es óptima si los datos fueran normales y usa el mínimo entre s y $\text{RIC}/1.34$ para no suavizar de más cuando hay extremos. Como un h pequeño inventa modas y uno grande las borra, a manera de verificación se recalcula la KDE con $2h$ y se reportan solo las modas que sobreviven.

3.1. Pregunta 10 — Densidad de la temperatura

```
densidad("Temperatura", "Temperatura (°C)", "lightblue")
```




Figura 3.1: Estimación histograma y kernel de la densidad de la temperatura a medio día.

```
c(h = bw.nrd0(datos$Temperatura),  
  g1 = g1(datos$Temperatura))
```

	h	g1
	0.6402307	-1.3912340

```
x <- datos$Temperatura  
list(modas_h = modas(x), modas_2h = modas(x, 2))
```

```
$modas_h  
[1] 23.50 31.08
```

```
$modas_2h  
[1] 23.77 30.84
```

```
shapiro.test(x)
```

Shapiro-Wilk normality test

```
data: x  
W = 0.85961, p-value = 3.403e-09
```

```
datos[x < 26, c("Municipio", "Departamento", "Temperatura")]
```

	Municipio	Departamento	Temperatura
637	CHÁMEZA	CASANARE	23.0
661	CHÁMEZA	CASANARE	23.7
2254	PAJARITO	BOYACÁ	22.4
2278	PAJARITO	BOYACÁ	23.4
2408	PAYA	BOYACÁ	23.5
2432	PAYA	BOYACÁ	23.7
3178	RECETOR	CASANARE	23.7
3202	RECETOR	CASANARE	24.8

¿Se podría afirmar que los datos provienen de una distribución normal? No, pues ambas estimaciones ($h = 0.640$ °C) muestran una forma que una campana no puede producir, lo cual se sostiene por tres vías:

- Asimetría.** La masa se apila entre 29 y 32 °C con una moda cerca de 31.1 °C y una cola larga hacia la izquierda ($g_1 = -1.39$), cuando una normal es simétrica.
- Segunda moda.** En esa cola aparece una moda pequeña cerca de 23.5 °C que sobrevive al duplicar el ancho de banda y que por tanto no es ruido del suavizado. La forman los 8 registros frescos ya marcados como atípicos en la Pregunta 4, los cuales corresponden a solo cuatro municipios medidos en ambas fechas (Chámeza y Recetor en Casanare, Pajarito y Paya en Boyacá), es decir, a una subpoblación de municipios más frescos y no a mediciones aisladas.
- Prueba de normalidad.** La prueba de Shapiro-Wilk (Shapiro y Wilk 1965), cuya hipótesis nula es que los datos son normales, la rechaza con contundencia ($W = 0.860$, $p < 0.001$) aunque la decisión se sostiene principalmente en la forma del gráfico.

Nota. Se atribuye el grupo fresco a que son municipios de piedemonte o de la cordillera, pero la base no tiene una columna de altitud, así que esta explicación geográfica no se verificó con los datos.

3.2. Pregunta 11 — Densidad de la presión

```
densidad("Presion", "Presión (hPa)", "#f08a3c")
```




Figura 3.2: Estimación histograma y kernel de la densidad de la presión a medio día.

```
c(h = bw.nrd0(datos$Presion),  
  g1 = g1(datos$Presion))
```

```
h      g1  
0.3844894 0.8384434
```

```
c(media = mean(datos$Presion),  
  mediana = median(datos$Presion))
```

```
media  mediana  
1012.776 1012.500
```

```
list(modas_h = modas(datos$Presion),  
     modas_2h = modas(datos$Presion, 2))
```

```
$modas_h  
[1] 1012.00 1015.46
```

```
$modas_2h  
[1] 1012.28
```

¿Es la distribución estimada simétrica? No, presenta asimetría positiva (cola a la derecha) que se sostiene por varias vías que coinciden:

- Coeficiente de asimetría.** Vale $g_1 = +0.84$, con signo opuesto al de la temperatura.
- Media contra mediana.** La media (1012.78 hPa) queda por encima de la mediana (1012.50 hPa) y los cuartiles lo confirman, pues de Q_1 a la mediana hay 0.6 hPa mientras que de la mediana a Q_3 hay 0.9 hPa.

- c. **Forma de la KDE.** Con $h = 0.384$ hPa la curva sube rápido desde 1010.9 hPa hasta su moda cerca de 1012 hPa y luego baja despacio, formando una pequeña joroba alrededor de 1015.5 hPa que termina en el valor 1015.7 hPa que la Pregunta 6 marcó como atípico.

Cabe mencionar que esa joroba la forman los mismos cuatro municipios de la cola fresca de la temperatura (Chámeza, Recetor, Pajarito y Paya), de modo que un único grupo de municipios estira a la vez la cola izquierda de una variable y la derecha de la otra. A diferencia de la moda secundaria de la temperatura esta joroba desaparece al duplicar el ancho de banda, por lo que no se afirma una bimodalidad aunque la asimetría positiva sí se mantiene con cualquier h razonable.

Nota. Que municipios presumiblemente más altos registren más presión resulta extraño si fuera presión de estación, lo que sugiere que el IDEAM reporta presión reducida al nivel del mar. Sin embargo esto no se confirmó en la documentación de la fuente.

3.3. Pregunta 12 — Densidad del viento frente a la normal

La densidad normal teórica se construye con la media y la desviación estándar observadas ($\bar{x} = 1.719$ m/h y $s = 0.789$ m/h)

$$f(x) = \frac{1}{s\sqrt{2\pi}} \exp\left(-\frac{(x - \bar{x})^2}{2s^2}\right),$$

para luego superponerse sobre la KDE de la velocidad del viento.

```
media_v <- mean(datos$Velocidad_del_Viento)
sd_v <- sd(datos$Velocidad_del_Viento)
ggplot(datos, aes(x = Velocidad_del_Viento)) +
  geom_density(colour = "blue", fill = "blue", alpha = 0.2,
               linewidth = 1) +
  stat_function(fun = dnorm, args = list(mean = media_v, sd = sd_v),
               colour = "firebrick", linetype = "dashed",
               linewidth = 1) +
  xlim(-0.5, 4.5) +
  labs(x = "Velocidad del viento (m/h)", y = "Densidad") +
  theme_minimal()
```




Figura 3.3: KDE de la velocidad del viento (azul) frente a la normal con media y desviación observadas (rojo punteado).

```
pnorm(0, media_v, sd_v) [1] 0.01471799
```

```
x <- datos$Velocidad_del_Viento
list(modas_h = modas(x), modas_2h = modas(x, 2))
```

```
$modas_h
[1] 1.01 1.93 3.28
```

```
$modas_2h
[1] 1.63
```

```
shapiro.test(x)
```

Shapiro-Wilk normality test

```
data: x
W = 0.96155, p-value = 0.001885
```

¿Se aproxima el modelo normal estimado a la densidad encontrada? Solo de lejos, pues $N(1.719, 0.789)$ acierta el centro y el ancho general de la distribución pero falla en la forma por tres motivos:

- a. **Asimetría y jorobas.** La KDE ($h = 0.274$ m/h) concentra su masa entre 1 y 2 m/h con jorobas locales cerca de 1.0, 1.9 y 3.3 m/h y una cola derecha más pesada ($g_1 = +0.49$), mientras que la normal es una sola campana simétrica. Vale la pena matizar que esas jorobas se funden en una sola moda al duplicar h , por lo que lo robusto es la asimetría y no la multimodalidad.
- b. **Masa imposible.** Con esa media y desviación la normal le asigna un 1.5 % de probabilidad a velocidades negativas, lo cual es imposible para una variable de razón acotada por cero. Este es el defecto conceptual del ajuste y no un detalle de la muestra, dado que la KDE también derrama algo de masa bajo cero pero únicamente por la cola infinita de su núcleo gaussiano.
- c. **Prueba de normalidad.** Shapiro-Wilk rechaza la normalidad ($W = 0.962$, $p = 0.002$) aunque de forma mucho menos rotunda que en la temperatura, algo coherente con que aquí las dos curvas al menos se parecen.

En resumen, la normal sirve como aproximación gruesa del centro y la dispersión del viento a medio día pero no como modelo de su forma, puesto que en particular no describe bien ni la cola derecha ni el piso físico en cero.

Bibliografía

- Attali, D. y C. Baker (2025). *ggExtra: Add Marginal Histograms to 'ggplot2', and More 'ggplot2' Enhancements*. R package version 0.11.0. DOI: [10.32614/CRAN.package.ggExtra](https://doi.org/10.32614/CRAN.package.ggExtra). URL: <https://CRAN.R-project.org/package=ggExtra>.
- Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (2022). *Datos meteorológicos de la red de estaciones — región Orinoquía*. Descarga libre del portal IDEAM. URL: <http://www.ideam.gov.co>.
- Pearson, K. (1895). “Note on Regression and Inheritance in the Case of Two Parents”. En: *Proceedings of the Royal Society of London* 58, págs. 240-242. DOI: [10.1098/rspl.1895.0041](https://doi.org/10.1098/rspl.1895.0041).
- R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R version 4.6.1. R Foundation for Statistical Computing. Vienna, Austria. URL: <https://www.R-project.org>.
- Shapiro, S. S. y M. B. Wilk (1965). “An Analysis of Variance Test for Normality (Complete Samples)”. En: *Biometrika* 52.3-4, págs. 591-611. DOI: [10.1093/biomet/52.3-4.591](https://doi.org/10.1093/biomet/52.3-4.591).
- Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. London: Chapman y Hall.
- Spearman, C. (1904). “The Proof and Measurement of Association between Two Things”. En: *The American Journal of Psychology* 15.1, págs. 72-101. DOI: [10.2307/1412159](https://doi.org/10.2307/1412159).
- Sturges, H. A. (1926). “The Choice of a Class Interval”. En: *Journal of the American Statistical Association* 21.153, págs. 65-66. DOI: [10.1080/01621459.1926.10502161](https://doi.org/10.1080/01621459.1926.10502161).
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Reading, MA: Addison-Wesley.
- Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. URL: <https://ggplot2.tidyverse.org>.

Apéndice A

Documentación de R

Se listan las funciones utilizadas en el taller junto con el paquete que las provee y la pregunta donde se usan, cada una enlazada a su página de ayuda oficial (la misma que se obtiene en R con `?función`). El documento se generó con R 4.6.1, ggplot2 4.0.3, ggExtra 0.11.0 y knitr 1.51.

Cuadro A.1: Funciones de R utilizadas y enlace a su documentación.

Función	Paquete	Uso
<code>read.csv()</code>	utils	Carga de la base
<code>table()</code>	base	P1, P2
<code>summary()</code>	base	P5
<code>quantile()</code>	stats	P4
<code>sd()</code>	stats	P5
<code>IQR()</code>	stats	P5
<code>boxplot()</code>	graphics	P6
<code>barplot()</code>	graphics	P2
<code>cov()</code>	stats	P8
<code>cor.test()</code>	stats	P8
<code>lm()</code>	stats	P7
<code>density()</code>	stats	P10 a P12
<code>bw.nrd0()</code>	stats	P10 a P12
<code>nclass.Sturges()</code>	grDevices	P10, P11
<code>shapiro.test()</code>	stats	P10, P12
<code>dnorm()</code>	stats	P12
<code>ggplot()</code>	ggplot2	P4, P7, P10 a P12
<code>geom_boxplot()</code>	ggplot2	P4
<code>geom_smooth()</code>	ggplot2	P7
<code>geom_histogram()</code>	ggplot2	P10, P11
<code>geom_density()</code>	ggplot2	P10 a P12
<code>stat_function()</code>	ggplot2	P12
<code>ggMarginal()</code>	ggExtra	P7