

Exploración de datos · SDA Lab

ori

2026-09-12 07:50

Cuaderno generado desde SDA Lab. Cada sección corresponde a un panel marcado con la casilla **Añadir**: trae su texto explicativo, los parámetros con que se produjo y el código R que lo redibuja sobre **datos**.

Los datos

Campo	Valor
Nombre	ori
Fuente	ori
Filas al cargar	4543
Columnas al cargar	18
Filas ahora	118
Columnas ahora	18

```
# ORI.csv es la base del Taller 01 (IDEAM). Dejalo al lado del cuaderno o
# ajustá `ruta`: se prueban los lugares habituales, en orden.
ruta <- Filter(file.exists, c("ORI.csv", "data/ORI.csv",
                             "../.../data/ORI.csv"))[1]
# La copia que reparte el curso viene en ISO-8859-1 y la de data/ del repo
# en UTF-8. Se detecta en vez de suponer: suponer es lo que rompe las
# tildes de los municipios (ACACÍAS -> ACACÁAS).
codificacion <- if (all(validUTF8(readLines(ruta, warn = FALSE,
                                             encoding = "bytes"))))
  "UTF-8" else "latin1"
datos <- read.csv(ruta, sep = ";", dec = ".", fileEncoding = codificacion,
                  stringsAsFactors = FALSE)
names(datos) <- trimws(names(datos)) # el encabezado trae "Pronostico "
cat("Al cargar:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Al cargar: 4543 filas x 18 columnas

Preparación

```
datos <- datos[datos$Hora %in% c("12:00"), ]
cat("Después de la preparación:", nrow(datos), "filas\n")
```

Después de la preparación: 118 filas

Análisis

Vista previa del dataset

Panel f1.fuente.vista_previa · marcado a las 07:25:51

Para qué sirve

Atrapar el desastre antes de gastar una hora en él. Es la única card que se mira sin haber decidido nada todavía, y la que dice si el archivo se cargó como creías o hay que volver a leerlo con otras opciones.

Qué muestra

Las primeras filas de lo que se acaba de cargar, con el pie que dice cuántas se muestran y cuántas hay. Es la comprobación más barata que existe y la que más errores atrapa: si la tabla se ve mal acá, todo lo que venga después está mal.

Qué buscar

- **Columnas de más o de menos:** casi siempre es el separador equivocado en un CSV. Si todo el archivo entró en una sola columna, probá ; o tabulador.
- **Números leídos como texto:** el separador decimal. Con coma decimal y punto como separador de miles, 1.234,5 se convierte en texto y ninguna operación numérica va a funcionar.
- **Tildes rotas:** es la codificación. UTF-8 y Latin-1 se confunden fácil.
- **Faltantes disfrazados:** ., -99, N/A, celdas vacías. Si no se declaran como faltantes, entran al análisis como valores reales.
- **La primera fila:** ¿es un encabezado o ya es un dato?

Cuándo engaña

Ver diez filas correctas no dice nada de las 35.000 restantes. El problema típico —una columna que cambia de formato a mitad del archivo— no aparece arriba. La subsección de Calidad es la que mira el archivo entero.

Un dataset del curso ya cargado también puede estar transformado. Si en el pivot país×año ves ceros, muchos no son ceros observados: son pares sin dato rellenados en la agregación. El panel lo avisa al cargar y conviene creerle.

El orden de las filas puede no ser inocente. Si el archivo viene ordenado por alguna variable, cualquier partición sin barajar hereda ese orden. Por eso la subsección de Partición baraja siempre y con semilla.

Estado al marcarlo:

Cod_Dist	Intit	Longitud	Región	Departamento	Municipio	Fecha	Hora	Temperatura	Velocidad	Dir. del viento	Presión	Hum. rel.	Vis. hor.	Dir. del viento	Presión	Hum. rel.	Vis. hor.	Calidad	Tiempo
500060009012		73.76594	ORI	METAACACÍA	16/08/2000	12:00	26.5	1.2	179.8	1014.2	18.3	70	0	0	60.7	Parcialmente Nublado			
500060009012		73.76594	ORI	METAACACÍA	16/08/2000	12:00	27.3	1.7	113.7	1013.9	21	80	0	0	68.7	Nublado			
850100007269		72.5463	ORI	CASANGRE	26/08/2000	12:00	30.2	2.1	176.7	1013	21.8	49.8	0	0	60.9	Parcialmente Nublado			
850100007269		72.5463	ORI	CASANGRE	27/08/2000	12:00	30.4	1.7	200	1013.2	24.4	63.2	0	0	70.4	Parcialmente Nublado			
8100100073902		70.74801	ORI	ARAUCAU	26/08/2000	12:00	30.4	2	150	1012	22.5	40	0	0	62.7	Parcialmente Nublado			
8100100073902		70.74801	ORI	ARAUCAU	27/08/2000	12:00	29	0.7	187.1	1011.6	22.3	80	0	0	67.5	Nublado			

Cod_Div	Latitud	Longitud	Region	Departamento	Municipio	Fecha	Hora	Temperatura	Velocidad del Viento	Direccion del Viento	Presion	Punto de Rocio	Cobertura total nubosa	Precipitacion mm/h	Estado del Cielo	Forma de Tormenta	
81065000	6000	3.990120	ORI	ARAUCA	ARAUCITA	26/08/2022	12:00	29.7	2.1	200.7	1011.6	18.3	50	0	0	50.3	Parcialmente Nublado
81065000	6000	3.990120	ORI	ARAUCA	ARAUCITA	27/08/2022	12:00	28.8	0.5	356.5	1011.9	24.5	80	0.8	0	77.6	Nublado - Lluvia
50110000	667202	72.96328	ORI	METABARRANCA DE UPÍA	ACACÍAS	26/08/2022	12:00	31	2	200	1012.2	21.4	50	0	0	56.7	Parcialmente Nublado
50110000	667202	72.96328	ORI	METABARRANCA DE UPÍA	ACACÍAS	27/08/2022	12:00	31.5	0.7	210.5	1012.8	28.7	80	0	0	85	Nublado

```
# f1.fuente.vista_previa
```

```
cat("Unidades estadísticas (filas):", nrow(datos), "\n")
```

```
## Unidades estadísticas (filas): 118
```

```
cat("Variables (columnas):", ncol(datos), "\n")
```

```
## Variables (columnas): 18
```

```
utils::head(datos, 10)
```

```
##      Cod_Div  Latitud  Longitud Region Departamento      Municipio      Fecha
## 21  50006000  3.990120 -73.76594  ORI          META          ACACÍAS 26/08/2022
## 45  50006000  3.990120 -73.76594  ORI          META          ACACÍAS 27/08/2022
## 98  85010000  5.172690 -72.54630  ORI          CASANARE        AGUAZUL 26/08/2022
## 122 85010000  5.172690 -72.54630  ORI          CASANARE        AGUAZUL 27/08/2022
## 175 81001000  7.073902 -70.74801  ORI          ARAUCA          ARAUCA 26/08/2022
## 199 81001000  7.073902 -70.74801  ORI          ARAUCA          ARAUCA 27/08/2022
## 252 81065000  7.026981 -71.42675  ORI          ARAUCA          ARAUCUITA 26/08/2022
## 276 81065000  7.026981 -71.42675  ORI          ARAUCA          ARAUCUITA 27/08/2022
## 329 50110000  4.567202 -72.96328  ORI          META BARRANCA DE UPÍA 26/08/2022
## 353 50110000  4.567202 -72.96328  ORI          META BARRANCA DE UPÍA 27/08/2022
##      Hora Temperatura Velocidad_del_Viento Direccion_del_Viento Presion
## 21  12:00          26.5                1.2                179.8  1014.2
## 45  12:00          27.3                1.7                113.7  1013.9
## 98  12:00          30.2                2.1                176.7  1013.0
## 122 12:00          30.4                1.7                200.0  1013.2
## 175 12:00          30.4                2.0                150.0  1012.0
## 199 12:00          29.0                0.7                187.1  1011.6
## 252 12:00          29.7                2.1                200.7  1011.6
## 276 12:00          28.8                0.5                356.5  1011.9
## 329 12:00          31.0                2.0                200.0  1012.2
## 353 12:00          31.5                0.7                210.5  1012.8
##      Punto_de_Rocio Cobertura_total_nubosa Precipitacion_mm_h
## 21          18.3                70.0                0.0
## 45          21.0                80.0                0.0
## 98          21.8                49.8                0.0
## 122         24.4                63.2                0.0
## 175         22.5                40.0                0.0
## 199         22.3                80.0                0.0
## 252         18.3                50.0                0.0
```

## 276	24.5	80.0	0.8
## 329	21.4	50.0	0.0
## 353	28.7	80.0	0.0
##	Probabilidad_de_Tormenta	Humedad	Pronostico
## 21	0	60.7	Parcialmente Nublado
## 45	0	68.7	Nublado
## 98	0	60.9	Parcialmente Nublado
## 122	0	70.4	Parcialmente Nublado
## 175	0	62.7	Parcialmente Nublado
## 199	0	67.5	Nublado
## 252	0	50.3	Parcialmente Nublado
## 276	0	77.6	Nublado - Lluvia
## 329	0	56.7	Parcialmente Nublado
## 353	0	85.0	Nublado

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Frecuencias por clase · Pronostico

Panel `f1.balaneo.frecuencias` · marcado a las 07:25:51

Para qué sirve

Ver de cuánto es el desbalance y decidir si hace falta hacer algo. La respuesta muchas veces es que no: un 60/40 no necesita tratamiento, y rebalancear por costumbre estropea la calibración de las probabilidades que salen del modelo.

Qué muestra

Cuántas observaciones hay por clase, antes y después de rebalancear. El subtítulo trae la razón de desbalance: cuántas veces la clase mayoritaria supera a la minoritaria.

Las tres técnicas disponibles no traen dependencias nuevas y no inventan datos:

- **sub-muestreo** — recorta las clases grandes. Se pierde información real.
- **sobre-muestreo** — repite filas de las chicas. No agrega información.
- **bootstrap** — remuestrea todas con reemplazo hasta un tamaño común.

SMOTE, que interpola entre vecinos y sí fabrica filas nuevas, está en el catálogo como pendiente: pedirlo suma un paquete al bundle.

Qué buscar

- **La razón de desbalance:** por debajo de 3 a 1 casi nunca hace falta tocar nada. Por encima de 20 a 1 el problema es real.
- **Cuánto se pierde con sub-muestreo:** si la minoritaria tiene 40 casos, la mayoritaria queda en 40 y tiraste miles de filas.
- **Cuánto se repite con sobre-muestreo:** si una fila aparece 30 veces, el modelo la va a memorizar.
- **Clases con menos de 10 casos:** ninguna técnica las salva.

Cuándo engaña

Balancear cambia las probabilidades a priori. Después de rebalancear, las probabilidades que estime el modelo no son las de la población: están calibradas para el mundo artificial 50/50 que construiste.

El desbalance a veces no es el problema. Con clases separables, un modelo aprende bien con 1 % de positivos. Lo que suele estar mal es la métrica: exactitud con 99 % de negativos se gana prediciendo siempre “no”. Antes de remuestrear, probá cambiar de métrica o usar pesos de clase.

Nunca se rebalancea la partición de prueba. Solo el entrenamiento. Si tocás la prueba, estás midiendo el desempeño en una población que no existe.

Estado al marcarlo:

	clase	n	proporcion
Parcialmente Nublado		63	0.5338983
Nublado		31	0.2627119
Parcialmente Nublado - Lluvia Fuerte		6	0.05084746
Parcialmente Nublado - Llovizna		5	0.04237288
Nublado - Llovizna		4	0.03389831
Nublado - Lluvia		4	0.03389831
Despejado		3	0.02542373
Parcialmente Nublado - Tormenta Ligera		2	0.01694915

Parámetros:

	Campo	Valor
clase		Pronostico

```
# f1.balanceo.frecuencias
tabla <- sort(table(datos$Pronostico), decreasing = TRUE)
print(cbind(n = tabla, prop = round(prop.table(tabla), 3)))

##              n  prop
## Parcialmente Nublado    63 0.534
## Nublado                  31 0.263
## Parcialmente Nublado - Lluvia Fuerte    6 0.051
## Parcialmente Nublado - Llovizna        5 0.042
## Nublado - Llovizna            4 0.034
## Nublado - Lluvia             4 0.034
## Despejado                   3 0.025
## Parcialmente Nublado - Tormenta Ligera  2 0.017

cat("Más frecuente: ", names(tabla)[1], " (n = ", tabla[1], ")\n",
    sep = "")


## Más frecuente: Parcialmente Nublado (n = 63)

cat("Menos frecuente: ", names(tabla)[length(tabla)],
    " (n = ", tabla[length(tabla)], ")\n", sep = "")

## Menos frecuente: Parcialmente Nublado - Tormenta Ligera (n = 2)

barplot(tabla, horiz = TRUE, las = 1, cex.names = 0.7,
    main = "Frecuencias de Pronostico")
```

Frecuencias de Pronostico



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Diccionario de columnas

Panel f1.diccionario.tabla · marcado a las 07:25:51

Para qué sirve

Declarar qué es cada columna, que es lo que después habilita o bloquea cada operación en el resto de la app. Es la card con más consecuencias del proyecto: marcar una variable como nominal apaga su media y su histograma a propósito, y con la razón escrita al lado.

Qué muestra

```

---
config:
  layout: elk
  theme: default
---
flowchart TD
  V["CLASIFICACIÓN DE VARIABLES<br/>(NB1: escala × clase, ejes independientes)"]

  V --> ESC["EJE 1 · ESCALA<br/>¿qué operaciones tienen sentido?"]
  V --> CLA["EJE 2 · CLASE<br/>¿cuál es el recorrido?"]

  %% ===== EJE 1: ESCALA =====
  ESC --> CUAL["CUALITATIVA<br/>mide atributos → categorías"]
  ESC --> CUAN["CUANTITATIVA<br/>mide cantidades → números"]

  CUAL --> NOM["NOMINAL<br/>solo = / "]
  CUAL --> ORD["ORDINAL<br/>= / + orden<br/>(distancias sin significado)"]
  CUAN --> INT["INTERVALO<br/>+ intervalos equidistantes<br/>CERO RELATIVO"]
  
```

```

CUAN --> RAZ["RAZÓN<br/>+ razones válidas<br/>CERO ABSOLUTO"]

NOM --> NOME["Municipio, Pronóstico, Region<br/>(código postal: numérico pero nominal)"]
ORD --> ORDE["Estrato {bajo, medio, alto}<br/>consumo eléctrico {alto, medio, bajo}"]
INT --> INTE["Temperatura en °C<br/>0 °C no es ausencia de temperatura"]
RAZ --> RAZE["Velocidad del viento (mph)<br/>Presion, Latitud - 0 = ausencia"]

%% ===== EJE 2: CLASE =====
CLA --> CUAL2["si es CUALITATIVA"]
CLA --> CUAN2["si es CUANTITATIVA"]

CUAL2 --> BIN["BINARIA / DICOTÓMICA<br/>2 categorías"]
CUAL2 --> POL["POLITÓMICA<br/>más de 2 categorías"]
CUAN2 --> DIS["DISCRETA<br/>valores contables"]
CUAN2 --> CON["CONTINUA<br/>cualquier valor de un intervalo real"]

BIN --> BINE["Sí / No · Presence {Sí, No}"]
POL --> POLE["Pronóstico (11 categorías)<br/>Municipio, Departamento"]
DIS --> DISE["n.º de turbinas<br/>n.º de hijos"]
CON --> CONE["Temperatura, Presion<br/>Velocidad del viento"]

%% ===== ESTILOS =====
classDef raiz fill:#65e94f,stroke:#222,stroke-width:2px,color:#000,font-weight:bold;
classDef eje fill:#91cbe8,stroke:#555,stroke-width:1px,color:#000,font-weight:bold;
classDef grupo fill:#ffffb0,stroke:#777,stroke-width:1px,color:#000,font-weight:bold;
classDef tipo fill:#e58be8,stroke:#777,stroke-width:1px,color:#000,font-weight:bold;
classDef ejemplo fill:#8de8d8,stroke:#777,stroke-width:1px,color:#000;

class V raiz;
class ESC,CLA eje;
class CUAL,CUAN,CUAL2,CUAN2 grupo;
class NOM,ORD,INT,RAZ,BIN,POL,DIS,CON tipo;
class NOME,ORDE,INTE,RAZE,BINE,POLE,DISE,CONE ejemplo;

```

Una fila por columna del dataset, con lo que la app necesita saber de ella: etiqueta, escala de medición, clase y rol.

```

escala {nominal, ordinal, intervalo, razon}
clase {cualitativa, discreta, continua}
rol {respuesta, predictor, id, grupo, peso, ignorar}

```

La escala no se puede deducir del tipo de dato, y ahí está todo el punto: un código postal es numérico y es nominal; un año es entero y es de intervalo, porque su cero es convencional. La autodetección propone; vos corregís.

Esta tabla gobierna el resto de la app. Si marcás una columna como nominal, el selector de media se deshabilita y aparece la moda, con la razón escrita al lado. Los métodos de la fase 2 se filtran por lo mismo.

Qué buscar

- **Identificadores marcados como predictores:** un id correlaciona con cualquier cosa por accidente y arruina un modelo en silencio.
- **Códigos numéricos que son categorías:** 1 = norte, 2 = sur. Numéricos en memoria, nominales de verdad.
- **Años y fechas marcados como razón:** son de intervalo. Duplicar un año no significa nada.

- **Columnas con muchos faltantes:** el porcentaje está en la tabla. Por encima de 40 %, imputar es inventar estructura.
- **Columnas constantes:** no aportan información y sobreviven hasta la fase 4 si nadie las marca como ignorar.

Cuándo engaña

La detección automática acierta el tipo, no el significado. Ve números y propone razón; ve texto y propone nominal. Ordinal e intervalo no los propone nunca, porque no se pueden inferir: los tenés que poner vos.

Un rol mal puesto no rompe nada hoy. La app te deja seguir y el error aparece dos fases después, cuando un modelo da un R^2 sospechosamente perfecto porque metiste el identificador como predictor.

Los avisos de conflicto son heurísticos. Que una columna se llame `year` no prueba que sea un año. El aviso pregunta; la decisión es tuya.

```
# f1.diccionario.tabla
# Escala, clase y rol los declara quien analiza: R no los puede
# deducir del tipo de dato (un código postal es numérico y nominal;
# los grados centígrados son de intervalo, no de razón).
diccionario <- data.frame(
  columna = c("Cod_Div", "Latitud", "Longitud", "Region", "Departamento",
              "Municipio", "Fecha", "Hora", "Temperatura",
              "Velocidad_del_Viento", "Direccion_del_Viento", "Presion",
              "Punto_de_Rocio", "Cobertura_total_nubosa",
              "Precipitacion_mm_h", "Probabilidad_de_Tormenta", "Humedad",
              "Pronostico"),
  escala = c("razon", "razon", "razon", "nominal", "nominal", "nominal",
             "nominal", "nominal", "intervalo", "razon", "razon", "razon",
             "razon", "razon", "razon", "razon", "razon", "nominal"),
  clase = c("continua", "continua", "continua", "cualitativa", "cualitativa",
            "cualitativa", "cualitativa", "cualitativa", "continua",
            "continua", "continua", "continua", "continua", "continua",
            "continua", "discreta", "continua", "cualitativa"),
  rol = c("predictor", "predictor", "predictor", "predictor", "predictor",
          "predictor", "predictor", "predictor", "predictor", "predictor",
          "predictor", "predictor", "predictor", "predictor", "predictor",
          "predictor", "predictor", "predictor")
)
print(diccionario)
```

##	columna	escala	clase	rol
## 1	Cod_Div	razon	continua	predictor
## 2	Latitud	razon	continua	predictor
## 3	Longitud	razon	continua	predictor
## 4	Region	nominal	cualitativa	predictor
## 5	Departamento	nominal	cualitativa	predictor
## 6	Municipio	nominal	cualitativa	predictor
## 7	Fecha	nominal	cualitativa	predictor
## 8	Hora	nominal	cualitativa	predictor
## 9	Temperatura	intervalo	continua	predictor
## 10	Velocidad_del_Viento	razon	continua	predictor
## 11	Direccion_del_Viento	razon	continua	predictor
## 12	Presion	razon	continua	predictor
## 13	Punto_de_Rocio	razon	continua	predictor

```
## 14 Cobertura_total_nubosa      razon      continua predictor
## 15      Precipitacion_mm_h      razon      continua predictor
## 16 Probabilidad_de_Tormenta      razon      discreta predictor
## 17              Humedad      razon      continua predictor
## 18              Pronostico      nominal  cualitativa predictor
```

Lo que R infiere solo, para comparar:

```
data.frame(columna = names(datos),
            clase_en_R = vapply(datos, function(v) class(v)[1], ""),
            distintos = vapply(datos, function(v) length(unique(v)), 0L),
            row.names = NULL)
```

```
##              columna clase_en_R distintos
## 1              Cod_Div      integer         59
## 2              Latitud      numeric         59
## 3              Longitud      numeric         59
## 4              Region      character          1
## 5      Departamento      character          8
## 6              Municipio      character        59
## 7              Fecha      character          2
## 8              Hora      character          1
## 9      Temperatura      numeric         54
## 10 Velocidad_del_Viento      numeric         31
## 11 Direccion_del_Viento      numeric         91
## 12              Presion      numeric         38
## 13      Punto_de_Rocio      numeric         79
## 14 Cobertura_total_nubosa      numeric         29
## 15      Precipitacion_mm_h      numeric         13
## 16 Probabilidad_de_Tormenta      integer          3
## 17              Humedad      numeric        100
## 18      Pronostico      character          8
```

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Diagrama de caja · Temperatura

Panel f1.analisis.boxplot · marcado a las 07:25:51

Para qué sirve

Comparar posición y dispersión de un vistazo, y decidir qué variable merece una mirada más detallada. Es el resumen que escala: veinte boxplots en fila se leen sin esfuerzo; veinte histogramas, no.

Qué muestra

El resumen de cinco números: mínimo dentro de la cerca, primer cuartil, mediana, tercer cuartil y máximo dentro de la cerca. La caja va de Q1 a Q3, así que encierra el 50 % central de los datos, y la línea de adentro es la mediana.

Los bigotes llegan hasta la observación más lejana que todavía cae dentro de 1,5 veces el rango intercuartílico:

$$\text{cerca inferior} = Q_1 - 1,5 \cdot \text{RIC} \quad \text{cerca superior} = Q_3 + 1,5 \cdot \text{RIC}$$

Lo que queda afuera se dibuja punto por punto. Son los **atípicos de Tukey**, y son una convención, no un diagnóstico.

Qué buscar

- **Posición de la mediana dentro de la caja:** si está pegada a un borde, la distribución es asimétrica.
- **Largo relativo de los bigotes:** el más largo apunta hacia la cola.
- **Cuántos puntos quedan afuera** y qué tan lejos. Uno muy separado del resto vale más atención que quince apenas pasada la cerca.
- **Ancho de la caja:** es el RIC, la medida de dispersión que no se deja arrastrar por los extremos.

Cuándo engaña

Esconde las modas. Una distribución con dos picos y otra con uno solo pueden dar cajas idénticas. El boxplot resume posiciones, no forma. Por eso está al lado del histograma y no en su lugar.


“Atípico” acá significa “pasó de $1,5 \cdot \text{RIC}$ ”, nada más. En una variable con cola derecha larga —ingresos, tiempos de espera— es normal que haya decenas de puntos afuera y ninguno es un error. Marcarlos no es motivo para borrarlos.

Con n chico los cuartiles son inestables. Por debajo de unas 20 observaciones, agregá los puntos encima de la caja: es más honesto mostrar el dato que su resumen.

Parámetros:

Campo	Valor
variable	Temperatura

```
# fl.analisis.boxplot
ggplot(datos, aes(x = "", y = Temperatura)) +
  geom_boxplot(fill = "steelblue", alpha = 0.5) +
  coord_flip() + labs(x = NULL)
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Diagrama de caja · Velocidad_del_Viento


Panel `f1.analisis.boxplot` · marcado a las 07:25:51

El texto de este panel está en la primera sección «Diagrama de caja».

Parámetros:

	Campo	Valor
variable		<code>Velocidad_del_Viento</code>

```
# f1.analisis.boxplot
ggplot(datos, aes(x = "", y = Velocidad_del_Viento)) +
  geom_boxplot(fill = "steelblue", alpha = 0.5) +
  coord_flip() + labs(x = NULL)
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Resumen numérico · Temperatura

Panel `f1.analisis.resumen` · marcado a las 07:25:51

Para qué sirve

Poner en números lo que la caja muestra en forma, y comprobar que las dos cuentan la misma historia. Es la tabla que se cita cuando hay que escribir el centro y la dispersión de una variable sin adjetivos.

Qué muestra

Los cinco números de `summary()` —mínimo, Q1, mediana, media, Q3, máximo— más la desviación estándar, el rango intercuartílico y la asimetría, con el conteo de faltantes al lado.

Qué estadísticos aparecen **lo decide la escala declarada en el Diccionario**, no el tipo de dato en memoria:

```
nominal -> moda y tabla de frecuencias
ordinal -> moda, mediana y cuantiles
intervalo -> todo menos los cocientes
razon -> todo
```

La media de una nominal no sale porque no se calcula, no porque esté escondida.

Qué buscar

- **Media contra mediana:** si la media es menor, hay cola a la izquierda; si es mayor, cola a la derecha. Es la regla de bolsillo de la asimetría, y se confirma con el coeficiente.

- **Desviación contra RIC:** cuando la desviación es mucho mayor de lo que el RIC sugiere, unos pocos valores extremos la están inflando.
- **Dispersión relativa:** un RIC de 2,5 °C sobre una mediana de 30 es el 8 %; el mismo 2,5 sobre una mediana de 1,7 sería otra variable completamente. Comparar dispersiones en unidades distintas no significa nada.
- **Faltantes:** cuántos son y si `summary()` los está descontando.

Cuándo engaña

Un resumen no distingue formas. Dos variables con los mismos seis números pueden tener una moda o dos. Por eso esta tabla va al lado del histograma y de la densidad, no en su lugar.

La media de una escala de intervalo se puede calcular; el cociente no. 30 °C no es el doble de calor que 15 °C. El resumen no lo avisa: lo avisa la escala que se declaró en el Diccionario.

Con n chico los cuartiles se mueven mucho. Por debajo de unas 20 observaciones, agregar o quitar un dato cambia Q1 y Q3 de forma visible, y la tabla se lee con la misma desconfianza que la caja.

Estado al marcarlo:

estadístico	mostrado
n	118
faltantes	0
moda	31
mediana	30.4
q1	28.83
q3	31.3
rango_inter	2.475
minimo	22.4
maximo	32.7
media	29.75
desviacion	2.276
asimetria	-1.391
curtosis	1.576

Parámetros:

Campo	Valor
variable	Temperatura
escala	intervalo

```
# f1.analisis.resumen
x <- datos$Temperatura
print(summary(x))

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    22.40  28.82   30.40   29.75   31.30   32.70

v <- x[!is.na(x)]
centrado <- v - mean(v)
raiz <- sqrt(mean(centrado^2))
asimetria <- mean(centrado^3) / raiz^3 # g1: hacia dónde va la cola
curtosis <- mean(centrado^4) / raiz^4 - 3 # g2: exceso sobre la normal
cat("Desviación:", round(sd(v), 4), "· RIC:", round(IQR(v), 4), "\n")
```

```
## Desviación: 2.2756 · RIC: 2.475
```

```
cat("Asimetría:", round(asimetria, 3),  
    "· Curtosis:", round(curtosis, 3), "\n")
```

```
## Asimetría: -1.391 · Curtosis: 1.576
```

```
cat("n:", length(v), "· faltantes:", sum(is.na(x)), "\n")
```

```
## n: 118 · faltantes: 0
```

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Resumen numérico · Velocidad_del_Viento

Panel `f1.analisis.resumen` · marcado a las 07:25:51

El texto de este panel está en la primera sección «Resumen numérico».

Estado al marcarlo:

	estadistico	mostrado
n		118
faltantes		0
moda		0.9
mediana		1.7
q1		1
q3		2.175
rango_inter		1.175
minimo		0.4
maximo		3.7
media		1.719
desviacion		0.7892
asimetria		0.4854
curtosis		-0.3234
coef_variacion		0.4592

Parámetros:

	Campo	Valor
variable	Velocidad_del_Viento	
escala	razon	

```
# f1.analisis.resumen  
x <- datos$Velocidad_del_Viento  
print(summary(x))
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
##    0.400  1.000   1.700   1.719  2.175   3.700
```

```
v <- x[!is.na(x)]  
centrado <- v - mean(v)  
raiz <- sqrt(mean(centrado^2))  
asimetria <- mean(centrado^3) / raiz^3 # g1: hacia dónde va la cola
```

```
curtosis <- mean(centrado^4) / raiz^4 - 3 # g2: exceso sobre la normal
cat("Desviación:", round(sd(v), 4), " · RIC:", round(IQR(v), 4), "\n")
```

```
## Desviación: 0.7892 · RIC: 1.175
```

```
cat("Asimetría:", round(asimetria, 3),
    " · Curtosis:", round(curtosis, 3), "\n")
```

```
## Asimetría: 0.485 · Curtosis: -0.323
```

```
cat("n:", length(v), " · faltantes:", sum(is.na(x)), "\n")
```

```
## n: 118 · faltantes: 0
```

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Atípicos detectados · Presion

Panel f1.calidad.atipicos · marcado a las 07:25:51

Para qué sirve

Decidir qué hacer con los valores extremos: corregirlos, dejarlos, o cambiar a un método robusto que no dependa de ellos. Lo que no se decide acá se decide solo más adelante, y casi siempre mal.

Qué muestra

Cada observación contra su posición en el archivo, con los atípicos marcados según el criterio elegido. Los tres criterios responden preguntas distintas:

IQR : $x \notin [Q_1 - 1.5 \cdot \text{RIC}, Q_3 + 1.5 \cdot \text{RIC}]$ robusto, univariado

z : $\frac{|x - \bar{x}|}{s} > 3$ no robusto, univariado

Mahalanobis : $d^2 > \chi_p^2(\alpha)$ multivariado

Los dos primeros miran una columna; el tercero mira todas a la vez y encuentra filas que ninguna columna por separado delata.

Qué buscar

- **Puntos aislados muy lejos del resto:** candidatos a error de captura.
- **Grupos de atípicos juntos en el eje horizontal:** no son ruido, es un tramo del archivo distinto —otro año, otro instrumento, otro criterio de medición.
- **Muchos atípicos de un solo lado:** no hay error, hay asimetría. La transformación log suele hacerlos desaparecer sin borrar nada.
- **La diferencia entre criterios:** si z no marca nada y el RIC marca veinte, es porque la media y la desviación ya fueron arrastradas por los extremos.

Cuándo engaña

Atípico no es sinónimo de error. El criterio es geométrico y no sabe nada del fenómeno. Borrar por costumbre es la peor decisión posible: en muchos estudios el atípico es el caso que motivó la investigación.

z se enmascara a sí mismo. La media y la desviación estándar se calculan con los atípicos adentro, así que un valor extremo infla s y termina pareciendo razonable. Con un solo extremo muy grande, ningún punto supera 3 desvíos.

El 1,5 de Tukey es una convención, no un umbral óptimo. Nada se rompe si lo movés; solo cambia cuántos puntos se pintan.

Mahalanobis exige covarianza invertible y datos completos. Con colinealidad exacta o con filas incompletas devuelve vacío, y eso no significa que no haya atípicos.

Parámetros:

Campo	Valor
columna	Presion

```
# f1.calidad.atipicos
x <- datos$Presion
# Ojo: boxplot() corta por bisagras y el panel del lab por cuartiles
# (tipo 7, que es con lo que ggplot2 dibuja la caja). Las cercas pueden
# diferir en décimas; el conteo de atípicos casi nunca cambia.
caja <- boxplot(x, plot = FALSE)
atipicos <- caja$out
ric <- diff(caja$stats[c(2, 4)])
cercas <- c(caja$stats[2] - 1.5 * ric, caja$stats[4] + 1.5 * ric)
cat("Atípicos por el criterio de Tukey:", length(atipicos),
    "de", length(x), "\n")
```

```
## Atípicos por el criterio de Tukey: 1 de 118
```


```
cat("Cercas:", round(cercas, 2), "\n")
```

```
## Cercas: 1009.65 1015.65
```

```
print(atipicos)
```

```
## [1] 1015.7
```

```
boxplot(x, horizontal = TRUE, main = "Presion")
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Atípicos detectados · Punto_de_Rocio

Panel f1.calidad.atipicos · marcado a las 07:25:51

El texto de este panel está en la primera sección «Atípicos detectados».

Parámetros:

Campo	Valor
columna	Punto_de_Rocio


```
# f1.calidad.atipicos
x <- datos$Punto_de_Rocio
# Ojo: boxplot() corta por bisagras y el panel del lab por cuartiles
# (tipo 7, que es con lo que ggplot2 dibuja la caja). Las cercas pueden
# diferir en décimas; el conteo de atípicos casi nunca cambia.
caja <- boxplot(x, plot = FALSE)
atipicos <- caja$out
ric <- diff(caja$stats[c(2, 4)])
cercas <- c(caja$stats[2] - 1.5 * ric, caja$stats[4] + 1.5 * ric)
cat("Atípicos por el criterio de Tukey:", length(atipicos),
    "de", length(x), "\n")

## Atípicos por el criterio de Tukey: 0 de 118
cat("Cercas:", round(cercas, 2), "\n")

## Cercas: 13.35 30.55
print(atipicos)

## numeric(0)
boxplot(x, horizontal = TRUE, main = "Punto_de_Rocio")
```

Punto_de_Rocio



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Diagrama de dispersión · Temperatura vs. Velocidad_del_Viento

Panel `f1.analisis.dispersion` · marcado a las 07:25:51

Para qué sirve

Decidir si dos variables tienen relación, y de qué tipo, antes de resumirla en un coeficiente. Todo lo que venga después —correlación, regresión— da por hecha una forma; acá se comprueba que esa forma existe.

Qué muestra

Cada observación como un punto en el plano de dos variables. Es el gráfico más directo que existe y el que sostiene toda la idea de regresión: si hay relación, se ve acá antes de ajustar nada.

El subtítulo trae dos números que conviene leer juntos:

`r` = correlación de Pearson → mide relación LINEAL
`rho` = correlación de Spearman → mide relación MONÓTONA

Cuando $|\text{rho}|$ es bastante mayor que $|\text{r}|$, hay relación y no es una recta.

Qué buscar

- **Forma:** recta, curva, abanico, nube sin estructura.
- **Dirección y fuerza:** cuánto se aprieta la nube alrededor de su tendencia.
- **Heterocedasticidad:** si la dispersión vertical crece con x , el abanico está avisando que la varianza no es constante.
- **Grupos:** dos nubes separadas piden colorear por una tercera variable.
- **Puntos con influencia:** los que están lejos en x mueven una recta ajustada mucho más que los que están lejos en y .

Cuándo engaña

El sobreploteo miente por saturación. Con muchos puntos, la mancha negra oculta dónde está la masa: cualquier zona llena se ve igual de negra que una diez veces más densa. Las tres curas están en el panel: bajar la transparencia, agregar jitter cuando los valores están redondeados, o pasar a conteo por celda, que ya no dibuja puntos sino cuánta gente hay en cada casilla.

$r = 0$ no significa “sin relación”. Significa “sin relación lineal”. Una parábola perfecta da r cercano a cero. Mirá la nube, no el número.


Correlación no es causa, y encima puede ser de un tercero. Dos variables pueden moverse juntas porque una tercera las mueve a las dos. Colorear por esa tercera suele deshacer el espejismo en un segundo.

El muestreo cambia el dibujo, no la cuenta. Si el badge de muestreo está activo, los puntos son una muestra con semilla; r y ρ se calcularon sobre el total.

Parámetros:

	Campo	Valor
x	Temperatura	
y	Velocidad_del_Viento	
marginales	TRUE	

```
# f1.analisis.dispersion
grafico <- ggplot(datos, aes(x = Temperatura, y = Velocidad_del_Viento)) +
  geom_point(alpha = 0.6) +
  labs(x = "Temperatura", y = "Velocidad_del_Viento")
ggExtra::ggMarginal(grafico, type = "histogram", fill = "grey70",
  color = "white")
```



```

cat("Covarianza:", cov(datos$Temperatura, datos$Velocidad_del_Viento, use = "complete.obs"), "\n")

## Covarianza: 0.04718528
cat("Pearson:   ", cor(datos$Temperatura, datos$Velocidad_del_Viento, use = "complete.obs"), "\n")

## Pearson:    0.02627245
cat("Spearman:  ", cor(datos$Temperatura, datos$Velocidad_del_Viento, use = "complete.obs",
  method = "spearman"), "\n")

## Spearman:   -0.01089905
print(cor.test(datos$Temperatura, datos$Velocidad_del_Viento))

##
## Pearson's product-moment correlation
##
## data:  datos$Temperatura and datos$Velocidad_del_Viento
## t = 0.28306, df = 116, p-value = 0.7776
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.1552241  0.2060533
## sample estimates:
##           cor
## 0.02627245

```

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Histograma · Temperatura

Panel f1.analisis.histograma · marcado a las 07:25:51

Para qué sirve

Formarse la primera idea de una variable antes de decidir cualquier otra cosa sobre ella: si transformarla, si partirla por grupos, si desconfiar de cómo se midió. Es la card que se abre primero y la que más veces termina cambiando el plan.

Qué muestra

Cuántas observaciones caen en cada intervalo de la variable. La altura de cada barra es una frecuencia; el ancho, un tramo del recorrido.

Es el primer retrato de una variable continua y el antecedente directo de la idea de **densidad**: si en vez de contar dividís por el total y por el ancho del intervalo, el área total pasa a valer 1 y ya estás mirando una densidad empírica.

Qué buscar

- **Centro**: ¿dónde está el grueso de los datos? ¿Coincide con la media?
- **Dispersión**: ¿ancho o angosto respecto al recorrido posible?
- **Forma**: ¿simétrico o con cola a un lado? Una cola derecha larga es la firma de variables que no pueden ser negativas (ingresos, tiempos, conteos), y suele pedir una transformación logarítmica.
- **Modas**: ¿un pico o varios? Dos picos casi siempre significan que hay dos poblaciones mezcladas, y ese es un hallazgo, no un defecto.

- **Huecos y paredes:** un vacío en medio, o un corte abrupto en un valor redondo, suelen delatar cómo se recogió el dato, no cómo se comporta.

Cuándo engaña

El número de clases cambia la historia. Es la trampa central de este gráfico y por eso el control está a la vista. Con pocas barras todo parece una campana suave; con muchas, todo parece ruido dentado. Ninguna de las dos versiones es “la verdadera”: son la misma tabla de datos leída con distinta resolución.

Movelo. Si una moda secundaria aparece y desaparece según el número de clases, no confíes en ella todavía — comparala con la densidad kernel, que suaviza sin depender de dónde caen los bordes.


El origen de los intervalos también importa. Dos histogramas con el mismo ancho de clase pero desplazados medio intervalo pueden verse distintos. La densidad kernel no tiene ese problema, porque no tiene bordes.

Con pocos datos no dice casi nada. Por debajo de unas 30 observaciones, la forma es principalmente azar. Ahí conviene un diagrama de puntos o el de tallo y hojas, que no esconden ninguna observación.

Parámetros:

	Campo	Valor
variable		Temperatura
densidad		TRUE

```
# f1.analisis.histograma
ggplot(datos, aes(x = Temperatura)) +
  geom_histogram(aes(y = after_stat(density)),
    bins = 30, fill = "steelblue") +
  geom_density(alpha = 0.4) +
  labs(x = "Temperatura", y = "densidad")
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Q-Q normal de la variable · Temperatura

Panel f1.analisis.qq_normal_datos · marcado a las 07:25:51

Para qué sirve

Comprobar la normalidad de una variable con más resolución que un histograma, sobre todo en las colas. Es donde se distingue si el problema son unos pocos valores extremos o la forma completa, y esa diferencia decide si alcanza con recortar o hay que cambiar de método.

Qué muestra

Los cuantiles observados de la variable contra los que tendría si fuera normal. Cada punto es una observación: en el eje horizontal, el valor que le tocaría bajo una normal; en el vertical, el que de verdad tiene.

Si la variable es normal, los puntos caen sobre la recta de referencia, que pasa por el primer y el tercer cuartil. Los desvíos se leen por su forma, no por su tamaño.

Qué buscar

- **S acostada:** asimetría. Si los puntos se despegan hacia arriba en la derecha, hay cola derecha larga.
- **Extremos que se van hacia afuera en los dos lados:** colas pesadas, más masa lejos del centro de la que una normal admite.
- **Extremos que se aplanan:** colas livianas, distribución más corta que la normal.
- **Escalones horizontales:** la variable está discretizada o redondeada.
- **Uno o dos puntos muy lejos de la recta al final:** atípicos, no forma.

Cuándo engaña

La prueba y el gráfico se contradicen a propósito, y el gráfico tiene razón más veces. Con n grande, Shapiro-Wilk rechaza la normalidad por desvíos minúsculos que no afectan a ningún método; con n chico, no rechaza nada porque no tiene potencia. El subtítulo trae la prueba y el p , pero la decisión se toma mirando la nube.

Casi ningún método pide que los DATOS sean normales. La regresión pide normalidad de los *residuos*, no de las variables. Este Q-Q sirve para conocer la forma de la variable y decidir una transformación, no para aprobar o reprobar un modelo que todavía no existe.


Con $n < 20$ la nube es tan errática que casi nada se puede concluir. Se espera ver zigzag; no lo leas como estructura.

Parámetros:

Campo	Valor
variable	Temperatura

```
# f1.analisis.qq_normal_datos
x <- datos$Temperatura
qqnorm(x, main = "Q-Q normal · Temperatura")
qqline(x, col = "firebrick")
```

Q-Q normal · Temperatura



```
cat("Shapiro-Wilk:\n"); print(shapiro.test(x))
```

```
## Shapiro-Wilk:
##
## Shapiro-Wilk normality test
##
## data: x
```

W = 0.85961, p-value = 3.403e-09

Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Histograma · Presion


Panel f1.analisis.histograma · marcado a las 07:25:51

El texto de este panel está en la primera sección «Histograma».

Parámetros:

Campo	Valor
variable	Presion
densidad	TRUE

```
# f1.analisis.histograma
ggplot(datos, aes(x = Presion)) +
  geom_histogram(aes(y = after_stat(density)),
                bins = 30, fill = "steelblue") +
  geom_density(alpha = 0.4) +
  labs(x = "Presion", y = "densidad")
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

Densidad kernel · Velocidad_del_Viento

Panel `f1.analisis.densidad` · marcado a las 07:25:51

Para qué sirve

Ver la forma de una variable sin la arbitrariedad del número de clases. Es la que conviene para juzgar si una transformación hizo falta y si funcionó, porque el cambio de forma se lee sin depender de dónde cayeron los bordes.

Qué muestra

Una curva suave que estima la densidad de probabilidad de la variable. En vez de contar por intervalos, pone una campanita —el **núcleo**— sobre cada observación y las suma todas.

El parámetro que manda es el ancho de banda **h**, no el número de clases:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

El área bajo la curva vale 1, así que la altura no es una cuenta de casos: es densidad. Comparar dos densidades de muestras de tamaño distinto es legítimo; comparar dos histogramas de conteos, no.

Qué buscar

- **Modas:** los picos son la razón de ser de este gráfico. Dos modas separadas y estables al mover **h** son dos poblaciones mezcladas.
- **Asimetría:** la cola más larga dice hacia dónde se estira la variable.
- **Colas:** qué tan rápido cae la curva en los extremos, comparado con la campana que uno esperaría si fuera normal.
- **El valor de h:** aparece en el subtítulo. Por defecto sale de la regla de Silverman, $h = 0.9 \cdot \min(s, \text{RIC}/1.34) \cdot n^{(1/5)}$, que es un punto de partida razonable y nada más.

Cuándo engaña

h chico inventa modas; h grande las borra. Es el mismo dilema del número de clases del histograma, con otro nombre: sesgo contra varianza. Movele y fijate cuáles picos sobreviven. Los que aparecen y desaparecen no son estructura, son ruido suavizado con distinta fuerza.

Suaviza más allá del recorrido real. El núcleo gaussiano tiene colas infinitas, así que la curva pone densidad en valores imposibles: edades negativas, porcentajes por encima de 100. Si la variable está acotada, la parte que se derrama por el borde es un artefacto del método.


Con pocos datos es casi solo el núcleo. Con $n = 10$ estás mirando la forma de la campanita que elegiste, no la de la variable.

Parámetros:

	Campo	Valor
variable		Velocidad_del_Viento
normal		TRUE

```
# f1.analisis.densidad
ggplot(datos, aes(x = Velocidad_del_Viento)) +
  geom_density() +
```

```
stat_function(fun = dnorm, args = list(mean = mean(datos$Velocidad_del_Viento, na.rm = TRUE), sd = sd
labs(x = "Valor", y = "densidad")
```



Interpretá acá qué muestra el gráfico y qué conclusión sacás. Una figura sin lectura no es un resultado: es un adorno.

14 paneles · dataset ori · generado en modo servidor.