

UNIVERSIDAD DEL ROSARIO

Escuela de Ingeniería, Ciencia y Tecnología

Maestría en Matemáticas Aplicadas y Ciencias de la Computación

Taller 2 — Componentes principales y agrupamiento de países (EIA)

Análisis Estadístico de Datos

Integrantes

Anyelo Leonardy Alvarez Baquero
Daniel Arias Mutis
Tania Fernanda Mora Cubillos
Over Haider Castrillón Valencia

Profesor

Andrés Nicolás López López

Bogotá D.C., 7 de octubre de 2026

Resumen

Se estudian 111 países descritos por 57 variables de petróleo y electricidad de la U.S. Energy Information Administration (EIA). Primero se eligen cinco variables, una por dimensión y con poca redundancia entre sí (producción de crudo, consumo de petróleo, exportación de crudo, generación eléctrica y generación renovable), se estiman su vector de medias y su matriz de covarianzas y se describen de forma univariada y bivariada, encontrando distribuciones muy asimétricas dominadas por unos pocos países y dos bloques casi independientes, el de la oferta petrolera y el del tamaño energético. Luego se ejecuta un análisis de componentes principales (ACP) normado y otro sin normalizar, se eligen cuatro componentes por el criterio del 80 % de varianza acumulada y se interpretan las variables y los países en los planos (1,2) y (2,3), donde el primer eje resulta ser el tamaño energético del país y los siguientes oponen productores de petróleo a productores de electricidad renovable. Al retirar a Estados Unidos, China, Arabia Saudita y Rusia el primer eje pasa de explicar el 62 % al 49 % y aparecen dos brazos de países que sugieren tres grupos. Finalmente se eligen tres grupos por la reducción de varianza explicada y se comparan k-medias y el agrupamiento jerárquico de enlace promedio, que coinciden en 101 de los 107 países y en separar a India y Japón, pero difieren en cómo tratan a ocho economías grandes, mientras que las cajas por grupo muestran que la partición sigue al consumo, generación eléctrica y no a la producción ni a la exportación de crudo.

Palabras clave: Análisis de componentes principales; Círculo de correlaciones; Criterio de Kaiser; K-medias; Agrupamiento jerárquico; Silueta; EIA

Índice general

Resumen **1**

1. Los datos **3**
1.1. Estructura de las variables . . . 3
1.2. Diagnóstico de la base . . . 4

2. Normal multivariada **7**
2.1. Pregunta 1 — Vector de medias y matriz de covarianzas . . . 7

3. Análisis de componentes principales **13**
3.1. Pregunta 2 — Análisis descriptivo univariado y bivariado . . . 13
3.2. Pregunta 3 — Contribuciones en el ACP normado y sin normalizar . . . 17
3.3. Pregunta 4 — Número de componentes . . . 21
3.4. Pregunta 5 — Representación de las variables . . . 25
3.5. Pregunta 6 — Mapa de individuos . . . 30
3.6. Pregunta 7 — ACP sin los cuatro países atípicos . . . 33

4. Agrupamiento **41**
4.1. Pregunta 8 — Número de grupos en el primer plano . . . 41
4.2. Pregunta 9 — Número de grupos por reducción de varianza explicada . . . 41
4.3. Pregunta 10 — K-medias frente a jerárquico de enlace promedio . . . 44
4.4. Pregunta 11 — Distribución de las cinco variables por grupo . . . 55

Bibliografía **61**

A. Documentación de R **63**

B. Abreviaturas de las variables **65**

Capítulo 1

Los datos

La base `EIA.csv` reúne, para 111 países, 57 variables de producción, consumo, comercio y capacidad instalada de petróleo y electricidad publicadas por la U.S. Energy Information Administration (EIA 2023), donde cada unidad estadística (UE) es un país. Las unidades vienen en el sufijo de cada nombre, es decir, TBPD son miles de barriles por día, MMTCD millones de toneladas métricas de CO_2, BKWH miles de millones de kWh, MK millones de kW y BB miles de millones de barriles. Todo el análisis se realiza en R (R Core Team 2026) con gráficos de `ggplot2` (Wickham 2016), `GGally` (Schloerke et al. 2024) y `factoextra` (Kassambara y Mundt 2020), mientras que la documentación de cada función utilizada se reúne en el Apéndice A.

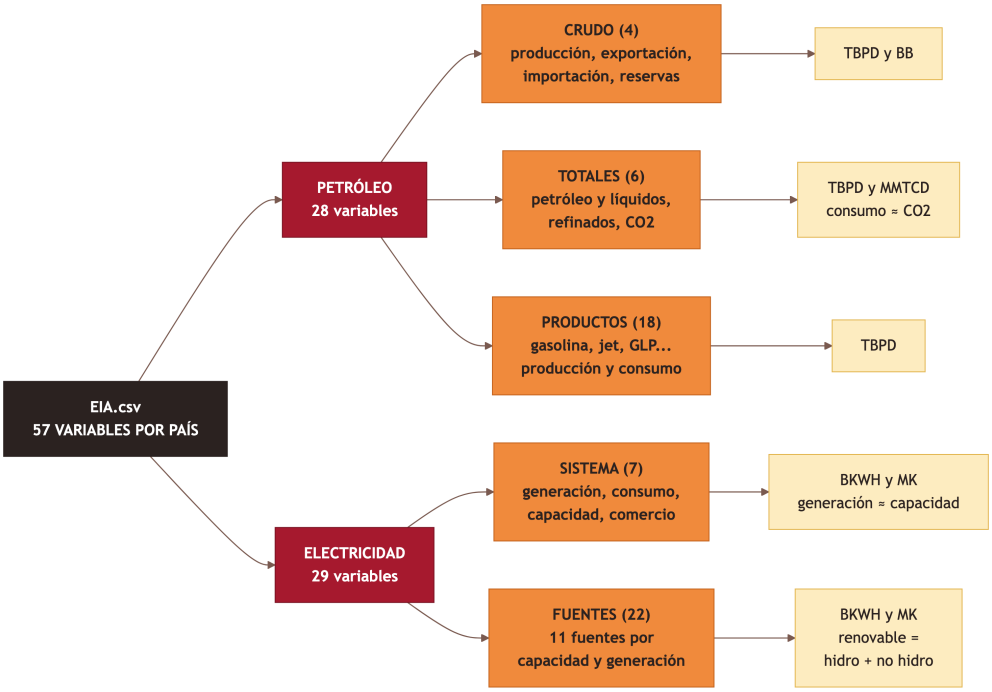
La base se descarga de Kaggle o, en caso de no haber conexión, se busca una copia local.

```
url <- paste0("https://www.kaggle.com/api/v1/datasets/download/",
              "overhcv/eia-united-states")
zip <- file.path(tempdir(), "kaggle.zip")
ruta <- tryCatch({
  download.file(url, zip, mode = "wb", quiet = TRUE)
  unzip(zip, files = "EIA.csv", exdir = tempdir())
}, error = function(e) {
  Filter(file.exists, c("EIA.csv", "data/EIA.csv",
                        "../../../data/EIA.csv"))[1]
})
datos <- read.csv(ruta, sep = ";", dec = ".",
                  stringsAsFactors = FALSE)
```

1.1. Estructura de las variables

Los nombres originales llegan a tener 60 caracteres, por lo que se reemplazan por abreviaturas con la función `abreviar()` del archivo `R/abreviaturas.R`, que se carga al inicio y cuyo código y tabla de equivalencias decidimos mover al Apéndice B al ser tan extensa la tabla. Por ejemplo `PetLiq_cons` es el consumo de petróleo y otros líquidos y `Renov_gen` la generación neta de electricidad renovable. Antes de calcular nada vale la pena ver cómo están organizadas las 57 variables pues no son 57 mediciones independientes sino un árbol en el que cada total se

vuelve a medir en sus partes.



Estructura de las 57 variables por sector energético, bloque y unidad: Cada total se repite en sus partes y cada fuente eléctrica se mide dos veces, por lo que la base es redundante desde su diseño.

El petróleo se describe en tres niveles (el crudo que se extrae y se comercia, los totales de petróleo, refinados y emisiones, y los productos uno por uno), mientras que la electricidad se describe como sistema (generación, consumo, capacidad, comercio y pérdidas) y por fuente, con cada una de las 11 fuentes medida en capacidad instalada y en generación.

1.2. Diagnóstico de la base

La matriz `num` guarda las 57 variables numéricas con el país como nombre de fila y sobre ella se cuentan los faltantes y las variables casi repetidas.

```r
num <- numericas(datos)
r <- cor(num)
knitr::kable(data.frame(nrow(num), ncol(num), sum(is.na(num)),
                        anyDuplicated(names(num)),
                        sum(r[upper.tri(r)] > 0.99),
                        sum(duplicated(as.list(num)))),
             col.names = c("Países", "Variables", "Faltantes",
                           "Nombres repetidos", "Pares r > 0.99",
                           "Columnas repetidas"),
             caption = "Diagnóstico de la base.")
```

Cuadro 1.1: Diagnóstico de la base.

Países	Variables	Faltantes	Nombres repetidos	Pares r > 0.99	Columnas repetidas
111	57	0	0	18	1

```r
pares <- which(upper.tri(r) & r > 0.99, arr.ind = TRUE)
cat(strwrap(paste(names(num)[pares[, 1]], names(num)[pares[, 2]],
                  sep = "~", collapse = ", "), 64), sep = "\n")
```

```
Gasolina_cons~Gasolina_prod, PetLiq_CO2~PetLiq_cons,
PetLiq_CO2~Refinados_cons, PetLiq_cons~Refinados_cons,
Gasolina_prod~GananciaRef, Elec_cap~Elec_cons,
Elec_cap~Elec_gen, Elec_cons~Elec_gen, Elec_cap~Fosil_cap,
Elec_cons~Fosil_cap, Elec_gen~Fosil_cap, Elec_cons~Fosil_gen,
Elec_gen~Fosil_gen, Fosil_cap~Fosil_gen,
Geotermica_cap~Geotermica_gen, Hidro_cap~Hidro_gen,
Nuclear_cap~Nuclear_gen, Renov_cap~Renov_gen
```

```r
names(num)[duplicated(
  as.list(num))]
```

```
[1] "Refinados_cons"
```

```r
max(abs(num$Renov_gen -
  num$Hidro_gen -
  num$NoHidro_gen))
```

```
[1] 1
```

¿Está lista la base para el análisis? Sí pues no hay datos faltantes y las 57 abreviaturas son distintas entre sí, aunque la base es muy redundante y esto hay que tenerlo presente desde ya:

a. **Lectura local.** La columna repetida, `Refinados_cons`, es el consumo de productos refinados, que resulta idéntico al consumo de petróleo y otros líquidos, mientras que la generación renovable coincide con la suma de la hidroeléctrica y la no hidroeléctrica salvo por una unidad de redondeo. Es decir que hay variables que no aportan nada que no esté ya en otra.

b. **Lectura global.** Los 18 pares con correlación mayor a 0.99 no son casualidad sino consecuencia del árbol de la figura anterior ya que cinco son la capacidad y la generación de una misma fuente (fósil, hidro, nuclear, geotérmica y renovable), ocho son el sistema eléctrico consigo mismo y con su parte fósil, tres son el consumo de petróleo, el de refinados y las emisiones entre sí, y dos son la producción de gasolina con su consumo y con la ganancia de refinación. Esto pesa en el ACP porque cada copia de una misma información suma varianza al mismo eje y en el agrupamiento porque las distancias entre países cuentan varias veces lo mismo.

Capítulo 2

Normal multivariada

2.1. Pregunta 1 — Vector de medias y matriz de covarianzas

¿Qué cinco variables y por qué? Se eligió una variable por cada dimensión de la base, buscando que entre ellas hubiera poca redundancia, ya que dos variables casi iguales describen dos veces lo mismo y no dicen nada nuevo de los países:

a. **Oferta petrolera.** Se mide con la producción de crudo (`Crudo_prod`, TBPD), que indica cuánto petróleo extrae el país.
b. **Demanda petrolera.** Se mide con el consumo de petróleo y otros líquidos (`PetLiq_cons`, TBPD), que refleja el tamaño de la economía que lo usa.
c. **Comercio petrolero.** Se mide con la exportación de crudo (`Crudo_exp`, TBPD), que distingue al país que vende su petróleo del que lo consume.
d. **Escala eléctrica.** Se mide con la generación neta de electricidad (`Elec_gen`, BKWH), que es el tamaño del sistema eléctrico.
e. **Transición energética.** Se mide con la generación neta renovable (`Renov_gen`, BKWH), que indica cuánto de esa electricidad viene de fuentes renovables.

Intentamos respaldar las elecciones con la matriz de correlación de las candidatas, que incluye las emisiones de CO_2 por petróleo (`PetLiq_CO2`), la variable que a primera vista representaría la dimensión ambiental.

```r
candidatas <- c("Crudo_prod", "PetLiq_cons", "PetLiq_CO2",
                "Crudo_exp", "Elec_gen", "Renov_gen")
knitr::kable(round(cor(num[candidatas]), 2),
             caption = "Correlación de Pearson de las candidatas.")
```

Cuadro 2.1: Correlación de Pearson de las candidatas.

	Crudo_prod	PetLiq_cons	PetLiq_CO2	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	1.00	0.64	0.64	0.83	0.52	0.44
PetLiq_cons	0.64	1.00	1.00	0.17	0.92	0.77
PetLiq_CO2	0.64	1.00	1.00	0.17	0.92	0.77
Crudo_exp	0.83	0.17	0.17	1.00	0.07	0.06
Elec_gen	0.52	0.92	0.92	0.07	1.00	0.92
Renov_gen	0.44	0.77	0.77	0.06	0.92	1.00

Las emisiones de CO_2 se descartan porque tienen correlación de 1.00 con el consumo, lo cual indica que se derivan del petróleo consumido y que incluirlas sería contar dos veces la demanda. En su lugar entra la exportación de crudo, que casi no se asocia con el bloque de tamaño (0.17 con el consumo, 0.07 con la generación y 0.06 con la renovable) y sí con la producción (0.83), aunque sin repetirla pues como se ve en la Pregunta 2 hay países que producen sin exportar. Las otras tres variables tienen entre sí correlaciones altas (de 0.77 a 0.92) pero describen cosas distintas ya que el consumo de petróleo es demanda de combustibles y la generación es electricidad, mientras que la renovable es solo una parte de esa electricidad cuyo peso cambia mucho de un país a otro.

Sobre las $n = 111$ filas se estiman el vector de medias y la matriz de varianzas y covarianzas muestrales

$$\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i, \qquad S = \frac{1}{n-1}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^{\top},$$

que son los estimadores insesgados de μ y Σ en el modelo normal multivariado explicado en clase (el de máxima verosimilitud de Σ que se divide por n en vez de $n-1$).

```r
cinco <- c("Crudo_prod", "PetLiq_cons", "Crudo_exp", "Elec_gen",
           "Renov_gen")
X <- num[cinco]
knitr::kable(data.frame(Variable = cinco,
                        Unidad = c("TBPD", "TBPD", "TBPD", "BKWH",
                                   "BKWH"),
                        Media = round(colMeans(X), 2),
                        Mediana = sapply(X, median),
                        row.names = NULL),
             caption = "Vector de medias (y mediana).")
```

Cuadro 2.2: Vector de medias (y mediana).

Variable	Unidad	Media	Mediana
Crudo_prod	TBPD	702.06	38.0
PetLiq_cons	TBPD	811.40	202.0
Crudo_exp	TBPD	361.56	8.5
Elec_gen	BKWH	198.29	43.0
Renov_gen	BKWH	44.77	8.3

```r
knitr::kable(round(cov(X), 1),
             caption = "Matriz de varianzas y covarianzas S.")
```

Cuadro 2.3: Matriz de varianzas y covarianzas S.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	3032022.8	2471112.6	1374119.6	594768.9	110047.2
PetLiq_cons	2471112.6	4858882.6	358231.7	1332865.6	245051.1
Crudo_exp	1374119.6	358231.7	907732.0	41014.9	8667.9
Elec_gen	594768.9	1332865.6	41014.9	434095.0	87623.9
Renov_gen	110047.2	245051.1	8667.9	87623.9	20864.5

Vector de medias. Se estima $\bar{\mathbf{x}} = (702.06,\ 811.40,\ 361.56,\ 198.29,\ 44.77)^\top$, es decir que un país promedio produce 702 mil barriles diarios de crudo, consume 811 mil barriles diarios de petróleo, exporta 362 mil barriles diarios de crudo y genera 198 mil millones de kWh, de los cuales 45 son renovables.

Matriz de covarianzas. Todas las covarianzas son positivas, lo que significa que las cinco variables crecen juntas y que un país que consume más petróleo también tiende a generar más electricidad. Sus magnitudes en cambio no se pueden comparar entre sí puesto que cada entrada lleva el producto de las unidades de sus dos variables (por ejemplo, la varianza del consumo está en TBPD² y su covarianza con la generación en TBPD·BKWH), por lo que la fuerza de cada asociación se lee en la Pregunta 2 con la correlación.

a. **Lectura local.** Como tal el país promedio no existe pues la media de la exportación de crudo (361.56 TBPD) es 42 veces su mediana (8.5 TBPD) y la de la producción (702.06 TBPD) más de 18 veces la suya (38 TBPD), de modo que cada componente de $\bar{\mathbf{x}}$ la fijan unos pocos países y no el país típico.
b. **Lectura global.** Bajo normalidad multivariada $\bar{\mathbf{x}}$ y S resumirían toda la distribución, pero estos datos están lejos de ser normales y S mezcla dos bloques, el petrolero (producción y exportación) y el de tamaño (consumo, generación y renovable), que casi no se mueven juntos. Esto puede anticiparnos que una sola dirección no baste para describir a los países y que el ACP necesite al menos dos ejes.

Para ver cuánto de las correlaciones de las candidatas se debe al tamaño se construyen dos razones internas a la base que no dependen de lo grande que sea el país, la participación renovable en la generación (`Renov_gen / Elec_gen`) y la autosuficiencia petrolera (`Crudo_prod / PetLiq_cons`), cuyos denominadores no valen cero en ningún país, para compararlas con la correlación de las mismas variables en términos absolutos.

```
stopifnot(all(num$Elec_gen > 0), all(num$PetLiq_cons > 0))
renovable <- num$Renov_gen / num$Elec_gen
autosuficiencia <- num$Crudo_prod / num$PetLiq_cons
knitr::kable(data.frame(
  par = c("Renovable y generación", "Producción y consumo",
          "Renovable y producción"),
  absolutas = c(cor(num$Renov_gen, num$Elec_gen),
                cor(num$Crudo_prod, num$PetLiq_cons),
                cor(num$Renov_gen, num$Crudo_prod)),
  con_razon = c(cor(renovable, num$Elec_gen),
                cor(autosuficiencia, num$PetLiq_cons),
                cor(renovable, autosuficiencia))),
  digits = 2,
  caption = "Correlación en términos absolutos y con razones.")
```

Cuadro 2.4: Correlación en términos absolutos y con razones.

par	absolutas	con_razon
Renovable y generación	0.92	-0.10
Producción y consumo	0.64	-0.07
Renovable y producción	0.44	-0.06

Del mismo modo se divide el CO_2 entre el consumo de petróleo para ver si las emisiones se miden por separado o se calculan a partir del consumo.

```r
co2 <- num$PetLiq_CO2 / num$PetLiq_cons
knitr::kable(data.frame(
  r = cor(num$PetLiq_CO2, num$PetLiq_cons),
  minimo = min(co2), mediana = median(co2), maximo = max(co2),
  cv = sd(co2) / mean(co2),
  t_por_barril = median(co2) * 1e6 / 365e3),
  digits = 3,
  caption = "Emisiones de CO2 por unidad de petróleo consumido.")
```

Cuadro 2.5: Emisiones de CO2 por unidad de petróleo consumido.

r	minimo	mediana	maximo	cv	t_por_barril
0.999	0.095	0.137	0.16	0.088	0.374

Notas

Interpretaciones.

a. **La elección es del grupo.** Con las cinco variables se cubren la oferta, la demanda y el comercio de petróleo, la escala eléctrica y la transición, y la única redundancia evidente (consumo y CO_2, $r = 1.00$) quedó por fuera.
b. **El costo de la elección.** La producción y la exportación de crudo comparten el 69 % de su variación (0.83^2) así que el bloque petrolero pesa doble en las preguntas 2 y 11, del mismo modo que el de tamaño pesa triple.

Decisiones.

- **Se mantienen las variables en términos absolutos.** El enunciado pide caracterizar a los países «en términos de importación, exportación, consumo, producción» y la base no trae población, de modo que pasar a valores por habitante exigiría traer datos de otra fuente. Las razones sí muestran cuánto de la correlación es tamaño pues la renovable y la generación pasan de 0.92 a −0.10 cuando la renovable se toma como participación, la producción y el consumo de 0.64 a −0.07 cuando la producción se divide por el consumo y la renovable y la producción de 0.44 a −0.06 cuando se comparan las dos razones, es decir que casi toda la asociación entre las variables absolutas la pone el tamaño del país y que, una vez descontado, el perfil renovable y el petrolero son casi independientes. Por esto el primer eje del ACP puede resultar más tamaño que perfil energético, lo que conviene tener presente desde ya.

  Respaldo. En la sesión 5 se advirtió que el agrupamiento queda limitado a las variables que se tienen, de modo que lo que no se mide (como la población) no lo recoge ningún método, mientras que en la sesión 2 se vio que las variables de razón admiten cocientes entre sí, que es lo que permite construir participaciones sin salir de la base.

- **La dimensión ambiental queda implícita en el consumo.** La correlación entre el CO_2 y el consumo de petróleo es 0.999 y el cociente entre ambos casi no cambia de un país

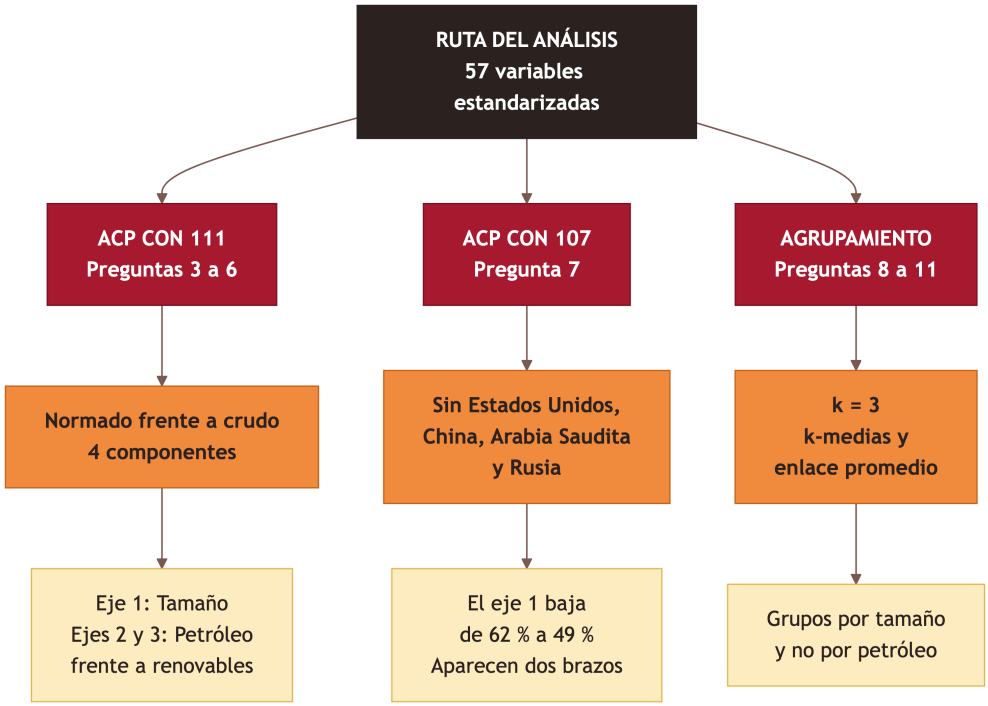
a otro (de 0.095 a 0.16 con mediana 0.137 y coeficiente de variación de 0.088), lo cual indica que las emisiones no se miden por separado sino que se calculan multiplicando el consumo por un factor de emisión que solo varía con la mezcla de productos de cada país. Si la cifra es anual la mediana equivale a 0.374 toneladas de CO_2 por barril, del orden de lo que emite un barril de combustible al quemarse. Por esto incluir el CO_2 sería repetir la demanda en otra unidad y no agregar una dimensión nueva.

Respaldo. La EIA calcula las emisiones de CO_2 del petróleo aplicando coeficientes de emisión al consumo de cada producto y sumándolas (EIA 2026), es decir que no las mide.

Capítulo 3

Análisis de componentes principales

Las preguntas 2 a 11 siguen la ruta del diagrama, consideramos que conviene tenerlo a la mano porque el número de países y lo que se busca cambian por el camino. Primero se describen las cinco variables (Pregunta 2) y luego se resume la base completa con el ACP, primero con los 111 países y después sin los cuatro más extremos, para terminar agrupando a los 107 restantes.



Ruta del análisis de las preguntas 3 a 11: Cada etapa cambia los países o la pregunta, y las conclusiones de una justifican la siguiente.

3.1. Pregunta 2 — Análisis descriptivo univariado y bivariado

```r
resumen <- t(sapply(X, function(x)
  c(media = mean(x), mediana = median(x), s = sd(x), min = min(x),
    max = max(x), g1 = g1(x), ceros = sum(x == 0))))
knitr::kable(round(resumen, 2),
             caption = "Resumen univariado de las cinco variables.")
```

Cuadro 3.1: Resumen univariado de las cinco variables.

	media	mediana	s	min	max	g1	ceros
Crudo_prod	702.06	38.0	1741.27	0.0	10107	3.91	27
PetLiq_cons	811.40	202.0	2204.29	15.0	19100	6.32	0
Crudo_exp	361.56	8.5	952.75	0.0	7120	4.48	41
Elec_gen	198.29	43.0	658.86	0.9	5400	6.46	0
Renov_gen	44.77	8.3	144.45	0.0	1287	6.56	11

```r
knitr::kable(sapply(X, function(x) rownames(X)[order(-x)][1:3]),
             caption = "Los tres países con el valor más alto.")
```

Cuadro 3.2: Los tres países con el valor más alto.

Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Russia	UnitedStates	SaudiArabia	China	China
SaudiArabia	China	Russia	UnitedStates	UnitedStates
UnitedStates	Japan	UnitedArabEmirates	India	Brazil

```r
sum(X$Crudo_prod > 0 &
    X$Crudo_exp == 0)
```

```
[1] 16
```

```r
rownames(X)[X$Crudo_exp > 0 &
  X$Crudo_prod == 0]
```

```
[1] "Senegal"   "Singapore"
```

```
ggpairs(X, upper = list(continuous = wrap("cor", size = 3)),
        lower = list(continuous = wrap("points", size = 0.6,
                                       alpha = 0.5))) +
  theme_minimal(base_size = 8)
```

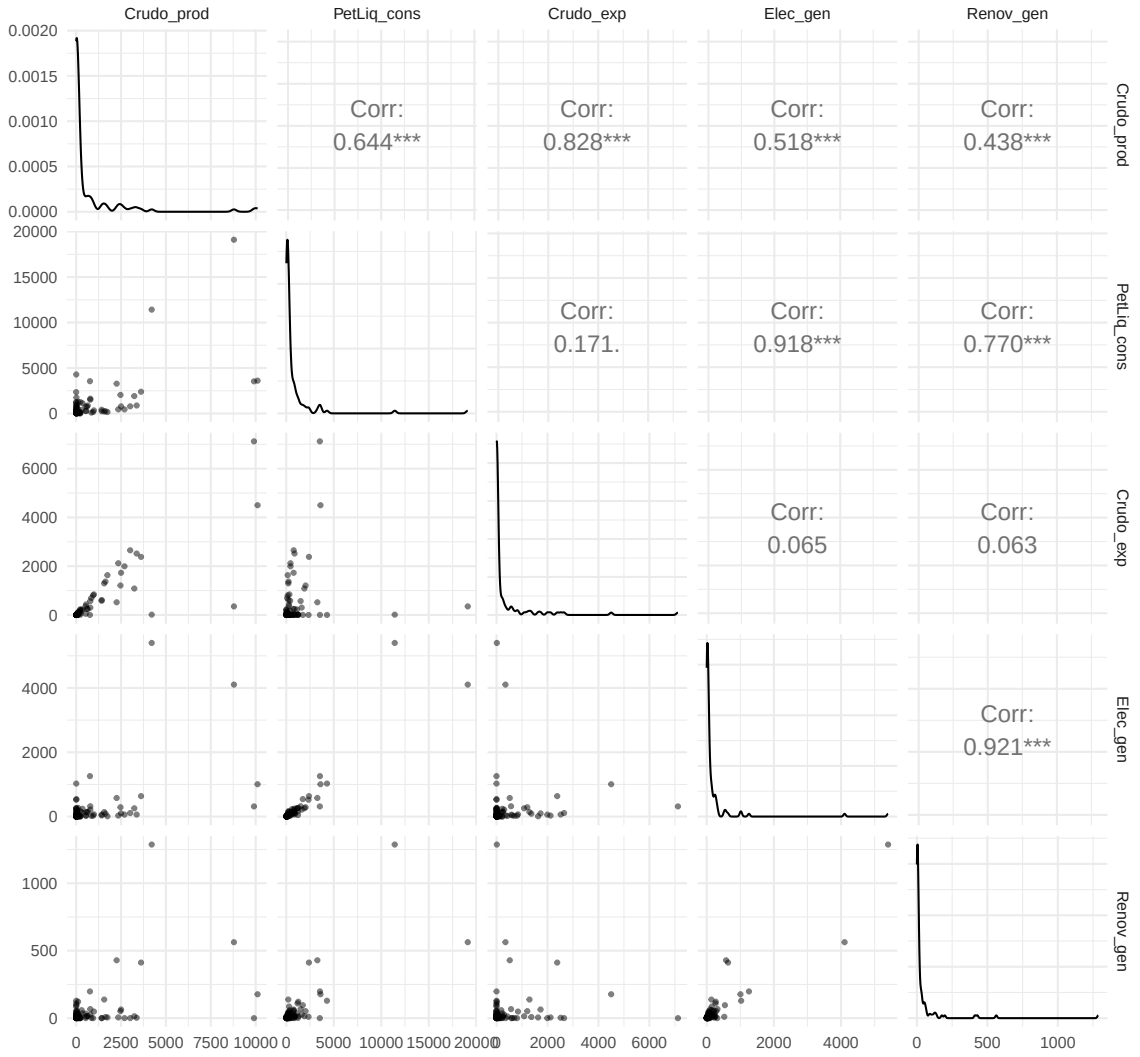


Figura 3.1: Matriz de dispersión de las cinco variables con densidades en la diagonal y correlación de Pearson arriba: Casi toda la nube está pegada al origen, unos pocos países definen las correlaciones y la exportación de crudo solo se asocia con la producción.

```
knitr::kable(round(cor(X, method = "spearman"), 2),
             caption = "Correlación de Spearman.")
```

Cuadro 3.3: Correlación de Spearman.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	1.00	0.48	0.89	0.42	0.14
PetLiq_cons	0.48	1.00	0.39	0.92	0.57
Crudo_exp	0.89	0.39	1.00	0.28	0.01
Elec_gen	0.42	0.92	0.28	1.00	0.67
Renov_gen	0.14	0.57	0.01	0.67	1.00

```
sin <- X[rownames(X) != "China", ]
round(cor(sin$Elec_gen,
  sin$Renov_gen), 3)
```

```
[1] 0.803
```

Univariado. Las cinco variables tienen asimetría positiva extrema, con coeficientes g_1 entre 3.91 (producción de crudo) y 6.56 (generación renovable), así como medias muy por encima de sus medianas, por ejemplo 811.40 contra 202 TBPD en el consumo de petróleo y 361.56 contra 8.5 TBPD en la exportación de crudo. Las densidades de la diagonal lo muestran como un pico pegado al cero con una cola larga a la derecha formada por los países más grandes ya que Estados Unidos y China ocupan los primeros puestos en consumo y generación, mientras que Rusia, Arabia Saudita y Estados Unidos encabezan la producción de crudo y Arabia Saudita, Rusia y Emiratos Árabes Unidos la exportación. Además la producción vale cero en 27 países y la exportación en 41, de modo que 16 países producen crudo sin exportarlo y dos (Senegal y Singapur) lo exportan sin producirlo, lo cual podría deberse a reexportaciones que la base no permite verificar.

Bivariado. Las asociaciones son todas positivas pero se ordenan en dos bloques:

a. **Bloque petrolero.** La producción y la exportación de crudo tienen correlación de Pearson (Pearson 1895) de 0.828 ya que solo exporta crudo quien lo produce, aunque no todo productor lo exporta.
b. **Bloque de tamaño.** El consumo de petróleo y la generación eléctrica se asocian con $r = 0.918$ y la generación con la renovable con $r = 0.921$, es decir que estas tres siguen al tamaño de la economía.
c. **Entre bloques.** La exportación casi no se asocia con el bloque de tamaño (0.171 con el consumo, 0.065 con la generación y 0.063 con la renovable), dado que los tres mayores consumidores (Estados Unidos, China y Japón) exportan poco o nada, mientras que la producción de crudo hace de puente entre ambos bloques (0.644 con el consumo y 0.518 con la generación).

Vale la pena matizar que varias de estas correlaciones dependen de los países extremos pues la de Spearman (Spearman 1904), que usa rangos y no se deja arrastrar por los valores grandes, baja de 0.921 a 0.672 entre generación y renovable, de 0.770 a 0.569 entre consumo y renovable y

de 0.438 a 0.140 entre producción de crudo y renovable. Solo el par consumo-generación (0.918) y el par producción-exportación (de 0.828 a 0.891) se mantienen con ambos coeficientes.

a. **Lectura local.** Un solo país mueve una correlación ya que sin China la de Pearson entre generación y renovable baja de 0.921 a 0.803 porque China es a la vez el mayor generador y el mayor productor de renovables.
b. **Lectura global.** Con rangos la separación entre bloques es todavía más clara (0.010 entre exportación y renovable), de modo que las cinco variables viven en al menos dos dimensiones casi independientes, la de tamaño y la petrolera, que podrían ser las que el ACP de la Pregunta 5 encuentre en sus dos primeros ejes con las 57 variables.

3.2. Pregunta 3 — Contribuciones en el ACP normado y sin normalizar

El análisis de componentes principales (ACP) (Pearson 1901; Hotelling 1933) busca combinaciones lineales de las variables, no correlacionadas entre sí, que recojan la mayor varianza posible. Para leerlo se usan tres medidas:

a. **ACP normado.** Es el ACP de las variables estandarizadas ($z_{ij} = (x_{ij} - \bar{x}_j)/s_j$), es decir, el de la matriz de correlación, de modo que cada variable aporta varianza 1 sin importar su unidad. El ACP sin normalizar usa la matriz de covarianzas en las unidades originales.
b. **Valor propio.** El valor propio λ_k es la varianza de la componente k, de modo que $\lambda_k / \sum_j \lambda_j$ es la proporción de varianza que explica. En el ACP normado los 57 valores propios suman 57.
c. **Contribución.** La contribución de la variable j al eje k es $100\, u_{jk}^2$, donde u_{jk} es su carga (su peso en el vector propio) y mide qué porcentaje del eje construye esa variable. La contribución a un plano pondera las de cada eje por su valor propio y se compara contra la referencia uniforme $100/57 = 1.75\,\%$.

```r
acp_normado <- prcomp(num, scale. = TRUE)
acp_crudo <- prcomp(num, scale. = FALSE)
aporte <- function(acp, n = 10) {
  a <- facto_summarize(acp, "var", axes = c(1, 2))
  a <- a[order(-a$contrib), ]
  data.frame(variable = a$name,
             contrib = round(a$contrib, 2))[1:n, ]
}
knitr::kable(cbind(aporte(acp_normado), aporte(acp_crudo)),
             row.names = FALSE,
             col.names = c("ACP normado", "%",
                           "Sin normalizar", "%"),
             caption = "Variables que más aportan al plano 1-2.")
```

Cuadro 3.4: Variables que más aportan al plano 1-2.

ACP normado	%	Sin normalizar	%
PetLiq_cons	2.49	Refinados_prod	18.01
Refinados_cons	2.49	PetLiq_cons	17.31
PetLiq_CO2	2.48	Refinados_cons	17.31
Refinados_prod	2.47	PetLiq_prod	16.58
Destilado_prod	2.45	Crudo_prod	10.79
Destilado_cons	2.44	Crudo_imp	3.57
Elec_cap	2.43	Crudo_exp	3.01
Elec_cons	2.42	Gasolina_prod	2.84
Elec_gen	2.42	Gasolina_cons	2.53
NoHidro_cap	2.42	Destilado_prod	1.36

```r
varianza <- sort(sapply(num, var), decreasing = TRUE)
knitr::kable(data.frame(
  variable = names(varianza)[1:5],
  porcentaje = round(100 * varianza[1:5] / sum(varianza), 1),
  row.names = NULL),
  caption = "Peso en la varianza total sin normalizar.")
```

Cuadro 3.5: Peso en la varianza total sin normalizar.

variable	porcentaje
Refinados_prod	17.7
PetLiq_cons	16.9
Refinados_cons	16.9
PetLiq_prod	16.2
Crudo_prod	10.5

```r
normado <- facto_summarize(
  acp_normado, "var",
  axes = c(1, 2))
sum(normado$contrib > 100 / 57)
```

```
[1] 37
```

```r
fviz_contrib(acp_normado, choice = "var", axes = c(1, 2),
             top = 20) +
  labs(title = NULL)
```

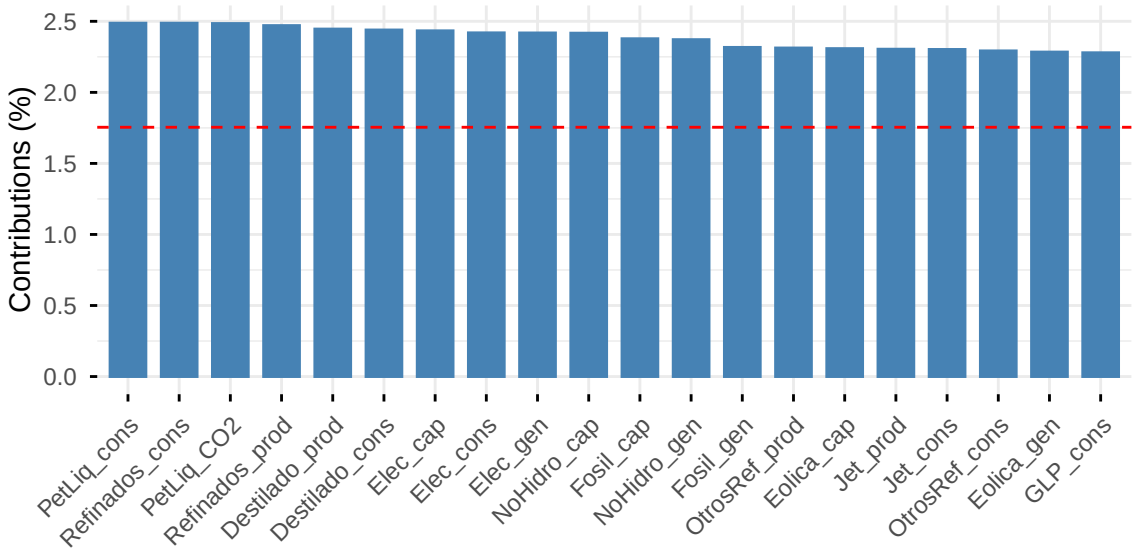


Figura 3.2: Contribución de las 20 primeras variables al plano 1-2 del ACP normado: Todas quedan cerca de la referencia uniforme (línea roja) pues el plano lo construyen muchas variables a la vez.

```
fviz_contrib(acp_crudo, choice = "var", axes = c(1, 2), top = 20) +
  labs(title = NULL)
```

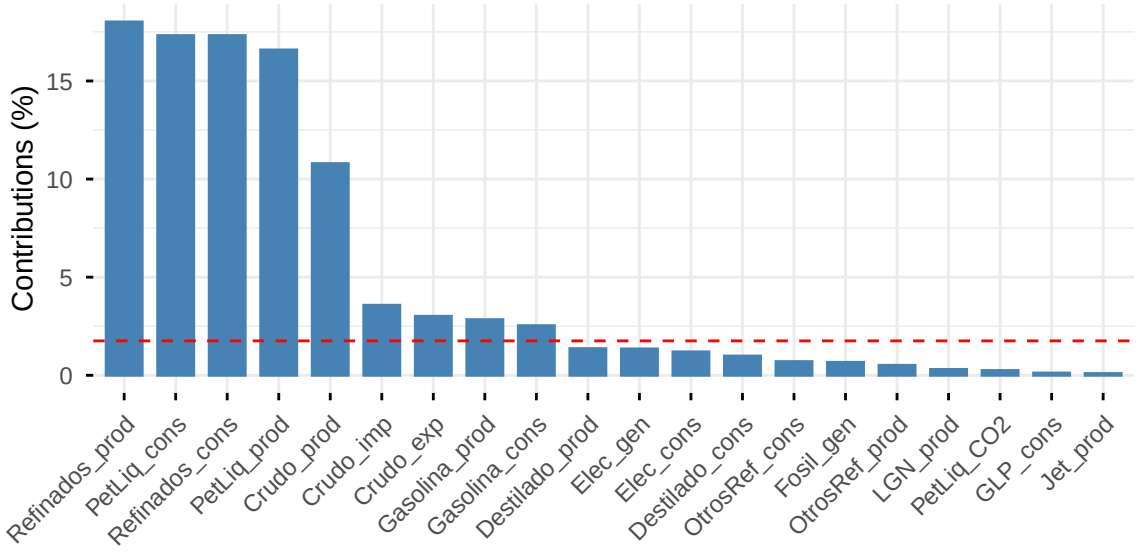
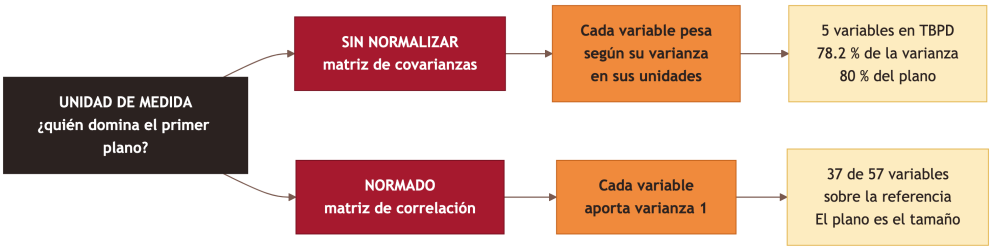


Figura 3.3: Contribución de las 20 primeras variables al plano 1-2 del ACP sin normalizar: Cinco variables medidas en TBPD construyen el 80 % del plano.

¿Cómo cambian las contribuciones al normalizar? Cambian por completo pues en el ACP sin normalizar el plano lo construyen casi solo cinco variables de barriles por día (producción de refinados con 18.01 %, consumo de petróleo y de refinados con 17.31 % cada una, producción de petróleo con 16.58 % y producción de crudo con 10.79 %), que suman el 80 % del plano. Esto sucede porque sin estandarizar cada variable pesa según su varianza, de manera que esas cinco variables concentran por sí solas el 78.2 % de la varianza total (medidas en miles de barriles diarios alcanzan valores de miles), mientras que por ejemplo la generación eléctrica en BKWH tiene una varianza once veces menor que la del consumo de petróleo. Así el primer plano explica un 97.25 % de la varianza (82.92 % el primer eje y 14.34 % el segundo), cifra que no indica una buena síntesis sino que la varianza total está en pocas columnas.

En el ACP normado, en cambio, ninguna variable pasa de 2.49 % y las diez primeras apenas suman 24.5 %, con 37 de las 57 variables por encima de la referencia de 1.75 %. Las que más aportan son de petróleo (consumo, emisiones, refinados y destilados) y de electricidad (capacidad instalada, consumo y generación), lo que significa que el primer plano resume el tamaño energético del país en ambos sectores. Por esto se usa el ACP normado en el resto del taller ya que las variables tienen unidades distintas y no es la unidad de medida la que debe decidir qué variable importa.



Por qué escalar cambia todo: La unidad de una sola columna decide, sin normalizar, quién construye el plano, mientras que normando el plano lo construye la estructura de toda la base.

a. **Lectura local.** El peso de una variable en el ACP sin normalizar lo decide su unidad y no lo que mide pues el consumo de petróleo tiene una varianza once veces mayor que la generación eléctrica solo porque los barriles diarios alcanzan cifras de miles y los BKWH de cientos.
b. **Lectura global.** El ACP sin normalizar no resume la base sino que la ordena por unidades, mientras que el normado muestra que el tamaño energético es una propiedad de toda la base pues lo construyen a la vez 37 de las 57 variables de los dos sectores.

3.3. Pregunta 4 — Número de componentes

El criterio de Kaiser (Kaiser 1960) retiene las componentes con valor propio mayor que 1, es decir, las que explican más varianza que una sola variable original estandarizada. Se compara con el porcentaje acumulado (retener hasta alcanzar el 80 %) y con el codo del gráfico de sedimentación.

```r
autovalores <- acp_normado$sdev^2
proporcion <- autovalores / sum(autovalores)
knitr::kable(data.frame(
  componente = 1:10, autovalor = round(autovalores[1:10], 2),
  porcentaje = round(100 * proporcion[1:10], 2),
  acumulado = round(100 * cumsum(proporcion)[1:10], 2)),
  caption = "Valores propios de las diez primeras componentes.")
```

Cuadro 3.6: Valores propios de las diez primeras componentes.

componente	autovalor	porcentaje	acumulado
1	35.32	61.96	61.96
2	4.41	7.74	69.69
3	4.00	7.01	76.71
4	2.71	4.75	81.46
5	2.45	4.31	85.76
6	1.87	3.28	89.04
7	1.31	2.29	91.33
8	1.12	1.96	93.29
9	0.90	1.58	94.87
10	0.76	1.33	96.20

```r
sum(autovalores > 1)
```

```
[1] 8
```

```r
which(cumsum(proporcion)
      >= 0.8)[1]
```

```
[1] 4
```

```r
fviz_eig(acp_normado, addlabels = TRUE, ncp = 10) +
  scale_y_continuous(limits = c(0, 70)) + labs(title = NULL)
```

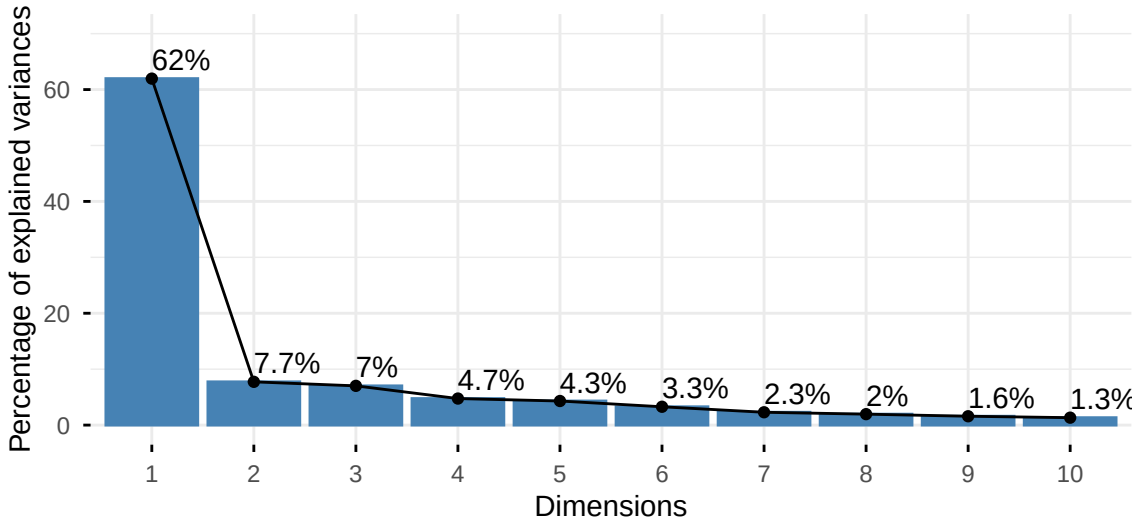


Figura 3.4: Gráfico de sedimentación del ACP normado: El primer eje explica el 62 % y desde el segundo la curva baja despacio.

¿Cuántas componentes se deberían seleccionar? Cuatro, bajo el criterio del porcentaje de varianza acumulada, dado que con ellas se explica el 81.46 % de la variación de las 57 variables (61.96 % la primera, 7.74 % la segunda, 7.01 % la tercera y 4.75 % la cuarta). Los otros dos criterios no sirven bien en este caso:

a. **Codo.** El gráfico de sedimentación se quiebra en la segunda componente, pero quedarse con dos componentes deja por fuera el 30.3 % de la varianza y además la tercera explica casi lo mismo que la segunda (7.01 % frente a 7.74 %), por lo que no hay razón para cortar entre ellas.
b. **Kaiser.** Retiene ocho componentes (93.29 %), lo cual es excesivo porque con 57 variables este criterio tiende a retener de más y las componentes de la quinta a la octava explican entre 1.96 % y 4.31 % cada una.

Retener cuatro es coherente con lo que pide la Pregunta 5, que analiza el plano (2,3) porque la tercera componente todavía carga información relevante.

a. **Lectura local.** La cuarta componente apenas agrega 4.75 % y es la que hace cruzar el umbral del 80 %, de modo que la frontera entre tres y cuatro componentes la marca la regla y no un cambio en la curva.
b. **Lectura global.** El primer valor propio vale 35.32, es decir que una sola componente equivale a 35 de las 57 variables, lo cual es la otra cara de la redundancia del diagnóstico pues las 57 columnas describen en realidad unas pocas dimensiones de los países.

Para ver si la redundancia del diagnóstico mueve los criterios se repite el ACP normado quitando un miembro de cada uno de los 18 pares con correlación mayor a 0.99, dejando siempre las cinco variables de la Pregunta 1.

```r
nombres <- names(num)
copia <- unique(ifelse(nombres[pares[, 2]] %in% cinco,
                       nombres[pares[, 1]], nombres[pares[, 2]]))
cat(strwrap(paste(copia, collapse = ", "), 64), sep = "\n")
```

```
Gasolina_prod, PetLiq_CO2, Refinados_cons, GananciaRef,
Elec_cons, Elec_cap, Fosil_cap, Fosil_gen, Geotermica_gen,
Hidro_gen, Nuclear_gen, Renov_cap
```

```r
sin_copias <- num[setdiff(nombres, copia)]
criterios <- function(x) {
  l <- prcomp(x, scale. = TRUE)$sdev^2
  p <- 100 * l / sum(l)
  rx <- cor(x)
  c(variables = ncol(x), pares = sum(rx[upper.tri(rx)] > 0.99),
    cp1 = p[1], cp2 = p[2], cp3 = p[3],
    acumulado_4 = sum(p[1:4]), regla_80 = which(cumsum(p) >= 80)[1],
    kaiser = sum(l > 1))
}
knitr::kable(data.frame(con_57 = criterios(num),
                        sin_copias = criterios(sin_copias)),
             digits = 2,
             caption = "ACP normado con y sin las copias.")
```

Cuadro 3.7: ACP normado con y sin las copias.

	con_57	sin_copias
variables	57.00	45.00
pares	18.00	0.00
cp1	61.96	57.92
cp2	7.74	9.25
cp3	7.01	6.55
acumulado_4	81.46	78.99
regla_80	4.00	5.00
kaiser	8.00	7.00

Notas

Interpretaciones.

a. **Tres criterios, tres respuestas.** El codo da dos componentes (69.69 %), el 80 % da cuatro (81.46 %) y Kaiser da ocho (93.29 %), de modo que el número no lo decide el dato sino el criterio.

b. **Lo que sí se interpreta.** Las preguntas 5 y 6 encuentran sentido hasta el tercer eje (exportadores frente a importadores de electricidad), lo que respalda quedarse con cuatro y no con dos.

Decisiones.

- **Cuatro componentes por la regla del 80 %.** Es el criterio que el curso toma como referencia y con él cuatro componentes explican el 81.46 %, mientras que el codo deja dos (69.69 %) y Kaiser ocho (93.29 %), de modo que la regla queda entre el criterio gráfico (que deja por fuera el 30.3 % de la varianza) y el más permisivo (que retiene componentes de entre 1.96 % y 4.31 % cada una). A esto se suma que la tercera componente todavía se interpreta en las preguntas 5 y 6, lo que hace que dos componentes se queden cortas.

  Respaldo. En la sesión 4 se presentó el 80 % como «la regla que usualmente usamos», el codo como el método gráfico y Kaiser como el criterio que «admite muchas» componentes, mientras que en la sesión 5 se repitió que el 80 % separa la señal del ruido. Jolliffe (2002, § 6.1.1) ubica el corte usual del porcentaje acumulado entre el 70 % y el 90 %.

- **Las copias no cambian la estructura pero dejan la cuarta componente en el límite.** Al quitar las 12 columnas redundantes de los 18 pares quedan 45 variables sin ningún par mayor a 0.99, donde el primer eje baja de 61.96 % a 57.92 %, el codo sigue en la segunda componente (9.25 % frente a 6.55 % de la tercera) y Kaiser pasa de ocho a siete. La regla del 80 % en cambio pide cinco pues las cuatro primeras explican el 78.99 %, es decir que las copias inflan el primer eje en unos cuatro puntos y que con ellas cuatro componentes pasan el umbral por 1.46 puntos mientras que sin ellas les falta 1.01. Se mantienen las 57 variables y las cuatro componentes porque la Pregunta 3 pide el ACP sobre la base completa y lo que se interpreta (un eje de tamaño dominante y el codo en dos) no cambia, pero la cuarta componente queda en el límite pues sin las copias no alcanzaría el 80 % y su inclusión la decide el umbral más que la curva.

  Respaldo. En la sesión 4 se aclaró que el 80 % «es usualmente un punto de referencia» y no un corte exacto, de modo que una diferencia de un punto alrededor de él no obliga por sí sola a cambiar el número de componentes que se interpretan aunque sí deja a la última en duda.

3.4. Pregunta 5 — Representación de las variables

El círculo de correlaciones ubica cada variable con coordenadas iguales a su correlación con cada eje del plano, de modo que la longitud de la flecha es $\sqrt{\cos^2}$, donde el $\cos^2$ (la correlación al cuadrado con el eje) mide qué tan bien representa el plano a esa variable. Una flecha que llega al círculo está bien representada, mientras que una corta está mayormente en otras componentes. Se dibujan solo las 30 variables que más contribuyen al plano.

```
fviz_pca_var(acp_normado, axes = c(1, 2),
             select.var = list(contrib = 30), col.var = "contrib",
             labelsize = 2.2, repel = TRUE) + labs(title = NULL)
```

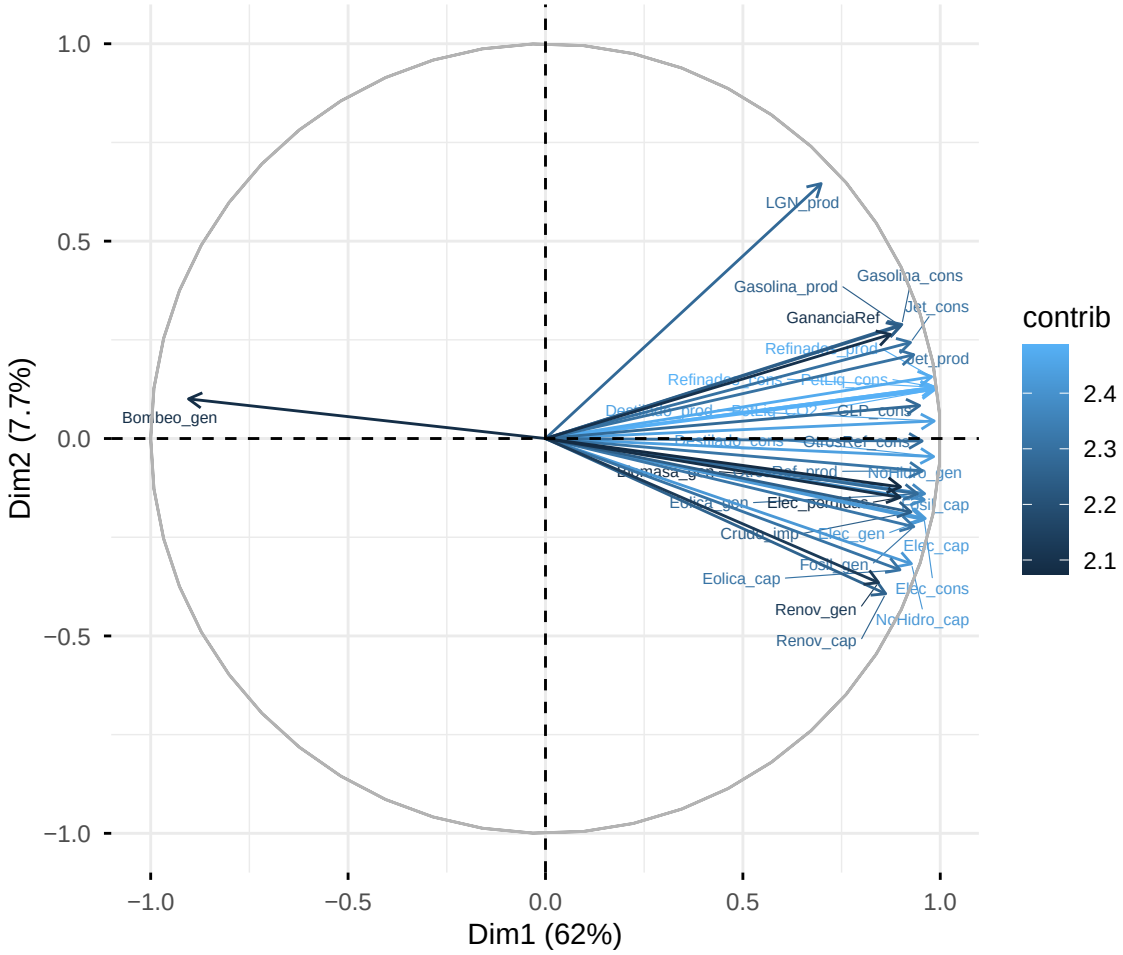


Figura 3.5: Círculo de correlaciones del ACP normado en el plano (1,2), con las 30 variables que más contribuyen: Casi todas apuntan hacia la derecha, de modo que el primer eje es el tamaño energético del país.

```
# Las mismas 30 sin la de bombeo, que apunta al otro lado.
plano <- facto_summarize(acp_normado, "var", axes = c(1, 2))
haz <- setdiff(plano$name[order(-plano$contrib)][1:30],
               "Bombeo_gen")
fviz_pca_var(acp_normado, axes = c(1, 2),
             select.var = list(name = haz), col.var = "contrib",
             labelsize = 2.6, repel = TRUE) +
  coord_cartesian(xlim = c(0.65, 1.02), ylim = c(-0.42, 0.68)) +
  labs(title = NULL)
```

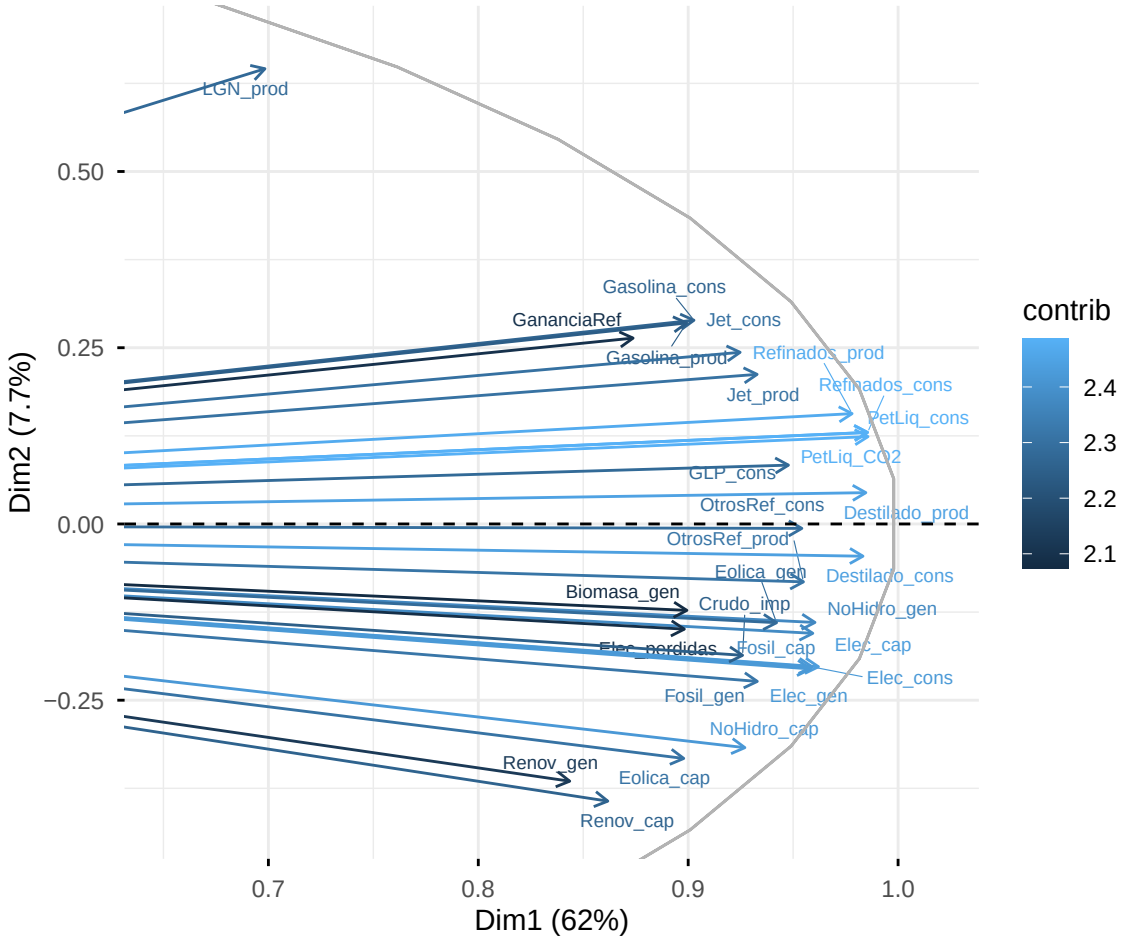


Figura 3.6: Acercamiento al haz de flechas del plano (1,2): La mayoría de las de petróleo quedan arriba del eje horizontal y las de electricidad abajo, todas con correlación de al menos 0.70 con el primer eje.

```r
coord <- get_pca_var(acp_normado)$coord[, 1:3]
round(coord[order(-abs(coord[, 2]))[1:8], ], 2)
```

```
                Dim.1 Dim.2 Dim.3
LGN_prod         0.70  0.65  0.06
Crudo_exp        0.13  0.59 -0.68
PetLiq_prod      0.69  0.58 -0.35
Crudo_prod       0.60  0.57 -0.49
Crudo_reservas   0.15  0.46 -0.60
Hidro_gen        0.74 -0.42 -0.35
Hidro_cap        0.78 -0.41 -0.33
Solar_cap        0.77 -0.40  0.05
```

```r
round(coord[order(-abs(coord[, 3]))[1:8], ], 2)
```

```
                Dim.1 Dim.2 Dim.3
Crudo_exp        0.13  0.59 -0.68
Crudo_reservas   0.15  0.46 -0.60
Residual_prod    0.49  0.35 -0.53
Crudo_prod       0.60  0.57 -0.49
Residual_cons    0.53  0.09 -0.48
Geotermica_cap   0.51  0.33  0.46
Geotermica_gen   0.51  0.34  0.46
Elec_imp         0.54  0.13  0.41
```

```r
sum(abs(coord[, 1]) > 0.7)
```

```
[1] 39
```

Plano (1,2). Las 30 flechas más largas llegan casi al borde del círculo, lo cual muestra que el plano las representa muy bien (el consumo de petróleo tiene $\cos^2 = 0.988$ y la generación eléctrica 0.961). Se concluye que:

a. **El primer eje es un factor de tamaño.** Prácticamente todas las variables tienen correlación alta y positiva con él, tanto las de petróleo como las de electricidad, por lo que un país está a la derecha si produce, consume, genera e importa mucho en términos absolutos. La única flecha que apunta hacia la izquierda es la generación neta por bombeo hidroeléctrico (`Bombeo_gen`, $r = -0.90$), lo cual tiene sentido porque esa generación neta es negativa (el bombeo consume más energía de la que devuelve) en 27 países y lo es más en los grandes, como Estados Unidos (−6.2 BKWH) y China (−4.7 BKWH).
b. **El segundo eje separa petróleo de renovables.** Según las correlaciones impresas arriba, del lado positivo quedan los líquidos de gas natural (`LGN_prod`, 0.65), las exportaciones de crudo (0.59) y la producción de crudo y de petróleo (0.57 y 0.59), mientras que del lado negativo quedan la generación y la capacidad hidroeléctrica (−0.42 y −0.41) y la capacidad solar y renovable (−0.40 y −0.39). Es decir que entre países de igual tamaño el segundo eje distingue a los productores de hidrocarburos de los que generan electricidad renovable.

```r
fviz_pca_var(acp_normado, axes = c(2, 3),
             select.var = list(contrib = 30), col.var = "contrib",
             labelsize = 2.5, repel = TRUE) + labs(title = NULL)
```

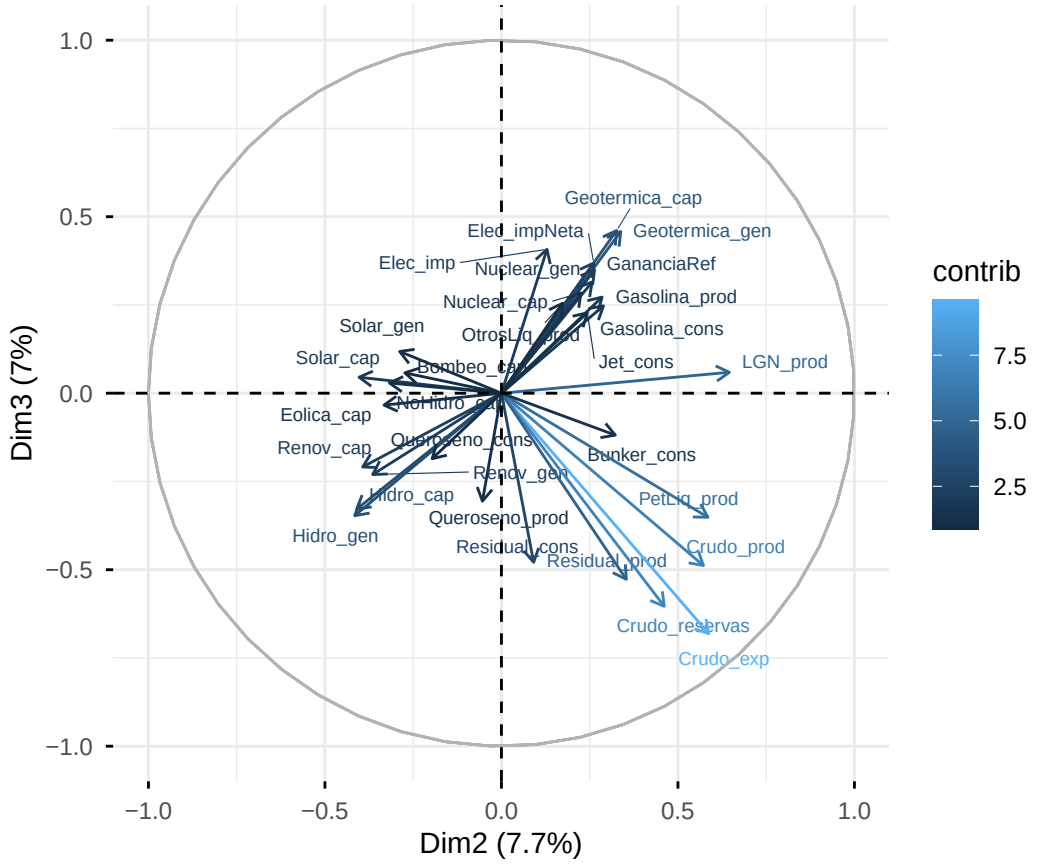


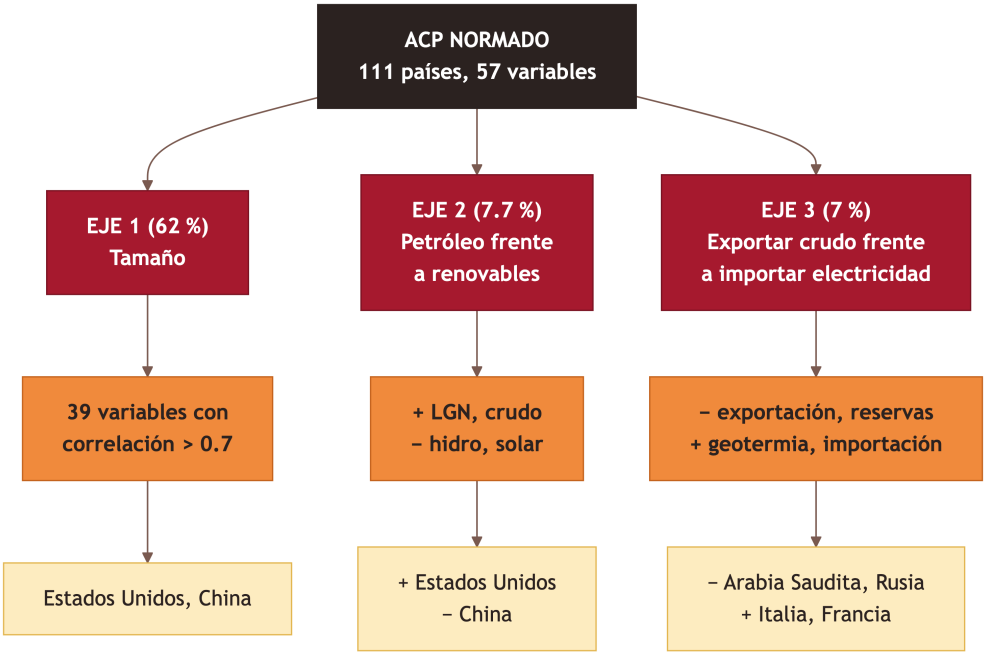
Figura 3.7: Círculo de correlaciones del ACP normado en el plano (2,3), con las 30 variables que más contribuyen: Las exportaciones y reservas de crudo bajan, las renovables van a la izquierda y la geotermia y las importaciones eléctricas suben.

Plano (2,3). Al quitar el efecto de tamaño las flechas se acortan y se abren en varias direcciones, lo que indica que este plano representa peor a cada variable (el mejor $\cos^2$ es el de las exportaciones de crudo con 0.81) pero muestra perfiles que el primero escondía:

a. **Perfil exportador de crudo.** Abajo a la derecha quedan las exportaciones de crudo (−0.68 con el tercer eje), las reservas (−0.60), la producción de combustóleo residual (−0.53) y la producción de crudo (−0.49), es decir, los países con yacimientos que venden su petróleo.
b. **Perfil renovable.** A la izquierda quedan la capacidad y generación hidroeléctrica, solar y renovable, con correlación negativa con el segundo eje.
c. **Perfil importador de electricidad.** Arriba quedan la capacidad y la generación geotérmica (0.46), las importaciones de electricidad (0.41) y las importaciones netas (0.37), así como la ganancia de refinación y la electricidad nuclear con correlaciones menores.

Se concluye que el tercer eje separa a los exportadores de crudo de los países que compran electricidad o la generan con fuentes como la geotérmica y la nuclear, lo cual justifica haber retenido más de dos componentes.

El diagrama resume lo que significa cada uno de los tres primeros ejes según las variables que más se asocian con él.



Qué mide cada eje del ACP normado con los 111 países y qué variables lo construyen: El primero ordena por tamaño y solo los siguientes distinguen perfiles energéticos.

a. **Lectura local.** La exportación de crudo, que en el primer plano casi no aparece (0.13 con el primer eje), es la variable mejor representada del plano (2,3), lo cual respalda que la dimensión comercial que se buscó en la Pregunta 1 existe y está fuera del eje de tamaño.
b. **Lectura global.** El primer eje es el tamaño porque 39 de las 57 variables tienen con él correlación mayor a 0.7 en valor absoluto, de modo que lo que distingue a los países más allá de su tamaño (petróleo, renovables, importaciones) solo aparece en los ejes siguientes, que explican mucho menos.

   Nota. El signo de cada componente es arbitrario pues `prcomp()` puede devolver u_k o $-u_k$ y ambos son igual de válidos. Lo que se interpreta es la oposición entre grupos de variables y no si quedan arriba o abajo.

3.5. Pregunta 6 — Mapa de individuos

Para que el mapa se pueda leer se dibujan todos los países como puntos y se rotulan solo los 20 más alejados del origen en cada plano, que son los que más contribuyen a él.

```r
mapa_paises <- function(acp, ejes, n = 20, grupos = "none") {
  coord <- data.frame(acp$x[, ejes])
  names(coord) <- c("x", "y")
  coord$pais <- rownames(coord)
  lejanos <- coord[order(-(coord$x^2 + coord$y^2))[seq_len(n)], ]
  fviz_pca_ind(acp, axes = ejes, geom = "point", habillage = grupos,
               col.ind = "grey45", mean.point = FALSE) +
    ggrepel::geom_text_repel(data = lejanos, inherit.aes = FALSE,
                             aes(x, y, label = pais), size = 2.4,
                             max.overlaps = Inf,
                             min.segment.length = 0) +
    labs(title = NULL, colour = "Grupo", shape = "Grupo")
}
```

```r
mapa_paises(acp_normado, c(1, 2))
```

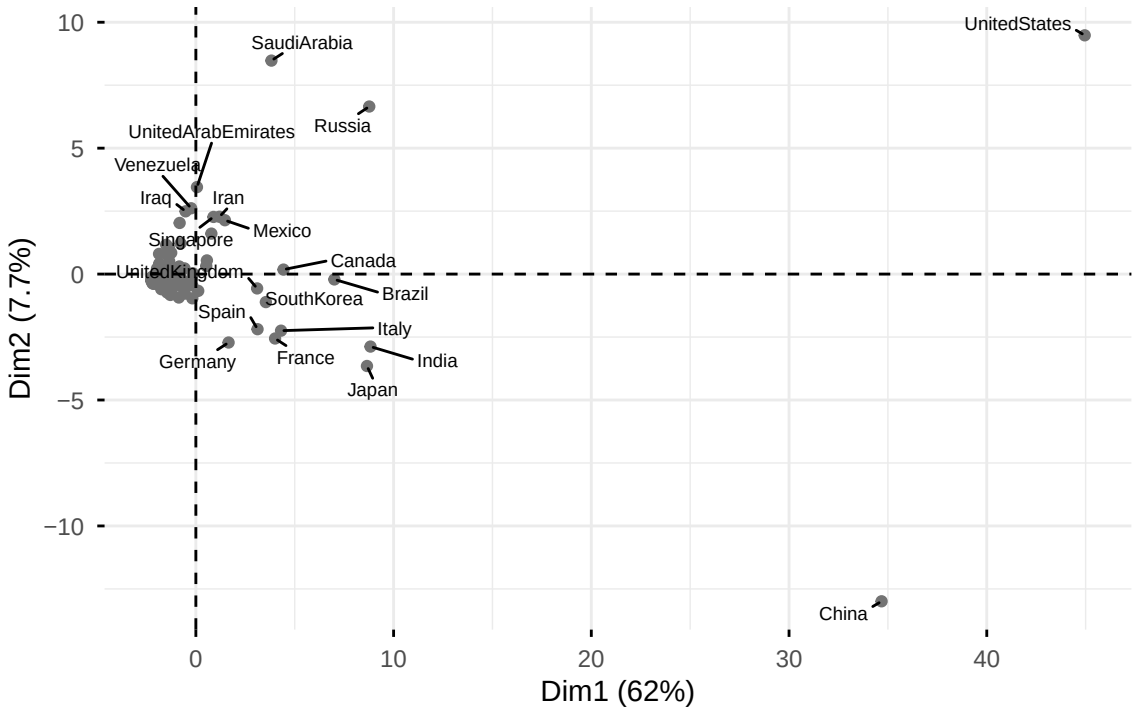


Figura 3.8: Países en el plano (1,2) del ACP normado: Estados Unidos y China quedan aislados a la derecha y el resto se amontona cerca del origen.

```
mapa_paises(acp_normado, c(2, 3))
```

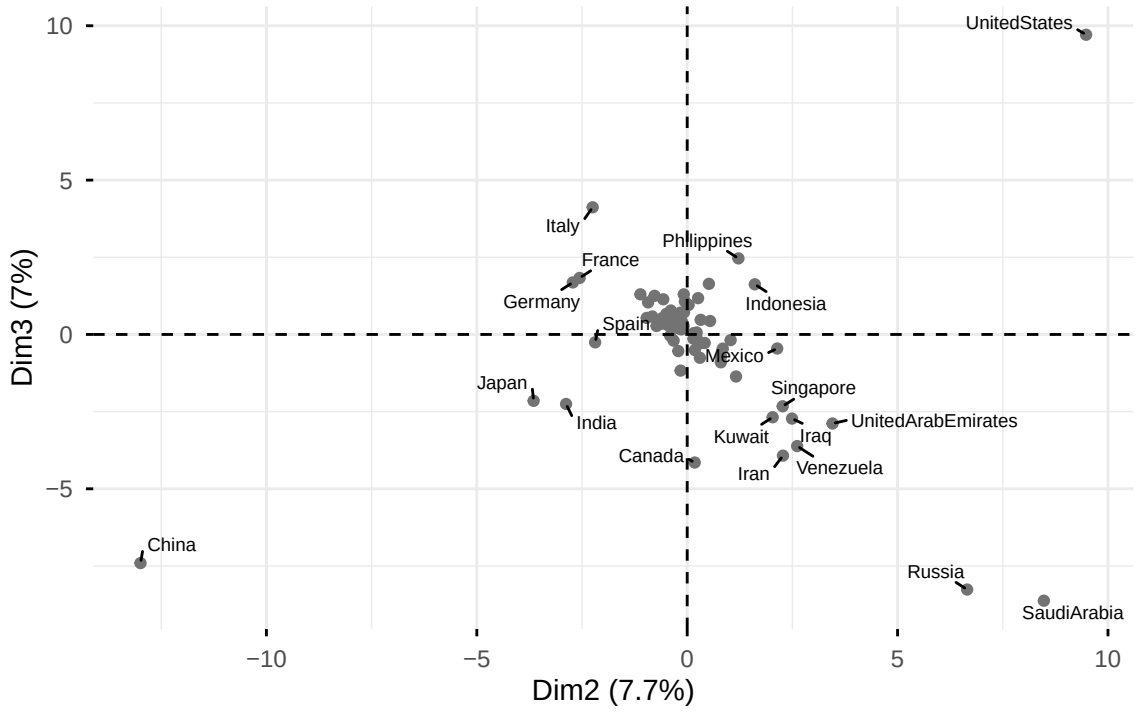


Figura 3.9: Países en el plano (2,3) del ACP normado: Arabia Saudita y Rusia quedan juntos abajo a la derecha, China a la izquierda y Estados Unidos arriba a la derecha.

```
contribucion <- get_pca_ind(acp_normado)$contrib
round(head(sort(contribucion[, 1], decreasing = TRUE), 4), 2)
```

```
UnitedStates        China        India       Russia
       52.02        30.96         2.01         1.98
```

```
round(acp_normado$x[c("SaudiArabia", "Russia", "Kuwait", "Iraq",
                      "Japan", "India", "Italy", "France",
                      "Germany"), 1:3], 2)
```

```
             PC1   PC2   PC3
SaudiArabia 3.82  8.48 -8.63
Russia      8.77  6.65 -8.26
Kuwait     -0.82  2.03 -2.68
Iraq       -0.52  2.49 -2.73
Japan       8.65 -3.65 -2.15
India       8.83 -2.88 -2.25
Italy       4.31 -2.25  4.12
France      4.01 -2.56  1.83
Germany     1.65 -2.72  1.69
```

```r
mean(abs(acp_normado$x[, 1])
     < 2)
```

```
[1] 0.5495495
```

¿Qué se concluye de la cercanía entre países? Que el ACP con los 111 países está dominado por cuatro de ellos y que la cercanía revela perfiles energéticos comunes:

a. **Dos gigantes.** Estados Unidos (44.95 en el primer eje) y China (34.68) están tan lejos del resto que construyen el 52.02 % y el 30.96 % del primer eje respectivamente, es decir, entre los dos el 83 %. Ningún otro país pasa de 9 en esa coordenada y el 55 % de los países queda a menos de 2 unidades del origen.
b. **Petroleros.** En el plano (2,3) Arabia Saudita (8.48, −8.63) y Rusia (6.65, −8.26) están juntos y lejos del resto, en la dirección de las exportaciones y reservas de crudo de la Pregunta 5, mientras que Kuwait, Irak, Emiratos Árabes, Venezuela e Irán aparecen en la misma dirección aunque mucho más cerca del origen.
c. **Grandes consumidores sin petróleo.** Japón (8.65, −3.65) e India (8.83, −2.88) quedan prácticamente superpuestos en el plano (1,2) pues ambos son economías grandes que consumen mucho petróleo y electricidad sin producir crudo en cantidad.
d. **China frente a Estados Unidos.** A pesar de estar ambos a la derecha del primer plano, se separan en el segundo eje (−12.99 contra 9.48) ya que China pesa por su generación hidroeléctrica y renovable mientras que Estados Unidos lo hace también por su producción de petróleo.
e. **Importadores de electricidad.** En el plano (2,3) Italia (4.12 en el tercer eje), Francia (1.83) y Alemania (1.69) quedan arriba a la izquierda, que es la dirección de las importaciones de electricidad y la generación nuclear y geotérmica de la Pregunta 5.

Estas cercanías se leen en dos niveles:

a. **Lectura local.** La cercanía de India y Japón no dice que sean países parecidos en todo sino que tienen el mismo perfil energético, es decir, mucho consumo y poca producción de crudo, de modo que dos economías que en otros aspectos pueden ser muy distintas quedan superpuestas porque las 57 variables solo miden energía.
b. **Lectura global.** El plano lo organizan pocas economías pues Estados Unidos y China construyen el 83 % del primer eje y fijan la escala del mapa, de modo que la mayoría de países no se distingue en estos planos y se justifica la Pregunta 7.

3.6. Pregunta 7 — ACP sin los cuatro países atípicos

Desde aquí se excluyen Estados Unidos, China, Arabia Saudita y Rusia, tanto para el ACP como para el agrupamiento de las preguntas 8 a 11.

```r
atipicos <- c("UnitedStates", "China", "SaudiArabia", "Russia")
datos <- datos[!datos$Country %in% atipicos, ]
num <- numericas(datos)
acp_sin4 <- prcomp(num, scale. = TRUE)
valores <- function(acp) {
  p <- acp$sdev^2 / sum(acp$sdev^2)
  round(100 * c(p[1:3], cumsum(p)[2:3]), 2)
}
knitr::kable(data.frame(
  medida = c("% CP1", "% CP2", "% CP3", "% plano 1-2",
             "% acumulado 3"),
  con_111 = valores(acp_normado), sin_4 = valores(acp_sin4)),
  caption = "Varianza explicada con y sin los cuatro países.")
```

Cuadro 3.8: Varianza explicada con y sin los cuatro países.

medida	con_111	sin_4
% CP1	61.96	48.95
% CP2	7.74	10.24
% CP3	7.01	8.11
% plano 1-2	69.69	59.19
% acumulado 3	76.71	67.30

```r
autovalores <- acp_sin4$sdev^2
coord <- get_pca_var(acp_sin4)$coord
round(coord[order(-abs(coord[, 2]))[1:6], 1:2], 2)
```

```
               Dim.1 Dim.2
PetLiq_prod     0.35 -0.84
Crudo_prod      0.30 -0.83
Crudo_exp       0.16 -0.75
LGN_prod        0.31 -0.69
Crudo_reservas  0.18 -0.66
Bombeo_gen     -0.49 -0.53
```

```r
round(head(sort(get_pca_ind(acp_sin4)$contrib[, 1],
                decreasing = TRUE), 4), 2)
```

```
 India  Japan Brazil Canada
 23.37  20.04  11.49   6.38
```

```
c(paises = nrow(num),
  kaiser = sum(autovalores > 1))
```

```
paises kaiser
   107      9
```

```
c(acumulado_80 = which(
  cumsum(autovalores) / 57
    >= 0.8)[1],
  tamano = sum(abs(
    coord[, 1]) > 0.7))
```

```
acumulado_80       tamano
           6           27
```

```
mapa_paises(acp_sin4, c(1, 2), n = 24)
```

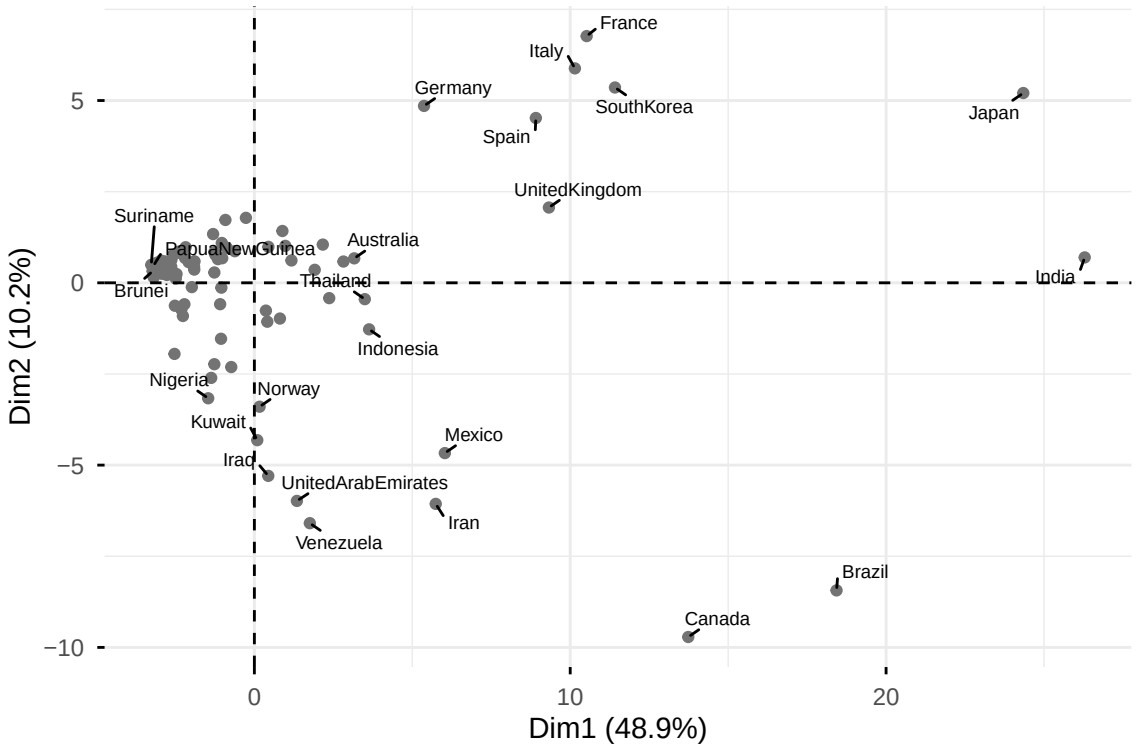


Figura 3.10: Países en el plano (1,2) del ACP normado sin Estados Unidos, China, Arabia Saudita y Rusia: La masa central se abre y aparecen dos brazos, uno de grandes consumidores hacia arriba y otro de productores de petróleo hacia abajo.

¿En qué cambia el ACP al excluir estos países? En tres aspectos:

a. **La varianza se reparte más.** La primera componente baja de 61.96 % a 48.95 % mientras que la segunda sube de 7.74 % a 10.24 % y la tercera de 7.01 % a 8.11 %, por lo que ahora se necesitan seis componentes para el 80 % (antes cuatro) y Kaiser retiene nueve (antes ocho). Esto muestra que buena parte del 62 % del primer eje se debía a que Estados Unidos y China son enormes en todas las variables a la vez.

b. **El segundo eje se vuelve un eje petrolero más nítido.** Las correlaciones de la producción de petróleo (−0.84), la producción de crudo (−0.83), las exportaciones de crudo (−0.75) y los líquidos de gas (−0.69) con la segunda componente son mucho más fuertes que con los 111 países (alrededor de 0.6), mientras que en el lado opuesto queda la electricidad solar (0.48). El signo cambió respecto al ACP anterior, lo cual no tiene importancia según la nota de la Pregunta 5.
c. **Aparecen nuevos países dominantes.** India (23.37 %) y Japón (20.04 %) pasan a construir el primer eje, de modo que el efecto de tamaño no desaparece sino que lo heredan los siguientes países más grandes.

¿Se perciben clusters con mayor claridad? Sí, aunque no como grupos compactos. La masa de países pequeños se abre hacia la derecha y de ella salen dos brazos, uno hacia arriba con grandes consumidores que no producen petróleo (Francia, Italia, Corea del Sur, Japón, Alemania y España) y otro hacia abajo con productores y exportadores de petróleo (Irak, Emiratos Árabes, Venezuela, Irán y México), al extremo del cual quedan Brasil y Canadá, que combinan producción de crudo (2255 y 3613 TBPD) con la mayor generación renovable de los 107 países (429 y 412 BKWH). India queda sola en el extremo derecho.

a. **Lectura local.** Quitar cuatro países no borra el tamaño sino que lo traslada pues India y Japón construyen ahora el 43 % del primer eje, que es la mitad de lo que construían Estados Unidos y China pero sigue siendo mucho para dos países de 107.
b. **Lectura global.** El tamaño es una propiedad de la base y no de cuatro países ya que todavía 27 de las 57 variables tienen correlación mayor a 0.7 con el primer eje (antes 39). Lo que sí cambia es que, al bajar la escala, la dimensión petrolera gana espacio y deja ver la estructura en brazos que la Pregunta 8 lee como grupos.

El enunciado fija los cuatro países, pero se puede comprobar si son los atípicos multivariados de la base con la distancia de Mahalanobis. Sobre las 57 variables no se puede calcular porque su matriz de covarianzas es singular así que se calcula sobre las k primeras componentes del ACP normado de los 111 países y se compara con el cuantil 0.975 de una χ^2_k.

```
num111 <- numericas(read.csv(ruta, sep = ";", dec = "."))
qr(cov(num111))$rank
```

```
[1] 50
```

```r
mahal <- function(k) {
  s <- acp_normado$x[, 1:k]
  d2 <- sort(mahalanobis(s, colMeans(s), cov(s)), TRUE)
  corte <- qchisq(0.975, df = k)
  list(fila = c(k = k, corte = corte, sobre = sum(d2 > corte),
                d2_India = d2[["India"]], d2_Japon = d2[["Japan"]],
                puesto_India = match("India", names(d2)),
                puesto_Japon = match("Japan", names(d2))),
       paises = names(d2)[d2 > corte])
}
casos <- lapply(c(2, 3, 4, 8), mahal)
knitr::kable(t(sapply(casos, `[[`, "fila")), digits = 2,
             caption = "Corte chi-cuadrado(k, 0.975) en k CP.")
```

Cuadro 3.9: Corte chi-cuadrado(k, 0.975) en k CP.

k	corte	sobre	d2_India	d2_Japon	puesto_India	puesto_Japon
2	7.38	4	4.09	5.14	6	5
3	9.35	4	5.36	6.30	7	5
4	11.14	8	5.41	15.95	12	7
8	17.53	11	15.43	78.60	13	4

```r
cat(strwrap(paste(casos[[3]]$paises, collapse = ", "), 64),
    sep = "\n")
```

```
UnitedStates, China, SaudiArabia, France, SouthKorea, Russia,
Japan, Italy
```

```r
cp4 <- abs(acp_normado$rotation[, 4])
round(head(sort(cp4, decreasing = TRUE), 3), 2)
```

```
Mareas_gen Mareas_cap   Elec_exp
      0.50       0.47       0.27
```

```r
rownames(num111)[num111$Mareas_gen > 0]
```

```
[1] "France"     "Germany"    "Italy"      "Slovakia"
[5] "SouthKorea" "Turkey"
```

Como alternativa a excluir países se repite el ACP normado de los 111 países sobre el logaritmo de las variables. Cuatro columnas (`PetLiq_prod`, `GananciaRef`, `Elec_impNeta` y `Bombeo_gen`) traen 80 valores negativos con los que `log1p()` daría `NaN`, por lo que se usa el logaritmo con signo $\text{sign}(x)\log(1+|x|)$, que deja el cero en cero.

```r
log111 <- sign(num111) * log1p(abs(num111))
acp_log <- prcomp(log111, scale. = TRUE)
knitr::kable(data.frame(
  medida = c("% CP1", "% CP2", "% CP3", "% plano 1-2",
             "% acumulado 3"),
  con_111 = valores(acp_normado), sin_4 = valores(acp_sin4),
  log_111 = valores(acp_log)),
  caption = "Varianza explicada sin quitar países, con logaritmo.")
```

Cuadro 3.10: Varianza explicada sin quitar países, con logaritmo.

medida	con_111	sin_4	log_111
% CP1	61.96	48.95	55.81
% CP2	7.74	10.24	11.83
% CP3	7.01	8.11	4.95
% plano 1-2	69.69	59.19	67.63
% acumulado 3	76.71	67.30	72.58

```r
autovalores_log <- acp_log$sdev^2
c(negativos = sum(num111 < 0),
  acumulado_80 = which(cumsum(autovalores_log) / 57 >= 0.8)[1],
  kaiser = sum(autovalores_log > 1))
```

```
   negativos acumulado_80       kaiser
          80            5            9
```

```r
names(which(colSums(num111 < 0) > 0))
```

```
[1] "PetLiq_prod"  "GananciaRef"  "Elec_impNeta" "Bombeo_gen"
```

```r
aporte_log <- get_pca_ind(acp_log)$contrib[, 1]
round(head(sort(aporte_log, decreasing = TRUE), 5), 2)
```

```
UnitedStates        China        India        Japan       Brazil
       12.48        10.27         4.60         3.89         3.15
```

```r
round(sum(aporte_log[c("UnitedStates", "China")]), 2)
```

```
[1] 22.75
```

```r
round(get_pca_var(acp_log)$coord[cinco, 1:2], 2)
```

```
             Dim.1 Dim.2
Crudo_prod    0.45 -0.69
PetLiq_cons   0.95 -0.21
Crudo_exp     0.27 -0.79
Elec_gen      0.95 -0.05
Renov_gen     0.75  0.33
```

Notas

Interpretaciones.

a. **Qué cambió.** El primer eje pasa de 61.96 % a 48.95 %, las variables ligadas a él de 39 a 27 y los países que lo construyen de Estados Unidos y China (83 %) a India y Japón (43 %).
b. **Qué no cambió.** El primer eje sigue siendo tamaño y el segundo sigue siendo petróleo, solo que más nítido.
c. **Quitar no es corregir.** Los cuatro países no son errores de medición sino datos reales, de modo que excluirlos cambia la población que se describe: Los resultados de las preguntas 7 a 11 valen para 107 países sin los cuatro mayores.

Decisiones.

- **Se quitan los cuatro países que pide el enunciado y no seis.** El enunciado nombra a Estados Unidos, China, Arabia Saudita y Rusia y la distancia de Mahalanobis lo respalda pues sobre las dos y las tres primeras componentes de los 111 países (la covarianza de las 57 variables es singular, de rango 50) son exactamente esos cuatro los que superan el corte de la χ^2 (7.38 y 9.35), mientras que Japón queda quinto con 5.14 y 6.30 e India sexta y séptima con 4.09 y 5.36, ambos por debajo. India no supera el corte con ningún número de componentes (5.41 con cuatro y 15.43 con ocho frente a 11.14 y 17.53) y Japón solo lo supera desde la cuarta componente (15.95), que construyen sobre todo las mareas (0.50 y 0.47) y con la que también salen Francia, Corea del Sur e Italia, tres de los seis países con generación por mareas. Es decir que quitar seis sería tan arbitrario como quitar ocho pues la lejanía de Japón con cuatro componentes no es la del tamaño que motivó la exclusión, de modo que India y Japón heredan el primer eje (43 %) sin ser atípicos por este criterio.

  Respaldo. En la sesión 3 se detectaron los atípicos multivariados con la distancia de Mahalanobis frente al cuantil 0.975 de una χ^2 con tantos grados de libertad como variables (el ejemplo de clase, con cuatro variables, daba el mismo corte de 11.14), que es el procedimiento de Johnson y Wichern (2007, § 4.7), mientras que en la sesión 4 se recomendó calcularla antes del ACP porque un punto lejano «va a jalonar» la dirección de máxima varianza.

- **El logaritmo entra como prueba de robustez y no reemplaza la exclusión.** Con el logaritmo con signo, necesario porque cuatro variables (producción de petróleo, ganancia de refinación, importación neta de electricidad y almacenamiento por bombeo)

traen 80 valores negativos, el ACP normado de los 111 países explica el 55.81 % en el primer eje y el 11.83 % en el segundo, mientras que Estados Unidos y China pasan de construir el 83 % del primer eje a construir el 22.75 % (12.48 % y 10.27 %), que es además menos que el 43 % que India y Japón construyen sin los cuatro. La estructura en cambio se conserva ya que el primer eje sigue siendo tamaño (consumo y generación con 0.95) y el segundo petróleo (exportación de crudo con −0.79 y producción con −0.69), con lo cual la regla del 80 % pide cinco componentes, entre las cuatro de los 111 y las seis de los 107. Se queda la exclusión porque la Pregunta 7 la pide y las preguntas 8 a 11 se plantean sobre los 107 países, pero el logaritmo sugiere que el dominio de dos países es un efecto de la escala de las variables más que de la estructura de la base y que con esta transformación los resultados podrían extenderse a los 111 países.

Respaldo. En la sesión 4 se advirtió que el ACP está «altamente influenciado por valores atípicos», mientras que reexpresar con el logaritmo las variables positivas muy asimétricas es el remedio clásico del análisis exploratorio (Tukey 1977) y una transformación usual antes del ACP (Jolliffe 2002, § 14.2.3).

Capítulo 4

Agrupamiento

Como pide el enunciado, las preguntas 8 a 11 se resuelven sin Estados Unidos, China, Arabia Saudita y Rusia, es decir, sobre los 107 países que quedaron en `datos` y `num` al final de la Pregunta 7.

4.1. Pregunta 8 — Número de grupos en el primer plano

¿Cuántos clusters se espera que existan? Tres, leídos sobre el plano (1,2) de la Pregunta 7:

a. **Masa central.** La mayoría de los 107 países, de consumo y producción pequeños, que se amontonan cerca del origen.
b. **Brazo de consumidores.** Las economías grandes sin producción importante de petróleo hacia arriba y a la derecha, con Japón e India en el extremo.
c. **Brazo de productores.** Los exportadores de petróleo hacia abajo, con Brasil y Canadá en el extremo.

Cabe aclarar que esta es una estimación a ojo sobre un plano que solo explica el 59.19 % de la varianza, que los brazos salen de la masa central sin un corte claro y que India, Japón, Brasil y Canadá están tan alejados que un método de agrupamiento podría separarlos como grupos propios. Por esto el número se contrasta en la Pregunta 9.

a. **Lectura local.** Los cuatro países de los extremos (India, Japón, Brasil y Canadá) son los que más construyen el primer eje (de 23.37 % a 6.38 %), de modo que pueden terminar como grupos propios aunque a ojo parezcan la punta de un brazo.
b. **Lectura global.** El 40.81 % de la varianza no está en este plano, por lo que dos países que se ven cerca pueden estar lejos en otras componentes y por eso el número de grupos se lee aquí como una hipótesis y no como un resultado.

4.2. Pregunta 9 — Número de grupos por reducción de varianza explicada

La inercia intra-grupo $W(k)$ es la suma de las distancias al cuadrado de cada país al centroide de su grupo, que mide qué tan compactos son los grupos y la varianza explicada por la partición

es

$$1 - \frac{W(k)}{T}, \qquad T = W(1) = \sum_{i=1}^{n} \|\mathbf{z}_i - \bar{\mathbf{z}}\|^2,$$

es decir, la fracción de la inercia total T que queda entre los grupos. Con las 57 variables estandarizadas $T = (n-1)\,p = 106 \times 57 = 6042$. Se corre k-medias (MacQueen 1967) para $k = 1, \ldots, 10$ y se busca el punto desde el que agregar un grupo ya no reduce mucho la inercia. Como verificación adicional se calcula la silueta media, que se define en la Pregunta 10.

```
z <- scale(num)
set.seed(42)
ajustes <- lapply(1:10, function(k)
  kmeans(z, centers = k, nstart = 100))
inercia <- sapply(ajustes, `[[`, "tot.withinss")
explicada <- 100 * (1 - inercia / inercia[1])
silueta <- c(NA, sapply(ajustes[-1], function(a)
  mean(silhouette(a$cluster, dist(z))[, 3])))
tamanos <- sapply(ajustes, function(a)
  paste(sort(a$size, decreasing = TRUE), collapse = "/"))
knitr::kable(data.frame(k = 1:10, W = round(inercia, 1),
                        explicada = round(explicada, 1),
                        ganancia = round(c(NA, diff(explicada)), 1),
                        silueta = round(silueta, 3), tamanos),
             col.names = c("k", "W", "explicada", "ganancia",
                           "silueta", "tamaños"),
             caption = "Inercia intra-grupo y varianza explicada.")
```

Cuadro 4.1: Inercia intra-grupo y varianza explicada.

k	W	explicada	ganancia	silueta	tamaños
1	6042.0	0.0	NA	NA	107
2	3838.6	36.5	36.5	0.698	98/9
3	3226.7	46.6	10.1	0.666	97/8/2
4	2767.7	54.2	7.6	0.538	87/10/8/2
5	2303.1	61.9	7.7	0.546	87/10/6/2/2
6	2023.6	66.5	4.6	0.552	87/10/4/2/2/2
7	1828.8	69.7	3.2	0.444	76/15/6/4/2/2/2
8	1615.5	73.3	3.5	0.429	73/17/6/4/2/2/2/1
9	1468.9	75.7	2.4	0.412	71/17/5/4/3/2/2/2/1
10	1376.4	77.2	1.5	0.391	65/16/7/5/4/3/2/2/2/1

```r
ggplot(data.frame(k = 1:10, explicada), aes(k, explicada)) +
  geom_line(colour = "grey50") +
  geom_point(colour = "#a6192e", size = 2) +
  geom_vline(xintercept = 3, linetype = "dashed",
             colour = "grey50") +
  scale_x_continuous(breaks = 1:10) +
  labs(x = "Número de grupos k", y = "Varianza explicada (%)") +
  theme_minimal()
```

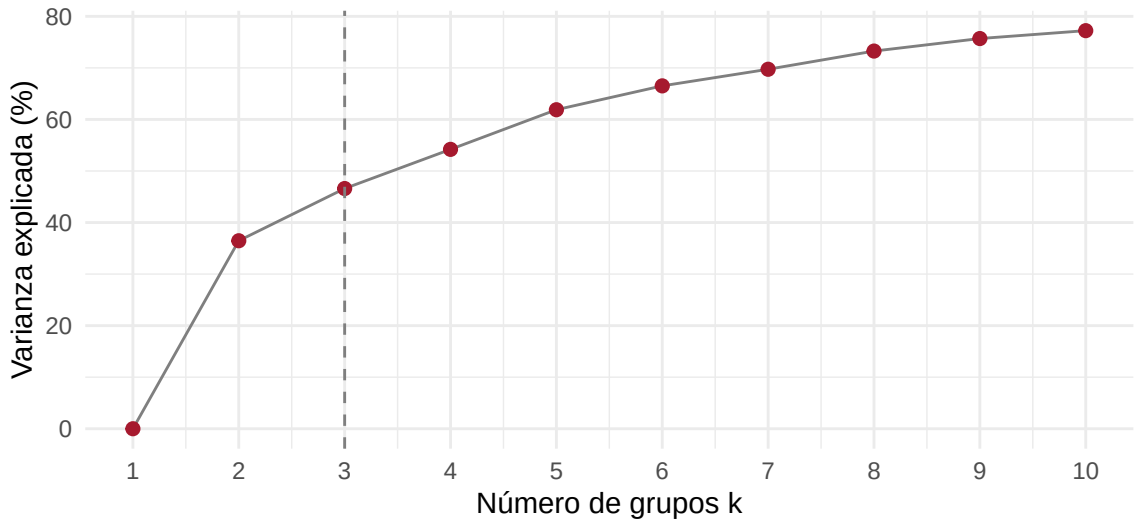


Figura 4.1: Varianza explicada por la partición de k-medias según el número de grupos: La ganancia cae de 36.5 a 10.1 puntos al pasar al tercer grupo y desde ahí se mantiene por debajo de 8.

¿Cuántos grupos se fijan? Tres, que explican el 46.6 % de la inercia total. La reducción más grande ocurre al pasar de uno a dos grupos (36.5 puntos), el tercer grupo todavía agrega 10.1 puntos y a partir de ahí cada grupo nuevo agrega 7.7 puntos o menos, cayendo a 4.6 en $k = 6$ y a 3.2 en $k = 7$. Vale la pena anotar con honestidad que la curva no tiene un codo marcado después de $k = 2$, sino una caída gradual, por lo que la elección se apoya además en dos hechos:

a. **Silueta.** La silueta media pasa de 0.698 con dos grupos a 0.666 con tres, pero cae a 0.538 con cuatro, de modo que el cuarto grupo empeora claramente la separación.
b. **Coherencia con el plano.** Tres grupos es lo que se esperaba a ojo en la Pregunta 8, mientras que dos grupos solo separarían a nueve países grandes del resto (partición 98/9).

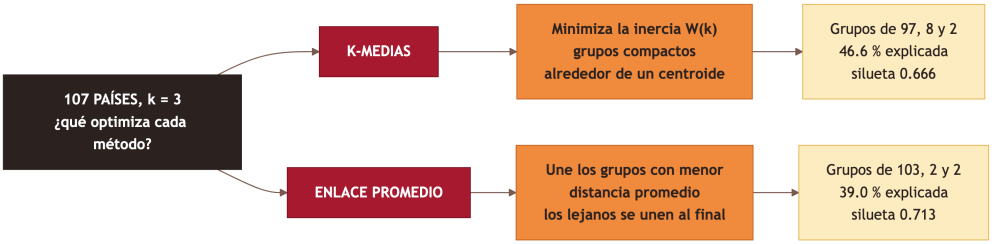
La elección también se lee en dos niveles:

a. **Lectura local.** El tercer grupo cuesta poco y aporta mucho pues con 10.1 puntos más de varianza explicada la silueta solo baja de 0.698 a 0.666, mientras que el cuarto parte la masa central (87/10/8/2) y la silueta cae a 0.538.
b. **Lectura global.** La curva sin codo después de $k = 2$ indica que la base no tiene grupos naturales bien separados sino una masa continua con unos pocos países extremos, de modo que cualquier k es en parte una decisión y no un descubrimiento.

4.3. Pregunta 10 — K-medias frente a jerárquico de enlace promedio

Se comparan dos formas de partir los 107 países en tres grupos con las 57 variables estandarizadas:

a. **K-medias.** Asigna cada país al centroide más cercano y mueve los centroides hasta minimizar $W(k)$. Se usan 100 arranques aleatorios (`nstart = 100`) con semilla fija, por la razón que explica la nota del final.
b. **Enlace promedio.** Es un agrupamiento jerárquico aglomerativo que parte de un grupo por país y une en cada paso los dos grupos con menor distancia promedio entre todos sus pares de países (Sokal y Michener 1958). Se corta el árbol en tres grupos.
c. **Correlación cofenética.** Es la correlación entre las distancias originales y la altura del árbol a la que se unen cada par de países, y mide qué tan fielmente el dendrograma conserva las distancias.
d. **Silueta.** Para cada país es $s(i) = (b_i - a_i)/\max(a_i, b_i)$, con a_i su distancia promedio a su propio grupo y b_i al grupo vecino más cercano (Rousseeuw 1987). Vale 1 si el país está bien ubicado, 0 si está en la frontera y es negativa si estaría mejor en otro grupo.



Qué optimiza cada método sobre los 107 países: K-medias busca grupos compactos y arma uno intermedio, mientras que el enlace promedio deja para el final a los países lejanos y los aísla en parejas.

```r
set.seed(42)
km3 <- kmeans(z, centers = 3, nstart = 100)
distancias <- dist(z)
hc_average <- hclust(distancias, method = "average")
jerarquico <- cutree(hc_average, k = 3)
# Grupos rotulados por tamaño: A el más grande. Los números que
# devuelven kmeans() y cutree() son arbitrarios.
rotular <- function(g) {
  orden <- rank(-tabulate(g), ties.method = "first")
  factor(LETTERS[orden[g]])
}
kmedias <- rotular(km3$cluster)
promedio <- rotular(jerarquico)
table(kmedias, promedio)
```

```
       promedio
kmedias  A  B  C
      A 97  0  0
      B  6  2  0
      C  0  0  2
```

```r
split(rownames(num), kmedias)[c("B", "C")]
```

```
$B
[1] "Brazil"        "Canada"        "France"
[4] "Germany"       "Italy"         "SouthKorea"
[7] "Spain"         "UnitedKingdom"

$C
[1] "India" "Japan"
```

```r
split(rownames(num), promedio)[c("B", "C")]
```

```
$B
[1] "Brazil" "Canada"

$C
[1] "India" "Japan"
```

```
explicada <- function(g) 1 - sum(sapply(split(as.data.frame(z), g),
  function(b) sum(scale(b, scale = FALSE)^2))) / sum(z^2)
sil <- function(g) summary(silhouette(as.integer(g), distancias))
medidas <- function(g) c(explicada(g), sil(g)$avg.width,
                         sil(g)$clus.avg.widths)
knitr::kable(round(rbind("k-medias" = medidas(kmedias),
                         "enlace promedio" = medidas(promedio)), 3),
             col.names = c("Explicada", "Silueta media",
                           "Silueta A", "Silueta B", "Silueta C"),
             caption = "Varianza explicada y silueta.")
```

Cuadro 4.2: Varianza explicada y silueta.

	Explicada	Silueta media	Silueta A	Silueta B	Silueta C
k-medias	0.466	0.666	0.731	-0.022	0.254
enlace promedio	0.390	0.713	0.732	0.174	0.266

```
round(cor(cophenetic(
  hc_average), distancias), 3)
```

```
[1] 0.986
```

```r
# Con 107 hojas los nombres no se leen: se rotulan los extremos.
par(mar = c(4, 4, 1, 1))
plot(hc_average, labels = FALSE, hang = -1, main = "", xlab = "",
     sub = "", ylab = "Altura (distancia promedio)")
rect.hclust(hc_average, k = 3, border = c("#a6192e", "#f08a3c",
                                          "#3572a8"))
# Cada par se rotula con una línea a la altura a la que se une.
hojas <- hc_average$labels[hc_average$order]
pares <- list("India y Japón" = c("India", "Japan"),
              "Brasil y Canadá" = c("Brazil", "Canada"))
rotulo_y <- c(27.5, 25.5)
for (i in 1:2) {
  par_i <- pares[[i]]
  x <- mean(match(par_i, hojas))
  y <- as.matrix(cophenetic(hc_average))[par_i[1], par_i[2]]
  segments(x, y, 12, rotulo_y[i], col = "grey40")
  text(12, rotulo_y[i], names(pares)[i], pos = 4, cex = 0.7)
}
```

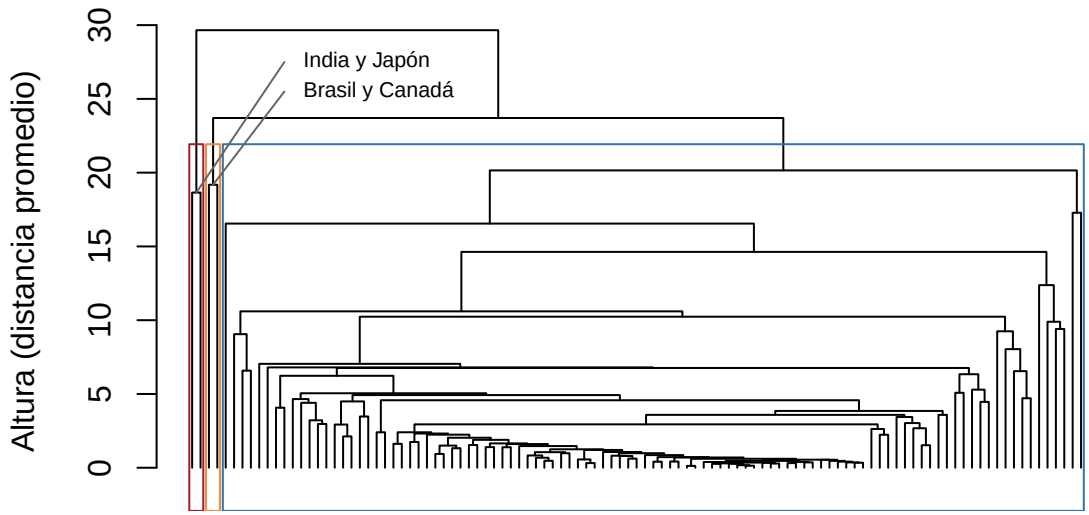


Figura 4.2: Dendrograma del enlace promedio con el corte en tres grupos, rotulando solo los cuatro países que quedan fuera de la rama grande: India y Japón, y Brasil y Canadá, se separan arriba del árbol mientras que los otros 103 países se unen en una sola rama.

```
knitr::kable(data.frame(
  k = 2:5,
  tamanos = sapply(2:5, function(k) paste(sort(table(
    cutree(hc_average, k)), decreasing = TRUE), collapse = "/")),
  silueta = sapply(2:5, function(k)
    round(sil(cutree(hc_average, k))$avg.width, 3))),
  col.names = c("k", "tamaños", "silueta"),
  caption = "Cortes del árbol de enlace promedio.")
```

Cuadro 4.3: Cortes del árbol de enlace promedio.

k	tamaños	silueta
2	105/2	0.752
3	103/2/2	0.713
4	101/2/2/2	0.686
5	101/2/2/1/1	0.678

```
mapa_paises(acp_sin4, c(1, 2), n = 14, grupos = kmedias)
```

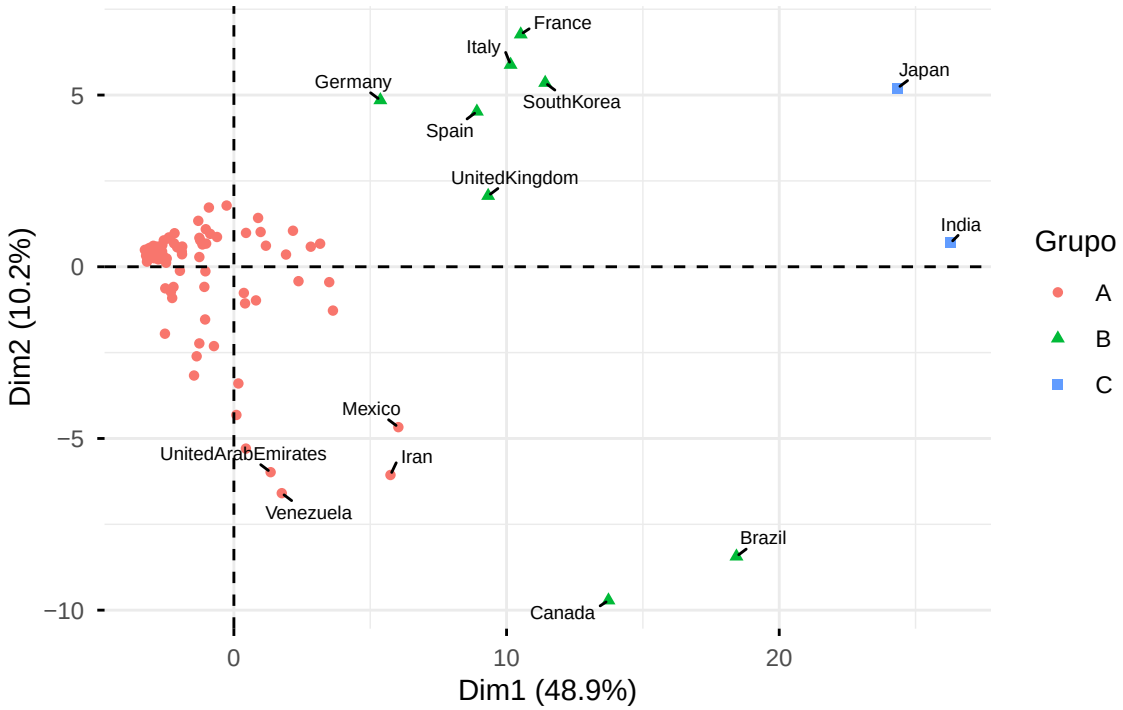


Figura 4.3: Grupos de k-medias sobre el plano (1,2) del ACP sin los cuatro países: El grupo B reúne las economías grandes de los dos brazos y el C a India y Japón.

¿Son diferentes los resultados de los dos análisis? Sí, aunque coinciden en lo principal pues 101 de los 107 países quedan en el grupo equivalente con ambos métodos:

a. **En qué coinciden.** Los dos aíslan a India y Japón como un grupo propio (grupo C) y dejan juntos a los mismos 97 países de la masa central.
b. **En qué difieren.** K-medias forma un grupo B de ocho economías grandes (Brasil, Canadá, Francia, Alemania, Italia, Corea del Sur, España y Reino Unido), mientras que el enlace promedio solo separa a Brasil y Canadá y devuelve los otros seis a la masa central, que queda de 103 países.

Esta diferencia viene de lo que optimiza cada método. K-medias minimiza la inercia intra-grupo y por eso arma un grupo intermedio que le da más varianza explicada (46.6 % frente a 39.0 %), mientras que el enlace promedio une primero lo que está cerca en promedio, de modo que solo deja por fuera a los pares más alejados, tanto así que cortar el árbol en cuatro o cinco grupos tampoco rescata a las seis economías intermedias sino que separa otro par o países sueltos (particiones de 101/2/2/2 y 101/2/2/1/1). La correlación cofenética de 0.986 indica que el árbol conserva muy bien las distancias, aunque cabe matizar que con una masa tan compacta y cuatro países tan lejanos cualquier árbol tiende a lograrlo. Por su parte la silueta media favorece al jerárquico (0.713 frente a 0.666), aunque la ventaja no se explica solo por el grupo B de k-medias, cuya silueta promedio de -0.022 indica que esos ocho países están en promedio tan cerca de la masa central como entre sí, sino sobre todo por la masa central pues las seis economías intermedias, al volver a ella, pasan de una silueta media de -0.051 a 0.262 y los 97 países que los dos métodos dejan juntos de 0.731 a 0.761, mientras que las dos parejas aisladas por el enlace promedio solo promedian 0.220 (el cálculo está al final de la pregunta). En resumen ambos métodos ven la misma estructura de una masa grande y pocos países extremos y lo que no está bien definido es si las economías grandes intermedias forman un grupo aparte.

```
inicios <- function(n) sapply(c(1, 42, 2026), function(s) {
  set.seed(s)
  round(kmeans(z, centers = 3, nstart = n)$tot.withinss, 1)
})
rbind(nstart_25 = inicios(25), nstart_100 = inicios(100))
```

```
             [,1]   [,2]   [,3]
nstart_25  3274.5 3231.9 3274.5
nstart_100 3226.7 3226.7 3226.7
```

> **Nota.** Con `nstart = 25` k-medias cae en óptimos locales distintos según la semilla (inercias de 3274.5 o 3231.9, con grupos de 90/14/3 y 95/10/2 países), mientras que con 100 arranques las tres semillas llegan a la misma partición de inercia 3226.7, que es también la que encuentra SDA Lab con 25 reinicios de k-medias++. Por eso se usan 100 arranques.

a. **Lectura local.** El grupo B es el punto débil de k-medias pues su silueta promedio es negativa (-0.022) y la de Alemania llega a -0.222, es decir que Alemania está más cerca, en promedio, de la masa central que de los otros siete países de su grupo.
b. **Lectura global.** Los dos métodos responden a la misma estructura de la base, una masa compacta con unos pocos extremos y difieren solo en la franja intermedia, que es justo donde los datos no tienen una frontera clara y donde cada criterio de optimización decide por su cuenta.

```r
s <- silhouette(as.integer(kmedias), distancias)
b <- kmedias == "B"
# vecino: El grupo más cercano a cada país después del suyo.
silueta_b <- data.frame(silueta = round(s[b, "sil_width"], 3),
                        vecino = LETTERS[s[b, "neighbor"]],
                        row.names = rownames(num)[b])
knitr::kable(silueta_b[order(silueta_b$silueta), ],
             caption = "Silueta y grupo vecino del grupo B.")
```

Cuadro 4.4: Silueta y grupo vecino del grupo B.

	silueta	vecino
Germany	-0.222	A
UnitedKingdom	-0.092	A
Spain	-0.054	A
SouthKorea	-0.021	A
Italy	0.020	A
Canada	0.046	A
France	0.062	A
Brazil	0.082	C

```r
# Si B se devuelve a la masa central quedan dos grupos: A+B y C.
sin_b <- droplevels(replace(kmedias, b, "A"))
round(c(explicada = explicada(sin_b),
        silueta = sil(sin_b)$avg.width), 3)
```

```
explicada   silueta
    0.245     0.752
```

Para decidir qué partición defender se comparan con k-medias otras cuatro particiones en tres grupos, dos de otros enlaces jerárquicos y dos de k-medias sobre las primeras componentes del ACP de la Pregunta 7, todas medidas sobre las 57 variables estandarizadas. Luego se descompone la silueta de los dos métodos por bloques de países.

```r
# Índice de Rand ajustado: 1 si dos particiones coinciden y cerca
# de 0 si coinciden lo que se esperaría al azar.
ari <- function(a, b) {
  t <- table(a, b)
  pares <- function(x) sum(choose(x, 2))
  f <- pares(rowSums(t))
  g <- pares(colSums(t))
  e <- f * g / choose(sum(t), 2)
  (pares(t) - e) / ((f + g) / 2 - e)
}
# K-medias sobre las primeras CP sin re-escalarlas, de modo que
# cada componente pesa según su varianza.
en_cp <- function(q) {
  set.seed(42)
  rotular(kmeans(acp_sin4$x[, 1:q], centers = 3,
                 nstart = 100)$cluster)
}
arbol <- function(m) rotular(cutree(hclust(distancias, m), 3))
alternativas <- list("k-medias" = kmedias,
                     "promedio" = promedio,
                     "completo" = arbol("complete"),
                     "Ward" = arbol("ward.D2"),
                     "k-medias CP1-CP4" = en_cp(4),
                     "k-medias CP1-CP6" = en_cp(6))
knitr::kable(t(sapply(alternativas, function(g) c(
  tamanos = paste(table(g), collapse = "/"),
  explicada = sprintf("%.1f", 100 * explicada(g)),
  silueta = sprintf("%.3f", sil(g)$avg.width),
  ARI = sprintf("%.3f", ari(kmedias, g))))),
  col.names = c("tamaños", "explicada (%)", "silueta", "ARI"),
  align = "lrrr",
  caption = "Particiones en tres grupos frente a k-medias.")
```

Cuadro 4.5: Particiones en tres grupos frente a k-medias.

	tamaños	explicada (%)	silueta	ARI
k-medias	97/8/2	46.6	0.666	1.000
promedio	103/2/2	39.0	0.713	0.528
completo	103/2/2	39.0	0.713	0.528
Ward	97/8/2	46.6	0.666	1.000
k-medias CP1-CP4	97/7/3	46.5	0.650	0.994
k-medias CP1-CP6	97/8/2	46.6	0.666	1.000

```r
round(c(promedio_completo = ari(promedio, alternativas$completo),
        cp4 = 100 * sum(acp_sin4$sdev[1:4]^2) / 57,
        cp6 = 100 * sum(acp_sin4$sdev[1:6]^2) / 57), 2)
```

```
promedio_completo               cp4               cp6
             1.00             73.92             82.78
```

```r
sp <- silhouette(as.integer(promedio), distancias)
comunes <- kmedias == "A" & promedio == "A"
seis <- kmedias == "B" & promedio == "A"
media <- function(x, i) round(mean(x[i, "sil_width"]), 3)
knitr::kable(data.frame(
  paises = c(sum(comunes), sum(seis), sum(promedio != "A")),
  k_medias = c(media(s, comunes), media(s, seis),
               media(s, promedio != "A")),
  promedio = c(media(sp, comunes), media(sp, seis),
               media(sp, promedio != "A")),
  row.names = c("masa común", "seis intermedios",
                "cuatro extremos")),
  col.names = c("países", "k-medias", "promedio"),
  caption = "Silueta media de cada bloque de países.")
```

Cuadro 4.6: Silueta media de cada bloque de países.

	países	k-medias	promedio
masa común	97	0.731	0.761
seis intermedios	6	-0.051	0.262
cuatro extremos	4	0.159	0.220

Notas

Interpretaciones.

a. **Cada método gana en su propio criterio.** K-medias explica más varianza (46.6 % frente a 39.0 %) porque eso es lo que minimiza y el enlace promedio tiene mejor silueta (0.713 frente a 0.666) porque no fuerza un grupo intermedio, de modo que «mejor» depende de qué se le pida a la partición.
b. **El grupo B de k-medias.** Su silueta promedio es −0.022, con cuatro de sus ocho países en negativo (Alemania −0.222, Reino Unido −0.092, España −0.054 y Corea del Sur −0.021) y los otros cuatro apenas por encima de cero (el mejor es Brasil con 0.082), por lo que B se comporta más como una franja de transición que como un grupo.
c. **Por qué el enlace promedio aísla parejas.** India y Japón, y Brasil y Canadá, están lejos en promedio de todos los demás, de modo que el árbol los une entre sí muy arriba y

los deja para el final. Al cortar en cuatro o cinco grupos se siguen separando parejas o países sueltos (101/2/2/2 y 101/2/2/1/1) y nunca las seis economías intermedias.

d. **El arranque importa.** Con `nstart = 25` la inercia depende de la semilla (3274.5 o 3231.9) y solo con 100 arranques se llega siempre a 3226.7 así que una partición de k-medias sin varios arranques puede ser un óptimo local.
e. **Qué k defendería cada uno.** Por silueta los dos preferirían $k = 2$ pues k-medias llega a 0.698 (98/9) y el enlace promedio a 0.752 (105/2, solo India y Japón aparte). El $k = 3$ se eligió por la varianza explicada y por la lectura del plano, no por la silueta.

Decisiones.

- **Las ocho economías del grupo B son el borde de la masa central y no un grupo propio.** Su silueta promedio es de -0.022 y la más alta es la de Brasil (0.082), de modo que las ocho quedan por debajo de 0.25, que es el valor desde el cual no se reconoce una estructura sustancial, mientras que siete de ellas tienen como grupo vecino a la masa central A y solo Brasil tiene como vecino al grupo de India y Japón. Si B se devuelve a la masa central la silueta sube de 0.666 a 0.752 pero la varianza explicada cae de 46.6 % a 24.5 % así que B se mantiene en la partición como una franja de transición que recoge la inercia de las economías grandes y no como un perfil energético distinto.

  Respaldo. Kaufman y Rousseeuw (1990, cap. 2) leen una silueta media de 0.25 o menos como ausencia de estructura sustancial y en la sesión 5 se mostró que un punto que queda entre dos grupos es el caso en que un método suave le asignaría una probabilidad cercana a 0.5 de pertenecer a cada uno.

- **Se defiende la partición de k-medias y el enlace promedio queda como chequeo.** K-medias explica el 46.6 % de la inercia frente al 39.0 % y es la partición que el enunciado usa en la Pregunta 11, mientras que la ventaja del enlace promedio en silueta (0.713 frente a 0.666) no viene de sus dos parejas, cuyos cuatro países promedian 0.220, sino de que al devolver a los seis países intermedios a la masa central estos pasan de -0.051 a 0.262 y los 97 países comunes de 0.731 a 0.761 porque su grupo vecino queda más lejos. Es decir que la silueta premia no formar el grupo intermedio, que es justo lo que se discute, por lo que no sirve para decidir entre los dos métodos. El índice de Rand ajustado (ARI), que vale 1 si dos particiones coinciden y cerca de 0 si coinciden como al azar, es de 0.528 entre ambos y esto se debe a que la diferencia se concentra en esos seis países pues los otros 101 quedan en el grupo equivalente.

  Respaldo. En la sesión 5 el objetivo del agrupamiento se planteó como grupos homogéneos por dentro y heterogéneos entre sí, que es el criterio que k-medias minimiza, se recomendó el argumento `nstart` para no quedarse en un óptimo local y los métodos se compararon por la concordancia de sus asignaciones, que aquí se mide con el índice de Hubert y Arabie (1985). El enlace promedio es el que se usa en la mayoría de los casos por ser robusto ante distancias particulares, por lo que entra como chequeo de la masa central y de los extremos.

- **Se agrupa sobre las 57 variables estandarizadas y las componentes quedan como diagnóstico.** K-medias sobre las cuatro primeras componentes sin re-escalar, que en los 107 países reúnen el 73.92 % de la varianza, da grupos de 97, 7 y 3 países con 46.5 % explicada, silueta de 0.650 y ARI de 0.994 frente a la partición de las 57 variables, es decir que la única diferencia es Brasil, que pasa del grupo B al de India y Japón, mientras que con seis componentes (82.78 %, las que pide el 80 % en la Pregunta 7) la partición es idéntica (ARI de 1.000). Esto tiene sentido pues las coordenadas sin re-escalar son una rotación de las variables estandarizadas que con todas las componentes conserva las mismas distancias, de modo que agrupar sobre las componentes no quita el peso repetido de las variables casi iguales (que ya está dentro de las componentes) y lo único que agrega quedarse con unas pocas es el riesgo de descartar información.

  Respaldo. El profesor dijo sobre agrupar en componentes que «en general no lo recomiendo» (sesión 4), usó el plano factorial como «una herramienta de diagnóstico, no como una parte del proceso» y advirtió que las componentes tardías pueden caracterizar un grupo que se pierde al quedarse con las primeras (sesión 5), que es lo que mostró Chang (1983) y lo que se critica del llamado análisis en tándem (Arabie y Hubert 1994).

- **El grupo intermedio es un rasgo del criterio de inercia y no solo de k-medias.** El enlace de Ward reproduce exactamente la partición de k-medias (97/8/2 y ARI de 1.000) mientras que el enlace completo reproduce la del promedio (103/2/2 y ARI de 1.00 entre ambos), de modo que los métodos se separan por lo que optimizan y no por ser jerárquicos o de partición pues Ward une en cada paso los dos grupos que menos aumentan la inercia intra-grupo, que es la misma $W(k)$ que minimiza k-medias, mientras que el promedio y el completo miden distancias entre pares de países y por eso dejan para el final a India, Japón, Brasil y Canadá.

  Respaldo. Ward (1963) define su enlace como el que minimiza el aumento de la suma de cuadrados dentro de los grupos y `ward.D2` es la versión de `hclust()` que aplica ese criterio sobre distancias euclidianas (Murtagh y Legendre 2014). En la sesión 5 se recomendó el enlace promedio en la mayoría de los casos y el completo o el simple para caracterizar valores inusuales, que es lo que hacen aquí al aislar las dos parejas extremas.

4.4. Pregunta 11 — Distribución de las cinco variables por grupo

```
largo <- stack(num[cinco])
largo$grupo <- rep(kmedias, times = length(cinco))
etiqueta <- function(g) sprintf("%s (%d)", g, table(kmedias)[g])
ggplot(largo, aes(x = etiqueta(grupo), y = values, fill = grupo)) +
  geom_boxplot(alpha = 0.6, show.legend = FALSE,
               outlier.size = 0.8) +
  stat_summary(fun = median, geom = "text", size = 2.4,
               vjust = -0.5,
               aes(label = round(after_stat(y), 1))) +
  facet_wrap(~ ind, scales = "free_y", nrow = 2) +
  # La escala se transforma DESPUÉS de calcular cajas y medianas,
  # para que la mediana anotada sea la de los datos originales.
  coord_transform(y = "pseudo_log") +
  scale_y_continuous(breaks = c(0, 10, 100, 1000, 10000)) +
  scale_fill_manual(values = c("#3572a8", "#f08a3c", "#a6192e")) +
  labs(x = "Grupo de k-medias (países)", y = "Valor") +
  theme_minimal(base_size = 9)
```

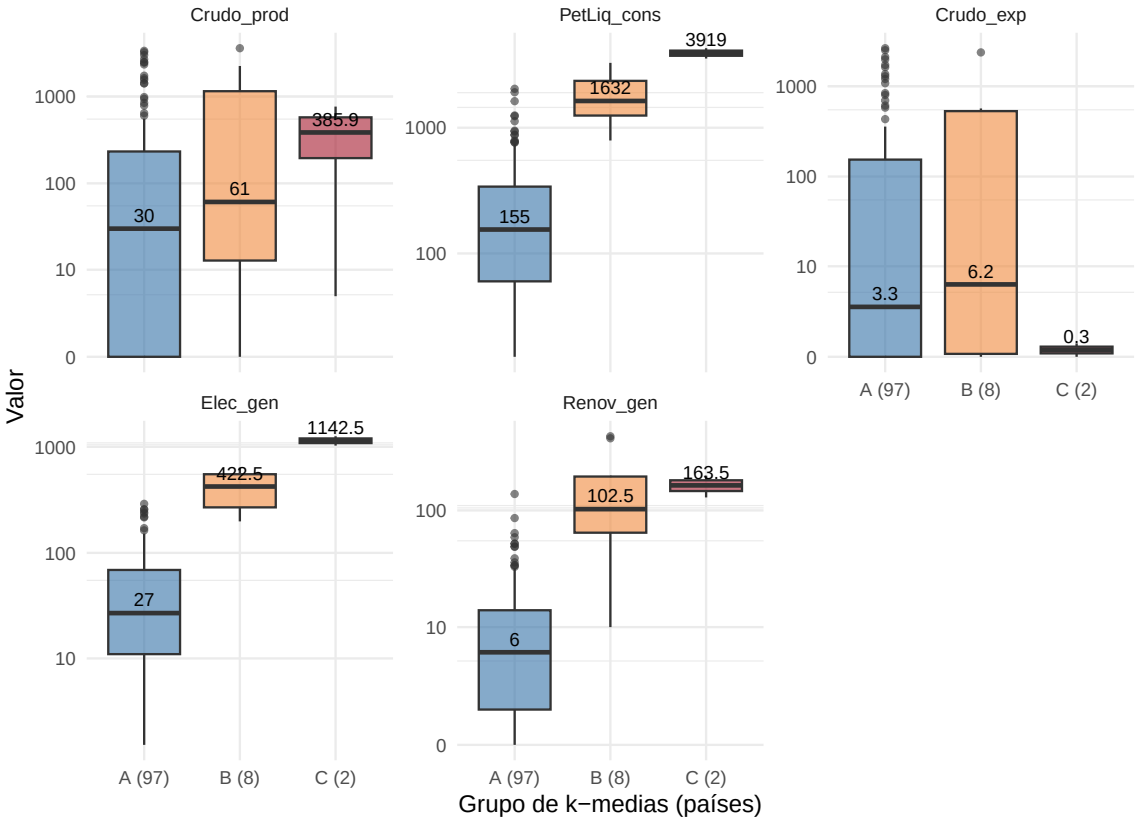


Figura 4.4: Distribución de las cinco variables de la Pregunta 1 por grupo de k-medias, en escala pseudo-logarítmica y con la mediana anotada: El consumo y la generación eléctrica y renovable crecen de A a C, mientras que la producción y la exportación de crudo no separan los grupos.

```
knitr::kable(sapply(cinco, function(v) tapply(num[[v]], kmedias,
  function(x) sprintf("%g a %g", round(min(x), 1),
                      round(max(x), 1)))),
  caption = "Rango (mínimo a máximo) de cada variable por grupo.")
```

Cuadro 4.7: Rango (mínimo a máximo) de cada variable por grupo.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
A	0 a 3370	15 a 2040	0 a 2651	0.9 a 290	0 a 138
B	0 a 3613	791.3 a 3279	0 a 2382	198 a 636	10 a 429
C	4.8 a 767	3550 a 4288	0 a 0.7	1027 a 1258	129 a 198

```r
exportadores <- order(-num$Crudo_exp)[1:5]
data.frame(exportacion = num$Crudo_exp[exportadores],
           grupo = kmedias[exportadores],
           row.names = rownames(num)[exportadores])
```

	exportacion	grupo
UnitedArabEmirates	2651	A
Iraq	2518	A
Canada	2382	B
Nigeria	2120	A
Kuwait	1995	A

```r
c(sin_exportar_A = sum(num$Crudo_exp[kmedias == "A"] == 0))
```

```
sin_exportar_A
            38
```

¿Hay diferencias importantes entre grupos en una misma variable? Sí en tres de las cinco variables (consumo de petróleo, generación eléctrica y generación renovable) y no en las dos petroleras (producción y exportación de crudo). Antes de leerlas vale la pena anotar que el grupo C tiene solo dos países (India y Japón) y el B ocho, de modo que sus cajas son apenas un resumen de pocos puntos y no una distribución y que el eje es pseudo-logarítmico porque los valores de los tres grupos difieren en órdenes de magnitud.

a. **Consumo de petróleo y generación eléctrica.** Las medianas crecen con claridad de A a C pues el consumo pasa de 155 a 1632 y a 3919 TBPD y la generación de 27 a 422.5 y a 1142.5 BKWH. India y Japón superan a todos los países de los otros grupos en las dos variables, aunque A y B se solapan en sus extremos, por ejemplo México consume 2040 TBPD y genera 290 BKWH siendo del grupo A, mientras que Alemania consume 791.3 TBPD y genera 198 BKWH siendo del grupo B.
b. **Generación renovable.** También crece de A a C (medianas de 6, 102.5 y 163.5 BKWH) pero con mucho solapamiento ya que el grupo B va de 10 BKWH (Corea del Sur) a 429 BKWH (Brasil) y el máximo de A (Noruega, 138 BKWH) supera incluso a Japón (129 BKWH) del grupo C.
c. **Producción de crudo.** No distingue los grupos, dado que los tres tienen países que casi no producen y el rango de A (de 0 a 3370 TBPD, este último Irak) cubre casi por completo los de B (de 0 a 3613) y C (de 4.8 a 767).
d. **Exportación de crudo.** Tampoco los distingue y además no crece con el tamaño pues las medianas son 3.3, 6.2 y 0.35 TBPD, India y Japón casi no exportan (0.7 y 0 TBPD) y cuatro de los cinco mayores exportadores de los 107 países (Emiratos Árabes Unidos con 2651 TBPD, Irak con 2518, Nigeria con 2120 y Kuwait con 1995) están en el grupo A, junto a 38 países que no exportan nada, mientras que el quinto, Canadá (2382 TBPD), está en B por su tamaño y no por su petróleo.

Se concluye que k-medias agrupó a los países por el tamaño de su consumo y de su sistema eléctrico, que es la información del primer eje del ACP y no por ser o no productores y exportadores de petróleo, que es la información del segundo eje.

a. **Lectura local.** Emiratos Árabes Unidos, el mayor exportador de crudo sin los cuatro atípicos, queda en el mismo grupo que países que no exportan nada porque en todo lo demás (consumo, generación) es un país mediano.
b. **Lectura global.** La partición sigue al tamaño porque la base mide sobre todo tamaño ya que 27 de las 57 variables están ligadas al primer eje y la dimensión petrolera la cargan unas pocas, de modo que en la distancia euclidiana entre países el petróleo pesa poco. Haber elegido la exportación en la Pregunta 1 es lo que permite verlo pues con las emisiones de CO_2 las cinco cajas habrían repetido el consumo.

Para ver si otra partición separa a los exportadores se repite k-medias con tres grupos sobre dos conjuntos que dan más peso al petróleo, las cinco variables de la Pregunta 1 estandarizadas y las componentes 2 y 3 del ACP de la Pregunta 7.

```
# Dos particiones que dan más peso al petróleo: Las cinco
# variables de la Pregunta 1 y las componentes 2 y 3 del ACP.
set.seed(42)
en_cinco <- rotular(kmeans(scale(num[cinco]), centers = 3,
                           nstart = 100)$cluster)
set.seed(42)
en_cp23 <- rotular(kmeans(acp_sin4$x[, 2:3], centers = 3,
                          nstart = 100)$cluster)
data.frame(exportacion = num$Crudo_exp[exportadores],
           k_medias = kmedias[exportadores],
           cinco = en_cinco[exportadores],
           cp2_cp3 = en_cp23[exportadores],
           row.names = rownames(num)[exportadores])
```

	exportacion	k_medias	cinco	cp2_cp3
UnitedArabEmirates	2651	A	B	B
Iraq	2518	A	B	B
Canada	2382	B	C	B
Nigeria	2120	A	B	B
Kuwait	1995	A	B	B

```
knitr::kable(t(sapply(list(cinco = en_cinco, cp2_cp3 = en_cp23),
  function(g) c(tamanos = paste(table(g), collapse = "/"),
    explicada = sprintf("%.1f", 100 * explicada(g)),
    ARI = sprintf("%.3f", ari(kmedias, g))))),
  col.names = c("tamaños", "explicada (%)", "ARI"), align = "lrr",
  caption = "Particiones con más peso petrolero.")
```

Cuadro 4.8: Particiones con más peso petrolero.

	tamaños	explicada (%)	ARI
cinco	93/10/4	36.9	0.244
cp2_cp3	93/10/4	21.1	0.405

```
split(rownames(num), en_cinco)[c("B", "C")]
```

```
$B
 [1] "Angola"             "Iran"
 [3] "Iraq"               "Kazakhstan"
 [5] "Kuwait"             "Mexico"
 [7] "Nigeria"            "Norway"
 [9] "UnitedArabEmirates" "Venezuela"

$C
[1] "Brazil" "Canada" "India"  "Japan"
```

```
split(rownames(num), en_cp23)[c("B", "C")]
```

```
$B
 [1] "Brazil"             "Canada"
 [3] "Iran"               "Iraq"
 [5] "Kuwait"             "Mexico"
 [7] "Nigeria"            "Norway"
 [9] "UnitedArabEmirates" "Venezuela"

$C
[1] "France"  "Germany" "Italy"   "Spain"
```

Notas

Interpretaciones.

a. **Lo que separa y lo que no.** Las medianas de consumo (155, 1632 y 3919 TBPD) y de

generación (27, 422.5 y 1142.5 BKWH) crecen de A a C, mientras que las de exportación (3.3, 6.2 y 0.35 TBPD) no siguen ningún orden.

b. **El petróleo queda dentro de A.** Cuatro de los cinco mayores exportadores de los 107 países (Emiratos Árabes Unidos, Irak, Nigeria y Kuwait) están en A, el mismo grupo de la masa central, es decir que la partición no reconoce al brazo de productores que se veía en la Pregunta 7.
c. **Cajas de pocos países.** C tiene dos países y B ocho así que sus cajas describen casos y no distribuciones.

Decisiones.

- **Agrupar con las cinco variables sí separa a los exportadores.** K-medias sobre las cinco variables estandarizadas forma un grupo B de diez países (Angola, Irán, Irak, Kazajistán, Kuwait, México, Nigeria, Noruega, Emiratos Árabes Unidos y Venezuela) que reúne a cuatro de los cinco mayores exportadores y deja a Canadá con Brasil, India y Japón, mientras que con las componentes 2 y 3 el grupo B reúne a los cinco mayores exportadores junto a Brasil, Irán, México, Noruega y Venezuela y el grupo C pasa a ser Francia, Alemania, Italia y España. Las dos particiones tienen grupos de 93, 10 y 4 países y concuerdan poco con la de las 57 variables (ARI de 0.244 y 0.405) así que no son un ajuste de la misma partición sino otra lectura de los países. Entre ellas se prefiere la de las cinco variables por coherencia con la decisión de la Pregunta 10 de no agrupar sobre componentes.

  Respaldo. El enunciado busca caracterizar a los países «en términos de importación, exportación, consumo, producción» y en la sesión 5 el profesor advirtió que el agrupamiento queda limitado a las variables que se le dan y que la segunda componente guardaba una separación que se pierde al agrupar sobre la primera, que es lo que ocurre aquí con el eje petrolero.

- **La partición pedida se mantiene y su sesgo de tamaño se reporta como limitación.** La Pregunta 11 pide los grupos de k-medias de la Pregunta 10, que explican el 46.6 % de la inercia de las 57 variables frente al 36.9 % de la partición de las cinco variables, de modo que la primera describe mejor la base completa pero lo que describe es tamaño, mientras que la segunda es la que responde al objetivo de separar productores y exportadores. Por esto los boxplots se dejan con la partición de k-medias y la de las cinco variables se cita como la alternativa que podría usarse si el interés fuera el perfil petrolero, con la salvedad de que depende de las cinco variables elegidas en la Pregunta 1.

  Respaldo. En la sesión 5 se insistió en que un grupo bien formado todavía no está caracterizado y que ese paso consiste en «entrar a los grupos, mirar cómo son», que es lo que hace esta pregunta y lo que deja ver que la partición de k-medias sigue al primer eje del ACP.

Bibliografía

Arabie, P. y L. Hubert (1994). "Cluster Analysis in Marketing Research". En: *Advanced Methods of Marketing Research*. Ed. por R. P. Bagozzi. Oxford: Blackwell, págs. 160-189.

Attali, D. y C. Baker (2025). *ggExtra: Add Marginal Histograms to 'ggplot2', and More 'ggplot2' Enhancements*. R package version 0.11.0. DOI: 10.32614/CRAN.package.ggExtra. URL: https://CRAN.R-project.org/package=ggExtra.

Chang, W.-C. (1983). "On Using Principal Components before Separating a Mixture of Two Multivariate Normal Distributions". En: *Journal of the Royal Statistical Society. Series C (Applied Statistics)* 32.3, págs. 267-275. DOI: 10.2307/2347949.

Hotelling, H. (1933). "Analysis of a Complex of Statistical Variables into Principal Components". En: *Journal of Educational Psychology* 24.6, págs. 417-441. DOI: 10.1037/h0071325.

Hubert, L. y P. Arabie (1985). "Comparing Partitions". En: *Journal of Classification* 2.1, págs. 193-218. DOI: 10.1007/BF01908075.

Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (2022). *Datos meteorológicos de la red de estaciones — región Orinoquía*. Descarga libre del portal IDEAM. URL: http://www.ideam.gov.co.

Johnson, R. A. y D. W. Wichern (2007). *Applied Multivariate Statistical Analysis*. 6.ª ed. Upper Saddle River, NJ: Pearson Prentice Hall.

Jolliffe, I. T. (2002). *Principal Component Analysis*. 2.ª ed. Springer Series in Statistics. New York: Springer. DOI: 10.1007/b98835.

Kaiser, H. F. (1960). "The Application of Electronic Computers to Factor Analysis". En: *Educational and Psychological Measurement* 20.1, págs. 141-151. DOI: 10.1177/001316446002000116.

Kassambara, A. y F. Mundt (2020). *factoextra: Extract and Visualize the Results of Multivariate Data Analyses*. R package version 1.0.7. DOI: 10.32614/CRAN.package.factoextra. URL: https://CRAN.R-project.org/package=factoextra.

Kaufman, L. y P. J. Rousseeuw (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley Series in Probability and Statistics. New York: John Wiley & Sons. DOI: 10.1002/9780470316801.

MacQueen, J. (1967). "Some Methods for Classification and Analysis of Multivariate Observations". En: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. University of California Press, págs. 281-297.

Murtagh, F. y P. Legendre (2014). "Ward's Hierarchical Agglomerative Clustering Method: Which Algorithms Implement Ward's Criterion?" En: *Journal of Classification* 31.3, págs. 274-295. DOI: 10.1007/s00357-014-9161-z.

Pearson, K. (1895). "Note on Regression and Inheritance in the Case of Two Parents". En: *Proceedings of the Royal Society of London* 58, págs. 240-242. DOI: 10.1098/rspl.1895.0041.

Pearson, K. (1901). “On Lines and Planes of Closest Fit to Systems of Points in Space”. En: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2.11, págs. 559-572. DOI: 10.1080/14786440109462720.

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R version 4.6.1. R Foundation for Statistical Computing. Vienna, Austria. URL: https://www.R-project.org.

Rousseeuw, P. J. (1987). “Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis”. En: *Journal of Computational and Applied Mathematics* 20, págs. 53-65. DOI: 10.1016/0377-0427(87)90125-7.

Schloerke, B., D. Cook, J. Larmarange, F. Briatte, M. Marbach, E. Thoen, A. Elberg y J. Crowley (2024). *GGally: Extension to 'ggplot2'*. DOI: 10.32614/CRAN.package.GGally. URL: https://CRAN.R-project.org/package=GGally.

Sokal, R. R. y C. D. Michener (1958). “A Statistical Method for Evaluating Systematic Relationships”. En: *University of Kansas Science Bulletin* 38, págs. 1409-1438.

Spearman, C. (1904). “The Proof and Measurement of Association between Two Things”. En: *The American Journal of Psychology* 15.1, págs. 72-101. DOI: 10.2307/1412159.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Reading, MA: Addison-Wesley.

U.S. Energy Information Administration (EIA) (2023). *International Energy Data: petroleum and electricity by country*. Extracción académica de 111 países publicada en Kaggle (overhcv/eia-united-states). URL: https://www.eia.gov/international/data/world.

— (2026). *International Energy Data: Definitions, Sources and Notes — Indicators of Carbon Dioxide Emissions*. Notas de tabla del navegador de datos internacionales. URL: https://www.eia.gov/international/content/info/table-notes.html (visitado 21-10-2026).

Ward, J. H. (1963). “Hierarchical Grouping to Optimize an Objective Function”. En: *Journal of the American Statistical Association* 58.301, págs. 236-244. DOI: 10.1080/01621459.1963.10500845.

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. URL: https://ggplot2.tidyverse.org.

Apéndice A

Documentación de R

Se listan las funciones utilizadas en el taller junto con el paquete que las provee y la pregunta donde se usan, cada una enlazada a su página de ayuda oficial. El documento se generó con R 4.6.1, `ggplot2` 4.0.3, `GGally` 2.4.0, `factoextra` 2.2.0 y `cluster` 2.1.8.2.

Cuadro A.1: Funciones de R utilizadas y enlace a su documentación.

Función	Paquete	Uso
`read.csv()`	utils	Carga
`download.file()`	utils	Carga
`source()`	base	Datos
`gsub()`	base	Datos
`cor()`	stats	Datos, P1, P2
`colMeans()`	base	P1
`median()`	stats	P1, P2
`cov()`	stats	P1
`prcomp()`	stats	P3, P4, P7
`mahalanobis()`	stats	P7
`qchisq()`	stats	P7
`log1p()`	base	P7
`scale()`	base	P9, P10
`facto_summarize()`	factoextra	P3
`fviz_contrib()`	factoextra	P3
`fviz_eig()`	factoextra	P4
`get_pca_var()`	factoextra	P5, P7
`get_pca_ind()`	factoextra	P6, P7
`fviz_pca_var()`	factoextra	P5
`fviz_pca_ind()`	factoextra	P6, P7, P10
`geom_text_repel()`	ggrepel	P6, P7, P10
`ggpairs()`	GGally	P2
`kmeans()`	stats	P9, P10, P11
`choose()`	base	P10
`dist()`	stats	P9, P10

Función	Paquete	Uso
`hclust()`	stats	P10
`cutree()`	stats	P10
`cophenetic()`	stats	P10
`rect.hclust()`	stats	P10
`silhouette()`	cluster	P9, P10
`stack()`	utils	P11
`ggplot()`	ggplot2	P9, P11
`geom_boxplot()`	ggplot2	P11
`facet_wrap()`	ggplot2	P11

Apéndice B

Abreviaturas de las variables

El archivo `R/abreviaturas.R`, que se carga en el chunk de configuración, trae las dos funciones con las que se acortan los nombres. La función `abreviar()` cambia cada fragmento del nombre original por su abreviatura y quita la unidad del final, mientras que `numericas()` arma la matriz `num` con las columnas numéricas y el país como nombre de fila.

```
# taller-02/R/abreviaturas.R
#
# Nombres cortos para las 57 variables de EIA.csv, que llegan a
# tener 60 caracteres y no caben en los gráficos. Se carga desde el
# chunk de configuración y su código se muestra en el Apéndice B.

# Cambia cada fragmento del nombre original por su abreviatura y
# quita la unidad del final (TBPD, BKWH, MK, MMTCD o BB). El orden
# importa: Los fragmentos largos van antes que los cortos que
# contienen.
abreviar <- function(v) {
  reglas <- c(
    Crude_oil_including_lease_condensate = "Crudo",
    Petroleum_and_other_liquids = "PetLiq",
    Refined_petroleum_products = "Refinados",
    Liquefied_petroleum_gases_.LPG. = "GLP",
    Natural_gas_plant_liquids = "LGN",
    Bunker_residual_fuel_oil = "BunkerRes",
    Bunker_fuel = "Bunker",
    Distillate_fuel_oil = "Destilado",
    Residual_fuel_oil = "Residual",
    Motor_gasoline = "Gasolina",
    Jet_fuel = "Jet",
    Kerosene = "Queroseno",
    Other_liquids = "OtrosLiq",
    Other_refined_products = "OtrosRef",
    Refinery_processing_gain = "GananciaRef",
```

```
    Hydroelectric_pumped_storage_electricity = "Bombeo",
    Hydroelectricity = "Hidro",
    Biomass_and_waste_electricity = "Biomasa",
    Fossil_fuels_electricity = "Fosil",
    Geothermal_electricity = "Geotermica",
    Non.hydro_renewable_electricity = "NoHidro",
    Renewable_electricity = "Renov",
    Nuclear_electricity = "Nuclear",
    Solar_electricity = "Solar",
    Tide_and_wave_electricity = "Mareas",
    Wind_electricity = "Eolica",
    Electricity = "Elec",
    installed_capacity = "cap",
    net_generation = "gen",
    net_consumption = "cons",
    net_imports = "impNeta",
    distribution_losses = "perdidas",
    CO2_emissions = "CO2",
    consumption = "cons",
    production = "prod",
    exports = "exp",
    imports = "imp",
    reserves = "reservas")
  for (r in names(reglas))
    v <- gsub(r, reglas[[r]], v, fixed = TRUE)
  sub("_(TBPD|BKWH|MK|MMTCD|BB)$", "", v)
}

# Las columnas numéricas, con el país como nombre de fila y los
# nombres abreviados.
numericas <- function(d) {
  num <- d[vapply(d, is.numeric, logical(1))]
  rownames(num) <- d$Country
  names(num) <- abreviar(names(num))
  num
}
```

Cuadro B.1: Abreviatura y nombre original (con su unidad).

Abreviatura	Variable
Bunker_cons	Bunker fuel consumption (TBPD)
BunkerRes_cons	Bunker residual fuel oil consumption (TBPD)
Crudo_exp	Crude oil including lease condensate exports (TBPD)
Crudo_imp	Crude oil including lease condensate imports (TBPD)
Crudo_prod	Crude oil including lease condensate production (TBPD)
Crudo_reservas	Crude oil including lease condensate reserves (BB)
Destilado_cons	Distillate fuel oil consumption (TBPD)
Destilado_prod	Distillate fuel oil production (TBPD)
Jet_cons	Jet fuel consumption (TBPD)
Jet_prod	Jet fuel production (TBPD)
Queroseno_cons	Kerosene consumption (TBPD)
Queroseno_prod	Kerosene production (TBPD)
GLP_cons	Liquefied petroleum gases (LPG) consumption (TBPD)
GLP_prod	Liquefied petroleum gases (LPG) production (TBPD)
Gasolina_cons	Motor gasoline consumption (TBPD)
Gasolina_prod	Motor gasoline production (TBPD)
LGN_prod	Natural gas plant liquids production (TBPD)
OtrosLiq_prod	Other liquids production (TBPD)
OtrosRef_cons	Other refined products consumption (TBPD)
OtrosRef_prod	Other refined products production (TBPD)
PetLiq_CO2	Petroleum and other liquids CO2 emissions (MMTCD)
PetLiq_cons	Petroleum and other liquids consumption (TBPD)
PetLiq_prod	Petroleum and other liquids production (TBPD)
Refinados_cons	Refined petroleum products consumption (TBPD)
Refinados_prod	Refined petroleum products production (TBPD)
GananciaRef	Refinery processing gain (TBPD)
Residual_cons	Residual fuel oil consumption (TBPD)
Residual_prod	Residual fuel oil production (TBPD)
Biomasa_cap	Biomass and waste electricity installed capacity (MK)
Biomasa_gen	Biomass and waste electricity net generation (BKWH)
Elec_perdidas	Electricity distribution losses (BKWH)
Elec_exp	Electricity exports (BKWH)
Elec_imp	Electricity imports (BKWH)
Elec_cap	Electricity installed capacity (MK)
Elec_cons	Electricity net consumption (BKWH)
Elec_gen	Electricity net generation (BKWH)
Elec_impNeta	Electricity net imports (BKWH)
Fosil_cap	Fossil fuels electricity installed capacity (MK)
Fosil_gen	Fossil fuels electricity net generation (BKWH)
Geotermica_cap	Geothermal electricity installed capacity (MK)
Geotermica_gen	Geothermal electricity net generation (BKWH)

Abreviatura	Variable
Bombeo_cap	Hydroelectric pumped storage electricity installed capacity (MK)
Bombeo_gen	Hydroelectric pumped storage electricity net generation (BKWH)
Hidro_cap	Hydroelectricity installed capacity (MK)
Hidro_gen	Hydroelectricity net generation (BKWH)
NoHidro_cap	Non-hydro renewable electricity installed capacity (MK)
NoHidro_gen	Non-hydro renewable electricity net generation (BKWH)
Nuclear_cap	Nuclear electricity installed capacity (MK)
Nuclear_gen	Nuclear electricity net generation (BKWH)
Renov_cap	Renewable electricity installed capacity (MK)
Renov_gen	Renewable electricity net generation (BKWH)
Solar_cap	Solar electricity installed capacity (MK)
Solar_gen	Solar electricity net generation (BKWH)
Mareas_cap	Tide and wave electricity installed capacity (MK)
Mareas_gen	Tide and wave electricity net generation (BKWH)
Eolica_cap	Wind electricity installed capacity (MK)
Eolica_gen	Wind electricity net generation (BKWH)