UNIVERSIDAD DEL ROSARIO

Escuela de Ingeniería, Ciencia y Tecnología

Maestría en Matemáticas Aplicadas y Ciencias de la Computación

Taller 2 — Componentes principales y agrupamiento de países (EIA)

Análisis Estadístico de Datos

Integrantes

Anyelo Leonardy Alvarez Baquero
Daniel Arias Mutis
Tania Fernanda Mora Cubillos
Over Haider Castrillón Valencia

Profesor

Andrés Nicolás López López

Bogotá D.C., 7 de octubre de 2026

Resumen

Se estudian 111 países descritos por 57 variables de petróleo y electricidad de la U.S. Energy Information Administration (EIA). Primero se eligen cinco variables, una por dimensión y con poca redundancia entre sí (producción de crudo, consumo de petróleo, exportación de crudo, generación eléctrica y generación renovable), se estiman su vector de medias y su matriz de covarianzas y se describen de forma univariada y bivariada, encontrando distribuciones muy asimétricas dominadas por unos pocos países y dos bloques casi independientes, el de la oferta petrolera y el del tamaño energético. Luego se ejecuta un análisis de componentes principales (ACP) normado y otro sin normalizar, se eligen cuatro componentes por el criterio del 80 % de varianza acumulada y se interpretan las variables y los países en los planos (1,2) y (2,3), donde el primer eje resulta ser el tamaño energético del país y los siguientes oponen productores de petróleo a productores de electricidad renovable. Al retirar a Estados Unidos, China, Arabia Saudita y Rusia el primer eje pasa de explicar el 62 % al 49 % y aparecen dos brazos de países que sugieren tres grupos. Finalmente se eligen tres grupos por la reducción de varianza explicada y se comparan k-medias y el agrupamiento jerárquico de enlace promedio, que coinciden en 101 de los 107 países y en separar a India y Japón, pero difieren en cómo tratan a ocho economías grandes, mientras que las cajas por grupo muestran que la partición sigue al consumo, generación eléctrica y no a la producción ni a la exportación de crudo.

Palabras clave: Análisis de componentes principales; Círculo de correlaciones; Criterio de Kaiser; K-medias; Agrupamiento jerárquico; Silueta; EIA

Índice general

Resumen **1**

1. Los datos **3**
1.1. Estructura de las variables . . . 3
1.2. Diagnóstico de la base . . . 4

2. Normal multivariada **7**
2.1. Pregunta 1 — Vector de medias y matriz de covarianzas . . . 7

3. Análisis de componentes principales **11**
3.1. Pregunta 2 — Análisis descriptivo univariado y bivariado . . . 11
3.2. Pregunta 3 — Contribuciones en el ACP normado y sin normalizar . . . 15
3.3. Pregunta 4 — Número de componentes . . . 19
3.4. Pregunta 5 — Representación de las variables . . . 22
3.5. Pregunta 6 — Mapa de individuos . . . 27
3.6. Pregunta 7 — ACP sin los cuatro países atípicos . . . 30

4. Agrupamiento **35**
4.1. Pregunta 8 — Número de grupos en el primer plano . . . 35
4.2. Pregunta 9 — Número de grupos por reducción de varianza explicada . . . 35
4.3. Pregunta 10 — K-medias frente a jerárquico de enlace promedio . . . 38
4.4. Pregunta 11 — Distribución de las cinco variables por grupo . . . 45

Bibliografía **50**

A. Documentación de R **52**

B. Abreviaturas de las variables **54**

Capítulo 1

Los datos

La base `EIA.csv` reúne, para 111 países, 57 variables de producción, consumo, comercio y capacidad instalada de petróleo y electricidad publicadas por la U.S. Energy Information Administration (EIA 2023), donde cada unidad estadística (UE) es un país. Las unidades vienen en el sufijo de cada nombre, es decir, TBPD son miles de barriles por día, MMTCD millones de toneladas métricas de CO_2, BKWH miles de millones de kWh, MK millones de kW y BB miles de millones de barriles. Todo el análisis se realiza en R (R Core Team 2026) con gráficos de `ggplot2` (Wickham 2016), `GGally` (Schloerke et al. 2024) y `factoextra` (Kassambara y Mundt 2020), mientras que la documentación de cada función utilizada se reúne en el Apéndice A.

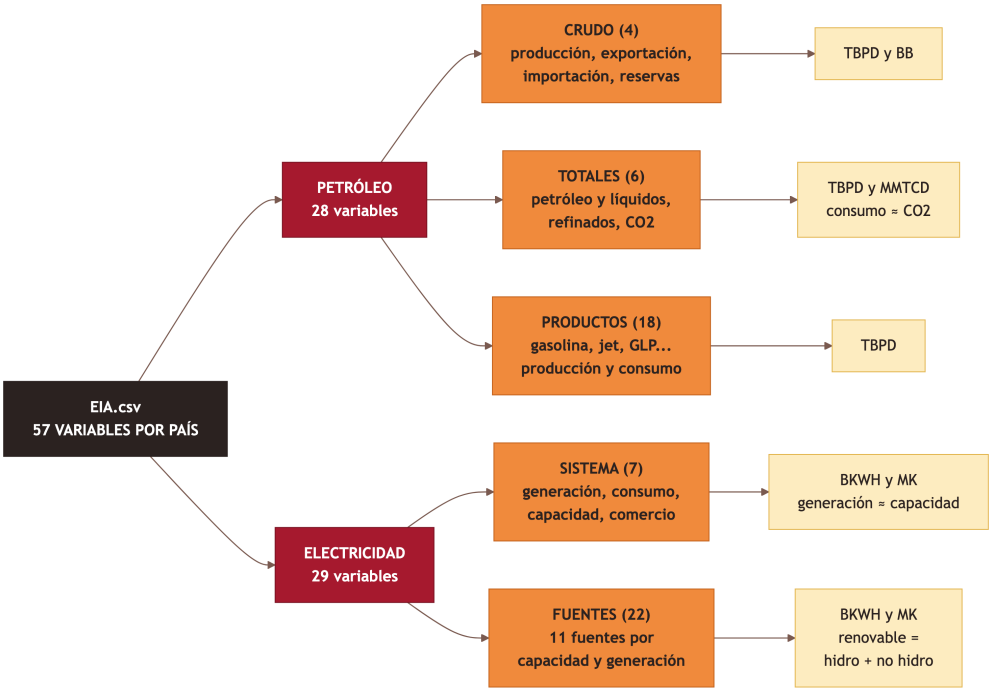
La base se descarga de Kaggle o, en caso de no haber conexión, se busca una copia local.

```
url <- paste0("https://www.kaggle.com/api/v1/datasets/download/",
              "overhcv/eia-united-states")
zip <- file.path(tempdir(), "kaggle.zip")
ruta <- tryCatch({
  download.file(url, zip, mode = "wb", quiet = TRUE)
  unzip(zip, files = "EIA.csv", exdir = tempdir())
}, error = function(e) {
  Filter(file.exists, c("EIA.csv", "data/EIA.csv",
                        "../../../data/EIA.csv"))[1]
})
datos <- read.csv(ruta, sep = ";", dec = ".",
                  stringsAsFactors = FALSE)
```

1.1. Estructura de las variables

Los nombres originales llegan a tener 60 caracteres, por lo que se reemplazan por abreviaturas con la función `abreviar()` del archivo `R/abreviaturas.R`, que se carga al inicio y cuyo código y tabla de equivalencias decidimos mover al Apéndice B al ser tan extensa la tabla. Por ejemplo `PetLiq_cons` es el consumo de petróleo y otros líquidos y `Renov_gen` la generación neta de electricidad renovable. Antes de calcular nada vale la pena ver cómo están organizadas las 57 variables pues no son 57 mediciones independientes sino un árbol en el que cada total se

vuelve a medir en sus partes.



Estructura de las 57 variables por sector energético, bloque y unidad: Cada total se repite en sus partes y cada fuente eléctrica se mide dos veces, por lo que la base es redundante desde su diseño.

El petróleo se describe en tres niveles (el crudo que se extrae y se comercia, los totales de petróleo, refinados y emisiones, y los productos uno por uno), mientras que la electricidad se describe como sistema (generación, consumo, capacidad, comercio y pérdidas) y por fuente, con cada una de las 11 fuentes medida en capacidad instalada y en generación.

1.2. Diagnóstico de la base

La matriz `num` guarda las 57 variables numéricas con el país como nombre de fila y sobre ella se cuentan los faltantes y las variables casi repetidas.

```r
num <- numericas(datos)
r <- cor(num)
knitr::kable(data.frame(nrow(num), ncol(num), sum(is.na(num)),
                        anyDuplicated(names(num)),
                        sum(r[upper.tri(r)] > 0.99),
                        sum(duplicated(as.list(num)))),
             col.names = c("Países", "Variables", "Faltantes",
                           "Nombres repetidos", "Pares r > 0.99",
                           "Columnas repetidas"),
             caption = "Diagnóstico de la base.")
```

Cuadro 1.1: Diagnóstico de la base.

Países	Variables	Faltantes	Nombres repetidos	Pares r > 0.99	Columnas repetidas
111	57	0	0	18	1

```r
pares <- which(upper.tri(r) & r > 0.99, arr.ind = TRUE)
cat(strwrap(paste(names(num)[pares[, 1]], names(num)[pares[, 2]],
                  sep = "~", collapse = ", "), 64), sep = "\n")
```

```
Gasolina_cons~Gasolina_prod, PetLiq_CO2~PetLiq_cons,
PetLiq_CO2~Refinados_cons, PetLiq_cons~Refinados_cons,
Gasolina_prod~GananciaRef, Elec_cap~Elec_cons,
Elec_cap~Elec_gen, Elec_cons~Elec_gen, Elec_cap~Fosil_cap,
Elec_cons~Fosil_cap, Elec_gen~Fosil_cap, Elec_cons~Fosil_gen,
Elec_gen~Fosil_gen, Fosil_cap~Fosil_gen,
Geotermica_cap~Geotermica_gen, Hidro_cap~Hidro_gen,
Nuclear_cap~Nuclear_gen, Renov_cap~Renov_gen
```

```r
names(num)[duplicated(
  as.list(num))]
```

```
[1] "Refinados_cons"
```

```r
max(abs(num$Renov_gen -
  num$Hidro_gen -
  num$NoHidro_gen))
```

```
[1] 1
```

¿Está lista la base para el análisis? Sí pues no hay datos faltantes y las 57 abreviaturas son distintas entre sí, aunque la base es muy redundante y esto hay que tenerlo presente desde ya:

a. **Lectura local.** La columna repetida, `Refinados_cons`, es el consumo de productos refinados, que resulta idéntico al consumo de petróleo y otros líquidos, mientras que la generación renovable coincide con la suma de la hidroeléctrica y la no hidroeléctrica salvo por una unidad de redondeo. Es decir que hay variables que no aportan nada que no esté ya en otra.

b. **Lectura global**. Los 18 pares con correlación mayor a 0.99 no son casualidad sino consecuencia del árbol de la figura anterior ya que cinco son la capacidad y la generación de una misma fuente (fósil, hidro, nuclear, geotérmica y renovable), ocho son el sistema eléctrico consigo mismo y con su parte fósil, tres son el consumo de petróleo, el de refinados y las emisiones entre sí, y dos son la producción de gasolina con su consumo y con la ganancia de refinación. Esto pesa en el ACP porque cada copia de una misma información suma varianza al mismo eje y en el agrupamiento porque las distancias entre países cuentan varias veces lo mismo.

Capítulo 2

Normal multivariada

2.1. Pregunta 1 — Vector de medias y matriz de covarianzas

¿Qué cinco variables y por qué? Se eligió una variable por cada dimensión de la base, buscando que entre ellas hubiera poca redundancia, ya que dos variables casi iguales describen dos veces lo mismo y no dicen nada nuevo de los países:

a. **Oferta petrolera.** Se mide con la producción de crudo (`Crudo_prod`, TBPD), que indica cuánto petróleo extrae el país.
b. **Demanda petrolera.** Se mide con el consumo de petróleo y otros líquidos (`PetLiq_cons`, TBPD), que refleja el tamaño de la economía que lo usa.
c. **Comercio petrolero.** Se mide con la exportación de crudo (`Crudo_exp`, TBPD), que distingue al país que vende su petróleo del que lo consume.
d. **Escala eléctrica.** Se mide con la generación neta de electricidad (`Elec_gen`, BKWH), que es el tamaño del sistema eléctrico.
e. **Transición energética.** Se mide con la generación neta renovable (`Renov_gen`, BKWH), que indica cuánto de esa electricidad viene de fuentes renovables.

Intentamos respaldar las elecciones con la matriz de correlación de las candidatas, que incluye las emisiones de CO_2 por petróleo (`PetLiq_CO2`), la variable que a primera vista representaría la dimensión ambiental.

```r
candidatas <- c("Crudo_prod", "PetLiq_cons", "PetLiq_CO2",
                "Crudo_exp", "Elec_gen", "Renov_gen")
knitr::kable(round(cor(num[candidatas]), 2),
             caption = "Correlación de Pearson de las candidatas.")
```

Cuadro 2.1: Correlación de Pearson de las candidatas.

	Crudo_prod	PetLiq_cons	PetLiq_CO2	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	1.00	0.64	0.64	0.83	0.52	0.44
PetLiq_cons	0.64	1.00	1.00	0.17	0.92	0.77
PetLiq_CO2	0.64	1.00	1.00	0.17	0.92	0.77
Crudo_exp	0.83	0.17	0.17	1.00	0.07	0.06
Elec_gen	0.52	0.92	0.92	0.07	1.00	0.92
Renov_gen	0.44	0.77	0.77	0.06	0.92	1.00

Las emisiones de CO_2 se descartan porque tienen correlación de 1.00 con el consumo, lo cual indica que se derivan del petróleo consumido y que incluirlas sería contar dos veces la demanda. En su lugar entra la exportación de crudo, que casi no se asocia con el bloque de tamaño (0.17 con el consumo, 0.07 con la generación y 0.06 con la renovable) y sí con la producción (0.83), aunque sin repetirla pues como se ve en la Pregunta 2 hay países que producen sin exportar. Las otras tres variables tienen entre sí correlaciones altas (de 0.77 a 0.92) pero describen cosas distintas ya que el consumo de petróleo es demanda de combustibles y la generación es electricidad, mientras que la renovable es solo una parte de esa electricidad cuyo peso cambia mucho de un país a otro.

Sobre las $n = 111$ filas se estiman el vector de medias y la matriz de varianzas y covarianzas muestrales

$$\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i, \qquad S = \frac{1}{n-1}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^{\top},$$

que son los estimadores insesgados de μ y Σ en el modelo normal multivariado explicado en clase (el de máxima verosimilitud de Σ que se divide por n en vez de $n-1$).

```r
cinco <- c("Crudo_prod", "PetLiq_cons", "Crudo_exp", "Elec_gen",
           "Renov_gen")
X <- num[cinco]
knitr::kable(data.frame(Variable = cinco,
                        Unidad = c("TBPD", "TBPD", "TBPD", "BKWH",
                                   "BKWH"),
                        Media = round(colMeans(X), 2),
                        Mediana = sapply(X, median),
                        row.names = NULL),
             caption = "Vector de medias (y mediana).")
```

Cuadro 2.2: Vector de medias (y mediana).

Variable	Unidad	Media	Mediana
Crudo_prod	TBPD	702.06	38.0
PetLiq_cons	TBPD	811.40	202.0
Crudo_exp	TBPD	361.56	8.5
Elec_gen	BKWH	198.29	43.0
Renov_gen	BKWH	44.77	8.3

```r
knitr::kable(round(cov(X), 1),
             caption = "Matriz de varianzas y covarianzas S.")
```

Cuadro 2.3: Matriz de varianzas y covarianzas S.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	3032022.8	2471112.6	1374119.6	594768.9	110047.2
PetLiq_cons	2471112.6	4858882.6	358231.7	1332865.6	245051.1
Crudo_exp	1374119.6	358231.7	907732.0	41014.9	8667.9
Elec_gen	594768.9	1332865.6	41014.9	434095.0	87623.9
Renov_gen	110047.2	245051.1	8667.9	87623.9	20864.5

Vector de medias. Se estima $\bar{\mathbf{x}} = (702.06,\ 811.40,\ 361.56,\ 198.29,\ 44.77)^\top$, es decir que un país promedio produce 702 mil barriles diarios de crudo, consume 811 mil barriles diarios de petróleo, exporta 362 mil barriles diarios de crudo y genera 198 mil millones de kWh, de los cuales 45 son renovables.

Matriz de covarianzas. Todas las covarianzas son positivas, lo que significa que las cinco variables crecen juntas y que un país que consume más petróleo también tiende a generar más electricidad. Sus magnitudes en cambio no se pueden comparar entre sí puesto que cada entrada lleva el producto de las unidades de sus dos variables (por ejemplo, la varianza del consumo está en TBPD² y su covarianza con la generación en TBPD·BKWH), por lo que la fuerza de cada asociación se lee en la Pregunta 2 con la correlación.

a. **Lectura local.** Como tal el país promedio no existe pues la media de la exportación de crudo (361.56 TBPD) es 42 veces su mediana (8.5 TBPD) y la de la producción (702.06 TBPD) más de 18 veces la suya (38 TBPD), de modo que cada componente de $\bar{\mathbf{x}}$ la fijan unos pocos países y no el país típico.
b. **Lectura global.** Bajo normalidad multivariada $\bar{\mathbf{x}}$ y S resumirían toda la distribución, pero estos datos están lejos de ser normales y S mezcla dos bloques, el petrolero (producción y exportación) y el de tamaño (consumo, generación y renovable), que casi no se mueven juntos. Esto puede anticiparnos que una sola dirección no baste para describir a los países y que el ACP necesite al menos dos ejes.

Notas

Interpretaciones.

a. **La elección es del grupo.** Con las cinco variables se cubren la oferta, la demanda y el comercio de petróleo, la escala eléctrica y la transición, y la única redundancia evidente (consumo y CO_2, $r = 1.00$) quedó por fuera.
b. **El costo de la elección.** La producción y la exportación de crudo comparten el 69 % de su variación (0.83^2) así que el bloque petrolero pesa doble en las preguntas 2 y 11, del mismo modo que el de tamaño pesa triple.

Preguntas para el profesor.

- ¿Se debió medir por habitante y no en términos absolutos? La base no trae población, de modo que no se puede verificar qué cambiaría.

  Por qué importa. En términos absolutos el consumo, la generación y la renovable crecen con el tamaño del país, de modo que parte de su correlación (de 0.77 a 0.92) y del primer eje del ACP puede deberse a la población y no al perfil energético.

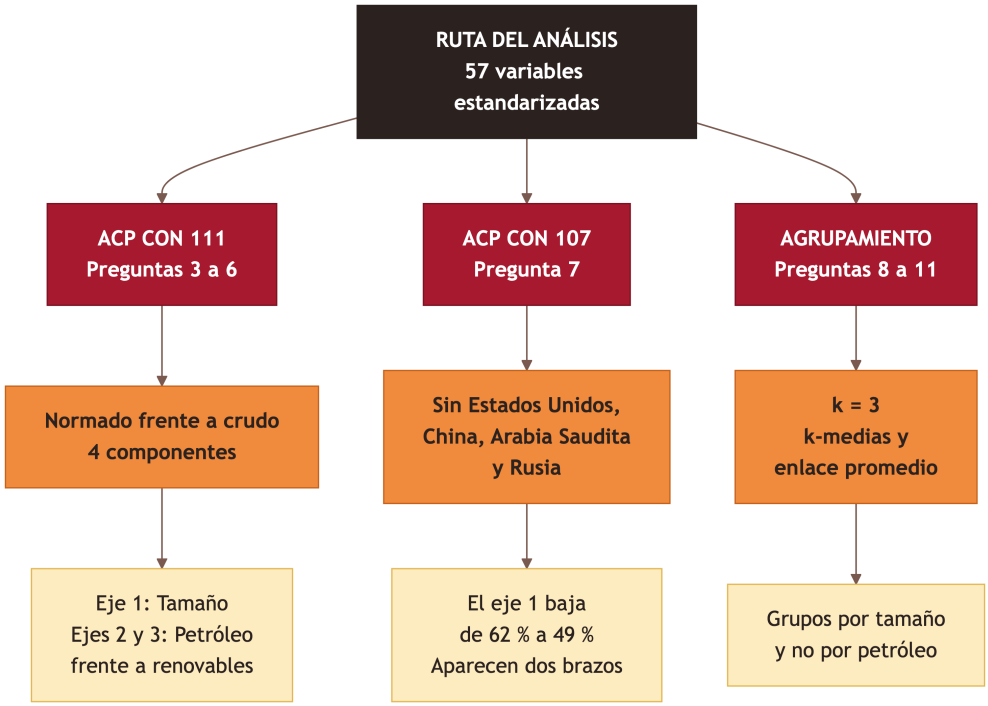
- ¿La dimensión ambiental se pierde al quitar el CO_2 o ya está implícita en el consumo?

  Por qué importa. La correlación de 1.00 sugiere que las emisiones se calculan a partir del petróleo consumido, por lo que no aportarían nada nuevo, pero si el enunciado espera una dimensión ambiental explícita hay que justificar su ausencia en las cinco variables.

Capítulo 3

Análisis de componentes principales

Las preguntas 2 a 11 siguen la ruta del diagrama, consideramos que conviene tenerlo a la mano porque el número de países y lo que se busca cambian por el camino. Primero se describen las cinco variables (Pregunta 2) y luego se resume la base completa con el ACP, primero con los 111 países y después sin los cuatro más extremos, para terminar agrupando a los 107 restantes.



Ruta del análisis de las preguntas 3 a 11: Cada etapa cambia los países o la pregunta, y las conclusiones de una justifican la siguiente.

3.1. Pregunta 2 — Análisis descriptivo univariado y bivariado

```r
resumen <- t(sapply(X, function(x)
  c(media = mean(x), mediana = median(x), s = sd(x), min = min(x),
    max = max(x), g1 = g1(x), ceros = sum(x == 0))))
knitr::kable(round(resumen, 2),
             caption = "Resumen univariado de las cinco variables.")
```

Cuadro 3.1: Resumen univariado de las cinco variables.

	media	mediana	s	min	max	g1	ceros
Crudo_prod	702.06	38.0	1741.27	0.0	10107	3.91	27
PetLiq_cons	811.40	202.0	2204.29	15.0	19100	6.32	0
Crudo_exp	361.56	8.5	952.75	0.0	7120	4.48	41
Elec_gen	198.29	43.0	658.86	0.9	5400	6.46	0
Renov_gen	44.77	8.3	144.45	0.0	1287	6.56	11

```r
knitr::kable(sapply(X, function(x) rownames(X)[order(-x)][1:3]),
             caption = "Los tres países con el valor más alto.")
```

Cuadro 3.2: Los tres países con el valor más alto.

Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Russia	UnitedStates	SaudiArabia	China	China
SaudiArabia	China	Russia	UnitedStates	UnitedStates
UnitedStates	Japan	UnitedArabEmirates	India	Brazil

```r
sum(X$Crudo_prod > 0 &
    X$Crudo_exp == 0)
```

```
[1] 16
```

```r
rownames(X)[X$Crudo_exp > 0 &
  X$Crudo_prod == 0]
```

```
[1] "Senegal"   "Singapore"
```

```
ggpairs(X, upper = list(continuous = wrap("cor", size = 3)),
        lower = list(continuous = wrap("points", size = 0.6,
                                       alpha = 0.5))) +
  theme_minimal(base_size = 8)
```

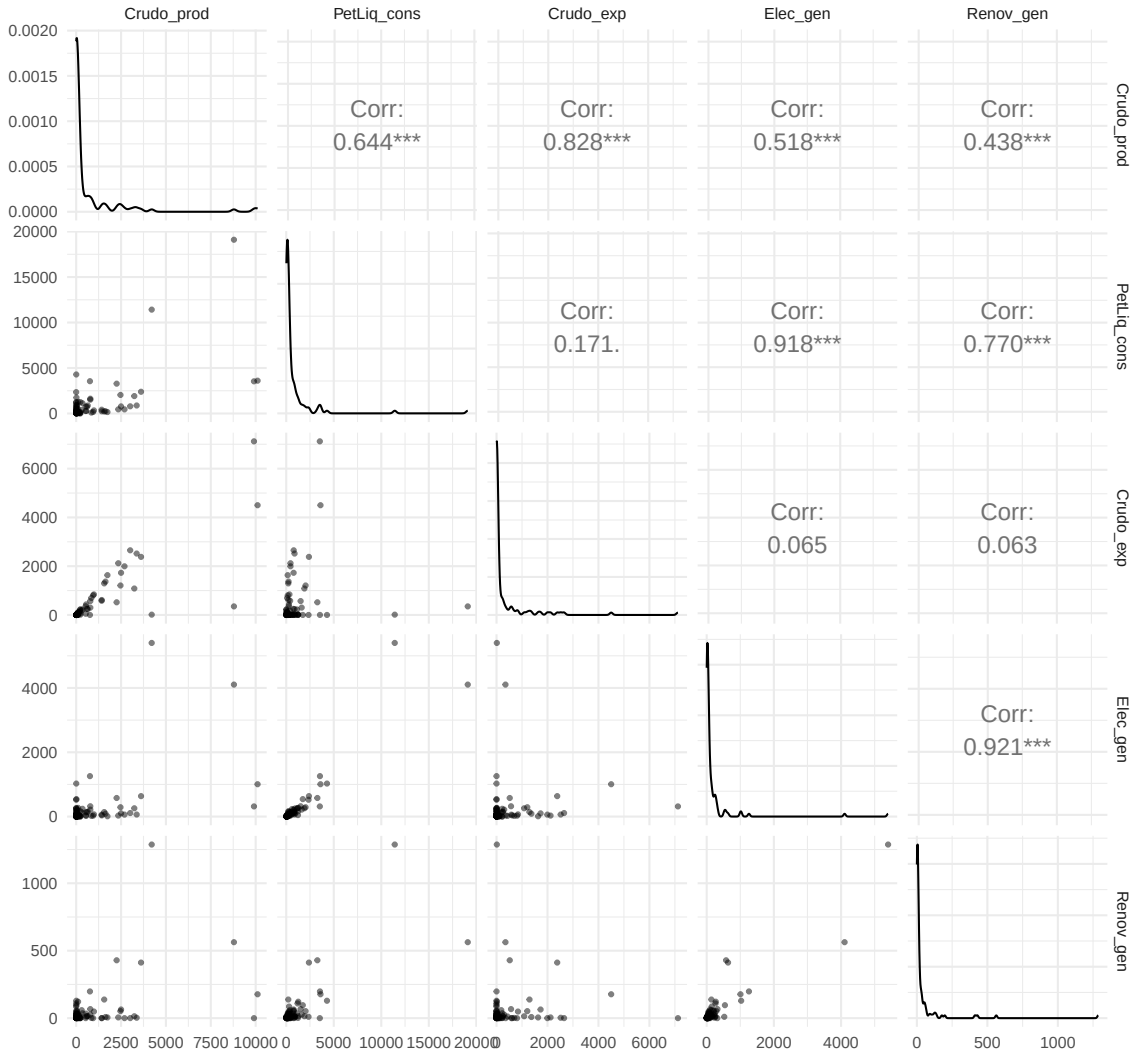


Figura 3.1: Matriz de dispersión de las cinco variables con densidades en la diagonal y correlación de Pearson arriba: Casi toda la nube está pegada al origen, unos pocos países definen las correlaciones y la exportación de crudo solo se asocia con la producción.

```
knitr::kable(round(cor(X, method = "spearman"), 2),
             caption = "Correlación de Spearman.")
```

Cuadro 3.3: Correlación de Spearman.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
Crudo_prod	1.00	0.48	0.89	0.42	0.14
PetLiq_cons	0.48	1.00	0.39	0.92	0.57
Crudo_exp	0.89	0.39	1.00	0.28	0.01
Elec_gen	0.42	0.92	0.28	1.00	0.67
Renov_gen	0.14	0.57	0.01	0.67	1.00

```
sin <- X[rownames(X) != "China", ]
round(cor(sin$Elec_gen,
  sin$Renov_gen), 3)
```

```
[1] 0.803
```

Univariado. Las cinco variables tienen asimetría positiva extrema, con coeficientes g_1 entre 3.91 (producción de crudo) y 6.56 (generación renovable), así como medias muy por encima de sus medianas, por ejemplo 811.40 contra 202 TBPD en el consumo de petróleo y 361.56 contra 8.5 TBPD en la exportación de crudo. Las densidades de la diagonal lo muestran como un pico pegado al cero con una cola larga a la derecha formada por los países más grandes ya que Estados Unidos y China ocupan los primeros puestos en consumo y generación, mientras que Rusia, Arabia Saudita y Estados Unidos encabezan la producción de crudo y Arabia Saudita, Rusia y Emiratos Árabes Unidos la exportación. Además la producción vale cero en 27 países y la exportación en 41, de modo que 16 países producen crudo sin exportarlo y dos (Senegal y Singapur) lo exportan sin producirlo, lo cual podría deberse a reexportaciones que la base no permite verificar.

Bivariado. Las asociaciones son todas positivas pero se ordenan en dos bloques:

a. **Bloque petrolero.** La producción y la exportación de crudo tienen correlación de Pearson (Pearson 1895) de 0.828 ya que solo exporta crudo quien lo produce, aunque no todo productor lo exporta.
b. **Bloque de tamaño.** El consumo de petróleo y la generación eléctrica se asocian con $r = 0.918$ y la generación con la renovable con $r = 0.921$, es decir que estas tres siguen al tamaño de la economía.
c. **Entre bloques.** La exportación casi no se asocia con el bloque de tamaño (0.171 con el consumo, 0.065 con la generación y 0.063 con la renovable), dado que los tres mayores consumidores (Estados Unidos, China y Japón) exportan poco o nada, mientras que la producción de crudo hace de puente entre ambos bloques (0.644 con el consumo y 0.518 con la generación).

Vale la pena matizar que varias de estas correlaciones dependen de los países extremos pues la de Spearman (Spearman 1904), que usa rangos y no se deja arrastrar por los valores grandes, baja de 0.921 a 0.672 entre generación y renovable, de 0.770 a 0.569 entre consumo y renovable y

de 0.438 a 0.140 entre producción de crudo y renovable. Solo el par consumo-generación (0.918) y el par producción-exportación (de 0.828 a 0.891) se mantienen con ambos coeficientes.

a. **Lectura local.** Un solo país mueve una correlación ya que sin China la de Pearson entre generación y renovable baja de 0.921 a 0.803 porque China es a la vez el mayor generador y el mayor productor de renovables.
b. **Lectura global.** Con rangos la separación entre bloques es todavía más clara (0.010 entre exportación y renovable), de modo que las cinco variables viven en al menos dos dimensiones casi independientes, la de tamaño y la petrolera, que podrían ser las que el ACP de la Pregunta 5 encuentre en sus dos primeros ejes con las 57 variables.

3.2. Pregunta 3 — Contribuciones en el ACP normado y sin normalizar

El análisis de componentes principales (ACP) (Pearson 1901; Hotelling 1933) busca combinaciones lineales de las variables, no correlacionadas entre sí, que recojan la mayor varianza posible. Para leerlo se usan tres medidas:

a. **ACP normado.** Es el ACP de las variables estandarizadas ($z_{ij} = (x_{ij} - \bar{x}_j)/s_j$), es decir, el de la matriz de correlación, de modo que cada variable aporta varianza 1 sin importar su unidad. El ACP sin normalizar usa la matriz de covarianzas en las unidades originales.
b. **Valor propio.** El valor propio λ_k es la varianza de la componente k, de modo que $\lambda_k / \sum_j \lambda_j$ es la proporción de varianza que explica. En el ACP normado los 57 valores propios suman 57.
c. **Contribución.** La contribución de la variable j al eje k es $100\,u_{jk}^2$, donde u_{jk} es su carga (su peso en el vector propio) y mide qué porcentaje del eje construye esa variable. La contribución a un plano pondera las de cada eje por su valor propio y se compara contra la referencia uniforme $100/57 = 1.75\,\%$.

```r
acp_normado <- prcomp(num, scale. = TRUE)
acp_crudo <- prcomp(num, scale. = FALSE)
aporte <- function(acp, n = 10) {
  a <- facto_summarize(acp, "var", axes = c(1, 2))
  a <- a[order(-a$contrib), ]
  data.frame(variable = a$name,
             contrib = round(a$contrib, 2))[1:n, ]
}
knitr::kable(cbind(aporte(acp_normado), aporte(acp_crudo)),
             row.names = FALSE,
             col.names = c("ACP normado", "%",
                           "Sin normalizar", "%"),
             caption = "Variables que más aportan al plano 1-2.")
```

Cuadro 3.4: Variables que más aportan al plano 1-2.

ACP normado	%	Sin normalizar	%
PetLiq_cons	2.49	Refinados_prod	18.01
Refinados_cons	2.49	PetLiq_cons	17.31
PetLiq_CO2	2.48	Refinados_cons	17.31
Refinados_prod	2.47	PetLiq_prod	16.58
Destilado_prod	2.45	Crudo_prod	10.79
Destilado_cons	2.44	Crudo_imp	3.57
Elec_cap	2.43	Crudo_exp	3.01
Elec_cons	2.42	Gasolina_prod	2.84
Elec_gen	2.42	Gasolina_cons	2.53
NoHidro_cap	2.42	Destilado_prod	1.36

```r
varianza <- sort(sapply(num, var), decreasing = TRUE)
knitr::kable(data.frame(
  variable = names(varianza)[1:5],
  porcentaje = round(100 * varianza[1:5] / sum(varianza), 1),
  row.names = NULL),
  caption = "Peso en la varianza total sin normalizar.")
```

Cuadro 3.5: Peso en la varianza total sin normalizar.

variable	porcentaje
Refinados_prod	17.7
PetLiq_cons	16.9
Refinados_cons	16.9
PetLiq_prod	16.2
Crudo_prod	10.5

```r
normado <- facto_summarize(
  acp_normado, "var",
  axes = c(1, 2))
sum(normado$contrib > 100 / 57)
```

```
[1] 37
```

```r
fviz_contrib(acp_normado, choice = "var", axes = c(1, 2),
             top = 20) +
  labs(title = NULL)
```

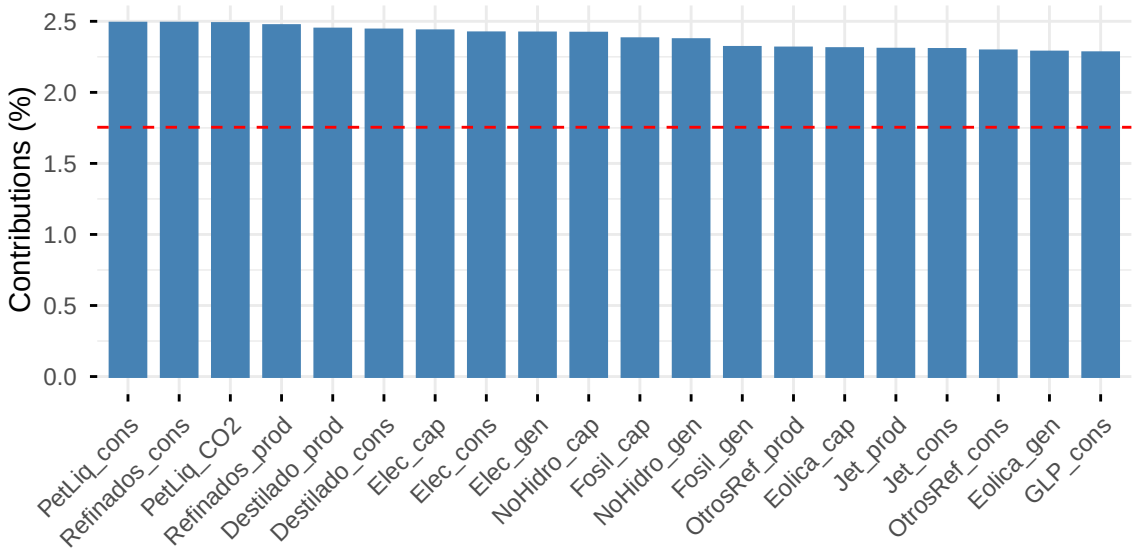


Figura 3.2: Contribución de las 20 primeras variables al plano 1-2 del ACP normado: Todas quedan cerca de la referencia uniforme (línea roja) pues el plano lo construyen muchas variables a la vez.

```r
fviz_contrib(acp_crudo, choice = "var", axes = c(1, 2), top = 20) +
  labs(title = NULL)
```

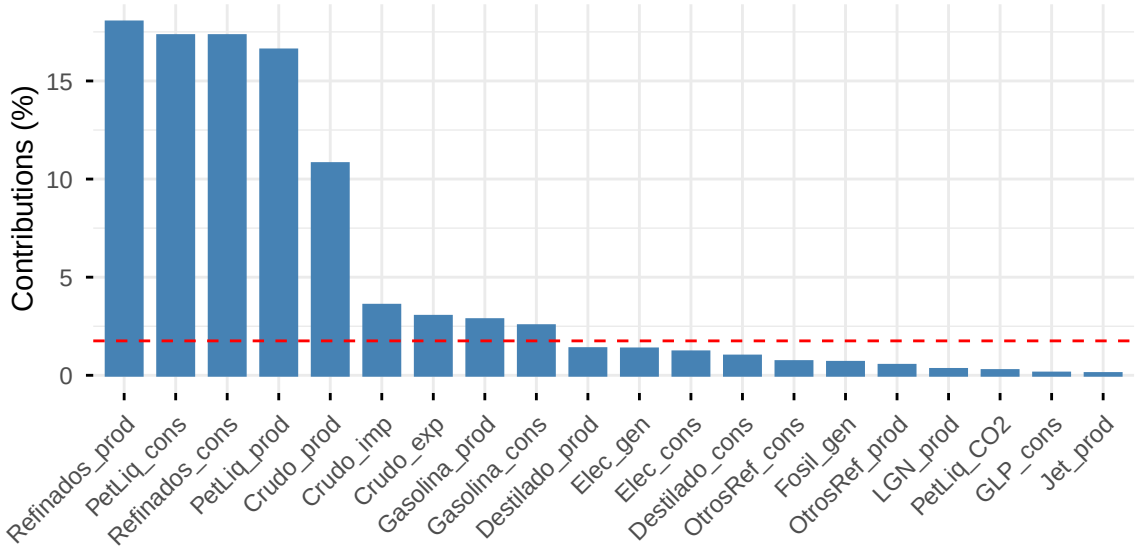
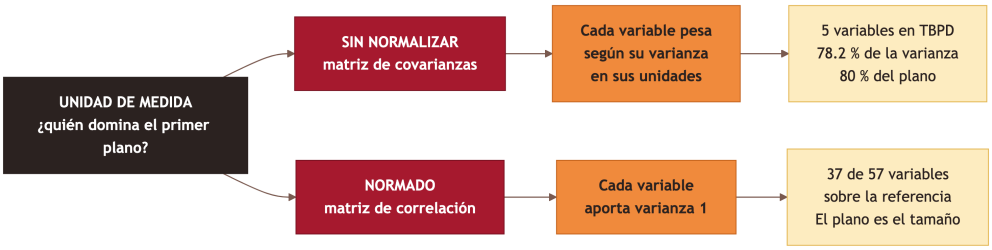


Figura 3.3: Contribución de las 20 primeras variables al plano 1-2 del ACP sin normalizar: Cinco variables medidas en TBPD construyen el 80 % del plano.

¿Cómo cambian las contribuciones al normalizar? Cambian por completo pues en el ACP sin normalizar el plano lo construyen casi solo cinco variables de barriles por día (producción de refinados con 18.01 %, consumo de petróleo y de refinados con 17.31 % cada una, producción de petróleo con 16.58 % y producción de crudo con 10.79 %), que suman el 80 % del plano. Esto sucede porque sin estandarizar cada variable pesa según su varianza, de manera que esas cinco variables concentran por sí solas el 78.2 % de la varianza total (medidas en miles de barriles diarios alcanzan valores de miles), mientras que por ejemplo la generación eléctrica en BKWH tiene una varianza once veces menor que la del consumo de petróleo. Así el primer plano explica un 97.25 % de la varianza (82.92 % el primer eje y 14.34 % el segundo), cifra que no indica una buena síntesis sino que la varianza total está en pocas columnas.

En el ACP normado, en cambio, ninguna variable pasa de 2.49 % y las diez primeras apenas suman 24.5 %, con 37 de las 57 variables por encima de la referencia de 1.75 %. Las que más aportan son de petróleo (consumo, emisiones, refinados y destilados) y de electricidad (capacidad instalada, consumo y generación), lo que significa que el primer plano resume el tamaño energético del país en ambos sectores. Por esto se usa el ACP normado en el resto del taller ya que las variables tienen unidades distintas y no es la unidad de medida la que debe decidir qué variable importa.



Por qué escalar cambia todo: La unidad de una sola columna decide, sin normalizar, quién construye el plano, mientras que normando el plano lo construye la estructura de toda la base.

a. **Lectura local.** El peso de una variable en el ACP sin normalizar lo decide su unidad y no lo que mide pues el consumo de petróleo tiene una varianza once veces mayor que la generación eléctrica solo porque los barriles diarios alcanzan cifras de miles y los BKWH de cientos.
b. **Lectura global.** El ACP sin normalizar no resume la base sino que la ordena por unidades, mientras que el normado muestra que el tamaño energético es una propiedad de toda la base pues lo construyen a la vez 37 de las 57 variables de los dos sectores.

3.3. Pregunta 4 — Número de componentes

El criterio de Kaiser (Kaiser 1960) retiene las componentes con valor propio mayor que 1, es decir, las que explican más varianza que una sola variable original estandarizada. Se compara con el porcentaje acumulado (retener hasta alcanzar el 80 %) y con el codo del gráfico de sedimentación.

```r
autovalores <- acp_normado$sdev^2
proporcion <- autovalores / sum(autovalores)
knitr::kable(data.frame(
  componente = 1:10, autovalor = round(autovalores[1:10], 2),
  porcentaje = round(100 * proporcion[1:10], 2),
  acumulado = round(100 * cumsum(proporcion)[1:10], 2)),
  caption = "Valores propios de las diez primeras componentes.")
```

Cuadro 3.6: Valores propios de las diez primeras componentes.

componente	autovalor	porcentaje	acumulado
1	35.32	61.96	61.96
2	4.41	7.74	69.69
3	4.00	7.01	76.71
4	2.71	4.75	81.46
5	2.45	4.31	85.76
6	1.87	3.28	89.04
7	1.31	2.29	91.33
8	1.12	1.96	93.29
9	0.90	1.58	94.87
10	0.76	1.33	96.20

```r
sum(autovalores > 1)
```

```
[1] 8
```

```r
which(cumsum(proporcion)
      >= 0.8)[1]
```

```
[1] 4
```

```r
fviz_eig(acp_normado, addlabels = TRUE, ncp = 10) +
  scale_y_continuous(limits = c(0, 70)) + labs(title = NULL)
```

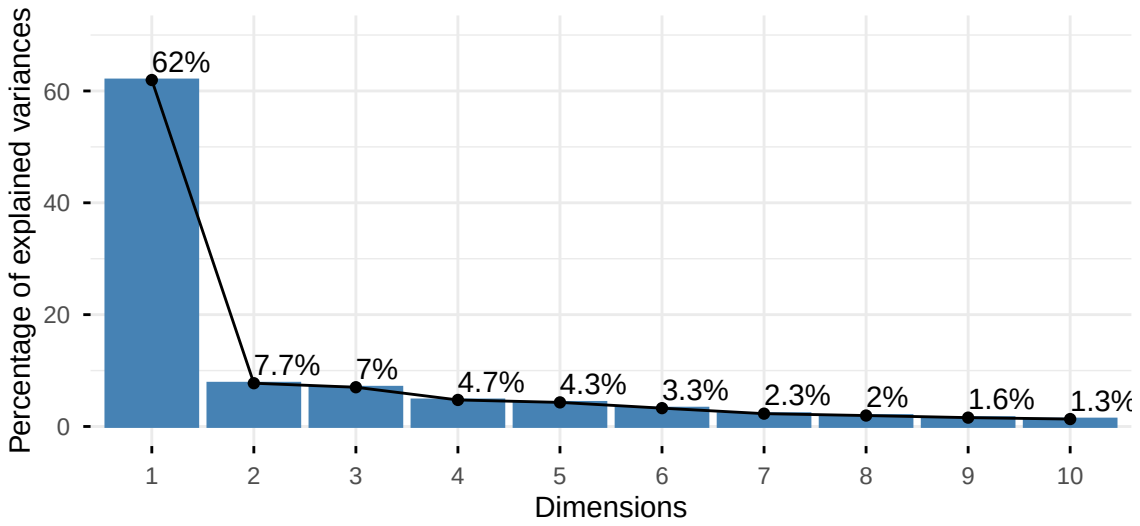


Figura 3.4: Gráfico de sedimentación del ACP normado: El primer eje explica el 62 % y desde el segundo la curva baja despacio.

¿Cuántas componentes se deberían seleccionar? Cuatro, bajo el criterio del porcentaje de varianza acumulada, dado que con ellas se explica el 81.46 % de la variación de las 57 variables (61.96 % la primera, 7.74 % la segunda, 7.01 % la tercera y 4.75 % la cuarta). Los otros dos criterios no sirven bien en este caso:

a. **Codo**. El gráfico de sedimentación se quiebra en la segunda componente, pero quedarse con dos componentes deja por fuera el 30.3 % de la varianza y además la tercera explica casi lo mismo que la segunda (7.01 % frente a 7.74 %), por lo que no hay razón para cortar entre ellas.
b. **Kaiser**. Retiene ocho componentes (93.29 %), lo cual es excesivo porque con 57 variables este criterio tiende a retener de más y las componentes de la quinta a la octava explican entre 1.96 % y 4.31 % cada una.

Retener cuatro es coherente con lo que pide la Pregunta 5, que analiza el plano (2,3) porque la tercera componente todavía carga información relevante.

a. **Lectura local.** La cuarta componente apenas agrega 4.75 % y es la que hace cruzar el umbral del 80 %, de modo que la frontera entre tres y cuatro componentes la marca la regla y no un cambio en la curva.
b. **Lectura global.** El primer valor propio vale 35.32, es decir que una sola componente equivale a 35 de las 57 variables, lo cual es la otra cara de la redundancia del diagnóstico pues las 57 columnas describen en realidad unas pocas dimensiones de los países.

Notas

Interpretaciones.

a. **Tres criterios, tres respuestas.** El codo da dos componentes (69.69 %), el 80 % da cuatro (81.46 %) y Kaiser da ocho (93.29 %), de modo que el número no lo decide el dato sino el criterio.
b. **Lo que sí se interpreta.** Las preguntas 5 y 6 encuentran sentido hasta el tercer eje (exportadores frente a importadores de electricidad), lo que respalda quedarse con cuatro y no con dos.

Preguntas para el profesor.

- ¿Debe el número de componentes salir de una regla o de lo que se logra interpretar?

  Por qué importa. Los tres criterios dan dos, cuatro y ocho componentes y de esa elección depende cuántos planos se interpretan en las preguntas 5 y 6, así que saber qué criterio espera el curso define si quedarse con cuatro es defendible.

- ¿Cambiarían los criterios si antes del ACP se quitaran las copias del diagnóstico (por ejemplo `Refinados_cons`)? No se calculó.

  Por qué importa. Los 18 pares con correlación mayor a 0.99 suman varianza al mismo eje, lo que puede inflar el 62 % del primer eje y con ello mover el número de componentes que pide el criterio del 80 %.

3.4. Pregunta 5 — Representación de las variables

El círculo de correlaciones ubica cada variable con coordenadas iguales a su correlación con cada eje del plano, de modo que la longitud de la flecha es $\sqrt{\cos^2}$, donde el $\cos^2$ (la correlación al cuadrado con el eje) mide qué tan bien representa el plano a esa variable. Una flecha que llega al círculo está bien representada, mientras que una corta está mayormente en otras componentes. Se dibujan solo las 30 variables que más contribuyen al plano.

```
fviz_pca_var(acp_normado, axes = c(1, 2),
             select.var = list(contrib = 30), col.var = "contrib",
             labelsize = 2.2, repel = TRUE) + labs(title = NULL)
```

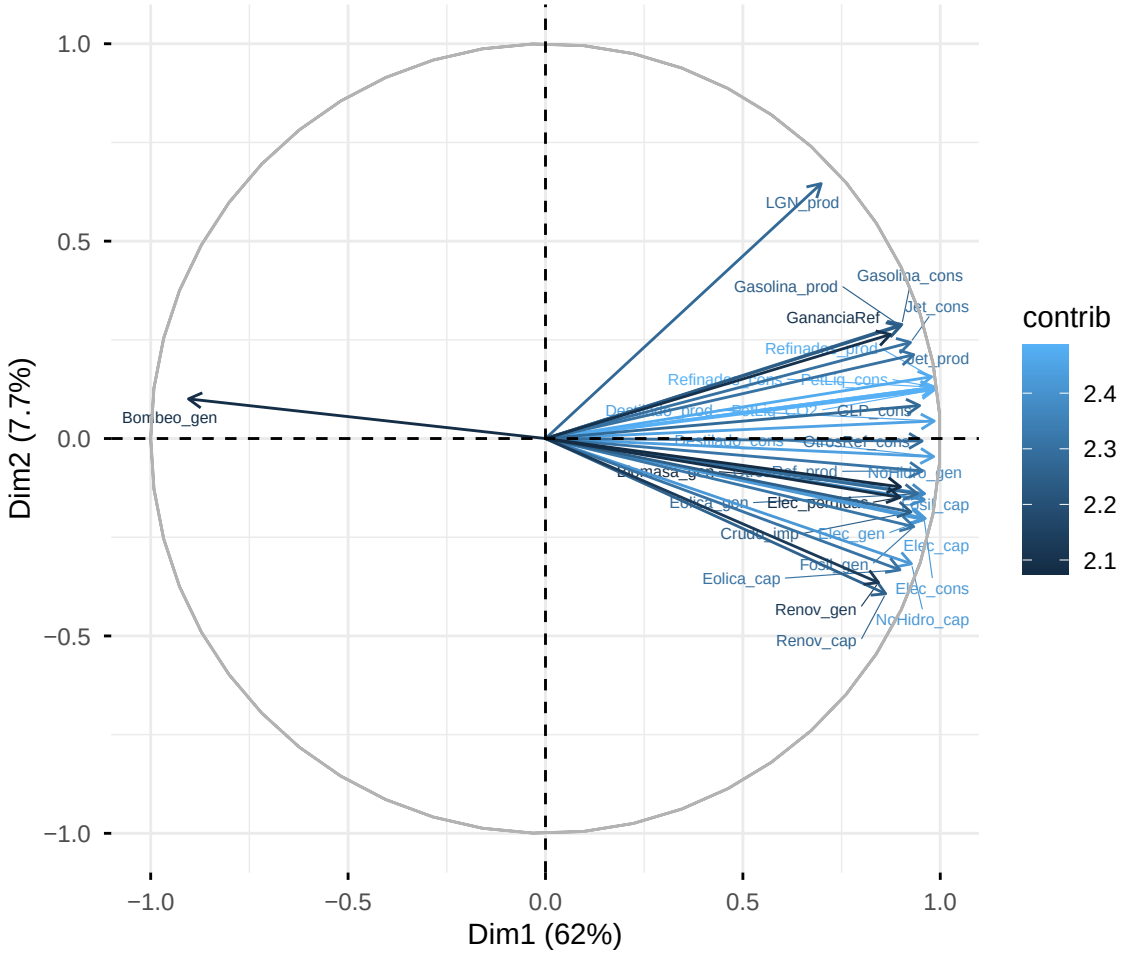


Figura 3.5: Círculo de correlaciones del ACP normado en el plano (1,2), con las 30 variables que más contribuyen: Casi todas apuntan hacia la derecha, de modo que el primer eje es el tamaño energético del país.

```
# Las mismas 30 sin la de bombeo, que apunta al otro lado.
plano <- facto_summarize(acp_normado, "var", axes = c(1, 2))
haz <- setdiff(plano$name[order(-plano$contrib)][1:30],
               "Bombeo_gen")
fviz_pca_var(acp_normado, axes = c(1, 2),
             select.var = list(name = haz), col.var = "contrib",
             labelsize = 2.6, repel = TRUE) +
  coord_cartesian(xlim = c(0.65, 1.02), ylim = c(-0.42, 0.68)) +
  labs(title = NULL)
```

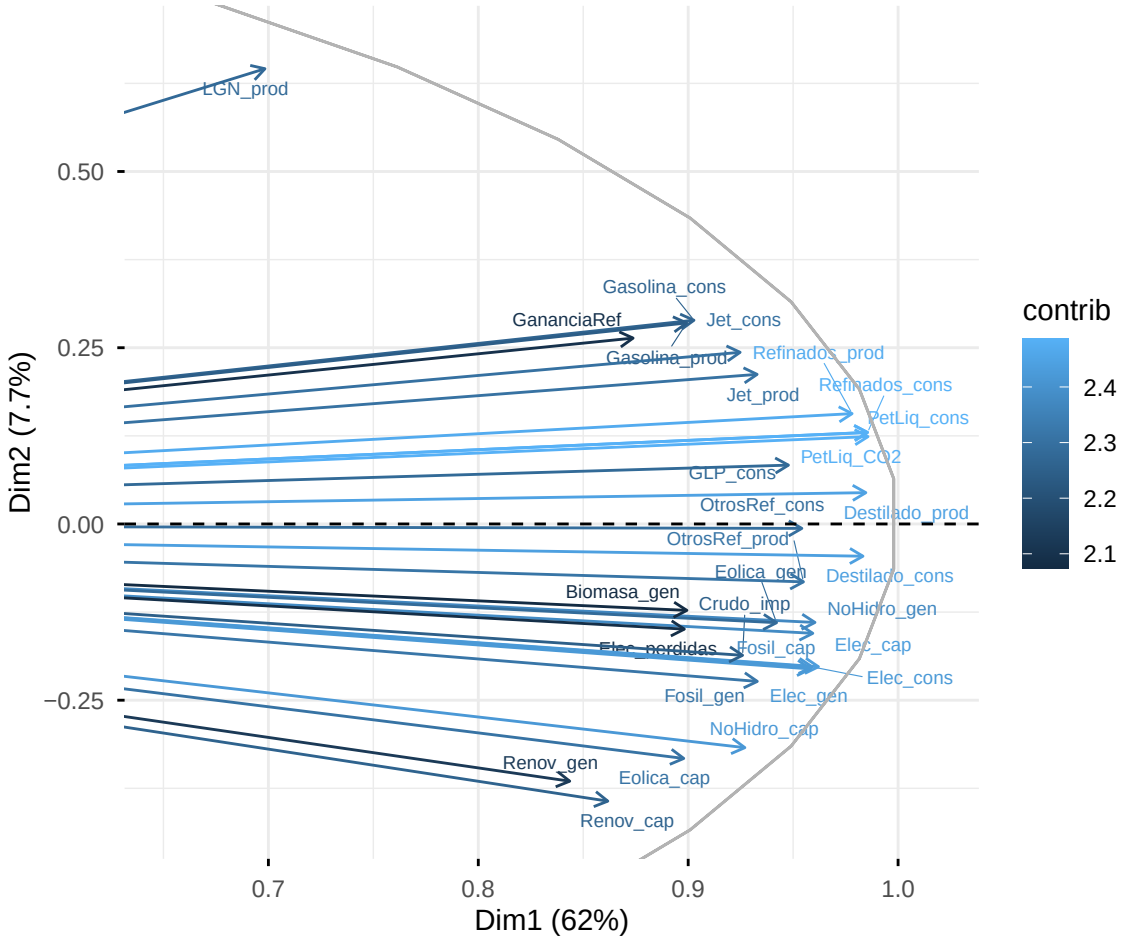


Figura 3.6: Acercamiento al haz de flechas del plano (1,2): La mayoría de las de petróleo quedan arriba del eje horizontal y las de electricidad abajo, todas con correlación de al menos 0.70 con el primer eje.

```r
coord <- get_pca_var(acp_normado)$coord[, 1:3]
round(coord[order(-abs(coord[, 2]))[1:8], ], 2)
```

```
                Dim.1 Dim.2 Dim.3
LGN_prod         0.70  0.65  0.06
Crudo_exp        0.13  0.59 -0.68
PetLiq_prod      0.69  0.58 -0.35
Crudo_prod       0.60  0.57 -0.49
Crudo_reservas   0.15  0.46 -0.60
Hidro_gen        0.74 -0.42 -0.35
Hidro_cap        0.78 -0.41 -0.33
Solar_cap        0.77 -0.40  0.05
```

```r
round(coord[order(-abs(coord[, 3]))[1:8], ], 2)
```

```
                Dim.1 Dim.2 Dim.3
Crudo_exp        0.13  0.59 -0.68
Crudo_reservas   0.15  0.46 -0.60
Residual_prod    0.49  0.35 -0.53
Crudo_prod       0.60  0.57 -0.49
Residual_cons    0.53  0.09 -0.48
Geotermica_cap   0.51  0.33  0.46
Geotermica_gen   0.51  0.34  0.46
Elec_imp         0.54  0.13  0.41
```

```r
sum(abs(coord[, 1]) > 0.7)
```

```
[1] 39
```

Plano (1,2). Las 30 flechas más largas llegan casi al borde del círculo, lo cual muestra que el plano las representa muy bien (el consumo de petróleo tiene $\cos^2 = 0.988$ y la generación eléctrica 0.961). Se concluye que:

a. **El primer eje es un factor de tamaño.** Prácticamente todas las variables tienen correlación alta y positiva con él, tanto las de petróleo como las de electricidad, por lo que un país está a la derecha si produce, consume, genera e importa mucho en términos absolutos. La única flecha que apunta hacia la izquierda es la generación neta por bombeo hidroeléctrico (`Bombeo_gen`, $r = -0.90$), lo cual tiene sentido porque esa generación neta es negativa (el bombeo consume más energía de la que devuelve) en 27 países y lo es más en los grandes, como Estados Unidos (−6.2 BKWH) y China (−4.7 BKWH).
b. **El segundo eje separa petróleo de renovables.** Según las correlaciones impresas arriba, del lado positivo quedan los líquidos de gas natural (`LGN_prod`, 0.65), las exportaciones de crudo (0.59) y la producción de crudo y de petróleo (0.57 y 0.59), mientras que del lado negativo quedan la generación y la capacidad hidroeléctrica (−0.42 y −0.41) y la capacidad solar y renovable (−0.40 y −0.39). Es decir que entre países de igual tamaño el segundo eje distingue a los productores de hidrocarburos de los que generan electricidad renovable.

```
fviz_pca_var(acp_normado, axes = c(2, 3),
             select.var = list(contrib = 30), col.var = "contrib",
             labelsize = 2.5, repel = TRUE) + labs(title = NULL)
```

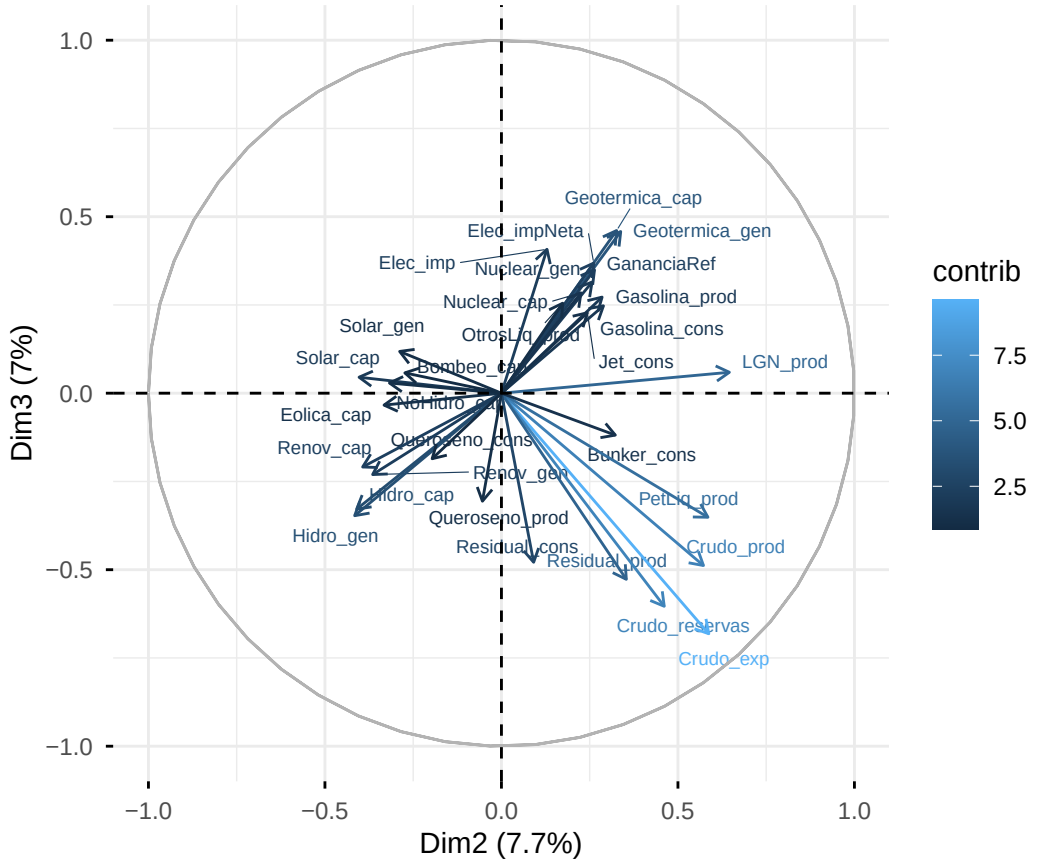


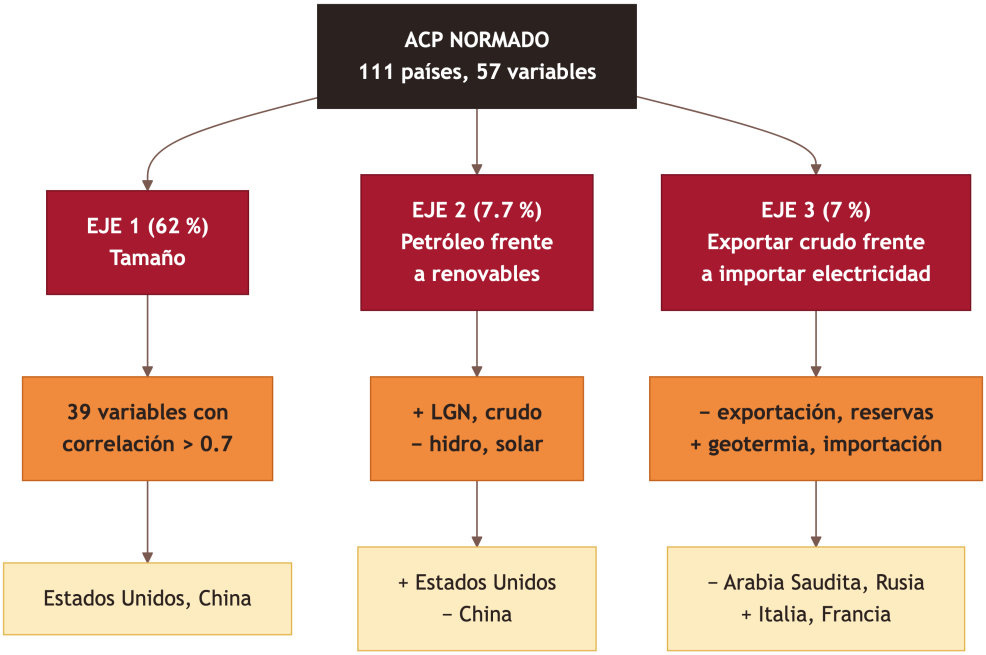
Figura 3.7: Círculo de correlaciones del ACP normado en el plano (2,3), con las 30 variables que más contribuyen: Las exportaciones y reservas de crudo bajan, las renovables van a la izquierda y la geotermia y las importaciones eléctricas suben.

Plano (2,3). Al quitar el efecto de tamaño las flechas se acortan y se abren en varias direcciones, lo que indica que este plano representa peor a cada variable (el mejor $\cos^2$ es el de las exportaciones de crudo con 0.81) pero muestra perfiles que el primero escondía:

a. **Perfil exportador de crudo.** Abajo a la derecha quedan las exportaciones de crudo (−0.68 con el tercer eje), las reservas (−0.60), la producción de combustóleo residual (−0.53) y la producción de crudo (−0.49), es decir, los países con yacimientos que venden su petróleo.
b. **Perfil renovable.** A la izquierda quedan la capacidad y generación hidroeléctrica, solar y renovable, con correlación negativa con el segundo eje.
c. **Perfil importador de electricidad.** Arriba quedan la capacidad y la generación geotérmica (0.46), las importaciones de electricidad (0.41) y las importaciones netas (0.37), así como la ganancia de refinación y la electricidad nuclear con correlaciones menores.

Se concluye que el tercer eje separa a los exportadores de crudo de los países que compran electricidad o la generan con fuentes como la geotérmica y la nuclear, lo cual justifica haber retenido más de dos componentes.

El diagrama resume lo que significa cada uno de los tres primeros ejes según las variables que más se asocian con él.



Qué mide cada eje del ACP normado con los 111 países y qué variables lo construyen: El primero ordena por tamaño y solo los siguientes distinguen perfiles energéticos.

a. **Lectura local.** La exportación de crudo, que en el primer plano casi no aparece (0.13 con el primer eje), es la variable mejor representada del plano (2,3), lo cual respalda que la dimensión comercial que se buscó en la Pregunta 1 existe y está fuera del eje de tamaño.
b. **Lectura global.** El primer eje es el tamaño porque 39 de las 57 variables tienen con él correlación mayor a 0.7 en valor absoluto, de modo que lo que distingue a los países más allá de su tamaño (petróleo, renovables, importaciones) solo aparece en los ejes siguientes, que explican mucho menos.

   Nota. El signo de cada componente es arbitrario pues `prcomp()` puede devolver u_k o $-u_k$ y ambos son igual de válidos. Lo que se interpreta es la oposición entre grupos de variables y no si quedan arriba o abajo.

3.5. Pregunta 6 — Mapa de individuos

Para que el mapa se pueda leer se dibujan todos los países como puntos y se rotulan solo los 20 más alejados del origen en cada plano, que son los que más contribuyen a él.

```r
mapa_paises <- function(acp, ejes, n = 20, grupos = "none") {
  coord <- data.frame(acp$x[, ejes])
  names(coord) <- c("x", "y")
  coord$pais <- rownames(coord)
  lejanos <- coord[order(-(coord$x^2 + coord$y^2))[seq_len(n)], ]
  fviz_pca_ind(acp, axes = ejes, geom = "point", habillage = grupos,
               col.ind = "grey45", mean.point = FALSE) +
    ggrepel::geom_text_repel(data = lejanos, inherit.aes = FALSE,
                             aes(x, y, label = pais), size = 2.4,
                             max.overlaps = Inf,
                             min.segment.length = 0) +
    labs(title = NULL, colour = "Grupo", shape = "Grupo")
}
```

```r
mapa_paises(acp_normado, c(1, 2))
```

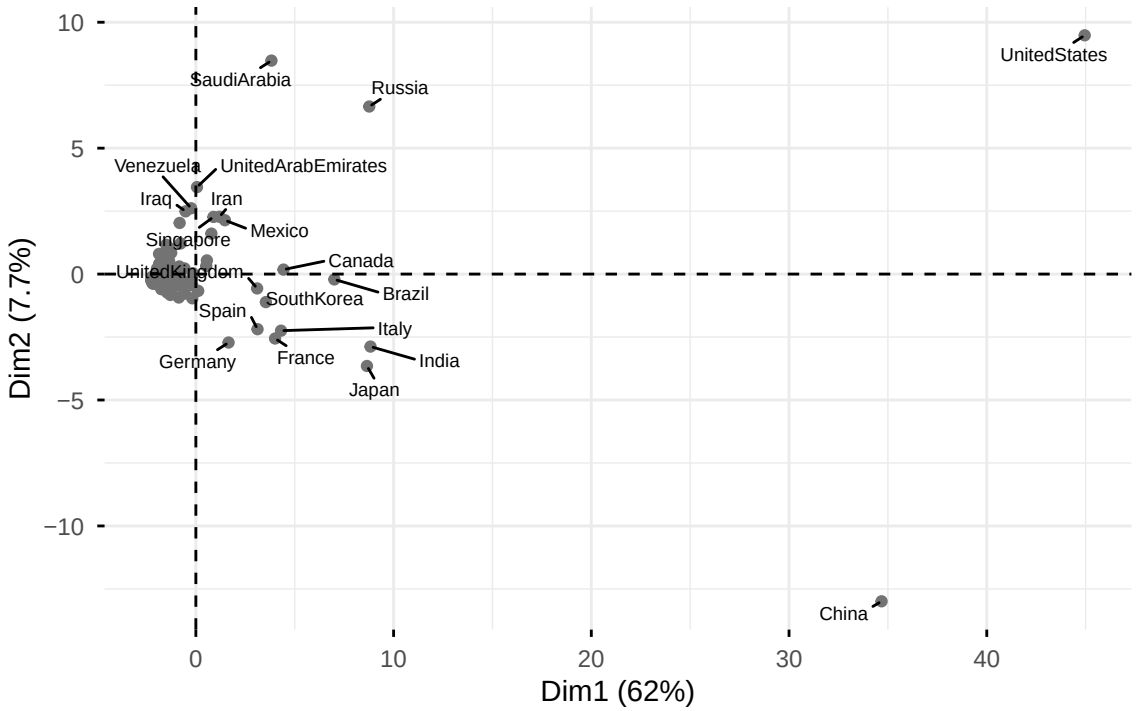


Figura 3.8: Países en el plano (1,2) del ACP normado: Estados Unidos y China quedan aislados a la derecha y el resto se amontona cerca del origen.

```
mapa_paises(acp_normado, c(2, 3))
```

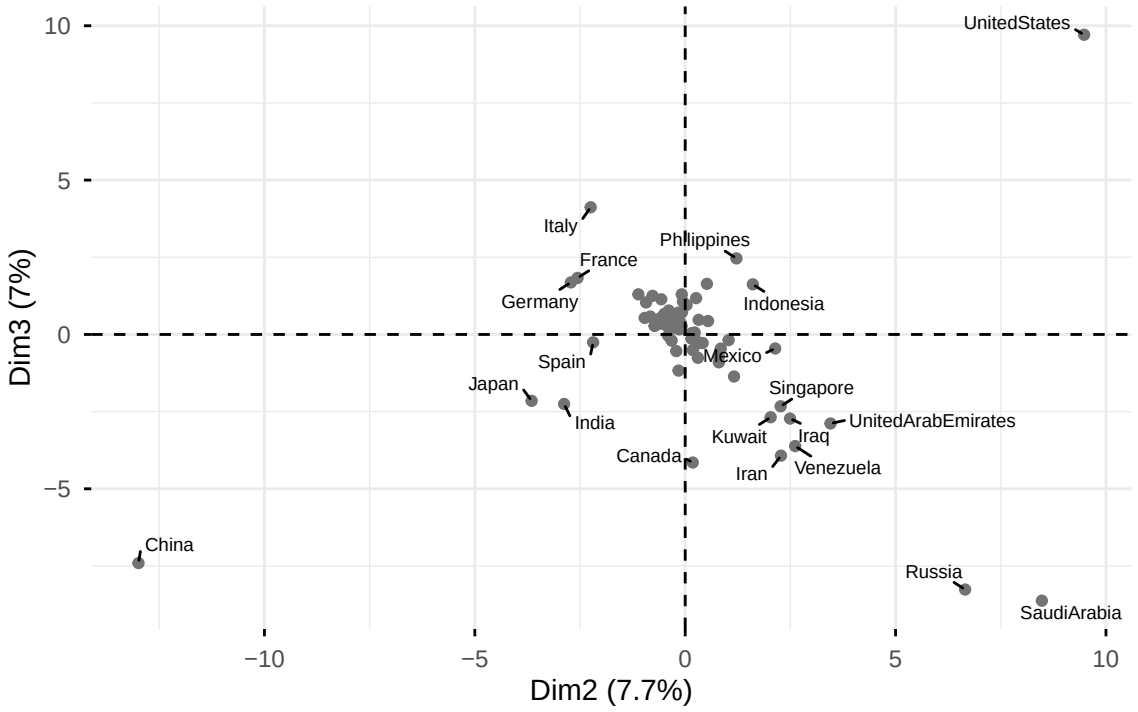


Figura 3.9: Países en el plano (2,3) del ACP normado: Arabia Saudita y Rusia quedan juntos abajo a la derecha, China a la izquierda y Estados Unidos arriba a la derecha.

```
contribucion <- get_pca_ind(acp_normado)$contrib
round(head(sort(contribucion[, 1], decreasing = TRUE), 4), 2)
```

```
UnitedStates        China        India       Russia
       52.02        30.96         2.01         1.98
```

```
round(acp_normado$x[c("SaudiArabia", "Russia", "Kuwait", "Iraq",
                      "Japan", "India", "Italy", "France",
                      "Germany"), 1:3], 2)
```

```
             PC1   PC2   PC3
SaudiArabia 3.82  8.48 -8.63
Russia      8.77  6.65 -8.26
Kuwait     -0.82  2.03 -2.68
Iraq       -0.52  2.49 -2.73
Japan       8.65 -3.65 -2.15
India       8.83 -2.88 -2.25
Italy       4.31 -2.25  4.12
France      4.01 -2.56  1.83
Germany     1.65 -2.72  1.69
```

```
mean(abs(acp_normado$x[, 1])
     < 2)
```

```
[1] 0.5495495
```

¿Qué se concluye de la cercanía entre países? Que el ACP con los 111 países está dominado por cuatro de ellos y que la cercanía revela perfiles energéticos comunes:

a. **Dos gigantes.** Estados Unidos (44.95 en el primer eje) y China (34.68) están tan lejos del resto que construyen el 52.02 % y el 30.96 % del primer eje respectivamente, es decir, entre los dos el 83 %. Ningún otro país pasa de 9 en esa coordenada y el 55 % de los países queda a menos de 2 unidades del origen.
b. **Petroleros.** En el plano (2,3) Arabia Saudita (8.48, −8.63) y Rusia (6.65, −8.26) están juntos y lejos del resto, en la dirección de las exportaciones y reservas de crudo de la Pregunta 5, mientras que Kuwait, Irak, Emiratos Árabes, Venezuela e Irán aparecen en la misma dirección aunque mucho más cerca del origen.
c. **Grandes consumidores sin petróleo.** Japón (8.65, −3.65) e India (8.83, −2.88) quedan prácticamente superpuestos en el plano (1,2) pues ambos son economías grandes que consumen mucho petróleo y electricidad sin producir crudo en cantidad.
d. **China frente a Estados Unidos.** A pesar de estar ambos a la derecha del primer plano, se separan en el segundo eje (−12.99 contra 9.48) ya que China pesa por su generación hidroeléctrica y renovable mientras que Estados Unidos lo hace también por su producción de petróleo.
e. **Importadores de electricidad.** En el plano (2,3) Italia (4.12 en el tercer eje), Francia (1.83) y Alemania (1.69) quedan arriba a la izquierda, que es la dirección de las importaciones de electricidad y la generación nuclear y geotérmica de la Pregunta 5.

Estas cercanías se leen en dos niveles:

a. **Lectura local.** La cercanía de India y Japón no dice que sean países parecidos en todo sino que tienen el mismo perfil energético, es decir, mucho consumo y poca producción de crudo, de modo que dos economías que en otros aspectos pueden ser muy distintas quedan superpuestas porque las 57 variables solo miden energía.
b. **Lectura global.** El plano lo organizan pocas economías pues Estados Unidos y China construyen el 83 % del primer eje y fijan la escala del mapa, de modo que la mayoría de países no se distingue en estos planos y se justifica la Pregunta 7.

3.6. Pregunta 7 — ACP sin los cuatro países atípicos

Desde aquí se excluyen Estados Unidos, China, Arabia Saudita y Rusia, tanto para el ACP como para el agrupamiento de las preguntas 8 a 11.

```r
atipicos <- c("UnitedStates", "China", "SaudiArabia", "Russia")
datos <- datos[!datos$Country %in% atipicos, ]
num <- numericas(datos)
acp_sin4 <- prcomp(num, scale. = TRUE)
valores <- function(acp) {
  p <- acp$sdev^2 / sum(acp$sdev^2)
  round(100 * c(p[1:3], cumsum(p)[2:3]), 2)
}
knitr::kable(data.frame(
  medida = c("% CP1", "% CP2", "% CP3", "% plano 1-2",
             "% acumulado 3"),
  con_111 = valores(acp_normado), sin_4 = valores(acp_sin4)),
  caption = "Varianza explicada con y sin los cuatro países.")
```

Cuadro 3.7: Varianza explicada con y sin los cuatro países.

medida	con_111	sin_4
% CP1	61.96	48.95
% CP2	7.74	10.24
% CP3	7.01	8.11
% plano 1-2	69.69	59.19
% acumulado 3	76.71	67.30

```r
autovalores <- acp_sin4$sdev^2
coord <- get_pca_var(acp_sin4)$coord
round(coord[order(-abs(coord[, 2]))[1:6], 1:2], 2)
```

```
               Dim.1 Dim.2
PetLiq_prod     0.35 -0.84
Crudo_prod      0.30 -0.83
Crudo_exp       0.16 -0.75
LGN_prod        0.31 -0.69
Crudo_reservas  0.18 -0.66
Bombeo_gen     -0.49 -0.53
```

```r
round(head(sort(get_pca_ind(acp_sin4)$contrib[, 1],
                decreasing = TRUE), 4), 2)
```

```
 India  Japan Brazil Canada
 23.37  20.04  11.49   6.38
```

```
c(paises = nrow(num),
  kaiser = sum(autovalores > 1))
```

```
paises kaiser
   107      9
```

```
c(acumulado_80 = which(
  cumsum(autovalores) / 57
    >= 0.8)[1],
  tamano = sum(abs(
    coord[, 1]) > 0.7))
```

```
acumulado_80       tamano
           6           27
```

```
mapa_paises(acp_sin4, c(1, 2), n = 24)
```

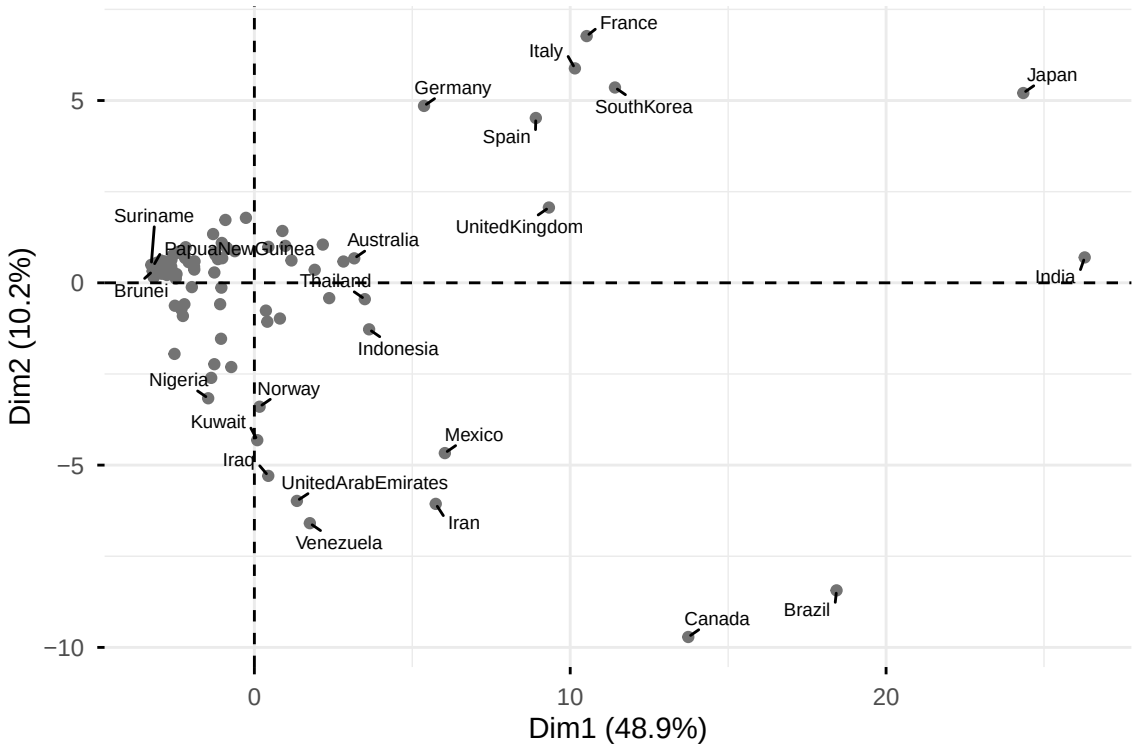


Figura 3.10: Países en el plano (1,2) del ACP normado sin Estados Unidos, China, Arabia Saudita y Rusia: La masa central se abre y aparecen dos brazos, uno de grandes consumidores hacia arriba y otro de productores de petróleo hacia abajo.

¿En qué cambia el ACP al excluir estos países? En tres aspectos:

a. **La varianza se reparte más.** La primera componente baja de 61.96 % a 48.95 % mientras que la segunda sube de 7.74 % a 10.24 % y la tercera de 7.01 % a 8.11 %, por lo que ahora se necesitan seis componentes para el 80 % (antes cuatro) y Kaiser retiene nueve (antes ocho). Esto muestra que buena parte del 62 % del primer eje se debía a que Estados Unidos y China son enormes en todas las variables a la vez.

b. **El segundo eje se vuelve un eje petrolero más nítido.** Las correlaciones de la producción de petróleo (−0.84), la producción de crudo (−0.83), las exportaciones de crudo (−0.75) y los líquidos de gas (−0.69) con la segunda componente son mucho más fuertes que con los 111 países (alrededor de 0.6), mientras que en el lado opuesto queda la electricidad solar (0.48). El signo cambió respecto al ACP anterior, lo cual no tiene importancia según la nota de la Pregunta 5.
c. **Aparecen nuevos países dominantes.** India (23.37 %) y Japón (20.04 %) pasan a construir el primer eje, de modo que el efecto de tamaño no desaparece sino que lo heredan los siguientes países más grandes.

¿Se perciben clusters con mayor claridad? Sí, aunque no como grupos compactos. La masa de países pequeños se abre hacia la derecha y de ella salen dos brazos, uno hacia arriba con grandes consumidores que no producen petróleo (Francia, Italia, Corea del Sur, Japón, Alemania y España) y otro hacia abajo con productores y exportadores de petróleo (Irak, Emiratos Árabes, Venezuela, Irán y México), al extremo del cual quedan Brasil y Canadá, que combinan producción de crudo (2255 y 3613 TBPD) con la mayor generación renovable de los 107 países (429 y 412 BKWH). India queda sola en el extremo derecho.

a. **Lectura local.** Quitar cuatro países no borra el tamaño sino que lo traslada pues India y Japón construyen ahora el 43 % del primer eje, que es la mitad de lo que construían Estados Unidos y China pero sigue siendo mucho para dos países de 107.
b. **Lectura global.** El tamaño es una propiedad de la base y no de cuatro países ya que todavía 27 de las 57 variables tienen correlación mayor a 0.7 con el primer eje (antes 39). Lo que sí cambia es que, al bajar la escala, la dimensión petrolera gana espacio y deja ver la estructura en brazos que la Pregunta 8 lee como grupos.

Notas

Interpretaciones.

a. **Qué cambió.** El primer eje pasa de 61.96 % a 48.95 %, las variables ligadas a él de 39 a 27 y los países que lo construyen de Estados Unidos y China (83 %) a India y Japón (43 %).
b. **Qué no cambió.** El primer eje sigue siendo tamaño y el segundo sigue siendo petróleo, solo que más nítido.
c. **Quitar no es corregir.** Los cuatro países no son errores de medición sino datos reales, de modo que excluirlos cambia la población que se describe: Los resultados de las preguntas 7 a 11 valen para 107 países sin los cuatro mayores.

Preguntas para el profesor.

- ¿Por qué cuatro y no seis, si India y Japón heredan el mismo papel?

  Por qué importa. El enunciado pide quitar los atípicos pero no dice cómo decidir cuáles son y al retirar a los cuatro mayores India y Japón pasan a construir el 43 % del primer eje, de modo que el criterio de corte decide qué países dominan las preguntas 7 a 11.

- ¿Una transformación logarítmica conseguiría lo mismo sin quitar a nadie? No se calculó.

Por qué importa. El logaritmo reduce el peso de los valores extremos sin excluirlos, con lo cual los resultados valdrían para los 111 países y no solo para 107.

Capítulo 4

Agrupamiento

Como pide el enunciado, las preguntas 8 a 11 se resuelven sin Estados Unidos, China, Arabia Saudita y Rusia, es decir, sobre los 107 países que quedaron en `datos` y `num` al final de la Pregunta 7.

4.1. Pregunta 8 — Número de grupos en el primer plano

¿Cuántos clusters se espera que existan? Tres, leídos sobre el plano (1,2) de la Pregunta 7:

a. **Masa central.** La mayoría de los 107 países, de consumo y producción pequeños, que se amontonan cerca del origen.
b. **Brazo de consumidores.** Las economías grandes sin producción importante de petróleo hacia arriba y a la derecha, con Japón e India en el extremo.
c. **Brazo de productores.** Los exportadores de petróleo hacia abajo, con Brasil y Canadá en el extremo.

Cabe aclarar que esta es una estimación a ojo sobre un plano que solo explica el 59.19 % de la varianza, que los brazos salen de la masa central sin un corte claro y que India, Japón, Brasil y Canadá están tan alejados que un método de agrupamiento podría separarlos como grupos propios. Por esto el número se contrasta en la Pregunta 9.

a. **Lectura local.** Los cuatro países de los extremos (India, Japón, Brasil y Canadá) son los que más construyen el primer eje (de 23.37 % a 6.38 %), de modo que pueden terminar como grupos propios aunque a ojo parezcan la punta de un brazo.
b. **Lectura global.** El 40.81 % de la varianza no está en este plano, por lo que dos países que se ven cerca pueden estar lejos en otras componentes y por eso el número de grupos se lee aquí como una hipótesis y no como un resultado.

4.2. Pregunta 9 — Número de grupos por reducción de varianza explicada

La inercia intra-grupo $W(k)$ es la suma de las distancias al cuadrado de cada país al centroide de su grupo, que mide qué tan compactos son los grupos y la varianza explicada por la partición

es

$$1 - \frac{W(k)}{T}, \qquad T = W(1) = \sum_{i=1}^{n} \|\mathbf{z}_i - \bar{\mathbf{z}}\|^2,$$

es decir, la fracción de la inercia total T que queda entre los grupos. Con las 57 variables estandarizadas $T = (n-1)\,p = 106 \times 57 = 6042$. Se corre k-medias (MacQueen 1967) para $k = 1, \ldots, 10$ y se busca el punto desde el que agregar un grupo ya no reduce mucho la inercia. Como verificación adicional se calcula la silueta media, que se define en la Pregunta 10.

```
z <- scale(num)
set.seed(42)
ajustes <- lapply(1:10, function(k)
  kmeans(z, centers = k, nstart = 100))
inercia <- sapply(ajustes, `[[`, "tot.withinss")
explicada <- 100 * (1 - inercia / inercia[1])
silueta <- c(NA, sapply(ajustes[-1], function(a)
  mean(silhouette(a$cluster, dist(z))[, 3])))
tamanos <- sapply(ajustes, function(a)
  paste(sort(a$size, decreasing = TRUE), collapse = "/"))
knitr::kable(data.frame(k = 1:10, W = round(inercia, 1),
                        explicada = round(explicada, 1),
                        ganancia = round(c(NA, diff(explicada)), 1),
                        silueta = round(silueta, 3), tamanos),
             col.names = c("k", "W", "explicada", "ganancia",
                           "silueta", "tamaños"),
             caption = "Inercia intra-grupo y varianza explicada.")
```

Cuadro 4.1: Inercia intra-grupo y varianza explicada.

k	W	explicada	ganancia	silueta	tamaños
1	6042.0	0.0	NA	NA	107
2	3838.6	36.5	36.5	0.698	98/9
3	3226.7	46.6	10.1	0.666	97/8/2
4	2767.7	54.2	7.6	0.538	87/10/8/2
5	2303.1	61.9	7.7	0.546	87/10/6/2/2
6	2023.6	66.5	4.6	0.552	87/10/4/2/2/2
7	1828.8	69.7	3.2	0.444	76/15/6/4/2/2/2
8	1615.5	73.3	3.5	0.429	73/17/6/4/2/2/2/1
9	1468.9	75.7	2.4	0.412	71/17/5/4/3/2/2/2/1
10	1376.4	77.2	1.5	0.391	65/16/7/5/4/3/2/2/2/1

```r
ggplot(data.frame(k = 1:10, explicada), aes(k, explicada)) +
  geom_line(colour = "grey50") +
  geom_point(colour = "#a6192e", size = 2) +
  geom_vline(xintercept = 3, linetype = "dashed",
             colour = "grey50") +
  scale_x_continuous(breaks = 1:10) +
  labs(x = "Número de grupos k", y = "Varianza explicada (%)") +
  theme_minimal()
```

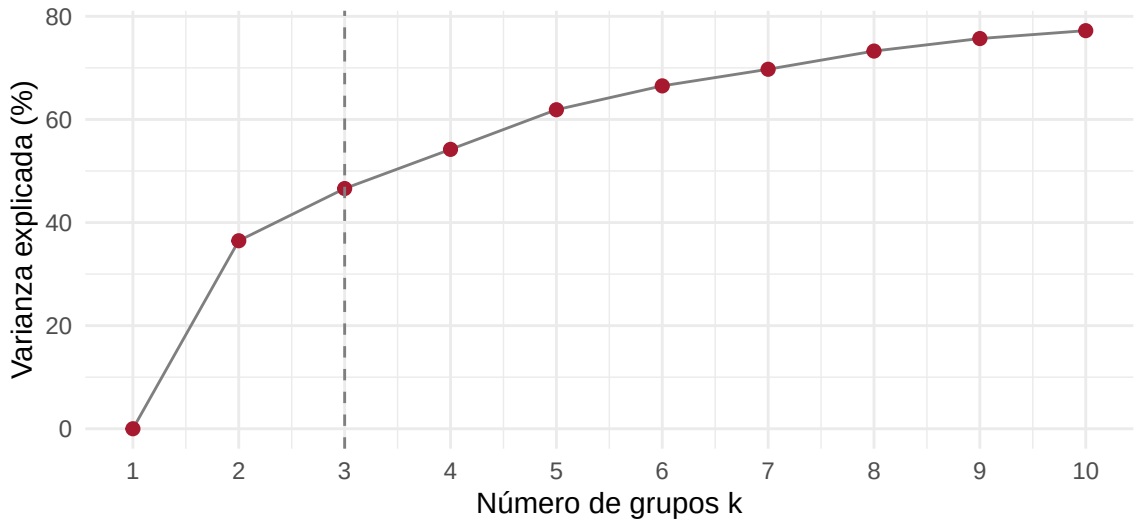


Figura 4.1: Varianza explicada por la partición de k-medias según el número de grupos: La ganancia cae de 36.5 a 10.1 puntos al pasar al tercer grupo y desde ahí se mantiene por debajo de 8.

¿Cuántos grupos se fijan? Tres, que explican el 46.6 % de la inercia total. La reducción más grande ocurre al pasar de uno a dos grupos (36.5 puntos), el tercer grupo todavía agrega 10.1 puntos y a partir de ahí cada grupo nuevo agrega 7.7 puntos o menos, cayendo a 4.6 en $k = 6$ y a 3.2 en $k = 7$. Vale la pena anotar con honestidad que la curva no tiene un codo marcado después de $k = 2$, sino una caída gradual, por lo que la elección se apoya además en dos hechos:

a. **Silueta.** La silueta media pasa de 0.698 con dos grupos a 0.666 con tres, pero cae a 0.538 con cuatro, de modo que el cuarto grupo empeora claramente la separación.
b. **Coherencia con el plano.** Tres grupos es lo que se esperaba a ojo en la Pregunta 8, mientras que dos grupos solo separarían a nueve países grandes del resto (partición 98/9).

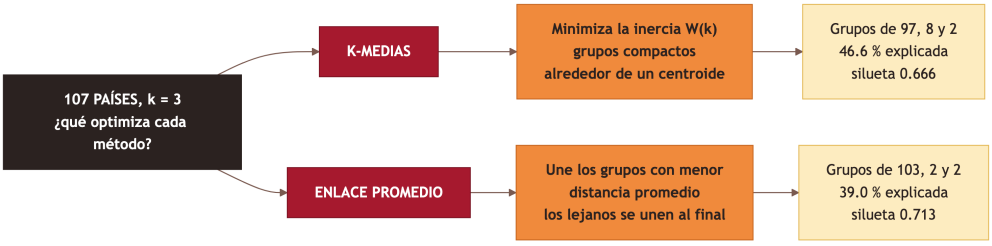
La elección también se lee en dos niveles:

a. **Lectura local.** El tercer grupo cuesta poco y aporta mucho pues con 10.1 puntos más de varianza explicada la silueta solo baja de 0.698 a 0.666, mientras que el cuarto parte la masa central (87/10/8/2) y la silueta cae a 0.538.
b. **Lectura global.** La curva sin codo después de $k = 2$ indica que la base no tiene grupos naturales bien separados sino una masa continua con unos pocos países extremos, de modo que cualquier k es en parte una decisión y no un descubrimiento.

4.3. Pregunta 10 — K-medias frente a jerárquico de enlace promedio

Se comparan dos formas de partir los 107 países en tres grupos con las 57 variables estandarizadas:

a. **K-medias.** Asigna cada país al centroide más cercano y mueve los centroides hasta minimizar $W(k)$. Se usan 100 arranques aleatorios (`nstart = 100`) con semilla fija, por la razón que explica la nota del final.
b. **Enlace promedio.** Es un agrupamiento jerárquico aglomerativo que parte de un grupo por país y une en cada paso los dos grupos con menor distancia promedio entre todos sus pares de países (Sokal y Michener 1958). Se corta el árbol en tres grupos.
c. **Correlación cofenética.** Es la correlación entre las distancias originales y la altura del árbol a la que se unen cada par de países, y mide qué tan fielmente el dendrograma conserva las distancias.
d. **Silueta.** Para cada país es $s(i) = (b_i - a_i)/\max(a_i, b_i)$, con a_i su distancia promedio a su propio grupo y b_i al grupo vecino más cercano (Rousseeuw 1987). Vale 1 si el país está bien ubicado, 0 si está en la frontera y es negativa si estaría mejor en otro grupo.



Qué optimiza cada método sobre los 107 países: K-medias busca grupos compactos y arma uno intermedio, mientras que el enlace promedio deja para el final a los países lejanos y los aísla en parejas.

```r
set.seed(42)
km3 <- kmeans(z, centers = 3, nstart = 100)
distancias <- dist(z)
hc_average <- hclust(distancias, method = "average")
jerarquico <- cutree(hc_average, k = 3)
# Grupos rotulados por tamaño: A el más grande. Los números que
# devuelven kmeans() y cutree() son arbitrarios.
rotular <- function(g) {
  orden <- rank(-tabulate(g), ties.method = "first")
  factor(LETTERS[orden[g]])
}
kmedias <- rotular(km3$cluster)
promedio <- rotular(jerarquico)
table(kmedias, promedio)
```

```
       promedio
kmedias  A  B  C
      A 97  0  0
      B  6  2  0
      C  0  0  2
```

```r
split(rownames(num), kmedias)[c("B", "C")]
```

```
$B
[1] "Brazil"        "Canada"        "France"
[4] "Germany"       "Italy"         "SouthKorea"
[7] "Spain"         "UnitedKingdom"

$C
[1] "India" "Japan"
```

```r
split(rownames(num), promedio)[c("B", "C")]
```

```
$B
[1] "Brazil" "Canada"

$C
[1] "India" "Japan"
```

```
explicada <- function(g) 1 - sum(sapply(split(as.data.frame(z), g),
  function(b) sum(scale(b, scale = FALSE)^2))) / sum(z^2)
sil <- function(g) summary(silhouette(as.integer(g), distancias))
medidas <- function(g) c(explicada(g), sil(g)$avg.width,
                         sil(g)$clus.avg.widths)
knitr::kable(round(rbind("k-medias" = medidas(kmedias),
                         "enlace promedio" = medidas(promedio)), 3),
             col.names = c("Explicada", "Silueta media",
                           "Silueta A", "Silueta B", "Silueta C"),
             caption = "Varianza explicada y silueta.")
```

Cuadro 4.2: Varianza explicada y silueta.

	Explicada	Silueta media	Silueta A	Silueta B	Silueta C
k-medias	0.466	0.666	0.731	-0.022	0.254
enlace promedio	0.390	0.713	0.732	0.174	0.266

```
round(cor(cophenetic(
  hc_average), distancias), 3)
```

```
[1] 0.986
```

```r
# Con 107 hojas los nombres no se leen: se rotulan los extremos.
par(mar = c(4, 4, 1, 1))
plot(hc_average, labels = FALSE, hang = -1, main = "", xlab = "",
     sub = "", ylab = "Altura (distancia promedio)")
rect.hclust(hc_average, k = 3, border = c("#a6192e", "#f08a3c",
                                          "#3572a8"))
# Cada par se rotula con una línea a la altura a la que se une.
hojas <- hc_average$labels[hc_average$order]
pares <- list("India y Japón" = c("India", "Japan"),
              "Brasil y Canadá" = c("Brazil", "Canada"))
rotulo_y <- c(27.5, 25.5)
for (i in 1:2) {
  par_i <- pares[[i]]
  x <- mean(match(par_i, hojas))
  y <- as.matrix(cophenetic(hc_average))[par_i[1], par_i[2]]
  segments(x, y, 12, rotulo_y[i], col = "grey40")
  text(12, rotulo_y[i], names(pares)[i], pos = 4, cex = 0.7)
}
```

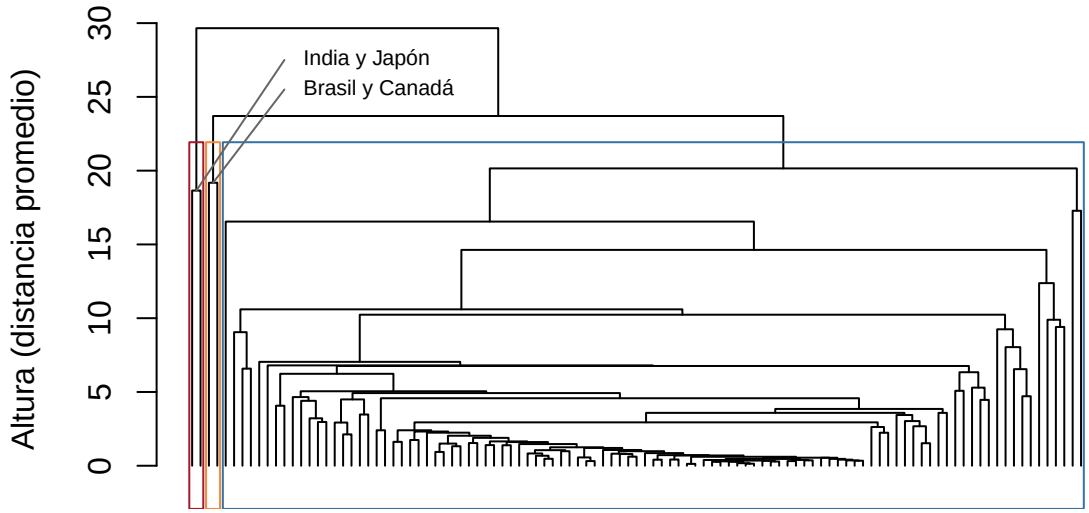


Figura 4.2: Dendrograma del enlace promedio con el corte en tres grupos, rotulando solo los cuatro países que quedan fuera de la rama grande: India y Japón, y Brasil y Canadá, se separan arriba del árbol mientras que los otros 103 países se unen en una sola rama.

```
knitr::kable(data.frame(
  k = 2:5,
  tamanos = sapply(2:5, function(k) paste(sort(table(
    cutree(hc_average, k)), decreasing = TRUE), collapse = "/")),
  silueta = sapply(2:5, function(k)
    round(sil(cutree(hc_average, k))$avg.width, 3))),
  col.names = c("k", "tamaños", "silueta"),
  caption = "Cortes del árbol de enlace promedio.")
```

Cuadro 4.3: Cortes del árbol de enlace promedio.

k	tamaños	silueta
2	105/2	0.752
3	103/2/2	0.713
4	101/2/2/2	0.686
5	101/2/2/1/1	0.678

```
mapa_paises(acp_sin4, c(1, 2), n = 14, grupos = kmedias)
```

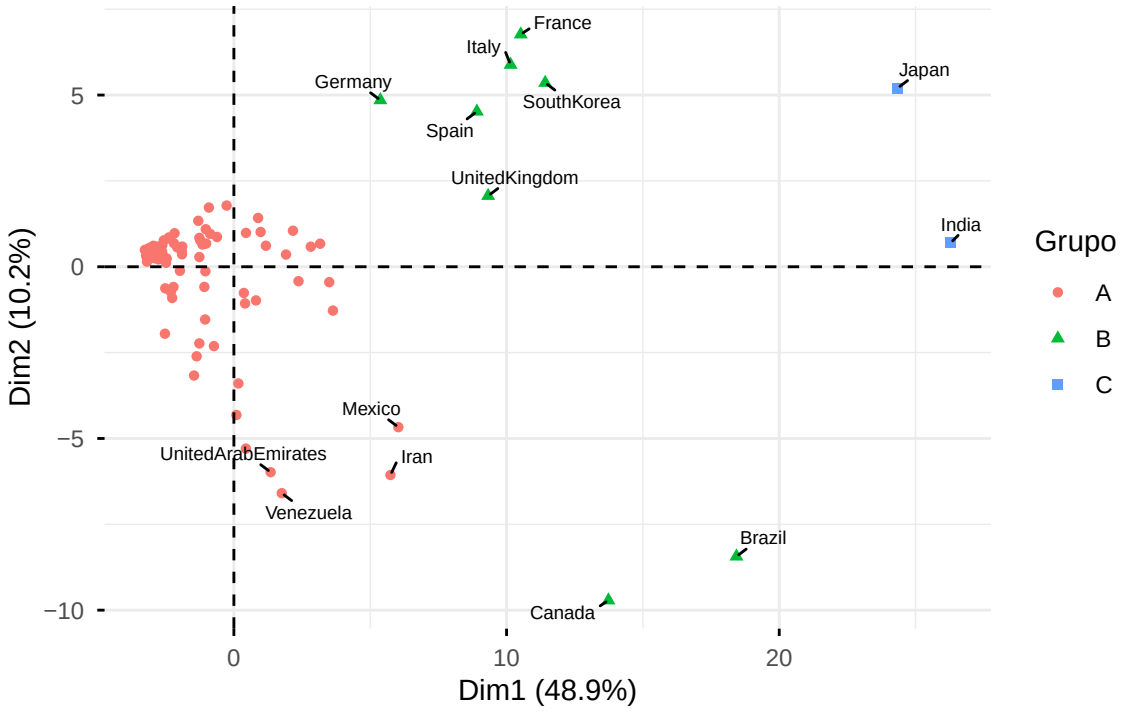


Figura 4.3: Grupos de k-medias sobre el plano (1,2) del ACP sin los cuatro países: El grupo B reúne las economías grandes de los dos brazos y el C a India y Japón.

¿Son diferentes los resultados de los dos análisis? Sí, aunque coinciden en lo principal pues 101 de los 107 países quedan en el grupo equivalente con ambos métodos:

a. **En qué coinciden.** Los dos aíslan a India y Japón como un grupo propio (grupo C) y dejan juntos a los mismos 97 países de la masa central.
b. **En qué difieren.** K-medias forma un grupo B de ocho economías grandes (Brasil, Canadá, Francia, Alemania, Italia, Corea del Sur, España y Reino Unido), mientras que el enlace promedio solo separa a Brasil y Canadá y devuelve los otros seis a la masa central, que queda de 103 países.

Esta diferencia viene de lo que optimiza cada método. K-medias minimiza la inercia intra-grupo y por eso arma un grupo intermedio que le da más varianza explicada (46.6 % frente a 39.0 %), mientras que el enlace promedio une primero lo que está cerca en promedio, de modo que solo deja por fuera a los pares más alejados, tanto así que cortar el árbol en cuatro o cinco grupos tampoco rescata a las seis economías intermedias sino que separa otro par o países sueltos (particiones de 101/2/2/2 y 101/2/2/1/1). La correlación cofenética de 0.986 indica que el árbol conserva muy bien las distancias, aunque cabe matizar que con una masa tan compacta y cuatro países tan lejanos cualquier árbol tiende a lograrlo. Por su parte la silueta media favorece al jerárquico (0.713 frente a 0.666), lo cual sucede porque el grupo B de k-medias tiene silueta promedio de −0.022, es decir que esos ocho países están en promedio tan cerca de la masa central como entre sí. En resumen ambos métodos ven la misma estructura de una masa grande y pocos países extremos y lo que no está bien definido es si las economías grandes intermedias forman un grupo aparte.

```
inicios <- function(n) sapply(c(1, 42, 2026), function(s) {
  set.seed(s)
  round(kmeans(z, centers = 3, nstart = n)$tot.withinss, 1)
})
rbind(nstart_25 = inicios(25), nstart_100 = inicios(100))
```

```
             [,1]   [,2]   [,3]
nstart_25  3274.5 3231.9 3274.5
nstart_100 3226.7 3226.7 3226.7
```

> **Nota.** Con `nstart = 25` k-medias cae en óptimos locales distintos según la semilla (inercias de 3274.5 o 3231.9, con grupos de 90/14/3 y 95/10/2 países), mientras que con 100 arranques las tres semillas llegan a la misma partición de inercia 3226.7, que es también la que encuentra SDA Lab con 25 reinicios de k-medias++. Por eso se usan 100 arranques.

a. **Lectura local.** El grupo B es el punto débil de k-medias pues su silueta promedio es negativa (−0.022) y la de Alemania llega a −0.222, es decir que Alemania está más cerca, en promedio, de la masa central que de los otros siete países de su grupo.
b. **Lectura global.** Los dos métodos responden a la misma estructura de la base, una masa compacta con unos pocos extremos y difieren solo en la franja intermedia, que es justo donde los datos no tienen una frontera clara y donde cada criterio de optimización decide por su cuenta.

```r
s <- silhouette(as.integer(kmedias), distancias)
b <- kmedias == "B"
round(sort(setNames(s[b, "sil_width"], rownames(num)[b])), 3)
```

```
      Germany UnitedKingdom         Spain    SouthKorea
       -0.222        -0.092        -0.054        -0.021
        Italy        Canada        France        Brazil
        0.020         0.046         0.062         0.082
```

Notas

Interpretaciones.

a. **Cada método gana en su propio criterio.** K-medias explica más varianza (46.6 % frente a 39.0 %) porque eso es lo que minimiza y el enlace promedio tiene mejor silueta (0.713 frente a 0.666) porque no fuerza un grupo intermedio, de modo que «mejor» depende de qué se le pida a la partición.
b. **El grupo B de k-medias.** Su silueta promedio es −0.022, con cuatro de sus ocho países en negativo (Alemania −0.222, Reino Unido −0.092, España −0.054 y Corea del Sur −0.021) y los otros cuatro apenas por encima de cero (el mejor es Brasil con 0.082), por lo que B se comporta más como una franja de transición que como un grupo.
c. **Por qué el enlace promedio aísla parejas.** India y Japón, y Brasil y Canadá, están lejos en promedio de todos los demás, de modo que el árbol los une entre sí muy arriba y los deja para el final. Al cortar en cuatro o cinco grupos se siguen separando parejas o países sueltos (101/2/2/2 y 101/2/2/1/1) y nunca las seis economías intermedias.
d. **El arranque importa.** Con `nstart = 25` la inercia depende de la semilla (3274.5 o 3231.9) y solo con 100 arranques se llega siempre a 3226.7 así que una partición de k-medias sin varios arranques puede ser un óptimo local.
e. **Qué k defendería cada uno.** Por silueta los dos preferirían $k = 2$ pues k-medias llega a 0.698 (98/9) y el enlace promedio a 0.752 (105/2, solo India y Japón aparte). El $k = 3$ se eligió por la varianza explicada y por la lectura del plano, no por la silueta.

Preguntas para el profesor.

- ¿Las ocho economías del grupo B son un grupo o el borde de la masa central?

  Por qué importa. Su silueta promedio es de −0.022 y si B no es un grupo la partición en tres equivale en la práctica a una masa central más India y Japón.

- ¿Qué partición se debería defender: la que más explica (k-medias) o la que mejor separa (enlace promedio)?

  Por qué importa. Cada método gana en su propio criterio (46.6 % frente a 39.0 % de varianza explicada y 0.666 frente a 0.713 de silueta), de modo que la respuesta a la Pregunta 10 depende de qué criterio considere el curso como el adecuado.

- ¿Cambiaría el resultado si se agrupara sobre las cuatro componentes de la Pregunta 4 en lugar de las 57 variables redundantes? No se calculó.

Por qué importa. Las distancias sobre las 57 variables cuentan varias veces la misma información (los 18 pares casi repetidos del diagnóstico), mientras que agrupar sobre las componentes es la forma usual de combinar el ACP con el agrupamiento.

- ¿Otro enlace (completo o de Ward) formaría el grupo intermedio? No se calculó.

  Por qué importa. El enlace promedio solo aísla parejas y nunca forma el grupo de las economías intermedias, por lo que otro enlace diría si ese grupo es un rasgo de los datos o del método.

4.4. Pregunta 11 — Distribución de las cinco variables por grupo

```r
largo <- stack(num[cinco])
largo$grupo <- rep(kmedias, times = length(cinco))
etiqueta <- function(g) sprintf("%s (%d)", g, table(kmedias)[g])
ggplot(largo, aes(x = etiqueta(grupo), y = values, fill = grupo)) +
  geom_boxplot(alpha = 0.6, show.legend = FALSE,
               outlier.size = 0.8) +
  stat_summary(fun = median, geom = "text", size = 2.4,
               vjust = -0.5,
               aes(label = round(after_stat(y), 1))) +
  facet_wrap(~ ind, scales = "free_y", nrow = 2) +
  # La escala se transforma DESPUÉS de calcular cajas y medianas,
  # para que la mediana anotada sea la de los datos originales.
  coord_transform(y = "pseudo_log") +
  scale_y_continuous(breaks = c(0, 10, 100, 1000, 10000)) +
  scale_fill_manual(values = c("#3572a8", "#f08a3c", "#a6192e")) +
  labs(x = "Grupo de k-medias (países)", y = "Valor") +
  theme_minimal(base_size = 9)
```

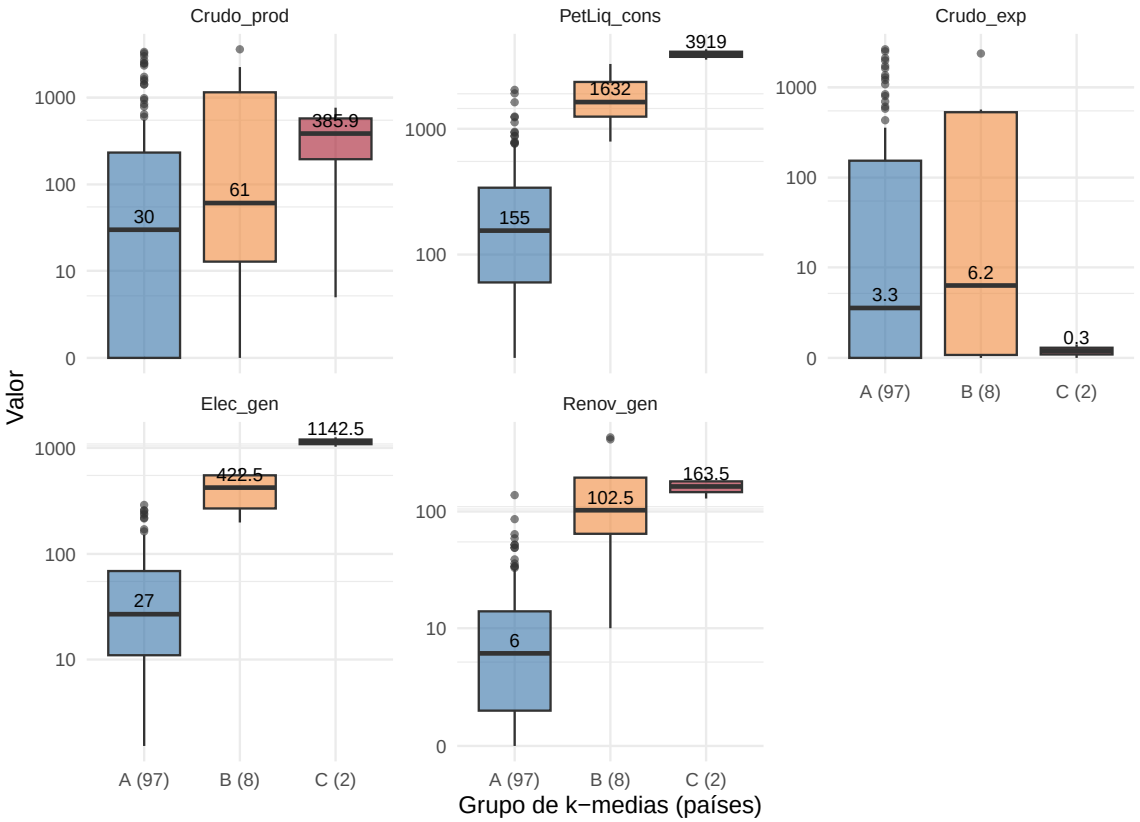


Figura 4.4: Distribución de las cinco variables de la Pregunta 1 por grupo de k-medias, en escala pseudo-logarítmica y con la mediana anotada: El consumo y la generación eléctrica y renovable crecen de A a C, mientras que la producción y la exportación de crudo no separan los grupos.

```
knitr::kable(sapply(cinco, function(v) tapply(num[[v]], kmedias,
  function(x) sprintf("%g a %g", round(min(x), 1),
                      round(max(x), 1)))),
  caption = "Rango (mínimo a máximo) de cada variable por grupo.")
```

Cuadro 4.4: Rango (mínimo a máximo) de cada variable por grupo.

	Crudo_prod	PetLiq_cons	Crudo_exp	Elec_gen	Renov_gen
A	0 a 3370	15 a 2040	0 a 2651	0.9 a 290	0 a 138
B	0 a 3613	791.3 a 3279	0 a 2382	198 a 636	10 a 429
C	4.8 a 767	3550 a 4288	0 a 0.7	1027 a 1258	129 a 198

```
exportadores <- order(-num$Crudo_exp)[1:5]
data.frame(exportacion = num$Crudo_exp[exportadores],
           grupo = kmedias[exportadores],
           row.names = rownames(num)[exportadores])
```

	exportacion	grupo
UnitedArabEmirates	2651	A
Iraq	2518	A
Canada	2382	B
Nigeria	2120	A
Kuwait	1995	A

```
c(sin_exportar_A = sum(num$Crudo_exp[kmedias == "A"] == 0))
```

```
sin_exportar_A
            38
```

¿Hay diferencias importantes entre grupos en una misma variable? Sí en tres de las cinco variables (consumo de petróleo, generación eléctrica y generación renovable) y no en las dos petroleras (producción y exportación de crudo). Antes de leerlas vale la pena anotar que el grupo C tiene solo dos países (India y Japón) y el B ocho, de modo que sus cajas son apenas un resumen de pocos puntos y no una distribución y que el eje es pseudo-logarítmico porque los valores de los tres grupos difieren en órdenes de magnitud.

a. **Consumo de petróleo y generación eléctrica.** Las medianas crecen con claridad de A a C pues el consumo pasa de 155 a 1632 y a 3919 TBPD y la generación de 27 a 422.5 y a 1142.5 BKWH. India y Japón superan a todos los países de los otros grupos en las dos variables, aunque A y B se solapan en sus extremos, por ejemplo México consume 2040 TBPD y genera 290 BKWH siendo del grupo A, mientras que Alemania consume 791.3 TBPD y genera 198 BKWH siendo del grupo B.

b. **Generación renovable.** También crece de A a C (medianas de 6, 102.5 y 163.5 BKWH) pero con mucho solapamiento ya que el grupo B va de 10 BKWH (Corea del Sur) a 429 BKWH (Brasil) y el máximo de A (Noruega, 138 BKWH) supera incluso a Japón (129 BKWH) del grupo C.
c. **Producción de crudo.** No distingue los grupos, dado que los tres tienen países que casi no producen y el rango de A (de 0 a 3370 TBPD, este último Irak) cubre casi por completo los de B (de 0 a 3613) y C (de 4.8 a 767).
d. **Exportación de crudo.** Tampoco los distingue y además no crece con el tamaño pues las medianas son 3.3, 6.2 y 0.35 TBPD, India y Japón casi no exportan (0.7 y 0 TBPD) y cuatro de los cinco mayores exportadores de los 107 países (Emiratos Árabes Unidos con 2651 TBPD, Irak con 2518, Nigeria con 2120 y Kuwait con 1995) están en el grupo A, junto a 38 países que no exportan nada, mientras que el quinto, Canadá (2382 TBPD), está en B por su tamaño y no por su petróleo.

Se concluye que k-medias agrupó a los países por el tamaño de su consumo y de su sistema eléctrico, que es la información del primer eje del ACP y no por ser o no productores y exportadores de petróleo, que es la información del segundo eje.

a. **Lectura local.** Emiratos Árabes Unidos, el mayor exportador de crudo sin los cuatro atípicos, queda en el mismo grupo que países que no exportan nada porque en todo lo demás (consumo, generación) es un país mediano.
b. **Lectura global.** La partición sigue al tamaño porque la base mide sobre todo tamaño ya que 27 de las 57 variables están ligadas al primer eje y la dimensión petrolera la cargan unas pocas, de modo que en la distancia euclidiana entre países el petróleo pesa poco. Haber elegido la exportación en la Pregunta 1 es lo que permite verlo pues con las emisiones de CO_2 las cinco cajas habrían repetido el consumo.

Notas

Interpretaciones.

a. **Lo que separa y lo que no.** Las medianas de consumo (155, 1632 y 3919 TBPD) y de generación (27, 422.5 y 1142.5 BKWH) crecen de A a C, mientras que las de exportación (3.3, 6.2 y 0.35 TBPD) no siguen ningún orden.
b. **El petróleo queda dentro de A.** Cuatro de los cinco mayores exportadores de los 107 países (Emiratos Árabes Unidos, Irak, Nigeria y Kuwait) están en A, el mismo grupo de la masa central, es decir que la partición no reconoce al brazo de productores que se veía en la Pregunta 7.
c. **Cajas de pocos países.** C tiene dos países y B ocho así que sus cajas describen casos y no distribuciones.

Preguntas para el profesor.

- ¿Un agrupamiento con solo las cinco variables o con las componentes 2 y 3 separaría a los exportadores? No se calculó.

Por qué importa. La partición actual sigue al tamaño y deja a cuatro de los cinco mayores exportadores en el grupo A, aunque el segundo eje del ACP es justamente el petrolero.

- Si el objetivo del enunciado es caracterizar países por importación, exportación y consumo, ¿sirve una partición que solo ve tamaño?

  Por qué importa. El enunciado busca caracterizar a los países «en términos de importación, exportación, consumo, producción», y si la partición solo responde al consumo y a la generación habría que decidir si se reformula el agrupamiento o se reporta como una limitación.

Bibliografía

Attali, D. y C. Baker (2025). *ggExtra: Add Marginal Histograms to 'ggplot2', and More 'ggplot2' Enhancements*. R package version 0.11.0. DOI: 10.32614/CRAN.package.ggExtra. URL: https://CRAN.R-project.org/package=ggExtra.

Hotelling, H. (1933). "Analysis of a Complex of Statistical Variables into Principal Components". En: *Journal of Educational Psychology* 24.6, págs. 417-441. DOI: 10.1037/h0071325.

Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (2022). *Datos meteorológicos de la red de estaciones — región Orinoquía*. Descarga libre del portal IDEAM. URL: http://www.ideam.gov.co.

Kaiser, H. F. (1960). "The Application of Electronic Computers to Factor Analysis". En: *Educational and Psychological Measurement* 20.1, págs. 141-151. DOI: 10.1177/001316446002000116.

Kassambara, A. y F. Mundt (2020). *factoextra: Extract and Visualize the Results of Multivariate Data Analyses*. R package version 1.0.7. DOI: 10.32614/CRAN.package.factoextra. URL: https://CRAN.R-project.org/package=factoextra.

MacQueen, J. (1967). "Some Methods for Classification and Analysis of Multivariate Observations". En: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. University of California Press, págs. 281-297.

Pearson, K. (1895). "Note on Regression and Inheritance in the Case of Two Parents". En: *Proceedings of the Royal Society of London* 58, págs. 240-242. DOI: 10.1098/rspl.1895.0041.

— (1901). "On Lines and Planes of Closest Fit to Systems of Points in Space". En: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2.11, págs. 559-572. DOI: 10.1080/14786440109462720.

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R version 4.6.1. R Foundation for Statistical Computing. Vienna, Austria. URL: https://www.R-project.org.

Rousseeuw, P. J. (1987). "Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis". En: *Journal of Computational and Applied Mathematics* 20, págs. 53-65. DOI: 10.1016/0377-0427(87)90125-7.

Schloerke, B., D. Cook, J. Larmarange, F. Briatte, M. Marbach, E. Thoen, A. Elberg y J. Crowley (2024). *GGally: Extension to 'ggplot2'*. DOI: 10.32614/CRAN.package.GGally. URL: https://CRAN.R-project.org/package=GGally.

Sokal, R. R. y C. D. Michener (1958). "A Statistical Method for Evaluating Systematic Relationships". En: *University of Kansas Science Bulletin* 38, págs. 1409-1438.

Spearman, C. (1904). "The Proof and Measurement of Association between Two Things". En: *The American Journal of Psychology* 15.1, págs. 72-101. DOI: 10.2307/1412159.

U.S. Energy Information Administration (EIA) (2023). *International Energy Data: petroleum and electricity by country*. Extracción académica de 111 países publicada en Kaggle (overhcv/eia-united-states). URL: https://www.eia.gov/international/data/world.

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. URL: https://ggplot2.tidyverse.org.

Apéndice A

Documentación de R

Se listan las funciones utilizadas en el taller junto con el paquete que las provee y la pregunta donde se usan, cada una enlazada a su página de ayuda oficial. El documento se generó con R 4.6.1, `ggplot2` 4.0.3, `GGally` 2.4.0, `factoextra` 2.2.0 y `cluster` 2.1.8.2.

Cuadro A.1: Funciones de R utilizadas y enlace a su documentación.

Función	Paquete	Uso
`read.csv()`	utils	Carga
`download.file()`	utils	Carga
`source()`	base	Datos
`gsub()`	base	Datos
`cor()`	stats	Datos, P1, P2
`colMeans()`	base	P1
`median()`	stats	P1, P2
`cov()`	stats	P1
`prcomp()`	stats	P3, P4, P7
`scale()`	base	P9, P10
`facto_summarize()`	factoextra	P3
`fviz_contrib()`	factoextra	P3
`fviz_eig()`	factoextra	P4
`get_pca_var()`	factoextra	P5, P7
`get_pca_ind()`	factoextra	P6, P7
`fviz_pca_var()`	factoextra	P5
`fviz_pca_ind()`	factoextra	P6, P7, P10
`geom_text_repel()`	ggrepel	P6, P7, P10
`ggpairs()`	GGally	P2
`kmeans()`	stats	P9, P10
`dist()`	stats	P9, P10
`hclust()`	stats	P10
`cutree()`	stats	P10
`cophenetic()`	stats	P10
`rect.hclust()`	stats	P10

Función	Paquete	Uso
`silhouette()`	cluster	P9, P10
`stack()`	utils	P11
`ggplot()`	ggplot2	P9, P11
`geom_boxplot()`	ggplot2	P11
`facet_wrap()`	ggplot2	P11

Apéndice B

Abreviaturas de las variables

El archivo `R/abreviaturas.R`, que se carga en el chunk de configuración, trae las dos funciones con las que se acortan los nombres. La función `abreviar()` cambia cada fragmento del nombre original por su abreviatura y quita la unidad del final, mientras que `numericas()` arma la matriz `num` con las columnas numéricas y el país como nombre de fila.

```
# taller-02/R/abreviaturas.R
#
# Nombres cortos para las 57 variables de EIA.csv, que llegan a
# tener 60 caracteres y no caben en los gráficos. Se carga desde el
# chunk de configuración y su código se muestra en el Apéndice B.

# Cambia cada fragmento del nombre original por su abreviatura y
# quita la unidad del final (TBPD, BKWH, MK, MMTCD o BB). El orden
# importa: Los fragmentos largos van antes que los cortos que
# contienen.
abreviar <- function(v) {
  reglas <- c(
    Crude_oil_including_lease_condensate = "Crudo",
    Petroleum_and_other_liquids = "PetLiq",
    Refined_petroleum_products = "Refinados",
    Liquefied_petroleum_gases_.LPG. = "GLP",
    Natural_gas_plant_liquids = "LGN",
    Bunker_residual_fuel_oil = "BunkerRes",
    Bunker_fuel = "Bunker",
    Distillate_fuel_oil = "Destilado",
    Residual_fuel_oil = "Residual",
    Motor_gasoline = "Gasolina",
    Jet_fuel = "Jet",
    Kerosene = "Queroseno",
    Other_liquids = "OtrosLiq",
    Other_refined_products = "OtrosRef",
    Refinery_processing_gain = "GananciaRef",
```

```
    Hydroelectric_pumped_storage_electricity = "Bombeo",
    Hydroelectricity = "Hidro",
    Biomass_and_waste_electricity = "Biomasa",
    Fossil_fuels_electricity = "Fosil",
    Geothermal_electricity = "Geotermica",
    Non.hydro_renewable_electricity = "NoHidro",
    Renewable_electricity = "Renov",
    Nuclear_electricity = "Nuclear",
    Solar_electricity = "Solar",
    Tide_and_wave_electricity = "Mareas",
    Wind_electricity = "Eolica",
    Electricity = "Elec",
    installed_capacity = "cap",
    net_generation = "gen",
    net_consumption = "cons",
    net_imports = "impNeta",
    distribution_losses = "perdidas",
    CO2_emissions = "CO2",
    consumption = "cons",
    production = "prod",
    exports = "exp",
    imports = "imp",
    reserves = "reservas")
  for (r in names(reglas))
    v <- gsub(r, reglas[[r]], v, fixed = TRUE)
  sub("_(TBPD|BKWH|MK|MMTCD|BB)$", "", v)
}

# Las columnas numéricas, con el país como nombre de fila y los
# nombres abreviados.
numericas <- function(d) {
  num <- d[vapply(d, is.numeric, logical(1))]
  rownames(num) <- d$Country
  names(num) <- abreviar(names(num))
  num
}
```

Cuadro B.1: Abreviatura y nombre original (con su unidad).

Abreviatura	Variable
Bunker_cons	Bunker fuel consumption (TBPD)
BunkerRes_cons	Bunker residual fuel oil consumption (TBPD)
Crudo_exp	Crude oil including lease condensate exports (TBPD)
Crudo_imp	Crude oil including lease condensate imports (TBPD)
Crudo_prod	Crude oil including lease condensate production (TBPD)
Crudo_reservas	Crude oil including lease condensate reserves (BB)
Destilado_cons	Distillate fuel oil consumption (TBPD)
Destilado_prod	Distillate fuel oil production (TBPD)
Jet_cons	Jet fuel consumption (TBPD)
Jet_prod	Jet fuel production (TBPD)
Queroseno_cons	Kerosene consumption (TBPD)
Queroseno_prod	Kerosene production (TBPD)
GLP_cons	Liquefied petroleum gases (LPG) consumption (TBPD)
GLP_prod	Liquefied petroleum gases (LPG) production (TBPD)
Gasolina_cons	Motor gasoline consumption (TBPD)
Gasolina_prod	Motor gasoline production (TBPD)
LGN_prod	Natural gas plant liquids production (TBPD)
OtrosLiq_prod	Other liquids production (TBPD)
OtrosRef_cons	Other refined products consumption (TBPD)
OtrosRef_prod	Other refined products production (TBPD)
PetLiq_CO2	Petroleum and other liquids CO2 emissions (MMTCD)
PetLiq_cons	Petroleum and other liquids consumption (TBPD)
PetLiq_prod	Petroleum and other liquids production (TBPD)
Refinados_cons	Refined petroleum products consumption (TBPD)
Refinados_prod	Refined petroleum products production (TBPD)
GananciaRef	Refinery processing gain (TBPD)
Residual_cons	Residual fuel oil consumption (TBPD)
Residual_prod	Residual fuel oil production (TBPD)
Biomasa_cap	Biomass and waste electricity installed capacity (MK)
Biomasa_gen	Biomass and waste electricity net generation (BKWH)
Elec_perdidas	Electricity distribution losses (BKWH)
Elec_exp	Electricity exports (BKWH)
Elec_imp	Electricity imports (BKWH)
Elec_cap	Electricity installed capacity (MK)
Elec_cons	Electricity net consumption (BKWH)
Elec_gen	Electricity net generation (BKWH)
Elec_impNeta	Electricity net imports (BKWH)
Fosil_cap	Fossil fuels electricity installed capacity (MK)
Fosil_gen	Fossil fuels electricity net generation (BKWH)
Geotermica_cap	Geothermal electricity installed capacity (MK)
Geotermica_gen	Geothermal electricity net generation (BKWH)

Abreviatura	Variable
Bombeo_cap	Hydroelectric pumped storage electricity installed capacity (MK)
Bombeo_gen	Hydroelectric pumped storage electricity net generation (BKWH)
Hidro_cap	Hydroelectricity installed capacity (MK)
Hidro_gen	Hydroelectricity net generation (BKWH)
NoHidro_cap	Non-hydro renewable electricity installed capacity (MK)
NoHidro_gen	Non-hydro renewable electricity net generation (BKWH)
Nuclear_cap	Nuclear electricity installed capacity (MK)
Nuclear_gen	Nuclear electricity net generation (BKWH)
Renov_cap	Renewable electricity installed capacity (MK)
Renov_gen	Renewable electricity net generation (BKWH)
Solar_cap	Solar electricity installed capacity (MK)
Solar_gen	Solar electricity net generation (BKWH)
Mareas_cap	Tide and wave electricity installed capacity (MK)
Mareas_gen	Tide and wave electricity net generation (BKWH)
Eolica_cap	Wind electricity installed capacity (MK)
Eolica_gen	Wind electricity net generation (BKWH)