CLUSTERING DE VARIABLES CUALITATIVAS

CUANDO LA MEDIA NO EXISTE: K-MODAS, GOWER Y CLASES LATENTES

ÁLVAREZ · ARIAS · MORA · CASTRILLÓN

ANÁLISIS ESTADÍSTICO DE DATOS · UNIVERSIDAD DEL ROSARIO

2026





Universidad del Rosario

CUATRO PARTES, UN SOLO ARCO

	Parte	Expone	
1	La pregunta de la sesión 5 y los datos	Anyelo Álvarez	3 min
2	Distancia, calidad de la partición y k-modas	Daniel Arias	3 min
3	Elegir K y jerárquico sobre Gower	Tania Mora	3 min
4	Clases latentes, tándem y anexo	Over Castrillón	3 min

Parte 1 de 4

La pregunta de la sesión 5 y los datos

Anyelo Álvarez

LA PREGUNTA QUE QUEDÓ ABIERTA

En la sesión 5 agrupamos 15 estaciones de Bogotá con 5 contaminantes:

- distancia **euclídea** y **estandarizar siempre**;
- centroide = **media** del grupo;
- plano factorial del **ACP** para ver los grupos.

¿Y si las variables son cualitativas?

¿Qué es la media de «tiene plumas»? ¿Qué es estandarizar «sí/no»?

La idea de toda la charla

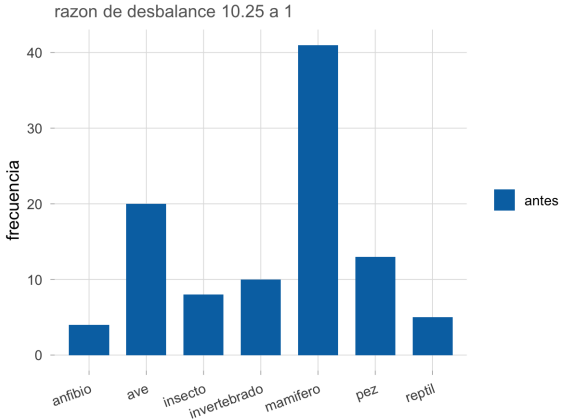
Se cambia la **distancia**, el **centro** o el **modelo**; el resto del arco se mantiene.

EL MISMO ARCO, CON CATEGORÍAS

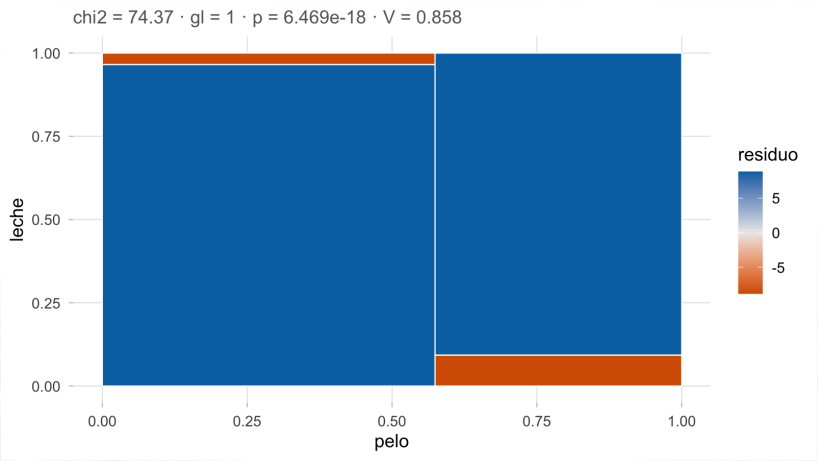
Sesión 5 (aire de Bogotá)	Este trabajo (Zoo)
Boxplots y correlación	Frecuencias y asociación
ACP: primer plano factorial	ACM: primer plano factorial
Euclídea + estandarizar	Emparejamiento simple · Gower
d^2 de la partición	d de la partición (desacuerdos)
K-medias (Lloyd, `nstart`)	K-modas (Huang, reinicios)
Codo sobre d^2	Codo sobre desacuerdos
Jerárquico: 3 enlaces	Jerárquico sobre Gower: 3 enlaces
GMM: «cursos más avanzados»	Clases latentes: EM y BIC
Anexo: estructura espacial	Anexo: la clase `tipo`

101 ANIMALES, 16 ATRIBUTOS

- 15 binarias: pelo, plumas, huevos, leche, vuela, acuático, depredador, dientes, vertebrado, respira, venenoso, aletas, cola, doméstico, tamaño de gato.
- `patas`: 0, 2, 4, 5, 6, 8 (categoría, no número).
- `tipo`: 7 clases reales. **No entra** al agrupamiento: se guarda para el anexo.

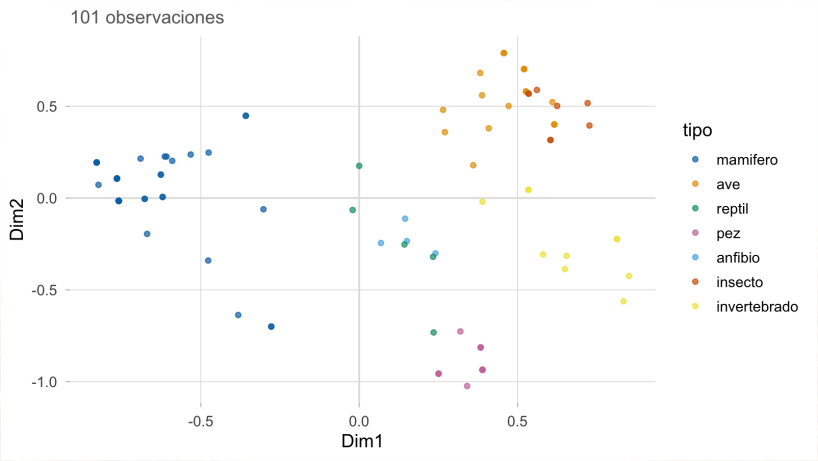


ASOCIACIÓN ENTRE ATRIBUTOS



Como CO, NO y NO_2 en el aire: pelo y leche van juntos porque vienen de la misma «fuente».

PRIMER PLANO FACTORIAL DEL ACM



El ACM es el ACP de las cualitativas: **herramienta de diagnóstico**, no parte del agrupamiento.

Parte 2 de 4

Distancia, calidad de la partición y k-modas

Daniel Arias

DUROS Y SUAVES, IGUAL QUE EN LA SESIÓN 5

	Duros	Suaves
Numéricas	K-medias, jerárquico	GMM
Cualitativas	**K-modas**, **Gower + jerárquico/PAM**	**Clases latentes**
Salida	$g_i \in \{1, \ldots, K\}$	$\boldsymbol{\pi}_i = (\pi_{i1}, \ldots, \pi_{iK})$

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^{p} \mathbb{1}[x_{ik} \neq x_{jk}]$$

Emparejamiento simple (Hamming): en cuántos atributos difieren. Todas las variables ya están en la misma escala: **no hay nada que estandarizar**.

$$s_{ij} = \frac{\sum_k w_{ijk}\, s_{ijk}}{\sum_k w_{ijk}}$$

Gower (Gower 1971): con datos mixtos normaliza cada numérica por su rango (su «estandarizar»); con binarias asimétricas dos «no» no cuentan.

CALIDAD DE LA PARTICIÓN

La fórmula de la sesión 5 no necesita un centro, solo distancias:

$$d(\text{Agrupamiento}) = \sum_{k=1}^{K} \frac{1}{n_k} \sum_{i,j \in G_k} d(\mathbf{x}_i, \mathbf{x}_j)$$

- Con d = euclídea al cuadrado es el d^2 de clase.
- Con d = desacuerdos funciona igual: **sirve con cualquier distancia**.

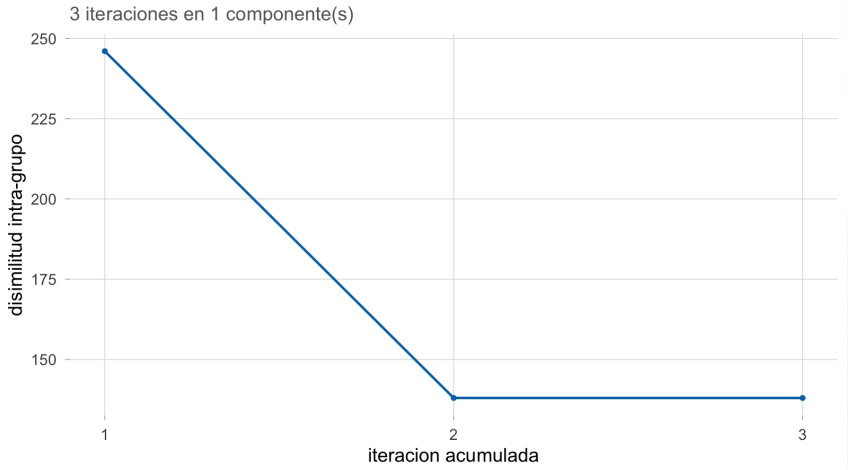
LLOYD CON OTRO CENTRO

1. Inicialización: K animales como modas iniciales.
2. Asignación: cada animal a la moda con menos desacuerdos.
3. Actualización: la moda de cada atributo en el grupo.
4. Repetir hasta que nadie cambie.

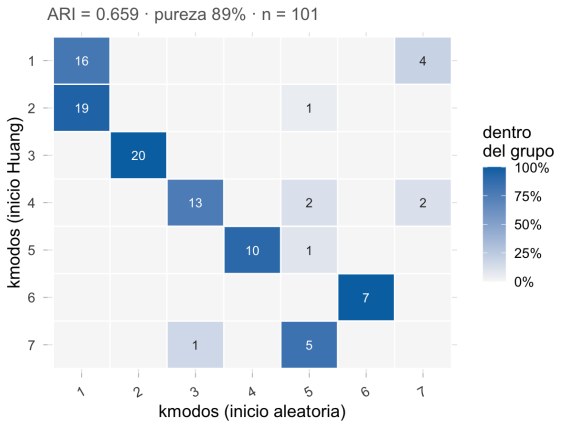
$$\sum_{i \in G} d(\mathbf{x}_i, \mathbf{m}) = \sum_{k} \big(n_G - n_k(m_k)\big)$$

El costo se separa por atributo, y lo minimiza la categoría más frecuente (Huang 1998).

K-MODAS PASO A PASO



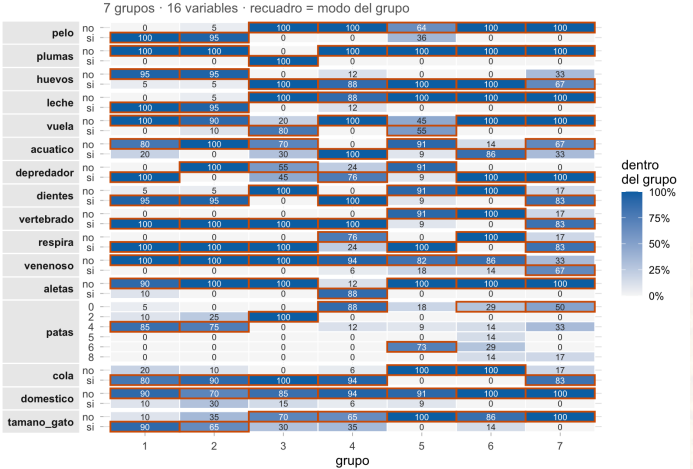
ADVERTENCIA IMPORTANTE: LA INICIALIZACIÓN



Arranque	Costo	ARI
Huang	138	0,63
Cao	137	0,59
Aleatorio	139	0,83

Como `nstart`: varios arranques y quedarse con el menor costo. Pero menor costo **no** garantiza recuperar la clase real.

PERFILES DE LOS GRUPOS

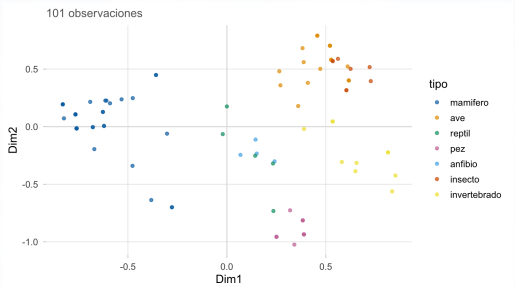


Parte 3 de 4

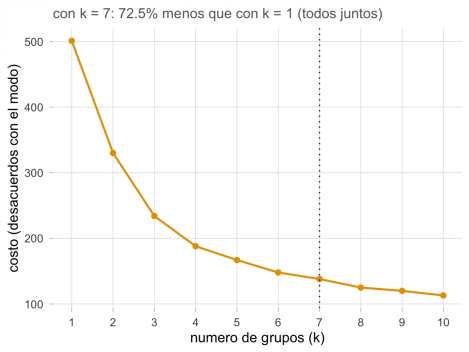
Elegir K y jerárquico sobre Gower

Tania Mora

DOS GUÍAS, COMO EN LA SESIÓN 5

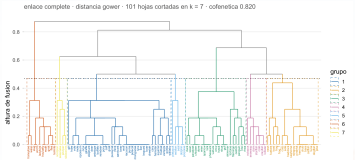


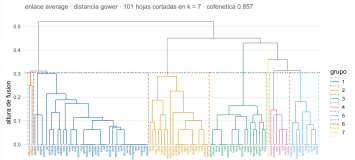
Guía 1: el plano factorial del ACM.

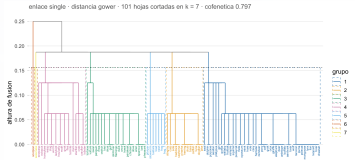


Guía 2: el codo sobre los desacuerdos.

LOS TRES ENLACES

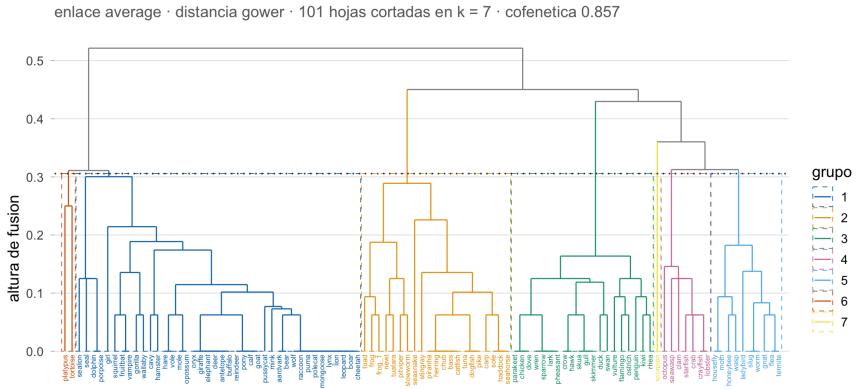




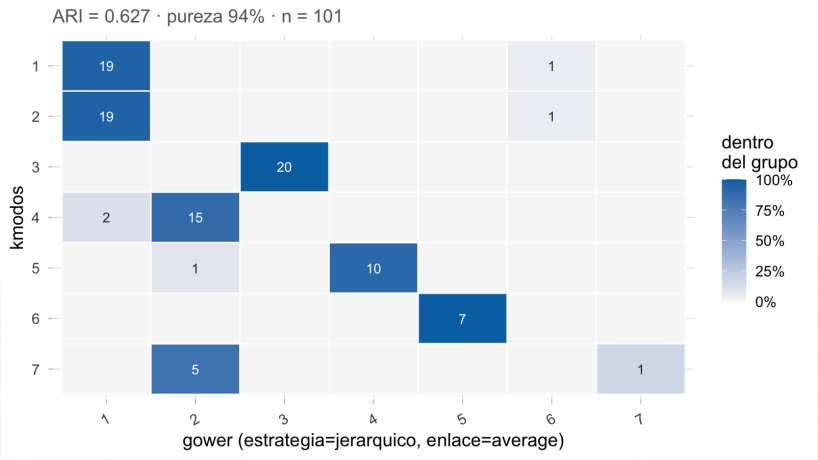


Completo · promedio · simple. El promedio suele ser el más robusto; el simple forma cadenas.

CORTAR EL ÁRBOL



¿QUÉ TAN CONCORDANTES SON LOS DOS MÉTODOS?



K-modas contra Gower jerárquico: donde discrepan están los animales de frontera.

Parte 4 de 4

Clases latentes, tándem y anexo

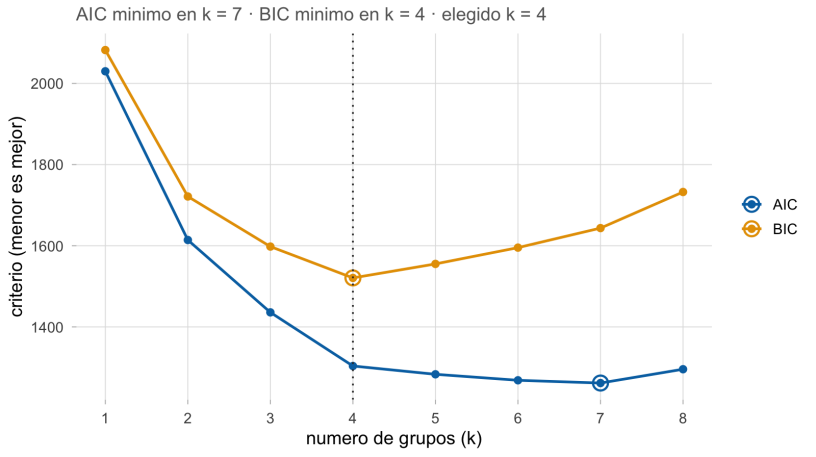
Over Castrillón

EL GMM DE LAS CATEGORÍAS

$$P(\mathbf{x}_i) = \sum_{c=1}^{K} \pi_c \prod_{k=1}^{p} \prod_{r} \theta_{krc}^{\mathbb{1}[x_{ik}=r]}$$

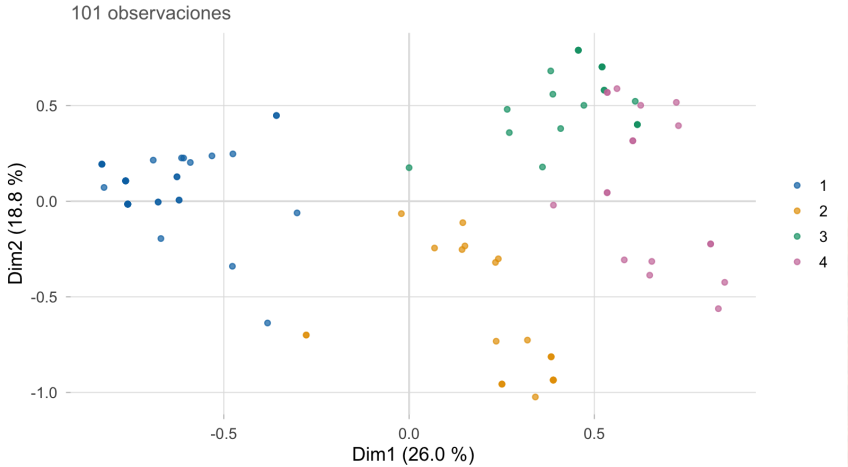
- Donde el GMM pone una normal, aquí va un producto de categóricas (**independencia local**).
- EM: probabilidad de pertenencia π_{ic} → nuevas π_c y θ_{krc}.
- K por BIC (Linzer y Lewis 2011).

¿CUÁNTAS CLASES?

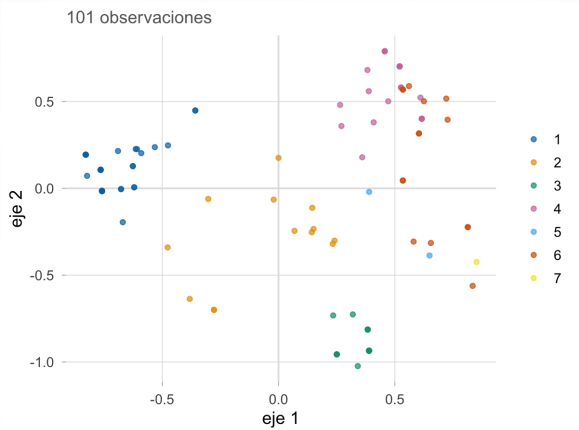


El BIC elige 4 clases; el AIC, que castiga menos los parámetros, elige 7, justo los tipos de Zoo.

CLASES LATENTES EN EL PLANO FACTORIAL



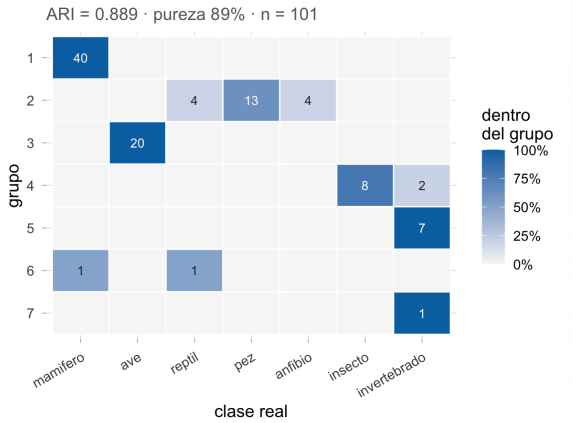
EL TÁNDEM ACM + K-MEDIAS



En clase: «el ACP es diagnóstico, no parte del proceso».

Aquí el tándem (5 dimensiones) recupera bien los tipos, pero las primeras dimensiones resumen inercia, no separación: no hay garantía de que eso se repita.

LA ESTRUCTURA QUE NO SE MIDIÓ



Método ($K = 7$)	ARI
K-modas (Huang)	0,63
Gower + PAM	0,64
Gower + jer. promedio	0,89
Clases latentes	0,83
Tándem ACM + k-medias	0,81

Como las estaciones y sus zonas: `tipo` nunca entró al agrupamiento y aun así se recupera.

DÓNDE SE ROMPE CADA UNO

K-modas

Depende del arranque · empates de moda · pesos iguales · pierde el orden de las ordinales.

Clases latentes

Independencia local (pelo y leche) · máximos locales · celdas con $\theta = 0$ o 1.

Gower

Pesos iguales · binarias asimétricas · memoria $O(n^2)$.

Tándem

Las dimensiones del ACM no buscan separar grupos.

PARA LLEVARSE

- El arco de la sesión 5 se mantiene; cambian la distancia, el centro o el modelo.
- Duros (k-modas, Gower) y suaves (clases latentes) también existen para categorías.
- El ACM y el clustering son **complementarios, no sustitutos**.

Una frase

Con datos cualitativos no se agrupa distinto: se mide distinto.

REFERENCIAS

- Cao, Fuyuan, Jiye Liang y Liang Bai (2009). “A New Initialization Method for Categorical Data Clustering”. En: *Expert Systems with Applications* 36.7, págs. 10223-10228. DOI: 10.1016/j.eswa.2009.01.060.
- Forsyth, Richard (1990). *Zoo*. UCI Machine Learning Repository. DOI: 10.24432/C5R59V.
- Gower, J. C. (1971). “A General Coefficient of Similarity and Some of Its Properties”. En: *Biometrics* 27.4, págs. 857-871. DOI: 10.2307/2528823.
- Greenacre, Michael (2017). *Correspondence Analysis in Practice*. 3.ª ed. Chapman y Hall/CRC.
- Huang, Zhexue (1998). “Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values”. En: *Data Mining and Knowledge Discovery* 2.3, págs. 283-304. DOI: 10.1023/A:1009769707641.
- Kaufman, Leonard y Peter J. Rousseeuw (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley.

REFERENCIAS



Linzer, Drew A. y Jeffrey B. Lewis (2011). “poLCA: An R Package for Polytomous Variable Latent Class Analysis”. En: *Journal of Statistical Software* 42.10, págs. 1-29. DOI: 10.18637/jss.v042.i10.

Foto de portada: *Slate Blocks*, CC BY 4.0. Formato: *Mid-Century Modern* Beamer.